

1 问题一的形式化建模

问题一的任务链为：质量信号标量化 → 综合质量评分 → 指标冲突度量与消解 → 配比-损失回归 → 跨尺度验证 → 质量与训练价值的桥接检验。本节依次给出各环节的数学定义。全节的建模立场是：文本的内在质量 Q 与其训练价值 ν 是两个不同的量，前者由质量信号构造 (§1.2–§1.3)，后者由配比实验回归度量 (§1.4)，二者的关系是待检验的科学假设而非先验前提 (§1.5)。

1.1 记号与数据对象

Table 1: 问题一主要记号

记号	取值范围	含义
$\mathcal{S}_1, \mathcal{S}_2, \mathcal{S}_3$	—	附件 A1 抽样集 ($ \mathcal{S}_1 = 51,230$, 含原文)、A2/A3 扩展集 (无原文)
$\mathcal{D}_q$	$ \mathcal{D}_q = 7$	质量信号域集合 (arxiv, book, c4, common-crawl, github, stackexchange, wikipedia)
$\mathcal{D}_m$	$ \mathcal{D}_m = 17$	训练配比域集合 (Pile 十七域)
$\mathcal{D}_v$	$ \mathcal{D}_v = 13$	验证损失域集合
$\mathbf{u}_i$	混合类型	文档 x_i 的 22 维原始质量信号 (含 8 个 logits 列表字段与 15 个规则统计量中的标量字段)
$\mathbf{z}_i$	$[0, 1]^J$	定向标量化并稳健归一后的质量特征向量
$q_i^{(g)}, Q_i$	$[0, 1]$	文档 x_i 的第 g 组分数与综合质量分
Q_d	$[0, 1]$	域 d 的域级质量分 (分文档口径与 token 口径)
c_i	$[0, 1]$	文档 x_i 的指标冲突度
$\mathbf{p}$	Δ^{16}	训练配比向量, $\Delta^{16} = \{\mathbf{p} \in \mathbb{R}_{\geq 0}^{17} : \mathbf{1}^\top \mathbf{p} = 1\}$
$\ell(\mathbf{p})$	$\mathbb{R}_{>0}^{13}$	配比 $\mathbf{p}$ 训练后 13 个验证域的交叉熵损失
$L_{\text{tgt}}(\mathbf{p})$	$\mathbb{R}_{>0}$	由评价权重 $\mathbf{w}$ 聚合的目标损失
ν_k	$\mathbb{R}$	配比域 k 的训练边际价值 (中心化回归系数的相反数)
Φ	文本 $\rightarrow \mathbb{R}^{15}$	规则质量统计量 (rps_*) 的确定性计算算子
$\hat{g}$	$\mathbb{R}^{15} \rightarrow [0, 1]$	由 A1 学得的“规则特征 $\rightarrow$ 综合质量分”校准函数

数据对象与附件的对应：A4/A5 为 $M = 512$ 组小代理实验 $\{(\mathbf{p}^{(m)}, \ell^{(m)})\}_{m=1}^M$ (1M 参数模型, 按 index 对齐); A6–A9 为同构的留出集 (1M 与 60M 各 256 组); A10/A11 为 1B 规模验证 (按 index 取交集后 63 组); A12–A15 为 10B/70B 外推估算表, 仅作一致性讨论。A16 给出 $\mathcal{D}_m \rightarrow \mathcal{D}_q$ 的部分映射 φ : 6 个域为 direct/near_direct, 11 个域无映射 (inferred)。A17/A18 提供 $\mathcal{D}_m$ 全部 17 域的原始文本抽样及其规模摘要。

1.2 模块一：质量信号的定向标量化与综合评分

定义 1.1 (定向标量化算子). 对文档 x_i 的第 j 个原始信号 u_{ij} , 按其输出形态定义标量化值 $\tilde{z}_{ij}$:

(i) 二元 logits 型 ($u_{ij} \in \mathbb{R}^2$, 如 *fluency_en*, *ad_en*):

$$\tilde{z}_{ij} = \text{softmax}(u_{ij})_1 = \frac{e^{u_{ij,1}}}{e^{u_{ij,0}} + e^{u_{ij,1}}} \in (0, 1); \quad (1)$$

(ii) K 档有序 *logits* 型 ($u_{ij} \in \mathbb{R}^K$, 如 *modernbert_** 的 $K = 6$): 取期望档位并归一,

$$\tilde{z}_{ij} = \frac{1}{K-1} \sum_{k=0}^{K-1} k \text{softmax}(u_{ij})_k \in [0, 1]; \quad (2)$$

(iii) 单值模型分 (*fineweb_edu*, *dsir_**): 直接取标量, 进入式 (4) 归一;

(iv) 适宜区间型规则统计量 (如平均词长、词数、数字字符占比): 给定由 $A1$ 分布确定的适宜区间 $[a_j, b_j]$ 与容忍尺度 γ_j ,

$$\tilde{z}_{ij} = \max\left(0, 1 - \frac{\text{dist}(u_{ij}, [a_j, b_j])}{\gamma_j}\right), \quad \text{dist}(x, [a, b]) = \max(a - x, x - b, 0); \quad (3)$$

(v) 方向型统计量 (重复 n -gram 占比、无字母词占比等负向指标, 以及 *ad_en*): 令方向系数 $\sigma_j \in \{+1, -1\}$, 负向指标取 $\sigma_j = -1$ 并以 $1 - \tilde{z}_{ij}$ 代入后续计算。

定义 1.2 (稳健归一化). 为消除量纲与重尾影响, 对每个标量化信号施加缩尾-经验分布变换:

$$z_{ij} = \hat{F}_j\left(\text{clip}(\tilde{z}_{ij}; \hat{F}_j^{-1}(0.005), \hat{F}_j^{-1}(0.995))\right) \in [0, 1], \quad (4)$$

其中 $\hat{F}_j$ 为该信号在 $A1$ 上的经验分布函数。同一组 $\{\hat{F}_j, [a_j, b_j], \gamma_j, \sigma_j\}$ 在 $A1$ 上估计后冻结, 原样应用于 $A2/A3$ 与 $A17$, 以保证跨数据集可比。

定义 1.3 (分组评分与综合质量分). 将归一化特征按语义划分为 $G = 4$ 组: J_1 教育/专业价值 (*fineweb_edu*, *qurater* 教育维, *modernbert_professionalism/reasoning*, *dsir_**), J_2 清洁度 (*ad_en* 反向, *modernbert_cleanliness*, 重复类 *rps* 指标反向), J_3 可读性 (*fluency_en*, *modernbert_readability*, 格式类 *rps* 指标), J_4 信息密度 (一元熵、唯一词占比等)。组内与组间两级加权:

$$q_i^{(g)} = \sum_{j \in J_g} \omega_j z_{ij}, \quad \sum_{j \in J_g} \omega_j = 1; \quad Q_i = \sum_{g=1}^G \lambda_g q_i^{(g)}, \quad \lambda \in \Delta^{G-1}. \quad (5)$$

组内权重 ω 取等权为主方案 (组内指标语义相近); 组间权重 λ 设三个候选: (a) 等权 $\lambda_g = 1/G$; (b) $A1$ 上组分数相关矩阵的第一主成分载荷 (归一化到单纯形); (c) 数据驱动方案, 见式 (17)。主结果用 (a), (b)(c) 进入敏感性分析。

定义 1.4 (域级质量分的双口径). 以 n_i 记文档 x_i 的词数 (*rps_doc_word_count*), 域 d 的质量分定义为

$$Q_d^{\text{doc}} = \frac{1}{|S_d|} \sum_{i \in S_d} Q_i, \quad Q_d^{\text{tok}} = \frac{\sum_{i \in S_d} n_i Q_i}{\sum_{i \in S_d} n_i}. \quad (6)$$

Q_d^{doc} 回答“平均一篇文档”的质量, Q_d^{tok} 回答“平均一个训练 *token*”的质量。后续问题二、三中作为标度律与成本函数自变量的 Q 统一采用 *token* 口径; 置信区间由文档层自助法 (*bootstrap*, $B = 2000$) 给出, 样本量小的域 (如 *book*, $n = 171$) 须报告区间而非点估计。

1.3 模块二: 指标冲突的度量、类型划分与消解

定义 1.5 (冲突度与冲突集). 文档 x_i 的冲突度定义为组分数的极差

$$c_i = \max_g q_i^{(g)} - \min_g q_i^{(g)} \in [0, 1], \quad (7)$$

冲突集为 $C = \{i: c_i \geq \tau\}$, 阈值取 $A1$ 上冲突度分布的高分位 $\tau = \hat{F}_c^{-1}(0.95)$ 。冲突类型由达到极差的组对 ($\arg \max_g q_i^{(g)}$, $\arg \min_g q_i^{(g)}$) 划分, 典型类型包括: 专业性型 (专业价值高、可读性低, 多见于代码与公式文本)、广告混合型 (教育价值高、清洁度低)、格式型 (信息密度高、格式统计差)。

注 1.1. 高冲突度是需要调查的信号而非低质量的判定。 $A1$ 含原文 *content*, 冲突集的类型划分须经人工抽查校验 (每类抽 ≥ 30 篇); $A2/A3$ 无原文, 只能应用已校验的规则并比较冲突比例与类型构成是否与 $A1$ 对应域一致。

定义 1.6 (条件化消解算子). 消解规则表述为组间权重对域与冲突类型的条件化:

$$\tilde{Q}_i = \sum_{g=1}^G \lambda_g(d_i, t_i) q_i^{(g)}, \quad (8)$$

其中 d_i 为文档域、 $t_i \in \{ \text{无冲突, 专业性型, 广告混合型, 格式型} \}$ 为冲突类型。例如对 $d_i \in \{github, arxiv\}$ 且 t_i 是专业性型的文档, 将可读性组权重下调、专业组权重上调 (具体数值由人工校验样本上的一致性标定)。消解规则的**外部准绳**是: 采纳使域级质量分与配比实验度量的训练价值 (§1.5) 秩一致性更高、且不误伤专业语料 (人工抽查通过率 $\geq 90\%$) 的规则集。

1.4 模块三: 配比-损失回归与最优配比 (RegMix 范式)

假设 1.1 (小代理可迁移性). 配比对各验证域损失的排序效应在 $1M-1B$ 参数范围内近似保持, 即存在跨尺度单调映射使 $1M$ 实验拟合的回归可预测更大尺度下不同配比的相对优劣。该假设由 $A8-A11$ 实证检验 (式 (13)), 不作先验接受。

定义 1.7 (逐域回归与目标损失). 对每个验证域 $j \in \mathcal{D}_v$, 以 $A4/A5$ 的 512 组观测拟合

$$\hat{L}_j(\mathbf{p}) = f_j(\mathbf{p}; \boldsymbol{\theta}_j), \quad \boldsymbol{\theta}_j = \arg \min_{\boldsymbol{\theta}} \sum_{m=1}^M (\ell_j^{(m)} - f_j(\mathbf{p}^{(m)}; \boldsymbol{\theta}))^2. \quad (9)$$

基线取单纯形线性模型 $f_j(\mathbf{p}) = \boldsymbol{\beta}_j^\top \mathbf{p}$ (不含自由截距), 对照模型取梯度提升树 f_j^{GB} 以捕捉域间交互; 模型选择依据 $A6/A7$ 留出集的预测性能。目标损失由事先固定的评价权重 $\mathbf{w} \in \Delta^{12}$ 聚合:

$$L_{\text{tgt}}(\mathbf{p}) = \sum_{j \in \mathcal{D}_v} w_j \hat{L}_j(\mathbf{p}). \quad (10)$$

$\mathbf{w}$ 与 $\mathbf{p}$ 严格分离: $\mathbf{w}$ 定义“考卷”, $\mathbf{p}$ 是被优化的“备考策略”, 二者同时变动将失去可比性。主方案取 w_j 为 *Pile* 验证集的 *token* 份额, 等权方案进入敏感性分析。

注 1.2 (可识别性). 由约束 $\mathbf{1}^\top \mathbf{p} = 1$, 系数 $\boldsymbol{\beta}_j$ 仅在差分意义下可识别: 可解释的量是份额转移效应

$$\Delta_{k \rightarrow k'}^{(j)} = \frac{\partial \hat{L}_j}{\partial p_{k'}} - \frac{\partial \hat{L}_j}{\partial p_k} = \beta_{jk'} - \beta_{jk}, \quad (11)$$

即“把 1 单位份额从域 k 移到域 k' ”对损失 j 的边际影响。报告一律采用此形式, 不报告绝对系数。

定义 1.8 (最优配比问题).

$$\mathbf{p}^* = \arg \min_{\mathbf{p} \in \Delta^{16}} L_{\text{tgt}}(\mathbf{p}), \quad (12)$$

线性基线下该问题为线性规划 (顶点解需正则化或加入配比上界约束以避免退化到单域); 非线性模型下采用 *Dirichlet* 大样本模拟 (10^5 组候选配比取预测最优的前 k 组平均) 与 *SLSQP* 多起点数值优化交叉校验。输出 $\mathbf{p}^*$ 、其相对 *Pile* 人工配比与均匀配比的预测收益, 及由残差自助法得到的收益置信区间。

定义 1.9 (跨尺度验证指标). 对尺度 $s \in \{1M \text{ 留出}, 60M, 1B\}$ 的观测集 $\{(\mathbf{p}^{(m)}, \ell^{(m,s)})\}$, 报告:

$$\text{MAE}_j^{(s)} = \frac{1}{M_s} \sum_m |\ell_j^{(m,s)} - \hat{L}_j(\mathbf{p}^{(m)})|, \quad \rho^{(s)} = \text{Spearman}\left(L_{\text{tgt}}(\mathbf{p}^{(m)}), \sum_j w_j \ell_j^{(m,s)}\right), \quad (13)$$

以及 $\text{top-}k$ 遗憾 $R_k^{(s)} = \min_{m \in \hat{\mathcal{T}}_k} \sum_j w_j \ell_j^{(m,s)} - \min_m \sum_j w_j \ell_j^{(m,s)}$, 其中 $\hat{\mathcal{T}}_k$ 为回归预测的前 k 优配比。绝对误差 MAE 预期随尺度增大而增大 (损失水平整体下移), 而假设 1.1 只要求 $\rho^{(s)}$ 与 $R_k^{(s)}$ 保持良好; 1B 验证使用 *index* 交集后的 63 组数据。A12–A15 (10B/70B) 为外推估算, 仅报告与我们外推的一致性, 证据层级标注为“模型外推”。

1.5 模块四：质量–配比桥接与“质量 $\neq$ 训练价值”检验

A16 映射 φ 仅覆盖 6 个配比域, 其余 11 域无对应质量信号。桥接方案利用 *rps_** 规则统计量的可精确复算性补全缺口。

定义 1.10 (规则特征复算与校准函数). 设 $\Phi: \text{文本} \rightarrow \mathbb{R}^{15}$ 为 15 个规则统计量的确定性计算算子 (定义公开, 可逐条复现)。第一步, 在 A1 上 (每篇文档同时具备 $\Phi(x_i)$ 与综合分 Q_i) 学习文档级校准函数

$$\hat{g} = \arg \min_{g \in \mathcal{G}} \sum_{i \in \mathcal{S}_1} (Q_i - g(\Phi(x_i)))^2, \quad (14)$$

$\mathcal{G}$ 取岭回归与梯度提升两类, 按域分层 5 折交叉验证选择, 报告 R_{cv}^2 与逐域残差。第二步, 对 A17 中域 $k \in \mathcal{D}_m$ 的每篇文本 x 计算 $\hat{Q}(x) = \hat{g}(\Phi(x))$, 聚合 (A18 的词数信息作 *token* 加权) 得全部 17 域的估计质量分 $\hat{Q}_k$ 及自助法置信区间。对 *direct/near_direct* 的 6 个域, $\hat{Q}_k$ 与由 A1–A3 模型分直接算得的 $Q_{\varphi(k)}$ 互为校验; 样本过少的域 (*ubuntu_irc* 16 篇、*philpapers* 67 篇) 标记为低置信, 仅列区间。

定义 1.11 (训练边际价值与解耦检验). 由式 (11), 定义域 k 对目标损失的训练边际价值为中心化系数的相反数:

$$\nu_k = -\left(\bar{\beta}_k - \frac{1}{17} \sum_{k'} \bar{\beta}_{k'}\right), \quad \bar{\beta}_k = \sum_{j \in \mathcal{D}_v} w_j \beta_{jk}, \quad (15)$$

$\nu_k > 0$ 表示向域 k 转移份额平均而言降低目标损失。核心检验为质量分与训练价值的秩相关

$$\rho_{Q\nu} = \text{Spearman}(\{\hat{Q}_k\}_{k=1}^{17}, \{\nu_k\}_{k=1}^{17}), \quad (16)$$

原假设 $H_0: \rho_{Q\nu} = 0$ (质量与训练价值无序关联)。无论检验结果如何均如实报告: 若 $\rho_{Q\nu}$ 显著为正, 说明质量分对配比选择有先验指导价值; 若不显著或为负 (*RegMix* 关于 *pile_cc* 的发现预示此可能), 则定量证实“内在质量不等于训练价值”, 配比必须由实验回归确定——这一结论将作为问题二引入配比修正项、问题三将 Q 与 $\mathbf{p}$ 设为独立决策变量的依据。

定义 1.12 (数据驱动的组间权重 (候选方案 c)). 利用同一桥接, 把 *Meta-rater* “权重由代理实验反推”的思想在本题数据上实现:

$$\boldsymbol{\lambda}^{\text{drv}} = \arg \max_{\boldsymbol{\lambda} \in \Delta^{G-1}} \text{Spearman}(\{\hat{Q}_k(\boldsymbol{\lambda})\}_{k \in \mathcal{K}}, \{\nu_k\}_{k \in \mathcal{K}}), \quad (17)$$

其中 $\mathcal{K}$ 主分析取 *direct/near_direct* 的 6 域, 敏感性分析扩至 17 域。由于 $|\mathcal{K}|$ 很小, 该方案可识别性弱, 仅作为候选与等权方案对照, 不单独支撑结论。

1.6 求解流程与验证清单

整体求解按以下步骤执行，括号内为对应数据与产出：

1. 数据审计：核对 A1–A18 行列结构、配比行和、`index` 对齐（已发现 A10/A11 需取 63 组交集），建立证据分层标签（直接观测 / 规则复算 / 校准推断 / 外推）。
2. 质量评分：按定义 1.1–1.4 在 A1 上构建 Q_i 与 Q_d ，规则冻结后应用于 A2/A3；以 KS 检验与分位数图比较 A1 对应域与 A2/A3 的分布一致性。（产出：七域质量分布、双口径域级分及置信区间）
3. 冲突分析：按定义 1.5–1.6 构建冲突集、人工抽查、标定消解规则，并在 A2/A3 上检验冲突比例迁移。（产出：冲突矩阵、类型表、消解前后评分变动）
4. 配比回归与优化：按定义 1.7–1.8 拟合、选型、求 $\mathbf{p}^*$ 。（产出：份额转移效应表、最优配比与收益区间）
5. 跨尺度验证：按定义 1.9 在 1M 留出、60M、1B 上报告 MAE、 $\rho^{(s)}$ 、top- k 遗憾。（产出：假设 1.1 的实证结论）
6. 桥接与检验：按定义 1.10–1.11 复算 A17 规则特征、校准 $\hat{g}$ 、估计 $\hat{Q}_k$ 、检验 $\rho_{Q\nu}$ 。（产出：17 域质量分、解耦检验结论）
7. 接口冻结：将 Q （token 口径）、 $\mathbf{p}$ 与 $L_{\text{tgt}}(\cdot)$ 、评价权重 $\mathbf{w}$ 、证据分层标签作为问题二至四的统一输入。