



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校 国防科技大学

参赛队号 26910020233

	1. 李重行
队员姓名	2. 李星谊
	3. 刘浩然

中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生

数学建模竞赛

题 目： 算力约束下提升大语言模型能力的资源配置建模

摘 要：

大语言模型的能力由参数规模 N 、数据量 D 、数据质量 Q 与领域配比 $\mathbf{p}$ 共同决定，而扩大规模、提升质量与延长上下文都要消耗有限的算力。本文沿赛题“数据刻画—规律建模—资源优化—演进预测”的递进主线建立四个相互衔接的模型：前一问的输出以固定接口文件的形式进入后一问，全文只估计一次广义标度律，并按证据等级（真实观测、半合成、外推生成）区分各附件的用途。

针对问题一，将 22 个异质质量信号展开为 25 个“越高越好”的指标，在域内做稳健归一，用 CRITIC 客观赋权与加权几何平均得到样本级连续质量分 Q ，再以中位数聚合为域级分。该排序与等权、TOPSIS、PCA 三种对照方法的 Spearman 相关为 0.991/0.946/0.871。以同一冻结管线复算扩展集 A2、A3 的全部记录，与抽样集的 KS 检验 $p = 0.60/0.12$ 。冲突定义为四组信号的域内分位排名极差，阈值取冲突率—阈值曲线的最大曲率点 $\tau = 0.75$ ，测得冲突率 21.5%（扩展集为 21.1%/22.9%）；主冲突类型“DSIR 高 $\times$ 规则型低”在三个数据集上复现，并用 Huber 连续降权消解（与原排序相关 0.997）。配比建模先做中心对数比（clr）变换以消除成分数据的闭合效应，检验集 R^2 由裸回归的 0.654 升至 0.772。由此得到 17×13 领域迁移矩阵与最优配比 $\mathbf{p}^*$ （相对均匀配比预测降损 9.9%）。跨尺度检验表明配比效应“斜率稳、截距漂”，加入截距漂移修正后外推 MAE 由 3.5 降至 0.10。另外，域级质量与训练边际价值的秩相关仅为 -0.06 。

针对问题二，先审计附件 B：B1 为公式生成的无噪声锚点，B6/B7 可由“基线 + 加性质量惩罚”以噪声水平刻画，B8 与之语义相反，不能混用。在五种候选形式中用交叉验证选型，加性形式（cv-RMSE 0.051）明显优于有效数据乘子族（0.099–0.105），据此建立广义标度律 $L = E + [A + k_1(1 - Q)]N^{-\alpha} + BD^{-\beta} + (1 - Q)k_0$ ； $Q = 1$ 时它严格退化为经典形式，配比经 $\bar{Q}(\mathbf{p})$ 与迁移矩阵接入。由该式推出四条闭式命题，均与数值解互验（相对误差 $< 10^{-5}$ ）：质量弹性约为规模弹性的 4 倍；质量提高 0.1 在 $N = 10^{10}$ 处等效于参数扩大 1.64 倍；低质量带来规模无法弥补的损失下界 $(1 - Q)k_0$ ；质量越高，算力最优配置越偏向“小模型、多数据”。

针对问题三，三项成本都与 D 成正比，最优时预算约束必取等，据此把 D 解析消去，将问题化为 $(\log N, Q)$ 上的二维无约束问题，并用“内层黄金分割 + 外层三级网格加密”的向量化求解器，在 3 种成本函数 $\times$ 7 档预算 $\times$ 5 档 L_{ctx} $\times$ 2 种基线质量下求得 210 组最优解。

数值解与闭式解的相对误差不超过 1.83×10^{-7} ，与穷举网格的 Loss 差不超过 1.6×10^{-5} 。以 KKT 活跃约束集的改变定义结构性转移，并由边际比 $\Phi(C) = 1$ 解析识别临界预算。主口径 ($Q_0 = 0.988$, $L_{\text{ctx}} = 2048$) 下， $\log_{10} C_{\text{crit}}$ 为：指数型 20.61、幂函数型 20.48、对数型 18.52。三种识别口径的极差不超过 0.05 dex，bootstrap 90% 区间在 ± 0.03 dex 以内。转移几乎呈“不提质 $\rightarrow$ 提满”的跳变，210 组中 34 组为 Q_0 角点、3 组为内点，均出现在 10^{19} – 10^{20} 。解析给出 $L_{\text{ctx}}^{\text{crit}} = 6/\eta = 30000$ ；上下文增至 131k 时， $C = 10^{22}$ 的最优模型缩至 0.48 倍，注意力成本占 81%。将配比联立优化可再降 13.7%，但几乎全部来自配比效应；最优配比排序在不同预算下的秩相关 ≥ 0.976 ，“先定配比、再定规模”的分离策略成立。

针对问题四，能力的主口径为 C1 的 Average，并对 C8 的 39 个叶子任务逐一聚合，识别出 10 个饱和任务，构造去饱和综合分，发现饱和任务使前沿增速被低估约 1.6 倍。将 base 与 chat 分开处理，时间轴采用 C2 发布日。按可比性等级分层，用加权 sigmoid 拟合 C6 的 Loss–Benchmark 桥接 ($r = -0.51$ ，留一 RMSE 8.08，优于线性的 8.28)。以问题二的标度律 $\hat{L}(N, D)$ 作为规模状态，建立“S 形桥接 + 时间技术项”的结构模型 ($R^2 = 0.87$)，并用 Shapley 分解前沿增长。2023.5 $\rightarrow$ 2025.0 期间 base 前沿由 12.5 升至 37.3，结构口径下非规模技术进步占 13%–23%，线性效率前沿口径为 38%–46%；两类方法的差异来自对 S 形加速段的归因不同。结论是规模扩张占主导。预测以问题三的最优配置为算力通道，在基线 / 减半 / 1/4 三种算力增速 (0.60/0.30/0.15 dex/yr) 情景下，base 开源前沿 24 个月中位数为 46.2/45.2/44.1。算力放缓时，技术进步在增量中的占比由 55% 升至 77%。回测误差为 -0.78 ，而朴素线性外推为 $+2.65$ 。

各模型都做了互验、交叉验证、bootstrap 与参数敏感性检验，《数据说明》中的误导性“建议”也逐条用数据核对。结论适用于附件数据覆盖的规模范围，半合成与外推数据只用于形式选择与稳健性讨论。

关键词：CRITIC 赋权；成分数据 clr 回归；广义标度律；KKT 结构性转移；Shapley 贡献分解

1 问题重述

1.1 问题背景

大语言模型的训练可以类比为培养学生：参数量 N 对应“脑容量”，训练 token 数 D 对应“阅读量”，训练算力 C 对应“教育经费”，数据质量 Q 对应“教材质量”，领域配比 $\mathbf{p}$ 对应“各科课时分配”。经典标度律 $L(N, D) = E + AN^{-\alpha} + BD^{-\beta}$ 描述验证集交叉熵损失随 N 、 D 的幂律下降 [1, 2]，但不含 Q 与 $\mathbf{p}$ 。高质量语料日益稀缺（“数据墙”），而 OpenScholar-8B 在若干任务上优于 GPT-4o[3]，这说明数据侧因素不可忽视。扩大规模、提升质量与延长上下文都要消耗算力，调整配比虽不增加总开销，却会改变算力的使用效果。赛题提供附件 A（质量信号与配比实验）、B（标度律观测）、C（排行榜、元数据与逐任务评测），要求在算力约束下研究资源配置。

1.2 问题描述

问题一：基于 A1–A3 的 22 个质量信号建立样本级与域级综合质量分 Q ，并与扩展集对照；定义指标冲突、分析成因并消解，在扩展集上复验；基于 A4–A15 建立 17 域配比 $\mathbf{p}$ （单纯形约束）与 13 个验证域损失的定量关系，在检验集 A6–A11 上验证，用外推表 A12–A15 讨论外推稳健性。

问题二：以问题一输出的 Q 、 $\mathbf{p}$ 为接口，综合附件 B 建立含 $N, D, Q, \mathbf{p}$ 的广义标度律；分析各因素的边际效用与弹性、领域间的替代或互补关系，推导质量提升与规模扩大可以相互替代的条件，并完成参数估计与检验。

问题三：总成本 $6ND + D[g(Q) - g(Q_0)]_+ + \eta NDL_{\text{ctx}} \leq C$ 下求最优资源配置，比较三类质量成本函数；解析给出 $L_{\text{ctx}}^{\text{crit}} = 6/\eta$ ，并在 C7 的可行上下文长度上做敏感性分析；给出预算跨越量级时“结构性转移”的数学定义与识别方法。


问题四：基于附件 C 分离并量化规模扩张与非规模技术进步的贡献，说明能力度量、开源筛选、模型类型与时间轴四项口径；建立分层的 Loss–Benchmark 映射，在算力增长放缓情景下预测 12/24 个月开源模型能力前沿，并给出不确定性。

2 问题分析

2.1 总体思路

四问构成一条递进链（图 1）：问题一把数据侧压缩为两个可注入的量，即连续质量分 Q 与配比—损失关系；问题二把它们嵌入标度律，得到 $L(N, D, Q, \mathbf{p})$ ；问题三在成本约束下优化该损失；问题四用桥接映射把损失翻译为能力得分，再结合时间项做分解与预测。为保证口径一致，每一问的产出都落盘为接口文件（P1–P4），后续各问只消费接口，不重复拟合。

数据使用遵循**证据分层**：直接观测（A1–A11、B1、B4、B5、C1–C4、C7、C8）支撑主结论；半合成与插值数据（B2、B3、B6–B8）只用于形式选择并明示局限；外推生成数据（A12–A15、B10）只用于稳健性讨论。方法选择遵循**可检验**原则：阈值由数据自适应确定，函数形式由交叉验证裁决，解析结果与数值结果互验，预测先做历史回测。



接口 P1: Q_d 、 p^* 、迁移矩阵 接口 P2: 参数与 $N^*(C, Q)$ 接口 P3: $L^*(C)$ 、 C_{crit} 接口 P4: 分解与前沿

图 1 四问递进关系与接口文件

2.2 各问题的关键难点

问题一。一是指标形态异质：有 logits 列表、负对数比、规则统计量三类，方向与量纲各不相同，且各域基线存在结构性差异。二是若用预设阈值定义冲突，结论就由定义决定。三是配比为成分数据，直接回归会产生闭合效应伪相关。四是 17 个配比域中只有 6 个有官方质量映射。对应策略分别为：域内稳健归一，用最大曲率点定阈值，做 clr 变换，自实现规则算子进行跨体系桥接。

问题二。附件 B 各表来源与噪声差异很大，必须先审计再拟合；质量进入损失的形式（加性惩罚还是有效数据乘子）不能先验指定；附件 B 的 Q 与问题一的 Q 尺度不同，需要锚定换算。

问题三。约束非线性，决策变量跨越十余个数量级；最优解可能落在质量上下界的角点，“结构性转移”需要可计算的定义，而不是凭图形判断； L_{ctx} 是外生变量，只能取 C7 中的可行值。

问题四。Benchmark 与 Loss 的尺度不同，桥接数据中高可比层样本很少；规模与时间高度共线；C1 的时间窗仅 9 个月，C3 口径混杂；此外，饱和任务会掩盖前沿进展。

3 模型假设

- 质量信号可信。**附件 A 的质量信号按原始定义计算，logits 经 softmax 后具有序数意义，仅用于文档间的相对比较。
- 小代理可迁移（待检验）。**配比对损失的排序效应在 1M-1B 参数范围内近似保持；该假设由三尺度留出集检验，检验结果决定其适用边界（§5.2.3）。
- 质量口径锚定。**附件 B 以 Pythia 所用 Pile 语料为 $Q = 1$ ，与问题一的换算为 $Q_B = Q_1 / Q_{ref}$ ， $Q_{ref} = \bar{Q}(p_{pile}) = 0.5608$ ；敏感性分析取双口径。
- 评价权重固定。**13 个验证域损失以等权汇总为目标损失，评价权重与被优化的配比严格分离；pile_cc 单域作为副口径。
- 成本模型。**训练、提质与注意力三项开销使用同一 D ； $\eta = 2 \times 10^{-4}$ 与附录 B 的成本函数参数按赛题给定。
- 技术进步平滑。**非规模技术进步在分析窗口内可用连续时间项刻画；预测为情景条件预测，不含新架构等离散突破。

4 符号说明

表 1 主要符号及含义

符号	含义	单位
N, D	模型参数量、训练 token 数	个
C	总算力预算	FLOPs
Q, Q_B	综合质量分（问题一口径）、附件 B 口径质量	无量纲, $[0, 1]$
Q_0	基线质量（问题三提质起点）	无量纲
$\mathbf{p}$	$=$ 17 域训练配比, $p_i \geq 0, \sum p_i = 1$	无量纲
$(p_1, \dots, p_{17})$		
$z_j(x), w_j$	文档 x 第 j 个标准化指标及其 CRITIC 权重	无量纲
$c(x), \tau$	文档冲突度、冲突阈值	无量纲
L_v, L	验证域 v 的交叉熵损失、综合损失	nats
T_{iv}	迁移矩阵：增配域 i 对验证域 v 损失的影响	无量纲
E, A, α, B, β	标度律基线参数	—
k_0, k_1	质量惩罚常数项、质量—规模交互系数	nats
$\tilde{A}(Q)$	$A + k_1(1 - Q)$, 质量修正后的参数项系数	—
$\varepsilon_N, \varepsilon_D, \varepsilon_Q$	损失对 N, D, Q 的弹性	无量纲
$g(Q), \eta$	单位 token 提质成本函数、注意力开销系数	FLOPs/token
L_{ctx}, κ	上下文长度、单位 ND 成本 $\kappa = 6 + \eta L_{\text{ctx}}$	token, —
C_{crit}	结构性转移的临界预算	FLOPs
$S, \hat{L}$	Benchmark 综合得分、标度律预测损失（规模状态）	分, nats
τ_t, δ	每年得分技术增益、每年等效降损	分/年, nats/年

表中只列全文反复使用的重要符号，局部符号在首次出现处说明。

5 模型的建立与求解

5.1 数据预处理

数据审计。建模前逐表核对实际文件，发现五个影响建模路线的事实：(i) A10/A11 分别为 64 行与 63 行，按 index 取交集；(ii) A16 的 17 域映射中只有 3 个 direct、3 个 near_direct，其余 11 个为 inferred；(iii) B1 可被三参数形式拟合到 $\text{RMSE} = 1.5 \times 10^{-4}$ ，呈公式生成特征；(iv) 在相同 (N, D, Q) 点上，B8 与 B6/B7 的损失相关系数为 -0.03 ，方向相反，因此 B8 不参与联合拟合；(v) C1 的提交日比发布日中位滞后 103.5 天，窗口仅为 2024-06 至 2025-03。

指标展开与归一。22 个字段按输出形态展开为 25 个指标：二元 logits 经 softmax 取正类概率；6 档 logits 取期望档位 $\sum_k k \sigma_k / 5$ ；qurater 拆为四个维度；DSIR 负对数比仅在域内比较；15 个规则统计量按定义方向处理。每个域的每个指标依次处理：“适宜区间型”指标改为到中位数的偏离；重尾指标取 $\log(1 + x)$ ；按 1%/99% 缩尾；做域内 Min–Max；负向指标取 $1 - x$ 。变换参数在 A1 上估计后**冻结**，原样用于 A2/A3，以免把管线差异混入抽样对照。A1–A3 的缺失率均低于 0.03%，用域内中位数填补。

附件 C 预处理。 C8 共 1958 个 JSON，其中 4 个截断，其余逐任务解析为长表；C2 与 C4 按（发布日，组织）联表，保留 $t \geq 2021$ 、 $D > 10^9$ 的记录；同一 C4 模型被多行命中时按 $1/\text{重复数}$ 加权。

5.2 问题一的模型建立与求解

5.2.1 模型建立

(a) 综合质量评分：CRITIC + 加权几何平均。 指标 j 的信息量同时取决于对比强度 σ_j 与它和其他指标的冲突性 $\sum_k (1 - r_{jk})$ ：

$$C_j = \sigma_j \sum_{k=1}^{25} (1 - r_{jk}), \quad w_j = \frac{C_j}{\sum_k C_k}, \quad Q(x) = \prod_{j=1}^{25} z_j(x)^{w_j}. \quad (1)$$

式 (1) 中 r_{jk} 为指标间的相关系数。选择 CRITIC 而不用熵权，是因为 CRITIC 会自动惩罚冗余指标；选择几何平均，是为了实现“短板支配”：广告概率等短板项趋于零时，总分被显著压低，这与工业界一票否决式过滤的方向一致，同时保留了连续性 [10, 8]。域级分取样本中位数，并给出 bootstrap 95% CI ($B = 2000$)。

(b) 冲突定义与消解。 把 25 个指标按信号来源分为四组：规则型、DSIR、轻量分类器、模型评分器。组内 Kendall W 分别为 0.128/0.998/0.627/0.447，说明冲突主要发生在组间。据此把组分数转为域内分位排名 $R_g(x) \in [0, 1]$ ，定义

$$c(x) = \max_g R_g(x) - \min_g R_g(x), \quad x \text{ 为冲突样本} \iff c(x) > \tau, \quad (2)$$

其中阈值 τ 取冲突率—阈值曲线的最大曲率点，不预先设定。消解采用 Huber 连续降权：文档 x 的组 g 相对其自身中位排名偏离 dev_g ，权重为 $u_g = \min(1, \tau_z/|\text{dev}_g|)$ ，与 CRITIC 权重相乘后重新归一，再代入式 (1) 得到修正分 $\tilde{Q}$ [11]。

跨体系桥接。 11 个 inferred 域没有质量信号。我们自实现 11 个 rps 规则算子 $\Phi(\text{text})$ ，在 A1 上 ($n = 21,590$) 学习校准函数 $\hat{g} : \Phi \mapsto \tilde{Q}$ ，再对 A18 的 17 域原文 (31,340 篇) 计算 $\hat{Q}_d$ 。

(c) 配比—损失模型：clr 回归。 配比满足 $\sum p_i = 1$ ，直接回归会把机械的此消彼长误读为领域间的替代 [9]。对 $\mathbf{p}$ 做中心对数比变换 $z_i = \ln(p_i/g(\mathbf{p}))$ ，其中 $g(\mathbf{p})$ 为几何均值，零分量乘性替换为 10^{-4} 。对每个验证域在对数空间回归：

$$\ln L_v = b_v + \sum_{i=1}^{17} \beta_{v,i} z_i + \varepsilon_v, \quad v = 1, \dots, 13, \quad (3)$$

用 Huber 损失抵抗异常配方。系数经链式法则折算到单纯形切空间，得到迁移矩阵 $T_{iv} = \partial \ln L_v / \partial p_i$ (在均匀配比处取值)。最优配比为

$$\mathbf{p}^* = \arg \min_{\mathbf{p} \in \Delta^{16}} \frac{1}{13} \sum_{v=1}^{13} \hat{L}_v(\mathbf{p}). \quad (4)$$

5.2.2 求解方法

评分管线对 A1 (21,590 篇)、A2 (arxiv 全量 17,523 篇)、A3 (github 全量 203,752 篇) 逐块流式计算。对照方法组包括：等权几何平均；PCA (取累计方差 80.6% 的 10 个主成

分)；以 CRITIC 权重加权的 TOPSIS；K-means 三档聚类。桥接校准函数用域分层五折交叉验证，在梯度提升与岭回归之间选型。式 (3) 在 1M 训练集上拟合，以梯度提升作为非线性对照。式 (4) 以训练配比均值为中心，用多浓度 Dirichlet 采样 10^5 个候选，由梯度提升模型打分，取最优的前 100 个求平均。跨尺度部分用 1M 系数直接预测 1M 留出 / 60M / 1B 三个检验集，并对 A12–A15 估计截距漂移律 $b_v(N) = b_v^0 + \rho_v \ln(N/10^6)$ 。

5.2.3 结果与分析

质量评分。 CRITIC 排序与等权、TOPSIS、PCA 的样本级 Spearman 相关分别为 0.991、0.946、0.871。三种互不蕴含的赋权假设给出高度一致的排序，说明质量结构是数据内在的。七域排序为 arxiv (0.713) > stackexchange (0.590) > commoncrawl (0.557) > github (0.533) > book (0.511) > c4 (0.499) > wikipedia (0.484)，见图 2。扩展集复算与 A1 对应子集的 KS 检验为 $D = 0.021$ ($p = 0.60$) 与 $D = 0.012$ ($p = 0.12$)，Cohen’s $d \approx 0.005$ ，抽样集具有代表性。




图 2 A1 七域质量分布 (CRITIC 加权几何平均)

冲突。 最大曲率点给出 $\tau = 0.75$ ，冲突率为 21.5% (图 3)，这否定了《数据说明》中“冲突率约 0%”的说法。冲突与领域强相关 ($\chi^2 = 142.4$, $df = 6$, $p \approx 10^{-23}$)。主冲突类型“DSIR 高 × 规则型低”在 A1/A2/A3 中分别占 19.6%/15.1%/18.1%，扩展集冲突率为 21.1%/22.9%，结论在扩展集上成立。抽查 30 篇原文后确认两类成因：LaTeX 与代码文本专业价值高而表层流畅度低；模板化网页规则统计量好而教育价值低。Huber 消解保持原有排序 ($\rho(Q, \tilde{Q}) = 0.997$)：冲突样本平均下调 0.0033，非冲突样本仅变动 -0.0004，做到了降权而不删除。




图 3 冲突率—阈值曲线与最大曲率点




图 4 17 配比域质量分 (误差条为 95% CI)

桥接。梯度提升校准的 $R_{cv}^2 = 0.31$, 优于岭回归的 0.25。在 6 个有映射的域上, 校准分与官方分的 Pearson 相关为 0.70, MAE 为 0.055。17 域中 arxiv 最高 (0.716), dm_mathematics 最低 (0.355), 见图 4; ubuntu_irc (16 篇) 与 philpapers (63 篇) 标为低置信。

配比—损失关系。表 2 显示, clr 变换使检验集 R^2 由 0.654 提高到 0.772, 这就是处理闭合效应带来的量化改进 [4]。梯度提升 (0.897) 说明存在域间交互, 因此系数解释用线性模型、最优搜索用非线性模型; 两者在 10^5 个候选上的秩相关为 0.77。迁移矩阵 (图 5) 中 13 个自域效应全部为负, dm_mathematics 的自域效应最强 (-2.47)。加入质量交互项 $\lambda_v \sum_i p_i (1 - \hat{Q}_{d(i)})$ 后, 10/13 个验证域的 λ_v 显著, 但符号在域间不一致 (中位数 -0.249 , arxiv 为 $+0.79$)。因此质量与配比应分别进入问题二的模型, 不能合并为单一乘子。

表 2 配比—损失模型对照 (1M 检验集, 256 组)

模型	平均 R^2	RMSE	说明
裸配比 OLS (RegMix 原式)	0.654	0.432	未处理闭合效应
clr + Huber (本文)	0.772	0.320	系数可解释, 用于迁移矩阵
梯度提升 (非线性对照)	0.897	—	用于最优配比搜索




图 5 迁移矩阵 T_{mv} (蓝色为增配降损)




图 6 域级质量与训练边际价值 ($\rho = -0.06$)

最优配比。等权口径下 $\mathbf{p}^*$ 的前五位为: pile_cc 15.6%、stackexchange 10.0%、wikipedia 9.5%、pubmed_central 9.1%、arxiv 8.9% (图 7)。相对均匀配比, 预测降损 9.9% (梯度提升

点估计；线性模型 bootstrap 95% CI 为 [9.7%, 14.1%])。pile_cc 单域口径下 pile_cc 占 33.2%，复现了 RegMix “网页语料对下游最有利”的结论。域级质量 $\hat{Q}_d$ 与训练边际价值的秩相关仅为 -0.06（图 6），说明内在质量不等于训练价值，配比必须由实验回归确定。




图 7 两种评价口径下的最优配比 p^*

跨尺度验证与外推。用 1M 系数直接预测三尺度留出集，目标损失排名的 Spearman 相关为 0.52/0.47/0.68（图 8），排序中等程度保持，但绝对预测失效。系数漂移分解显示，**截距显著下漂，斜率几乎不变** ($\max_i |\rho_\beta| \approx 0.007$)。对 A12-A15，直接套用 1M 系数的 MAE 约为 3.5，经漂移律修正后降到 0.10。外推最稳健的是 arxiv 与 pubmed_central ($\rho > 0.85$)，最不稳健的是 pile_cc 与 pubmed_abstracts ($\rho < 0.40$)。由此假设 2 的适用边界是：排序效应可迁移，绝对水平需要做尺度修正。




图 8 配比排序可迁移性随规模的变化

5.3 问题二的模型建立与求解

5.3.1 模型建立

建模思路。经典标度律只有 N 与 D 两个变量。本文采用基线 + 质量修正的结构：先在附件内锚定经典项，再让数据决定质量以何种形式进入。候选形式分两族。第一族是**加性惩罚族**，质量不足直接抬高损失；第二族是文献常用的**有效数据乘子族**，低质量数据折算为更少的有效 token[7]。两族在经济含义上不同：前者意味着低质量带来规模无法弥补的损失，后者意味着多读数据总能弥补质量不足。

数据审计与逆向。 B1 可被三参数形式拟合到 $\text{RMSE} = 1.5 \times 10^{-4}$ ，是公式生成的无噪声锚点。在 B6/B7 的 $N \times D \times Q$ 网格上，残差去除基线后与 $(1 - Q)$ 呈线性关系，且斜率随 $N^{-0.34}$ 衰减（图 9）。据此逆向得到的生成式为“基线 + $(1 - Q)(0.19 + 175N^{-0.34})$ ”。B8 与 B6/B7 在相同 (N, D, Q) 点上的相关系数为 -0.03 ，语义不同源，因此不参与联合拟合。




图 9 附件 B 的逆向分析：B1 锚点（左）、B6/B7 残差对 $(1 - Q)$ 的线性结构（中）、B8 与 B6/B7 的不一致（右）

主模型。 交叉验证选型后（见 5.3.2 节），广义标度律为

$$L(N, D, Q) = E + \tilde{A}(Q) N^{-\alpha} + B D^{-\beta} + (1 - Q) k_0, \quad \tilde{A}(Q) = A + k_1 (1 - Q) \quad (5)$$

$Q = 1$ 时式 (5) 严格退化为经典 Chinchilla 形式 [1]。 k_0 项是不随规模衰减的“质量地板”， k_1 项是随 $N^{-\alpha}$ 衰减的“质量—规模交互”。

配比的接入。 按赛题要求，问题二不重复读取附件 A，配比只通过问题一的接口进入：

$$Q_B(\mathbf{p}) = \frac{1}{Q_{\text{ref}}} \sum_{i=1}^{17} p_i \hat{Q}_{d(i)}, \quad Q_{\text{ref}} = \bar{Q}(\mathbf{p}_{\text{pile}}) = 0.5608, \quad (6)$$

即把配比映射为语料平均质量后代入 Q 。配比的域结构效应（哪个域帮哪个验证域）由迁移矩阵 T 单独描述。问题一已发现交互系数 λ_v 的符号在域间不一致，因此不把质量与配比合并为单一乘子。

5.3.2 求解方法

两步拟合。 第一步在 B1 上网格搜索 (α, β) ，再以最小二乘确定 (E, A, B) ，得到 $L_0 = 1.6901 + 406.4N^{-0.340} + 410.6D^{-0.280}$ 。第二步固定基线，在 B6/B7 的 450 个点上对五种候选质量项做五折交叉验证（表 3）。参数区间用残差 bootstrap ($B = 500$) 估计。

表 3 质量项形式选择（五折 cv-RMSE；数据噪声水平 $\sigma \approx 0.05$ ）

候选形式	所属族	cv-RMSE
加性 + 规模交互 $(1 - Q)(k_0 + k_1 N^{-\alpha})$	加性惩罚	0.0512
纯加性 $k(1 - Q)$	加性惩罚	0.0731
指数乘子 $D_{\text{eff}} = D e^{-\gamma(1-Q)}$	有效数据乘子	0.0985
线性乘子 $D_{\text{eff}} = D(q_0 + (1 - q_0)Q)$	有效数据乘子	0.1030
幂律乘子 $D_{\text{eff}} = D Q^\gamma$	有效数据乘子	0.1050

主模型的 cv-RMSE 达到数据噪声水平，而文献偏好的有效数据乘子族全部落败。模型形式由交叉验证裁决，而不是从文献先验借用。

表 4 广义标度律参数估计（括号内为残差 bootstrap 95% CI）

E	A	α	B	β	k_0	k_1	残差 σ
1.6901	406.39	0.34	410.59	0.28	0.1922 [0.175, 0.211]	175.29 [156.6, 193.0]	0.051

5.3.3 结果与分析

跨源检验。在真实文献点上，主模型预测与观测的 Spearman 相关为：scaling_baseline (57 点) 0.983, published (44 点) 0.959；平均偏差分别为 0.22 与 0.02 nats。趋势一致，绝对偏移来自 tokenizer 与验证集差异，符合“跨源只比趋势”的原则。B2（半合成）Spearman 为 0.788、偏差为 1.18 nats，仅作定性佐证。

解析命题。以下四条命题均由式 (5) 直接推出，并与数值优化互验：命题 2 为逐点代入，命题 4 与数值最优解的最大相对误差 $< 10^{-5}$ 。

命题 1 (弹性). 损失对三个因素的弹性为 $\varepsilon_N = -\frac{\alpha \tilde{A}(Q) N^{-\alpha}}{L}$, $\varepsilon_D = -\frac{\beta B D^{-\beta}}{L}$, $\varepsilon_Q = -\frac{Q(k_0 + k_1 N^{-\alpha})}{L}$. 在 $(N, D, Q) = (10^{10}, 10^{12}, 0.9)$ 处三者依次为 -0.028 、 -0.024 、 -0.115 ，即质量弹性约为规模弹性的 4 倍。由于 k_0 项不随 N 衰减，规模越大，质量的相对优势越明显。

命题 2 (质量—参数等效替代及其边界). 固定 D ，使 $L(N', D, Q) = L(N, D, Q + \delta)$ 成立的等效参数量为

$$N' = N \left[1 - \frac{\delta (k_0 + k_1 N^{-\alpha})}{\tilde{A}(Q) N^{-\alpha}} \right]^{-1/\alpha}, \quad (7)$$

当且仅当括号内为正时有限。质量从 0.9 提高到 1.0，在 $N = 10^9$ 处等效于参数扩大 1.33 倍，在 $N = 10^{10}$ 处等效于扩大 1.64 倍（bootstrap 区间 [1.52, 1.77]）。同一份质量改进，模型越大价值越高；超过临界规模后，任何有限的扩参都无法替代这次质量提升。这就是“质量与规模可相互替代”的条件。

命题 3 (质量地板). $\lim_{N, D \rightarrow \infty} L = E + (1 - Q)k_0$ 。低质量会带来规模无法弥补的损失下界： $Q = 0.5$ 的地板比 $Q = 1$ 高 0.096 nats。这为问题三的“付费提质”提供了理论依据。

命题 4 (算力最优配置随质量移动). 在约束 $6ND = C$ 下,

$$N^*(C, Q) = \left[\frac{\alpha \tilde{A}(Q)}{\beta B} \right]^{\frac{1}{\alpha+\beta}} \left(\frac{C}{6} \right)^{\frac{\beta}{\alpha+\beta}}, \quad \frac{\beta}{\alpha+\beta} = 0.452, \quad \frac{\partial N^*}{\partial Q} < 0. \quad (8)$$

质量越高, 最优配置越偏向“小模型、多数据”: $C = 10^{22}$ 时, 最优 $token/参数$ 比由 $Q = 0.3$ 时的 27 升至 $Q = 1$ 时的 63。其机制是低质量数据抬高了 $\tilde{A}(Q)$, 相当于提高了参数的边际收益。这一命题是问题三结构性转移的机制来源。




图 10 解析理论三联图: 等损失线 (左)、等效参数倍数 (中)、 $N^*(C, Q)$ (右)

领域间的替代与互补。 广义律中的配比通道由两部分组成。第一部分是 $Q_B(\mathbf{p})$: 把质量高的域 (arxiv、stackexchange) 换入, 会通过 $(1 - Q)$ 两项同时降损。第二部分是迁移矩阵 T (表 5): 13 个自域效应全部为负, 说明各域“自己补自己”最有效; 非对角的负值对应**互补**, 最典型的是 github 与 stackexchange 双向互补 ($-0.21/-0.32$), pubmed_central 与 pubmed_abstracts 双向互补 ($-0.16/-0.11$), pile_cc 增配也会降低 wikipedia 的损失 (-0.11); 正值对应**替代** (挤占), 最典型的是 dm_mathematics 列除 ubuntu_irc 外全为正 ($0.04-0.50$), 即几乎任何其他域的增配都会挤占数学能力, enron_emails 增配则使全部 13 个验证域的损失上升。第二部分主导配比效应, 这一点在问题三的联立优化中得到印证 (5.4.3 节): 联合降损几乎全部来自配比结构, 而不是 $Q_B(\mathbf{p})$ 通道。

表 5 迁移矩阵 T_{iv} 中的代表性互补与替代关系 (节选)

增配域 i	验证域 v	T_{iv}	关系
stackexchange	github	-0.32	互补 (问答 → 代码)
github	stackexchange	-0.21	互补 (代码 → 问答)
pubmed_central	pubmed_abstracts	-0.16	互补 (全文 → 摘要)
stackexchange	arxiv	-0.15	互补
pile_cc	wikipedia_en	-0.11	互补 (网页 → 百科)
enron_emails	dm_mathematics	+0.50	替代 (挤占)
pile_cc	dm_mathematics	+0.26	替代 (挤占)

5.4 问题三的模型建立与求解

5.4.1 模型建立

优化问题。以问题二的广义标度律式 (5) 为目标，建立

$$\begin{aligned} \min_{N,D,Q} L(N,D,Q) \\ \text{s.t. } 6ND + D[g(Q) - g(Q_0)]_+ + \eta NDL_{\text{ctx}} \leq C, \quad Q_0 \leq Q \leq 1, \end{aligned} \quad (9)$$

其中 $\eta = 2 \times 10^{-4}$ 。三种单位 token 提质成本函数为：指数型 $g_1 = 10^7 e^{6Q}$ ，幂函数型 $g_2 = 5 \times 10^9 Q^4$ ，对数型 $g_3 = 2 \times 10^9 \ln(1 + 10Q)$ 。基线质量 Q_0 取两个口径：主口径为 $\mathbf{p}^*$ 加权质量按式 (6) 换算， $Q_0 = 0.9878$ ；副口径取网页语料 c4， $Q_0 = 0.8892$ 。

降维。三项成本都与 D 成正比，而 L 对 D 严格递减，所以最优时预算约束必取等。记 $\kappa = 6 + \eta L_{\text{ctx}}$ 、 $\Delta g(Q) = [g(Q) - g(Q_0)]_+$ ，则

$$D(N, Q) = \frac{C}{\kappa N + \Delta g(Q)}, \quad (10)$$

代回后，式 (9) 化为 $(\log N, Q)$ 上的二维无约束问题，不需要罚函数。

上下文长度的解析临界值。注意力项与训练项之比为 $\eta L_{\text{ctx}}/6$ ，二者相等时

$$L_{\text{ctx}}^{\text{crit}} = 6/\eta = 30000. \quad (11)$$

在不提质区域，把式 (8) 中的 6 换成 κ 即得闭式解 $N^* \propto (C/\kappa)^{\beta/(\alpha+\beta)}$ ，因此

$$N^*(L_{\text{ctx}}) / N^*(2048) = [(6 + 2048\eta)/\kappa]^{0.452}. \quad (12)$$

结构性转移的定义。

定义 1 (结构性转移). 记 $x^*(C) = (N^*, D^*, Q^*)$ 为预算 C 下的最优解，其 KKT 活跃约束集 $\mathcal{A}(C)$ 有三种状态： $\{Q \geq Q_0\}$ 活跃（不提质）、内点（部分提质）、 $\{Q \leq 1\}$ 活跃（提满）。若 $\mathcal{A}(C)$ 在 C_{crit} 两侧不同，则称预算在 C_{crit} 处发生**结构性转移**。

在 $Q = Q_0$ 处，“提质的边际收益”与“提质挤占数据的边际损失”之比为

$$\Phi(C) = \frac{(k_0 + k_1 N^{-\alpha})(\kappa N + \Delta g)}{\beta B D^{-\beta} g'(Q)} \Big|_{x^*(C)}. \quad (13)$$

$\Phi < 1$ 时，不提质就是 KKT 点； $\Phi(C) = 1$ 的解就是 C_{crit} ，用二分法求得（口径 A）。另设两个辅助口径：口径 B 取提质成本占比 s_Q 的峰值点；口径 C 取 D^*/N^* 的对数斜率偏离常数 $(\alpha - \beta)/(\alpha + \beta)$ 最大的点。

5.4.2 求解方法

内层对 $\log N$ 做黄金分割搜索（剖面损失关于 N 单峰），外层对 Q 做三级网格加密，最终步长小于 10^{-5} ，并对端点 Q_0 与 1 做保护。求解器全向量化（附录 A.2）。求解范围为：3 种 $g \times 7$ 档预算 (10^{19} – 10^{25}) $\times$ 5 档 L_{ctx} （取 C7 中的可行值 2k/4k/8k/32k/128k） $\times$ 2 种 Q_0 ，共 210 组。

求解器做两项互验。在 $\Delta g = 0$ 的 15 组中，数值解与闭式 N^* 的相对误差不超过 1.83×10^{-7} ；与粗网格穷举对比的 18 组中，Loss 差不超过 1.6×10^{-5} ，且区制判定一致。稳健性部分对问题二的 500 组 bootstrap 参数逐组重解 C_{crit} ，并对 η 做 $\pm 50\%$ 扰动。

5.4.3 结果与分析

关键预算下的最优配置。表 6 给出主口径、指数型、 $L_{\text{ctx}} = 2048$ 的结果。 D^*/N^* 由 31 升至 97，符合 $\alpha > \beta$ 时“数据增长快于参数”的规律。提质只占很小的成本份额 ($< 1\%$)，却带来最优解的区制变化。

表 6 关键预算下的最优配置 (主口径 $Q_0 = 0.9878$, 指数型, $L_{\text{ctx}} = 2048$)

C	N^*	D^*	Q^*	L^*	D^*/N^*	s_Q	区制
10^{19}	2.23×10^8	6.99×10^9	0.9878	3.004	31.3	0	不提质 (Q_0 角点)
10^{22}	5.06×10^9	3.06×10^{11}	1	2.144	60.4	0.87%	提满 ($Q = 1$ 角点)
10^{24}	4.01×10^{10}	3.88×10^{12}	1	1.914	96.7	0.11%	提满

幂函数型结果与表 6 几乎相同；对数型在 10^{19} 就已提满 ($L^* = 3.002$)。副口径起点质量更低，提质更划算： $C = 10^{22}$ 时，指数型与幂函数型的 s_Q 约为 5.4%，对数型为 0.65%。




图 11 最优质量 Q^* 随预算的变化 (三种成本函数, 两种 Q_0 口径)




图 12 最优解中训练、提质、注意力三项成本的占比

结构性转移。表 7 给出三种识别口径下的 $\log_{10} C_{\text{crit}}$ 。主要发现有三点。

第一，转移几乎是跳变式的“不提质 → 提满”。主口径下“离开 Q_0 ”与“到达 $Q = 1$ ”几乎重合（2048 档宽度 ≤ 0.024 dex），原因是两个质量项对 Q 都是线性的，而 $g(Q)$ 是凸的，最优解倾向落在角点。全部 210 组中有 34 组为 Q_0 角点、3 组为内点，均出现在 $C = 10^{19}$ 与 10^{20} 的指数型与幂函数型；副口径指数型存在约 0.33 dex 宽的部分提质区间。

第二，成本函数的形式决定临界点。对数型的 g' 在接近 1 时最小，因此比另两种早约两个数量级开始提质。“是否提质”取决于成本函数的形式，不能一概而论。

第三，识别结果稳健。主口径三种口径的极差不超过 0.05 dex；副口径最大为 0.385 dex（指数型、 $L_{\text{ctx}} = 131\text{k}$ ），仍低于事先设定的 0.5 dex 一致性门槛。对问题二的 500 组 bootstrap 参数，主口径指数型 C_{crit} 的中位数为 20.610，90% 区间为 [20.594, 20.628]；六种组合的区间宽度都在 ± 0.03 dex 以内， $10^{19}/10^{22}/10^{24}$ 三档的区制判定一致率为 100%。

表 7 结构性转移临界预算 $\log_{10} C_{\text{crit}}$ ($L_{\text{ctx}} = 2048$)

Q_0 口径	g	A: 离开 Q_0	A: 到达 $Q = 1$	A: $\Phi = 1$ 解析	B: s_Q 峰值	C: D/N 拐点	极差
主 0.988	指数型	20.610	20.634	20.610	20.65	20.60	0.050
	幂函数型	20.483	20.483	20.486	20.50	20.45	0.050
	对数型	18.523	18.523	18.540	18.55	18.50	0.050
副 0.889	指数型	20.100	20.430	20.100	20.45	20.15	0.350
	幂函数型	20.199	20.250	20.199	20.25	20.20	0.051
	对数型	18.449	18.449	18.592	18.45	18.40	0.050




图 13 结构性转移的三种识别口径（主口径）




图 14 Q_0 - C 相图: Q_0 越低, C_{crit} 越小, 内点区间越宽




图 15 C_{crit} 对 bootstrap 参数与 η 的敏感性

上下文长度的影响。表 8 显示，数值解与解析式 $[(6 + 2048\eta)/\kappa]^{0.452}$ 吻合（最大偏差 0.002）。32k 档刚好越过 $L_{\text{ctx}}^{\text{crit}} = 30000$ ，注意力成本开始超过一半。长上下文相当于给每个参数加价，最优策略是缩小模型、按比例保留数据。 C_{crit} 随 L_{ctx} 增大而单调减小（主口径指数型由 20.61 降至 19.99），因为每 token 的训练成本变高后，同样的提质开销占比相对变小。 η 取 $\pm 50\%$ 时，2048 档的 C_{crit} 仅移动约 ± 0.012 dex，131k 档移动约 ± 0.2 dex。

表 8 上下文长度敏感性（主口径，指数型， $C = 10^{22}$ ）

L_{ctx}	κ	N^*/N_{2048}^* 数值	N^*/N_{2048}^* 解析	L^*	注意力成本占比
2 048	6.41	1.000	1.000	2.1438	6.3%
4 096	6.82	0.972	0.972	2.1481	11.9%
8 192	7.64	0.923	0.924	2.1562	21.3%
32 768	12.55	0.736	0.738	2.1930	51.9%
131 072	32.21	0.480	0.482	2.2710	81.1%




图 16 L_{ctx} 对最优规模、 C_{crit} 与成本结构的影响

配比联立。把配比也纳入决策，联合目标为 $L_{\text{joint}} = L(N, D, Q) \cdot m(\mathbf{p})$ 。其中 $m(\mathbf{p})$ 用问题一求 $\mathbf{p}^*$ 时的同一组 13 个验证域梯度提升模型计算，并以 $\mathbf{p}^*$ 处为 1 归一化；提质起点改为 $Q_0(\mathbf{p}) = \sum_i p_i Q_{B,i}$ ；在 $\mathbf{p}^*$ 周围做 Dirichlet 采样，共 4000 个候选。结果显示，联合最优相对 $\mathbf{p}^*$ 可再降 13.69%–13.78%，其中配比效应 $1 - m$ 贡献 13.69%，规模与提质通道只贡献 0.001%–0.105%。若取最优前 100 个点的平均，与 $\mathbf{p}^*$ 的全变差距离为 0.017–0.022，收益为 1.0%–2.2%，更为稳健。在不同 (g, C) 组合下，4000 个候选的排序秩相关最小为 0.976 (图 17)。因此配比决策与规模/质量决策近似可分离，“先定配比、再定规模”的做法成立。




图 17 配比联立优化：降损来源分解与跨预算排序一致性

对《数据说明》中建议的核对。说明文档称“ $C = 10^{22}$ 时 $N^* = 1.2 \times 10^{-3}B$ 、 $D^* = 850B$ 、 $Loss = 3.41$ ”。该配置只用掉 0.06% 的预算，按本文标度律其损失为 5.361，而真实最优为 $L^* = 2.143$ 、 $N^* \approx 5 \times 10^9$ 。说明文档称“各档预算 $Q^* = 1$ ，无需比较成本函数”，与上文 34 组 Q_0 角点 + 3 组内点的结果矛盾。说明文档建议“穷举网格 + 罚系数取 1”，但由式 (10) 可解析消去约束；网格法与本文求解器的 $Loss$ 差虽不超过 1.6×10^{-5} ，却无法连续识别 C_{crit} 。

5.5 问题四的模型建立与求解

5.5.1 模型建立

四项口径。赛题要求逐条说明的四项口径见表 9。按许可证分档后，permissive 与 community 两档的 base 前沿 (Top-5 Average 均值) 几乎持平 (34.24 与 33.60)，noncommercial 档样本少、前沿偏低 (9.58)。因此“开源前沿”取全部可下载权重的模型，不再按许可证剔除。

表 9 问题四的四项口径

口径	主口径	副口径 / 说明
能力度量	C1 Average (六维等权, 已扣随机基线, 0–100)	C8 逐任务重算的去饱和综合分
开源筛选	C1/C2 均来自 HF Hub, 权重可下载; 按许可证分三档	C4 中 Model accessibility 含 Open weights (1961 个 LM 中 901 个)
模型类型	base = pretrained 275 + continuously pre-trained 58 = 333	chat = chat 718 + fine-tuned 1785 = 2503; merges / multimodal 剔除
时间轴	C2 真实发布日 (447 行有值)	C1 提交日中位滞后 103.5 天, 只用于月度窗口与回测

任务饱和与去饱和分。C8 的每个叶子任务按随机基线归一化, $\hat{s} = \max\{0, (s-c)/(1-c)\}$, 其中 c 为随机猜测得分。月度累计前沿按“终点前沿、剩余空间、关闭率、噪声门槛”四个判据, 把 39 个任务分为饱和、快速增长、常规增长、低位停滞四类。去饱和综合分剔除饱和任务, 其余任务按起点剩余空间加权、各 family 等权。

Loss-Benchmark 桥接。得分有底噪下界和上界，因此采用 S 形映射

$$S = lo + \frac{hi - lo}{1 + e^{k(L-L_0)}}, \quad (14)$$

给定 (k, L_0) 时 (lo, hi) 可线性求解。C6 按可比性分层：High 层（Pythia，同模型同验证集，7 条）权重 1；Medium 层（不同验证集，近似可比，68 条）权重 0.5。High 层的 Val_Loss 与问题二标度律 $\hat{L}$ 的差小于 10^{-4} ，证明二者处于同一尺度。

分解模型。以问题二标度律 ($Q = 1$) 计算每个模型的 $\hat{L}(N, D)$ ，作为“规模状态”。主模型 (M1b，结构·加性) 为

$$S_m = lo + amp \cdot \sigma(k(\hat{L}_m - L_0)) + \tau(t_m - 2023) + \varepsilon_m, \quad (15)$$

其中 σ 为 logistic 函数。 τ 是每年的得分技术增益，也就是“非规模技术进步”。副模型 M1c 把技术项写成等效降损， $\sigma(k(\hat{L}_m - \delta t_m - L_0))$ 。对照模型包括：M2 效率前沿（Epoch 口径，帕累托有效模型上的 $S = a + b \log_{10} C + ct$ ）、M3 分位数回归与全样本 OLS。前沿增量用 Shapley 值分解（两种顺序的平均）：“规模贡献”为只让前沿 $\hat{L}$ 按实际演进时的增量，“技术贡献”为只让 t 演进时的增量。

预测链条。预测不新增自由参数，四步依次为：算力情景 → 问题三最优配置 ($Q = 1$, $L_{ctx} = 4096$) 下的 $\Delta L^* \rightarrow$ 叠加到前沿 $\hat{L}$ 上（锚定增量：现有前沿并非算力最优，只借用 L^* 的斜率）→ 经式 (15) 与技术项得到 ΔS 。chat 前沿等于 chat 锚点加上 base 增量，再加上后训练增益增量。

5.5.2 求解方法

C8 共 1958 个 JSON，逐任务解析；重算的六个 family 分与 C1 的 Pearson 相关 ≥ 0.989 (MATH 为 0.801)，说明解析口径正确。式 (14) 采用“网格 + 两级加密 + 加权最小二乘”拟合（环境无 scipy），用留一交叉验证比较 sigmoid、线性与常数三种桥接。分解面板由 C2 与 C4 按（发布日，组织）联表得到：base 58 行，其中 23 行的 D 由 $C/(6N)$ 反解；chat 37 行，只保留同时发布了 base 的原厂组织。区间由模型簇重抽样 bootstrap (120 次) 给出。预测部分做 4000 次蒙特卡洛，不确定性来源依次为：问题二 bootstrap 参数，分解 bootstrap (M1b 与 M1c 各半)，后训练增益 bootstrap，前沿残差 (sd 2.05)。回测只用 $t < 2024.5$ 的数据重估模型，再预测 2025.25 的前沿。

5.5.3 结果与分析

任务饱和。39 个任务中 10 个饱和 (temporal_sequences 达到 1.00, 另有 IFEval、hyperbaton 等), 9 个快速增长 (web_of_lies 由 0.20 升至 0.78), 17 个常规增长, 3 个低位停滞 (gpqa_diamond 等)。表 10 显示，模型级去饱和分与 Average 的相关为 0.948，排序基本一致，但饱和任务稀释了增速：按相对增幅计，Average 低估前沿进展约 1.6 倍。

表 10 三种能力口径下的前沿变化 (C1 提交日窗口)

口径	2024-06 前沿	2025-03 前沿	相对增幅	月斜率
C1 Average	38.52	49.89	+29.5%	1.285
C8 全任务重算	37.98	49.40	+30.1%	1.326
C8 去饱和分	26.36	39.06	+48.2%	1.536




图 18 39 个叶子任务的饱和度分类




图 19 去饱和分与 Average 的前沿对比

桥接。 Loss 与 Average 负相关：全体 $r = -0.510$ ，High 层 -0.397 ，Medium 层 -0.502 。base 主桥接为 $lo = 8.63$ 、 $hi = 21.57$ 、 $k = 46.1$ 、 $L_0 = 2.07$ 。留一 RMSE 为：sigmoid 8.08、线性 8.28、常数 9.51。只用系列内变异的固定效应斜率为 $dS/dL = -23.6$ （base）与 -36.7 （chat）。Medium 层权重取 0.25/0.5/1.0 时， $S(L = 1.85)$ 分别为 21.79/21.57/21.43，结果稳定。但 High 层的 7 个点全部落在底噪区 ($L \in [2.09, 2.60]$)，只能锁定下界，S 形的上升段依赖 Medium 层，这是 C6 数据的硬限制。




图 20 C6 分层 Loss-Benchmark 桥接（base 与 chat）

贡献分解。 主模型 M1b 的估计为 $\tau = 2.45$ 分/年， $R^2 = 0.870$ ；去掉 τ 后 R^2 降为 0.832；M1c 的 $\delta = 0.035$ Loss/年。主窗口 2023.5→2025.0 内，base 前沿由 12.54 升至 37.30 ($\Delta S = 24.76$)， $\hat{L}$ 由 2.006 降至 1.869， $\log_{10} C$ 由 23.35 升至 24.64。表 11 给出各方法的分解结果。

表 11 base 前沿增长的贡献分解（2023.5→2025.0，Shapley）

类别	方法	规模贡献	技术贡献	技术占比	90% 区间
结构模型	M1b (主)	23.06	3.40	12.9%	6%–22%
	M1c	20.12	6.04	23.1%	4%–46%
线性对照	M2 效率前沿	7.36	6.19	45.7%	9%–60%
	M3 $q = 0.75$	7.40	4.45	37.5%	—
	M3 $q = 0.5$	6.24	5.88	48.5%	—
	OLS	7.72	3.24	29.5%	—
反例	M1a 桥接直接套用	0.63	4.84	88%	不可迁移

核心三法（M1b、M2、M3 $q = 0.75$ ）的极差为 32.8 个百分点，超过事先设定的 $\pm 15pp$ 一致性门槛，因此不强行给出单一数字。差异是结构性的：M2 与 M3 假设得分对 $\log C$ 线

性，无法表达桥接的 S 形加速段，把“Loss 刚进入陡峭区带来的规模红利”部分记到了时间项上；M1b 与 M1c 用“标度律 + S 形桥接”吸收了这部分，拟合优度也明显更高 (R^2 0.87 对 0.66)。故主结论采用结构口径：**规模扩张贡献约 77%–87%，非规模技术进步约 13%–23%**；线性口径的 30%–46% 作为上界参考。所有方法在“规模为主”这一定性结论上一致。M1a 直接套用 C6 桥接 ($h_i = 21.6$, 低于面板前沿)，把桥接的非线性全部记为“技术”，得到 88%，与索洛余值法的偏差同源，只作为反例列出。

换算为算力等效，各方法的技术进步为：M1b 0.29、M1c 0.56、M2 0.78、OLS 0.39 dex/yr。这与 C1 窗口内回归的 0.44–0.77 dex/yr 同量级，两者相互印证。加入 C3 历史点做敏感性：权重 0.2 时为 0.50 dex/yr。C3 的 Average 与其六维均值的相关仅为 0.634，口径混杂，因此不进入主结果。

chat 与后训练。在 89 对同组织的 (base, chat) 配对中，后训练平均增益为 4.30 分；对有发布日的 31 对做回归，得 $G(t) = -0.40 + 3.35(t - 2023)$ ，说明后训练本身是一类逐年增强的非规模技术。chat 前沿在 2023.5→2025.0 由 8.76 升至 46.06：规模贡献 23.77，预训练技术 3.56，后训练技术 4.86，技术占比 26%。




图 21 分解面板：规模状态 $\hat{L}$ 、得分与时间




图 22 各方法、各窗口的规模/技术贡献

算力放缓情景与前沿预测。C4 中开源权重模型的年度最大训练算力，2019 年为 $10^{22.52}$ ，2025 年为 $10^{25.59}$ 。按最大值、Top-5、2022–25 与全部 LM 四种统计，斜率分别为 0.58/0.60/0.69/0.65 dex/yr。据此设三种情景：基线 0.60、减半 0.30、1/4 0.15 dex/yr。起点 $T_0 = 2025.25$ ，锚点 base $S = 37.30$ ($\hat{L} = 1.869$)，chat $S = 46.06$ 。预测结果见表 12。

表 12 开源前沿 (Average) 预测：中位数 [90% 区间]

情景	base			chat (24 个月)	
	12 个月	24 个月	技术占比	后训练增益延续	后训练增益停滞
基线 0.60	43.1 [37.4, 52.8]	46.2 [37.5, 68.5]	55%	61.6 [51.8, 79.6]	54.8 [46.4, 70.1]
减半 0.30	41.7 [37.0, 49.7]	45.2 [37.7, 58.3]	65%	60.7 [51.5, 75.3]	54.0 [46.2, 67.6]
1/4 0.15	41.1 [36.6, 47.6]	44.1 [37.5, 54.9]	77%	59.8 [50.9, 71.6]	52.7 [46.1, 63.3]

算力增速从 0.60 降到 0.15 dex/yr, 24 个月的 base 中位数只减少约 2 分 (46.2 → 44.1)。原因是规模增量本身被 S 形桥接的饱和和段压缩 (规模部分由 3.9 分降为 1.5 分)，而技术项 (约 5 分) 基本不受影响。所以**算力放缓时，技术进步成为增量主体** (占比由 55% 升至 77%)。模型不确定性主要来自技术项的形式：基线情景下 M1b 的中位数为 46.6，M1c 为 44.7，后者上尾更宽。chat 前沿对“后训练增益是否延续”最敏感 (相差约 7 分)，这一差别大于算力情景之间的差别 (约 2 分)。作为上界参考，M1b 的纯规模天花板为 44.2，“算力无限”时 24 个月为 49.2。




图 23 三种算力情景下 base/chat 开源前沿的 12/24 个月预测 (阴影为 90% 区间)

回测。只用 $t < 2024.5$ 的 42 个 base 模型重估模型 ($\tau = 2.74$)，以 2024.5 的前沿 29.28 为锚点，预测 2025.25 的前沿 (实际为 37.30)。M1b 在基线情景下的误差为 -0.78 ，用实际算力增速 (0.76 dex/yr) 时误差为 $+0.21$ ，朴素线性外推的误差为 $+2.65$ 。在提交日轴上，C1 月度前沿做纯时间序列外推，3 个月误差达到 $+7.91$ ，因为前沿在 49.89 附近进入平台。这是不直接用 ARIMA 外推的实证理由。

对《数据说明》中建议的核对。(i) 说明文档称“Loss-Benchmark 正相关 $r = +0.68$ ”，实测为 $r = -0.51$ 。(ii) 说明文档称“ $b_N = -6.2$ ，规模越大得分越低”，实测规模系数全部为正 (C1 窗口 7.41，面板 6.85，效率前沿 5.71)。(iii) 说明文档建议“年份独热编码”，但独热编码无法外推到未见年份，本文改用连续时间项，并以算力等效率互证。(iv) 索洛余值法把桥接的非线性全部记入技术项 (即 M1a 的 88%)，本文把它列为反例，并用结构模型修正。

6 模型的检验与灵敏度分析

6.1 模型检验

表 13 汇总了全文的检验。“互相验证”只用于同一问题、不同假设的方法对，判据取排序或数值的一致性；上下游分工衔接的方法之间不存在验证关系，本文也不作此类声称。

表 13 全文检验清单

问题	检验对	类型	判据	结果
一	CRITIC vs 等	互相验证	样本级 Spearman	0.991/0.946/0.871
	权/TOPSIS/PCA			
	A1 vs A2/A3 全量	代表性	KS、Cohen's d	$p = 0.60/0.12$, $d \approx 0.005$
	冲突结论跨集复现	稳健性	冲突率、主类型	21.5%/21.1%/22.9%, 类型一致
	clr vs 裸 OLS	改进证据	检验集 R^2	0.772 vs 0.654
	clr 线性 vs 梯度提升	互相验证	候选秩相关	0.77
	1M $\rightarrow$ 60M $\rightarrow$ 1B	假设 2 检验	排名 Spearman	0.52/0.47/0.68, 截距漂、斜率稳
二	加性 vs 乘子族	形式选择	五折 cv-RMSE	0.051 vs 0.099–0.105
	解析解 vs 数值优化	互相验证	相对误差	$< 10^{-5}$
	标度律 vs 真实文献点	外部合理性	趋势 Spearman	0.959–0.983
三	数值解 vs 闭式 N^*	互相验证	相对误差	$\leq 1.83 \times 10^{-7}$ (15 组)
	求解器 vs 网格穷举	互相验证	Loss 差、区制	$\leq 1.6 \times 10^{-5}$, 区制一致
	C_{crit} 三口径	互相验证	极差	主口径 ≤ 0.05 dex
四	C8 重算 vs C1	口径核验	Pearson	≥ 0.989 (MATH 0.801)
	sigmoid vs 线性桥接	形式选择	留一 RMSE	8.08 vs 8.28
	分解 dex/yr vs 窗口回归	互相验证	同量级	0.29–0.78 vs 0.44–0.77
	预测回测	外部检验	2025.25 误差	M1b -0.78 , 线性外推 $+2.65$

不一致的地方同样是结论。 $\rho_{Q_v} = -0.06$ 是“内在质量不等于训练价值”的定量证据，而不是检验失败；60M/1B 的绝对预测失效源于截距漂移，这正说明跨尺度外推必须做尺度修正；问题四中结构模型与线性模型相差 32.8pp，本文如实并列，并解释其来源。A12–A15、B6–B8 与 B10 的证据等级（半合成、外推生成）在全文中始终保留标注，没有升格为实证。

6.2 灵敏度与稳健性分析

问题一。冲突阈值 τ 在 $[0.6, 0.85]$ 内变化时，冲突率在 12%–35% 之间连续变化，域排序与主冲突类型不变。Huber 降权与调和平均两种消解规则下，域级质量排序的 Spearman 相关 > 0.95 。评价权重取等权与 pile_cc 单域两个口径时， $\mathbf{p}^*$ 的头部域一致，只是集中度不同。

问题二。 Q_{ref} 取 Pile 配比加权 (0.5608) 与 token 加权两个口径时, $\hat{Q}_B$ 相差不到 0.02, 命题 1–4 的定性结论不变。 k_0, k_1 的 95% CI 宽度约为 $\pm 10\%$, 代入命题 2 后, 等效倍数的区间为 [1.52, 1.77]。

问题三。 对问题二的 500 组 bootstrap 参数, C_{crit} 的区间宽度在 $\pm 0.03 \text{ dex}$ 以内。 η 取 $\pm 50\%$ 时, 2048 档的 C_{crit} 移动约 $\pm 0.012 \text{ dex}$, 131k 档移动约 $\pm 0.2 \text{ dex}$, 此时 $L_{\text{ctx}}^{\text{crit}}$ 相应变为 60000/20000。 Q_0 相图 (图 14) 表明: Q_0 越低, C_{crit} 越小, 内点区间越宽。

问题四。 C6 中 Medium 层的权重取 0.25–1.0 时, $S(1.85)$ 的变化不到 0.4 分。C3 历史点的权重取 0.2 与 1.0 时, 技术进步率分别为 0.50 与 0.21 dex/yr, 因此只作敏感性分析。分解换用 2024→2025 与 2024.5→2025.25 两个窗口, M1b 的技术占比为 7.1% 与 8.2%, M2 为 30.6% 与 24.3%, “规模为主”的定性结论不变。

7 模型的评价与推广

7.1 模型的优点

(1) **证据分层, 接口贯通。** 半合成与外推数据只用于形式选择和稳健性讨论, 没有混入主结论。四问之间通过接口文件衔接, 广义标度律全文只估计一次, 下游各问直接消费, 口径前后一致。

(2) **形式由数据裁决。** 冲突阈值取最大曲率点, 质量项形式由五折交叉验证决定, 桥接形式由留一交叉验证决定, 结构性转移由 KKT 活跃集定义, 每一步都有可检验的判据。

(3) **解析与数值互验。** 四条命题、 $L_{\text{ctx}}^{\text{crit}}$ 与 $\Phi(C) = 1$ 判据都有闭式表达, 并与数值解逐项对照, 结论可解释。

(4) **直面误导信息。** 冲突率、Loss–Benchmark 相关的符号、最优配置、是否提质等问题上, 本文都用量化证据修正了《数据说明》中的误导性说法。

7.2 模型的局限与改进方向

(1) 11 个 inferred 域的质量分依赖校准函数 ($R_{\text{cv}}^2 = 0.31$), 信息量有限; 若能增补这些域的模型评分器信号, 可显著收紧区间。

(2) 附件 B 的 B6–B8 为半合成数据, k_0, k_1 的绝对数值不宜直接外推到真实训练体系, 应用时以趋势与结构结论为主。

(3) 问题三中 $g(Q)$ 的形式与参数取自赛题附录 B, “角点解”与“对数型早两个数量级提质”对成本函数的形式敏感, 本文已把三种形式并列给出。

(4) C6 的 High 层只有 7 点且全部位于底噪区, 桥接的上升段依赖 Medium 层; 问题四的结构口径与线性口径相差 32.8pp, 是全文最大的不确定性来源。若能获得更多同验证集的 Loss–Benchmark 对, 可以缩小这一分歧。

(5) 预测为情景条件预测, 不包含新架构等离散突破。

7.3 模型的推广

“基线 + 质量修正”的标度律结构, 以及“约束取等后解析消元”的降维方法, 可推广到含多种数据处理成本 (去重、合成数据、多模态对齐) 的资源配置问题。“S 形桥接 + 连续时间项 + Shapley 分解”的框架也适用于其他存在能力饱和的技术演进分析。

8 结论

本文围绕“算力约束下如何配置资源以提升大模型能力”，建立了四个递进衔接的模型。

问题一建立了从 22 个异质信号到连续质量分的可复现管线，测得并消解了 21.5% 的指标冲突，用 clr 回归给出 17 域配比的迁移矩阵与最优配比（预测降损 9.9%），并发现域级质量与训练边际价值近乎无关（ $\rho = -0.06$ ）。

问题二以交叉验证选出的加性形式建立了广义标度律 $L = E + [A + k_1(1 - Q)]N^{-\alpha} + BD^{-\beta} + (1 - Q)k_0$ ，并推出四条解析结论：质量弹性约为规模弹性的 4 倍；质量与规模的等效替代随规模放大；存在规模无法弥补的质量地板；质量越高，最优配置越偏向小模型、多数据。

问题三把约束优化解析降维为二维无约束问题，以 KKT 活跃集的改变定义结构性转移，并用 $\Phi(C) = 1$ 识别临界预算。主口径下，指数型、幂函数型、对数型的 $\log_{10} C_{\text{crit}}$ 为 20.61/20.48/18.52，转移为“不提质 → 提满”的跳变。上下文长度越过 $6/\eta = 30000$ 后，注意力成本占主导，最优模型随之缩小。配比与规模决策近似可分离。

问题四用“标度律 + S 形桥接 + 时间技术项”的结构模型分解前沿增长：规模扩张是主导，非规模技术进步占 13%–23%（结构口径；线性口径的 30%–46% 为上界参考）。在算力增速放缓至 0.15 dex/yr 的情景下，24 个月的 base 开源前沿中位数为 44.1，技术进步在增量中的占比升至 77%。

四问共同说明，**数据质量与配比是与算力并列的一等资源**：小预算时应把算力用在规模上，跨过临界预算后应把质量提满；算力增长放缓时，能力增长将越来越依赖非规模技术进步。

参考文献

- [1] Hoffmann J, Borgeaud S, Mensch A, et al. Training compute-optimal large language models[C]//Advances in Neural Information Processing Systems 35 (NeurIPS). 2022.
- [2] Bahri Y, Dyer E, Kaplan J, et al. Explaining neural scaling laws[J]. Proceedings of the National Academy of Sciences, 2024, 121(27): e2311878121.
- [3] Asai A, et al. Synthesizing scientific literature with retrieval-augmented language models[J]. Nature, 2026, 650: 857–863.
- [4] Xia M, et al. RegMix: Data mixture as regression for language model pre-training[C]//International Conference on Machine Learning (ICML). 2024.
- [5] Biderman S, et al. Pythia: A suite for analyzing large language models across training and scaling[C]//International Conference on Machine Learning (ICML). 2023.
- [6] Schaeffer R, Miranda B, Koyejo S. Are emergent abilities of large language models a mirage?[C]//Advances in Neural Information Processing Systems 36 (NeurIPS). 2023.
- [7] Muennighoff N, et al. Scaling data-constrained language models[C]//Advances in Neural Information Processing Systems 36 (NeurIPS). 2023.

- [8] Penedo G, et al. The FineWeb datasets: Decanting the web for the finest text data at scale[C]//NeurIPS Datasets and Benchmarks Track. 2024.
- [9] Aitchison J. The Statistical Analysis of Compositional Data[M]. London: Chapman & Hall, 1986.
- [10] Diakoulaki D, Mavrotas G, Papayannakis L. Determining objective weights in multiple criteria problems: The CRITIC method[J]. Computers & Operations Research, 1995, 22(7): 763–770.
- [11] Huber P J. Robust estimation of a location parameter[J]. The Annals of Mathematical Statistics, 1964, 35(1): 73–101.
- [12] Shapley L S. A value for n -person games[M]//Contributions to the Theory of Games II. Princeton: Princeton University Press, 1953: 307–317.

附录 A 补充材料与程序

A.1 支撑材料清单与运行说明

全部代码为 Python 3，只依赖 numpy、pandas、matplotlib，不依赖 scipy。各脚本在所在目录内运行，产出落盘到对应的 outputs_q* 目录，下游各问只读取上游的接口文件 (interface/)。

表 14 程序清单

目录	脚本	功能
code_q1/	q1_01-q1_07	指标展开、CRITIC 评分、冲突、桥接、clr 回归、跨尺度、 $\mathbf{p}^*$
code_q2/	q2_00_reverse_engineering q2_01_fit, q2_02_theory	附件 B 生成公式逆向 两步拟合与五形式交叉验证；四条命题的数值互验
code_q3/	q3_00_model q3_01-q3_03	广义律、三项成本、向量化求解器、 Φ 判据 210 组最优解、结构性转移与敏感性、配比联立
code_q4/	q4_01-q4_05 q4_99_check_report	C8 解析、饱和度、桥接、分解、预测与回测 问题三、四的 76 项关键数字与输出文件自动核对

运行顺序为: code_q1(q1_01→q1_07)→code_q2→code_q3(q3_01→q3_03)→code_q4(q4_01→q4_05, 最后运行 q4_99)。

A.2 核心程序

(1) CRITIC 权重与加权几何平均 (code_q1/q1_02_quality.py 节选)

```
def fit_critic(self, Z):
    sd = Z.std(axis=0, ddof=1)                    # contrast intensity
    R = np.corrcoef(Z.T)                          # indicator correlation
    C = sd * (1 - R).sum(axis=1)                  # information content C_j
    self.critic_w = C / C.sum()
    return self.critic_w

def score(self, Z, w=None):                        # weighted geometric mean
    w = self.critic_w if w is None else w
    return np.exp((w[None, :] * np.log(np.clip(Z, EPS, 1))).sum(axis=1))
```

(2) 问题三向量化求解器 (code_q3/q3_00_model.py 节选)

```
def _profile(C, Q, dg, kappa, p, lo=1.0, hi=17.0, it=70):
    """golden-section search on log10 N for fixed Q; D solved from budget"""
    def f(x):
```

```

        N = 10.0 ** x
        D = C / (kappa * N + dg)                # budget binds: D eliminated
        return loss(N, D, Q, p)
a = np.full(C.shape, lo); b = np.full(C.shape, hi)
for _ in range(it):
    c = b - _GR * (b - a); d = a + _GR * (b - a)
    m = f(c) < f(d)
    b = np.where(m, d, b); a = np.where(m, a, c)
x = (a + b) / 2
return f(x), x

def solve(C, g, Lctx=2048, Q0=Q0_MAIN, p=PAR, eta=ETA, nQ=41, levels=3):
    kappa = 6 + eta * Lctx
    lo, hi = Q0, 1.0
    for _ in range(levels):                    # 3-level grid refinement on Q
        Qg = lo + (hi - lo) * np.linspace(0, 1, nQ)
        dg = np.maximum(g(Qg) - g(Q0), 0.0)
        Lm, _ = _profile(C, Qg, dg, kappa, p)
        Qb = Qg[np.argmin(Lm)]; step = (hi - lo) / (nQ - 1)
        lo, hi = max(Qb - step, Q0), min(Qb + step, 1.0)
    # endpoint protection at Q0 and 1, then classify KKT active set
    ...

def phi_ratio(C, g, Lctx, Qeval, Q0, p=PAR, eta=ETA):
    """Phi = marginal gain of quality / marginal loss from crowding out D"""
    kappa = 6 + eta * Lctx
    dg = max(g(Qeval) - g(Q0), 0.0)
    _, x = _profile(C, Qeval, dg, kappa, p)
    N = 10.0 ** x; D = C / (kappa * N + dg)
    num = (p["k0"] + p["k1"] * N ** -p["al"]) * (kappa * N + dg)
    den = p["be"] * p["B"] * D ** -p["be"] * g_prime(Qeval)
    return num / den                        # C_crit solves Phi(C) = 1

```

(3) 结构分解模型与 Shapley 分解 (code_q4/q4_04_decomp.py 节选)

```

def f_add(p, L, t):                          # M1b: S-bridge + linear tech
    term
    return p["lo"] + p["amp"] * sig(L, p["k"], p["L0"]) + p["tau"] * t

def shapley(fun, L0, t0, L1, t1):
    """two-factor Shapley: scale (L_hat) vs technology (t)"""
    sc = 0.5 * ((fun(L1, t0) - fun(L0, t0)) + (fun(L1, t1) - fun(L0, t1)))
    te = 0.5 * ((fun(L0, t1) - fun(L0, t0)) + (fun(L1, t1) - fun(L1, t0)))
    return sc, te

```

A.3 AI 使用披露

依据赛题“AI 使用规范”，现披露如下。

所用工具：Claude (Anthropic)。

使用环节与贡献范围：(1) 资料整理与概念理解：梳理赛题附件的字段结构与《数据说明》中的条目；(2) 代码编写与调试：数据读取、向量化求解器、绘图脚本的编写与报错排查；(3) 结果核对：编写自动核对脚本，把报告中的数字与程序输出逐项比对；(4) 排版与文字：LaTeX 排版、图表整理与语句润色。

参赛队的工作与责任：模型路线的选择（证据分层、质量项形式由交叉验证裁决、结构性转移按 KKT 活跃集定义、分解方法并列报告等）、公式推导与结论判断由参赛队确定，并对 AI 输出的全部代码与数值逐项运行、核验。文中理论与公式均引用正式文献或由附件数据验证，未以 AI 输出作为学术依据。全部数值结果可由随文代码在附件数据上复现。