

rmfamilyssfamilyttfamilynormalfont



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校 国防科技大学

参赛队号 26910020233

	1. 李重行
队员姓名	2. 李星谊
	3. 刘浩然

中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生 数学建模竞赛

题 目： 算力约束下提升大语言模型能力的资源配置建模

摘 要：

经典标度律用模型参数量 N 与训练数据量 D 解释损失随规模的变化；面对异质语料和有限算力，还需研究如何将数据质量 Q 与领域配比 p 纳入广义标度律。本题依次涉及数据质量建模、广义标度律建模、算力约束下的模型训练优化和能力演进预测。四问环环相扣：先回答“数据如何衡量”，再回答“资源如何发挥作用、如何分配”，最后考察模型能力如何演进，逐步接近真实训练与评测场景。

针对问题一，我们将来源不同、方向与量纲各异的质量信号转为可比指标，用稳健聚合获得文档和领域质量分；把来源间的显著分歧作为人工复核线索，不将其直接判为真实质量冲突。对于领域配比，先处理份额之和固定带来的约束，再建立配比与验证损失的关系。由此得到可供后续问题使用的质量和配比接口；代理模型预测，所选配比较均匀配比的损失约低 9.9%，这一数字不是大模型训练的实测收益。

针对问题二，我们以经典标度律为基线，比较质量进入损失的不同方式，并区分可由扩大规模部分补偿的质量影响与难以补偿的损失下界。在半合成数据的证据范围内，模型提示提质与扩规模可以部分替代；领域配比的作用暂作为探索性关系保留。

针对问题三，我们把训练、提质和长上下文开销放入同一预算，利用成本结构缩减求解维度，并以最优质量所处的边界状态识别资源策略的转变。现有模型显示，预算和提质成本共同改变资源的最优去向；上下文变长也会挤占可用于模型规模和数据量的算力。

针对问题四，我们区分模型类型与时间口径，先识别基准任务的饱和现象，再把损失变化映射为能力得分，分解历史前沿中的规模扩张与非规模变化，并考察算力增速放缓的情景。既有历史结果提示规模扩张是主要解释项；前沿走势保留为受预测起点与数据范围约束的条件性情景。

上述结论依赖附件覆盖的模型规模、数据来源和评测口径；尚未完成独立留出检验与当前时点重估的环节，不给出确定的收益倍数或未来分数。

关键词：数据质量；领域配比；广义标度律；算力约束优化；能力演进预测

1 问题重述

1.1 问题背景

大语言模型通过预训练从大量文本中学习通用能力。经典标度律以模型参数量 N 和训练 token 数 D 为自变量，用幂律形式刻画验证集交叉熵损失 $L_0(N, D) = E + AN^{-\alpha} + BD^{-\beta}$ 的下降 [1, 2]。扩大 N 或 D 都需要算力；按本题采用的近似，基础训练开销 $C \approx 6ND$ ，因而有限预算下必须权衡模型规模与数据量。

仅比较 N, D, C 仍不足以描述真实训练：不同语料的质量和领域组成会改变同等投入的效果。因而需要先建立数据质量 Q 的可比口径与领域配比 $\mathbf{p}$ 的损失关系，再研究如何把二者接入经典标度律，形成广义标度律 $L(N, D, Q, \mathbf{p})$ 。这一递进把数据选择、训练成本以及最终能力评测纳入同一资源配置问题。赛题的附件 A 提供质量信号与配比实验，附件 B 提供标度律相关数据，附件 C 提供模型、算力与能力评测信息。

1.2 问题描述

本题依次要求完成四项数学任务：评价训练语料的质量并刻画领域配比的损失效应；在经典标度律中引入质量与配比，建立可检验的广义标度律；在非线算力成本约束下优化训练配置；把规模和非规模因素映射到能力前沿，作有条件的演进预测。前一问的输出是后一问的输入，数据口径和检验边界也随之累积。

问题一：数据质量与领域配比。建模对象是文档、领域和混合语料的质量，以及 17 个训练领域的配比对 13 个验证域损失的影响；约束是质量信号方向和量纲不一、部分领域缺少直接质量映射，且配比份额非负、总和为 1。用 A1 拟合文档质量评分与预处理规则，冻结后在扩展集 A2/A3 上检查分数与冲突诊断的稳定性；用 A16 的领域映射和 A18 的文本特征把质量扩展到 17 域。A4/A5 按索引连接后拟合配比—损失关系；A6/A7 作同尺度留出检验，A8–A11 作跨尺度直接检验；A12–A15 仅用于估算或外推情景讨论，不当作真实训练验证。

问题二：广义标度律。建模对象是损失对 $N, D, Q, \mathbf{p}$ 的依赖；约束是理想质量与基准配比下应回到经典基线，A、B 两组损失的评测管线和质量尺度不能直接等同，且配比始终满足份额约束。以 B1 拟合经典基线，以 B6 拟合质量进入损失的候选形式，并仅用 B7 相对 B6 新增的配置作独立留出检验；B2/B3 作半合成或插值参照，B4/B5 作不同来源的趋势对照，B8 作方向冲突压力检查；B9/B10 按模型名及 N, D 对齐，B10 仅作估算对照，B11/B12 拟用于来源审计。问题一的领域质量和配比关系经固定接口引入；其中配比通道在满足训练与留出条件前只作为探索性扩展。

问题三：算力约束下的训练优化。建模对象是在给定预算 C 下的参数量 N 、数据量 D 与质量 Q 的最优配置；约束包括训练、提质和长上下文三项成本，质量下界由问题一的推荐配比确定，主方案固定该配比。读取问题一的质量与配比接口，并在问题二完成留出验收后使用其冻结的标度律参数，不在本问重新拟合；三类提质成本函数来自赛题，C7 提供可行的上下文长度用于敏感性分析。比较质量下界、内点和上界解，判断预算变化时是否存在以及何处出现结构性转移。

问题四：能力演进与预测。建模对象是开源模型能力前沿及其规模与非规模变化；约束是能力、时间、模型类型和开放权重口径必须一致，且损失与 Benchmark 分数不在同一

尺度。C1 提供榜单能力，C2 在同批记录上补充发布日期；C4 补充规模和算力并与 C2 匹配；C8 用于逐任务聚合和饱和度检查；C6 分层拟合损失到得分的桥接，C3 只作历史混合口径的敏感性对照。结合前问的标度律与预算情景建立可解释的演进模型，对历史前沿作分解与回测，再讨论算力增速放缓时 12/24 个月的条件预测及其不确定性。

2 问题分析

2.1 总体思路

四问按“测量数据—描述损失—优化训练—解释能力”递进（图 1）。问题一从文档质量 $Q(x)$ 聚合到领域质量 Q_d ，再按配比得到语料质量 $Q(\mathbf{p})$ ；问题二在经典的 $L_0(N, D)$ 上引入 Q ，并探索配比作用。经典律只是广义律在理想质量、基准配比下的一个切片。问题三以标度律为目标，新增预算 C 、提质成本与上下文长度约束，求得最优配置；问题四再引入时间 t 和 Benchmark 度量，把损失变化转为能力前沿的解释与预测。各问的冻结结果通过 P1-P4 接口传递，未通过留出检验的配比通道不进入下游主优化。

数据使用保持证据分层：A1-A11 是质量与配比实验数据，B4/B5 提供不同评测口径下的趋势对照，C1/C2/C4/C7/C8 提供榜单、模型与任务信息；B1 是近乎公式生成的经典锚点，B2、B6-B8 含半合成成分，B3 为插值，A12-A15 与 B10 为估算或外推，C3 为混合历史口径。拟合与检验分开：A1、A4/A5 和 B6 用于相应模型训练，A2/A3、A6-A11 与 B7 新增配置承担各自明确的检验角色；不能把异源 Loss 的绝对值视为同一交叉熵，也不能把合成数据上的拟合称为真实大模型验证。

阶段	建模对象与条件约束	新增量及向下游传递的结果
问题一	文档质量、领域映射与 17 域配比；指标异质、部分域缺映射、配比份额和为 1	$Q(x) \rightarrow Q_d \rightarrow Q(\mathbf{p})$ ；推荐配比 $\mathbf{p}^*$ 与配比损失关系 (P1)
↓ 数据质量和配比进入规模模型		
问题二	从 $L_0(N, D)$ 扩展质量项；A/B 评测尺度不同，B6 拟合、B7 新增配置留出	固定 $\mathbf{p}^*$ 的 $L_{\text{core}}(N, D, Q)$ ；配比通道暂为探索性 (P2)
↓ 标度律成为预算优化的目标		
问题三	在预算 C 、三项成本、质量边界和外生 L_{ctx} 下配置 N, D, Q	N^*, D^*, Q^*, L^* 与结构性转移状态 (P3)
↓ 最优损失与算力情景进入能力分析		
问题四	在开放权重、模型类型、时间和评测口径约束下解释前沿	能力得分、规模与非规模模型贡献、条件预测 (P4)

图 1 四问的递进关系：参数、约束与输出接口逐层进入下一问

2.2 各问题的关键难点

问题一：从异质指标得到唯一语料质量。目标是由 A1-A3 的文档信号建立 $Q(x)$ ，借 A16/A18 得到 17 域质量，再用 A4-A11 识别对比对 13 域损失的作用。难点在于 logits、规

则量与DSIR的方向和尺度不一，长度与领域基线会干扰质量；17域又有11域缺少直接评分。为避免冗余信号和极端指标支配结果，采用域内冻结预处理、CRITIC权重与Huber中心；冲突只在评分后按来源诊断。领域质量以映射和文本桥接补齐，配比因份额闭合而采用中心对数比建模，并以A6–A11检查跨尺度边界。

问题二：跨附件质量口径与可推广的函数形式。目标是用B1的经典基线和B6的质量网格建立 $L(N, D, Q, \mathbf{p})$ ，并以B7新增配置、B4/B5趋势及问题一接口检验。A、B两组Loss的分词器与验证集可能不同，绝对值不能直接对齐； Q 与 $\mathbf{p}$ 的作用也易重复计算。因而先规定语料质量到B组的锚定口径，再在固定基线上比较质量项候选形式，选择须经过留出检验的形式；配比效应保持独立，未满足跨尺度留出条件前仅作探索。B6/B7的半合成性质限制了真实训练泛化结论。

问题三：非线性约束与边界转移。目标是把前两问冻结的 Q_0 、 $\mathbf{p}^*$ 和标度律参数作为输入，在给定 C 与上下文长度下求 N, D, Q 。训练、提质和注意力开销共同形成非线性约束，变量跨数量级，三种提质成本形状也不同。故先利用预算取等缩减维度，再分质量下界、内点和上界比较可行解，并以活跃约束变化判断结构性转移；不能仅凭单次局部优化或预设所有成本函数均凸。

问题四：能力演进的解释边界。目标是结合前问的规模状态与C1/C2/C4/C6/C8的能力、日期、算力和任务数据，解释前沿并作条件预测。难点是Loss与Benchmark得分尺度不同、任务会饱和，且规模与时间共变，C3还有混合口径。故采用可检验的损失—得分桥接和连续时间项，在一致的开放权重与模型类型口径下分解增长，并作回测及窗口敏感性分析。时间项只表示控制规模后的剩余关联，不直接解释为已识别的因果技术进步。

3 模型假设

1. 质量信号可作相对测量。A组指标经方向与域内尺度校正后，可比较同域文档的相对质量；不假定它们有人工标注的绝对真值。服务问题一的 $Q(x)$ ；用A2/A3冻结评分与删去极端指标的扰动检查适用性。
2. 领域质量可按份额聚合。给定A16的映射与A18的桥接模型，混合语料质量取17域质量的份额加权值；配比对验证损失的额外影响单独建模。服务问题一至三；以六个可映射域的桥接误差、A6/A7留出和A8–A11跨尺度直接检验检查边界。
3. 评价目标预先固定。13个验证域等权定义主目标，pile_cc单域仅作敏感性口径，评价权重不随候选配比改变。服务问题一的配比搜索与问题三的目标选择；用两口径的候选差异检查敏感性。
4. 质量刻度需要锚定。主口径以理想质量对应经典式，取 $Q_B = Q(\mathbf{p})$ ，推荐配比的起点 $Q_0 = Q(\mathbf{p}^*)$ ；另一锚定方式仅作敏感性分析。服务问题二、三；锚点不能由B1的公式生成数据直接识别。
5. 成本按同一训练量计。训练、提质和注意力开销均使用同一 D ，成本函数参数依赛题给定。服务问题三；在三种函数和预算边界下分别检查最优解，不预设统一凸性。
6. 非规模变化在窗口内平滑。问题四用连续时间项描述控制规模后的剩余得分变化，并以不同窗口与模型回测；遇到离散架构突破时，该条件预测不适用。

4 符号说明

表 1 主要符号及含义

符号	含义	单位	角色
N, D	模型参数量、训练 token 数	个, token	Q1/Q2 输入; Q3 决策变量
C	总训练算力预算	FLOPs	给定参数 (Q3)
$Q(x), Q_i$	文档 x 的主质量分、训练域 i 的质量分	$[0, 1]$	估计量 (Q1)
$Q(\mathbf{p}), Q_B$	混合语料质量、B 组质量刻度; 主口径二者相同	无量纲	Q1 输出; Q2 输入
Q_0	推荐配比下的提质起点 $Q(\mathbf{p}^*)$	无量纲	接口参数 (Q3)
$\mathbf{p} = (p_i)_{i=1}^{17}$	17 域训练份额, 非负且总和为 1	无量纲	决策变量 (Q1)
$z_j(x), w_j$	文档第 j 项标准化指标及冻结的 CRITIC 权重	$[0, 1]$, 无量纲	数据变换、估计参数
$B(x), \tau_d$	六来源分歧度、A1 域 d 的 P95 筛查阈值	$[0, 1]$	诊断量、固定阈值
L_v, L	验证域 v 的损失、等权综合损失	nats	观测量或预测目标
T_{iv}	均匀配比附近, 域 i 份额对域 v 的对数损失局部效应	无量纲	估计参数 (Q1)
E, A, B, α, β	经典标度律的地板、幅度与指数	依公式确定	估计参数 (Q2)
k_0, κ_N, κ_D	质量地板及两项质量耦合强度	nats, 无量纲	估计参数 (Q2)
$g(Q), L_{\text{ctx}}$	单位 token 提质成本、上下文长度	FLOPs/token	给定函数与情景参数
C_{crit}	质量约束状态改变的临界预算	FLOPs	求解结果 (Q3)
S, t	Benchmark 综合得分、模型发布日期	分, 年	响应量、时间变量 (Q4)

表中只列全文反复使用的重要符号, 局部符号在首次出现处说明。

5 模型的建立与求解

5.1 数据来源与接口约定

附件 A、B、C 分别承担质量与配比、标度律、能力演进的输入角色; 同一附件内仍须区分拟合集、独立检验集和估算表。跨问只传递已定义的质量分、配比候选及模型参数, 不以不同评测管线的 Loss 绝对值直接拼接。各项清洗、连接键、训练与留出划分在相应问题中说明; 问题一的 A1–A3 指标处理见表 2。

5.2 问题一的模型建立与求解

问题一分为三个相接的任务：先把异质质量信号变成文档、领域与语料的统一质量分，再诊断评分指标之间的分歧，最后建立领域配比、语料质量与验证损失的定量关系。建模对象分别是文档 x 、17 个训练域及配比 $\mathbf{p}$ ；待估量为权重 w_j 、质量 $Q(x)$, Q_i 和配比—损失参数，待选择量为满足 $p_i \geq 0, \sum_i p_i = 1$ 的候选配比。配比搜索以 13 域等权预测损失最小为目标，质量分本身是测量结果而非需要最大化的目标。质量评分先于冲突诊断；冲突候选不反向修改主评分。所有下游质量接口均使用同一 CRITIC 加权 Huber 主分（假设 1.–3.）。

5.2.1 任务一：数据质量评估

数据预处理。 目标是把每项质量信号变为 $z_j(x) \in [0, 1]$ ，并使数值越大表示该项指标下的质量越高。附件 A1 的 22 个原始字段按输出形态展开为 25 项；不同领域分别建立尺度，避免领域本身的取值差异被误判为文档质量。表 2 给出 A1–A3 的角色与处理顺序。

表 2 质量数据的处理与检验分工

数据	规模与角色	处理方法
A1	51,230 篇； 拟合参照	展开 25 项、校正特殊字段；在 A1 各领域拟合方向、适宜区间、重尾变换、1%/99% 缩尾、Min–Max 端点、缺失填充值及评分参数。
A2	arxiv 17,523 篇； 扩展检验	流式读取原文及指标；只应用 A1 的 arxiv 参数并评分，对照 A1 中相应领域，不在 A2 重估权重或阈值。
A3	github 203,752 篇； 扩展检验	使用 A1 的 github 参数作同样的冻结处理与评分，对照 A1 中相应领域。

几类字段需要额外处理。ModernBERT 的六档 logits 先取 softmax 期望，QuRating 拆成四项；轻量分类器的 ad_en、fluency_en 取标签 1 的概率，其中 ad_en 的标签 1 表示无广告。三个 DSIR 分量先除词数，再在 A1 各领域对 $\log(1 + \text{word_count})$ 回归并使用残差；词数、句数、平均词长和词熵则改为相对 A1 域内中位数的适宜区间型指标。其余指标按定义统一方向，对非负重尾值作 $\log(1 + x)$ ，然后在 A1 拟合的分位端点缩尾并归一到 $[0, 1]$ ；A2/A3 只复用这些参数。DSIR 与词数的绝对秩相关中位数由原量 0.957 降至残差化后的 0.095，但 book 域仍有剩余相关，故这一校正不等于完全消除了长度影响。

单篇文档的综合评价模型。 令 $z_j(x)$ 为文档 x 的第 j 项标准化指标。我们在 A1 上用 CRITIC 的离散度和指标间非冗余性确定固定权重，再求加权 Huber 中心：

$$C_j = \sigma_j \sum_{k=1}^{25} (1 - r_{jk}), \quad w_j = \frac{C_j}{\sum_k C_k}, \quad Q(x) = \arg \min_{q \in [0, 1]} \sum_{j=1}^{25} w_j \rho_\delta(z_j(x) - q). \quad (1)$$

其中 σ_j 是 A1 第 j 项标准化指标的标准差， r_{jk} 是两项指标在 A1 的相关系数； C_j 表示评分信息量，与算力预算 C 无关。Huber 损失 $\rho_\delta(e)$ 在 $|e| \leq \delta$ 时等于 $e^2/2$ ，否则等于 $\delta|e| - \delta^2/2$ ； $\delta = 0.403491$ 按 A1 的加权 MAD 尺度确定，并随权重一同冻结到 A2/A3[10, 11]。其一维

凸目标在 $q \in [0, 1]$ 上以导数二分求解，28 次迭代使搜索区间宽度不超过 2^{-28} 。这样保留多指标的连续信息，同时减小单项极端值对整篇分数的影响。A1 上主分与相同权重算术均值、PCA、TOPSIS 的文档排序相关分别为 0.9936/0.8166/0.9588；在极端程度最高 10% 的文档中删除一项最偏离指标，主分的典型绝对变动为 0.0260，算术均值为 0.0374，约小 30%。这些是方法一致性与扰动稳健性，不是独立质量真值检验。

A1 与扩展集的表现。 A1 七个领域的主分中位数由高到低为 arxiv 0.7707、commoncrawl 0.6761、stackexchange 0.6600、c4 0.6545、book 0.6313、github 0.6172、wikipedia 0.5991（图 2）。领域分取文档中位数，并以 2,000 次文档重抽样给出条件区间。A2 的 arxiv 中位数为 0.7697，对应 A1 子集为 0.7707；A3 的 github 中位数为 0.6158，对应 A1 子集为 0.6172。两组 KS 检验的 p 值为 0.313/0.220，表示在冻结管线下未检出明显分布差异，不能证明抽样完全无偏或分数具有独立准确性。




图 2 A1 七领域的 CRITIC 加权 Huber 主质量分

5.2.2 任务二：质量指标冲突的诊断与消解

冲突如何定义。 冲突指同一文档在可比指标或来源上的相对评价不一致，不能仅凭一个绝对分差判定。先用 A1 各领域、各指标的经验分布把 $z_j(x)$ 转成中秩排名 $r_j(x)$ ，并按生成机制分为 RPS (11 项)、DSIR (3 项)、轻量分类器 (2 项)、FineWeb-Edu (1 项)、QuRating (4 项)、ModernBERT (4 项) 六个来源。每个来源取指标排名中位数，再用 A1 同域的来源中心分布转为 $u_s(x) \in [0, 1]$ ；六来源间分歧定义为

$$B(x) = \max_{s=1,\dots,6} u_s(x) - \min_{s=1,\dots,6} u_s(x). \quad (2)$$

每领域以 A1 的 B 第 95 百分位作为高分歧候选筛查阈值，并冻结用于 A2/A3。若 B 超阈值且高端 ($u_s \geq 0.8$)、低端 ($u_s \leq 0.2$) 各有至少两个来源支持，称为多来源对立候选；支持来源不足则列为稀疏来源对立。另用来源内指标排名跨度与留一偏离识别孤立指标：单指标独有候选是不同的筛查类，不与来源间候选相加。

A1 中有多少候选、有哪些类型。 表 3 将同一 A1 规则冻结到三集。A1 的 2,561 篇高分歧候选（约 5%）来自预设 P95 筛查预算，不能称为测得的真实冲突率。高分歧中的多来源对

立与稀疏来源对立互斥；单指标独有候选另列。

表 3 六来源冲突诊断的候选规模；百分比均以该数据集全部文档为分母

候选类型	A1: 51,230 篇	A2: 17,523 篇	A3: 203,752 篇
来源间高分歧	2,561 (5.00%)	829 (4.73%)	10,167 (4.99%)
多来源对立	695 (1.36%)	277 (1.58%)	3,598 (1.77%)
稀疏来源对立	1,866 (3.64%)	552 (3.15%)	6,569 (3.22%)
单指标独有	2,879 (5.62%)	709 (4.05%)	8,606 (4.22%)

原因、跨集复现与评价模型的关系。 A1 的 RPS 指标内部 Kendall $W = 0.140$ 、文档内排名跨度中位数 0.625，远低于 DSIR 的一致性 $W = 0.967$ ；同一规则型来源内部就可能给出相反意见。旧四组把 RPS 压为一个中心，又把 FineWeb-Edu、QuRating、ModernBERT 合为模型评分器，会遮蔽来源内部及原合并组内部的对立。现行六来源最高加权方向在 A1、A3 均为“RPS 高、FineWeb-Edu 低”，在 A2 为“ModernBERT 高、FineWeb-Edu 低”；旧模型评分器组内部的新方向在三集均可检出。这说明不同信号测量的文本属性并不完全相同，但尚无人工质量标签，不能把某种意见认定为错误成因或判定哪一种来源更准确。A2/A3 高分歧候选比例接近 A1，主要方向有变化，因此复现的是诊断结构，不是逐篇冲突类型完全不变。




图 3 A1 指标来源内部离散与六来源之间的对立方向

冲突的“消解”在现行主链中是区分测量校正、稳健聚合与评分后诊断：DSIR 的长度校正发生在评分前，但与冲突类型无关；式 (1) 已抑制单项极端指标；式 (2) 只生成复核名单，不删除文档、不按冲突类型降权，也不改变 $Q(x)$ 。为检验是否值得建立另一评价模型，以六来源内部 Kendall W 缩放原 CRITIC 权重得到实验分 Q_{v2} ；它与主分在 A1/A2/A3 的秩相关为 0.9547/0.9207/0.9395，A1 七域排序未变。由于没有独立质量标签证明新权重更准确， Q_{v2} 只作敏感性对照，文档、领域、桥接及下游接口仍统一使用主 Q 。

5.2.3 任务三：领域配比、语料质量与损失

先统一领域及质量口径。A16 的 17 个配比域中只有 3 个可直接映射、3 个近直接映射至 A1 质量域，其余 11 个需借助 A18 文本推断。我们在 A1 的 21,590 篇原文上复算 11 项近似规则特征，以任务一的同一 $Q(x)$ 作标签，按领域分层五折选择 GBDT，再对 A18 的 31,340 篇预测。桥接的五折 $R^2 = 0.4106$ ；六个映射域的预测与 A1 主分的 MAE 为 0.0365（仅六域，不是独立质量准确率）。最终 Q_i ：六映射域取 A1 对应领域的中位数及同源区间，11 个推断域取 A18 预测中位数及同源区间；小样本域及模型偏差另作低置信处理（图 4）。对任一非负且和为 1 的配比 $\mathbf{p}$ ，语料质量统一写为

$$Q(\mathbf{p}) = \sum_{i=1}^{17} p_i Q_i, \quad p_i \geq 0, \quad \sum_i p_i = 1. \quad (3)$$

这是从文档到领域再到混合语料的聚合口径，不等于配比对验证损失的全部作用。




图 4 17 个配比域的质量分及按来源构造的条件区间

配比如何影响 Loss。A4/A5 按 index 连接，作为 1M 参数代理模型的训练集。配比总和固定，直接把 17 份额同时回归会有闭合效应；因此在非正份额替换并重新闭合后作中心对数比变换，对 13 个验证域分别拟合稳健回归 [9, 4]：

$$\xi_i(\mathbf{p}) = \log p_i - \frac{1}{17} \sum_{k=1}^{17} \log p_k, \quad \log L_v = b_v + \sum_{i=1}^{17} \beta_{vi} \xi_i(\mathbf{p}) + \varepsilon_v. \quad (4)$$

式中 b_v 是域 v 的截距， β_{vi} 是待估配比系数， ε_v 是回归残差； ξ_i 与前文文档指标 $z_j(x)$ 分开记号。在均匀配比处将系数投影到单纯形切空间，得 17×13 迁移矩阵 $T_{iv} = 17(\beta_{vi} - \bar{\beta}_v)$ ，其中 $\bar{\beta}_v = 17^{-1} \sum_i \beta_{vi}$ 。另以原始份额 OLS 和 GBDT 对照，前者检验变换的作用，后者表示可能的非线性。表 4 中的 R^2 来自 A6/A7 的 1M 留出：clr+Huber 的平均逐域 $R^2 = 0.772$ ，高于原始 OLS 的 0.654，但在 13 域等权目标上低于原始 OLS；因此保留 clr+Huber 解释局部迁移，同时以留出目标表现更好的 GBDT 搜索候选。加入 Q_i 的附加交互后，13 域中仅 6 域的系数区间不含零且方向不一，这只能说明质量与配比损失存在混杂的关联，不能解释为独立因果质量效应。

表 4 A6/A7 的 1M 留出配比模型对照

模型	13 域平均逐域 R^2	13 域等权目标 R^2
原始份额 OLS	0.654	0.418
clr + Huber (解释模型)	0.772	0.260
GBDT (非线性对照)	0.897	0.826




图 5 配比对各验证域损失的局部迁移效应




图 6 域质量与训练边际价值的关系

候选配比与两个不同的 Q, p 通道。按假设 3., 搜索目标是在单纯形 $\Delta^{16} = \{\mathbf{p} : p_i \geq 0, \sum_i p_i = 1\}$ 上使 $13^{-1} \sum_{v=1}^{13} \hat{L}_v(\mathbf{p})$ 尽量小, 其中 $\hat{L}_v$ 是冻结的 1M 代理模型预测。以 Dirichlet 分布生成 99,996 组候选, 用 GBDT 排序并平均前 100 组, 得到推荐候选 $\mathbf{p}^*$, 对应 $Q(\mathbf{p}^*) = 0.66089$ 。代理模型预测其相对均匀配比降损 9.915%; 另一线性模型对该固定候选的 bootstrap 中位数为 11.90%、95% 区间为 [9.72%, 14.12%], 不是前一 GBDT 点估计的区间, 也不是候选配比的真实训练收益。域质量与训练边际价值在 17 域上的秩相关为 -0.211, 说明单凭 Q_i 不能代替配比实验。式 (3) 给出 $\mathbf{p} \mapsto Q$, 式 (4) 给出 $\mathbf{p} \mapsto L_v$; 二者应分别进入后续问题, 避免重复计算同一配比效应。




图 7 13 域等权与 pile_cc 单域目标下的配比搜索候选

A6-A11 检验与A12-A15 外推。 冻结 A4/A5 训练的 1M 配比模型，直接应用于 A6/A7 的 1M 留出、A8/A9 的 60M 和 A10/A11 的 1B 配置；三档等权目标排序的 Spearman 分别为 0.523/0.467/0.677。在 60M 和 1B 上，固定线性模型的绝对 Loss 误差明显扩大，说明配比排序的部分保持不等于损失水平可直接迁移。固定 1M GBDT 的跨尺度排序相关为 0.872/0.664，但绝对误差仍不能忽略（图 8）；在检验集重新拟合得到的成绩只算同集对照。A12-A15 是 10B/70B 的估算或外推 Loss 表，可用来检查情景趋势，不能称为真实大模型验证；利用 A6-A11 重拟合的尺度漂移修正也只列探索性对照，不作为已通过留出检验的配比通道输入问题二。




图 8 冻结的 1M 配比模型在不同参数尺度上的排序保持度

求解设置与复现。 当前复核环境为 Python 3.12.13、NumPy 2.4.4、pandas 3.0.2；回归、KS 检验和 GBDT 为仓库内实现，不依赖 SciPy 或 scikit-learn。质量中心在 $[0, 1]$ 上固定二分 28 次；配比的 Huber 回归以最小二乘初始化，标准化残差阈值为 1.35，IRLS 最多 50 次，以最大系数变化小于 10^{-8} 停止。GBDT 使用深度为 1 的树桩和学习率 0.06：桥接五折比较用 250 棵，最终桥接用 300 棵，配比对照用 250 棵。桥接按域分层五折并只在训练折估计特征标准化参数；质量域中位数做 2,000 次文档 bootstrap，固定候选配比的线性收益做 200 次案例 bootstrap。随机发生器在质量评分、桥接、配比拟合与候选搜索中分别固定种子 2026, 42, 2026, 1234；候选由四档浓度的 Dirichlet 分布生成。树数和候选数是预设计算上限，不应误写为已证明的优化收敛。

检验、敏感性及适用边界。 A2/A3 的冻结评分与 KS 检验检查抽样扩展，A6/A7 的 1M 留出用于比较配比模型，A8-A11 只检验冻结模型的跨尺度排序。由于依据 A6/A7 的表现选择 GBDT 搜索候选，该留出集不能再充当最终候选收益的独立验证。冲突筛查阈值从 P90、P95 调至 P97.5 时，A1 候选比例约由 10.00%、5.00% 变为 2.50%，这是复核工作量的变化，不是质量真值变化；pile_cc 单域目标用于检查评价权重选择。11 个推断域的质量区间仅反映给定桥接模型后的文档抽样变动，不能覆盖模型选择与跨域偏差。该模型的优点是同一冻结 Q 贯通样本、领域与语料，并用训练外配置检验配比模型；局限是缺少人工质量标签、候选收益没有独立训练验证、1M 代理的绝对 Loss 不能直接迁移到大尺度。后续若获得目标域的人工质量标注和新训练配置，应先校准桥接，再重新检验推荐配比及其真实收益。

5.3 问题二的模型建立与求解

5.3.1 模型建立

建模思路。经典标度律只有 N 与 D 。本文保持 Chinchilla 的加式骨架，把质量写成可约损失上的乘性耦合，并把配比写成总损失上的对数可加项。 $Q = 1$ 且 $\mathbf{p} = \mathbf{p}^*$ 时，新公式退化为经典形式。质量项的具体形状不先验指定，而在同一基线上用嵌套族让数据裁决。

数据审计。B1 与 Hoffmann 等 (2022) 的常数吻合到 $\text{RMSE} = 1.6 \times 10^{-4}$ ，是公式生成的无噪声锚点，不能当作“Pile 语料 $\Leftrightarrow Q_B = 1$ ”的实证。在 B6/B7 的 $N \times D \times Q$ 网格上，去掉基线后的质量效应与 $(1 - Q)$ 呈线性关系 (图 9)，分档 $\Delta(Q)$ 对 $(1 - Q)$ 的 $R^2 = 0.997$ 。B8 与 B6/B7 在相同格点上的相关为 -0.03 ，且损失随 Q 上升，因此不参与联合拟合。B6/B7 为半合成数据，下文的 κ_N, κ_D, k_0 不得表述为真实训练的观测。




图 9 附件 B 的逆向分析：B1 锚点（左）、B6/B7 残差对 $(1 - Q)$ 的线性结构（中）、B8 与 B6/B7 的不一致（右）

主模型。交叉验证选出的广义标度律为

$$L = \{E + AN^{-\alpha}h_N(Q) + BD^{-\beta}h_D(Q) + k_0(1 - Q)\} e^{s(N)[\bar{f}(\mathbf{p}) - \bar{f}(\mathbf{p}^*)]} \quad (5)$$

其中 $h_N(Q) = 1 + \kappa_N(1 - Q)$ ， $h_D(Q) = 1 + \kappa_D(1 - Q)$ ，

$$s(N) = \max\{1.003 - 0.077 \log_{10}(N/10^6), 0\}.$$

$Q = 1$ 且 $\mathbf{p} = \mathbf{p}^*$ 时，式 (5) 退化为经典 Chinchilla 形式 [1]。 $\kappa_N > \kappa_D$ 表示质量不足主要抬高参数项。 $k_0(1 - Q)$ 是不随规模衰减的质量地板。旧加性形式 $(1 - Q)(k_0 + k_1 N^{-\alpha})$ 是 $\kappa_D = 0$ 处的特例（嵌套检验 $F = 25.6$ ， $p = 6 \times 10^{-7}$ ）。去掉地板的检验为 $F = 109$ ，但该地板是 B6/B7 的生成特征： $N, D \rightarrow \infty$ 时 $L \rightarrow E + k_0(1 - Q)$ ，外推到真实训练时须标注。

配比渠道与质量口径。按赛题要求，问题二不重复读取附件 A。 $s(N)$ 由问题一 Step6 的三尺度系数漂移标定：把各验证域系数投影到 1M 的方向上，得 $s(1M) = 1.00$ 、 $s(60M) = 0.87$ 、 $s(1B) = 0.77$ ，方向余弦不低于 0.94。1B 以上是外推。质量口径取仿射形式 $Q_B = 1 - b(q^* - \bar{q}(\mathbf{p}))$ 。 q^* 与 b 不能由损失数据识别。主口径取题面建议的“完美教材 $\Leftrightarrow$ 经典式”：

$$Q_B(\mathbf{p}) = \bar{q}(\mathbf{p}) = \sum_{i=1}^{17} p_i \hat{Q}_{d(i)}, \quad Q_0 = \bar{q}(\mathbf{p}^*) = 0.6609, \quad (6)$$

副口径取“当前推荐配比语料 $\Leftrightarrow$ 经典式”， $Q_B = \bar{q}(\mathbf{p})/0.6609$ ，此时 $Q_0 = 1$ 。 κ_N, κ_D, k_0 在附件 B 自身的 Q 网络上估计，与锚点无关。早期 Pile 锚点 $Q_{\text{ref}} = 0.5608$ 已废弃。17 个域质量的凸包为 $[0.509, 0.771]$ ，凸包外的延拓是额外假设。配比的域结构由迁移矩阵 T 单独描述。问题一的交互系数在显著域中多数反号，因此不把质量与配比合并成单一乘子。问题三的主口径即式 (6) 的 $Q_0 = 0.6609$ ，网页副口径取 pile_cc 的域质量 0.676。

5.3.2 求解方法

两步拟合。第一步在 B1 上确定基线 $L_0 = 1.6901 + 406.4N^{-0.340} + 410.6D^{-0.280}$ 。第二步固定基线，在 B7（含 B6 全部 360 点）的 450 个点上比较嵌套族：经典式、只耦合数据项、只耦合参数项、整体乘子、两项自由耦合，以及加上地板项。质量乘子同时比较线性 $1 + \kappa(1 - Q)$ 、幂 $Q^{-\kappa}$ 和指数 $e^{\kappa(1-Q)}$ 。裁决用五折交叉验证、留一规模交叉验证、12B 外推和嵌套 F 检验（表 5）。参数区间用残差 bootstrap（ $B = 300$ ）估计。

表 5 质量项形式选择（五折 cv-RMSE；数据噪声水平 $\sigma \approx 0.05$ ）

候选形式	所属族	cv-RMSE
耦合 + 地板（主） h_N, h_D, k_0	线性乘性耦合	0.0497
旧加性 $(1 - Q)(k_0 + k_1N^{-\alpha})$	$\kappa_D = 0$ 特例	0.0512
幂形状 $Q^{-\kappa}$	乘性耦合	0.0817
有效数据 $\kappa_N = 0$	文献口径	0.0979

主模型的 cv-RMSE 达到噪声水平。二次项检验 $t = -0.35$ ，幂形状被否决。只作用于数据项的文献口径在单参数模型中最差。bootstrap 中 $P(\kappa_N > \kappa_D) = P(\kappa_D > 0) = P(k_0 > 0) = 1$ 。

表 6 广义标度律参数估计（括号内为残差 bootstrap 95% CI）

E	A	α	B	β	κ_N	κ_D	k_0
1.6901	406.39	0.34	410.59	0.28	0.431 [0.390, 0.473]	0.140 [0.085, 0.195]	0.141 [0.114, 0.168]

5.3.3 结果与分析

跨源检验。在 $Q = 1$ 的切片上，主模型与观测的 Spearman 相关为：scaling_baseline（57 点）0.983，published（44 点）0.959，平均偏差分别为 0.22 与 0.02 nats。趋势一致，水平偏移来自 tokenizer 与验证集差异，不用于标定参数。B2 的 Spearman 为 0.788、偏差为 1.18 nats，仅作定性佐证。B9/B10 的百亿以上对照中，B10 本身就是 $Q = 1$ 的公式值； $Q_0 = 0.661$ 相对 $Q = 1$ 的损失缺口中位数为 0.063，约占可约损失的 30%，且 B10 为估算值。

解析命题。以下四条命题在 $\mathbf{p} = \mathbf{p}^*$ 时由式 (5) 直接推出。等效替代的解析解与数值解相对误差为 0； N^* 的相对误差小于 10^{-6} 。 $\mathbf{p} \neq \mathbf{p}^*$ 时， $s(N)$ 使配比与规模耦合，闭式不再成立：在 1B、 $\Delta \bar{f}$ 的 P90 处，修正项约为该点 ε_N 的 7%，在 7×10^{10} 处约为 26%。

命题 1（弹性）。记 $\Phi(Q) = \kappa_N A N^{-\alpha} + \kappa_D B D^{-\beta} + k_0$ 。损失对三个因素的弹性为 $\varepsilon_N = -\frac{\alpha A N^{-\alpha} h_N(Q)}{L}$ ， $\varepsilon_D = -\frac{\beta B D^{-\beta} h_D(Q)}{L}$ ， $\varepsilon_Q = -\frac{Q \Phi(Q)}{L}$ 。在 $(N, D, Q) = (10^{10}, 10^{12}, 0.9)$

处三者依次为 -0.028 、 -0.025 、 -0.103 ，即质量弹性约为参数弹性的 3.7 倍。 $Q = 0.6$ 时的有效规模为 $0.626N$ 与 $0.823D$ 。由于 k_0 不随 N 衰减，规模越大，质量的相对优势越明显。

命题 2 (质量—参数等效替代及其边界). 固定 D ，使 $L(N', D, Q) = L(N, D, Q + \delta)$ 成立的等效倍数为

$$\frac{N'}{N} = t^{-1/\alpha}, \quad t = \frac{h_N(Q + \delta)}{h_N(Q)} - \frac{\delta (\kappa_D B D^{-\beta} + k_0)}{A N^{-\alpha} h_N(Q)}. \quad (7)$$

可替代当且仅当 $t > 0$ ，即 $N < N_{\max}$ 。 $D = 3 \times 10^{11}$ 、 $\delta = 0.1$ 时， $N_{\max}$ 约为 $(0.7-1.1) \times 10^{13}$ 。在算力最优点上，主口径 Q_B 从 0.5 提到 0.6，等效于参数扩大 1.29 倍 ($C = 10^{20}$)、1.42 倍 ($C = 10^{22}$)、1.77 倍 ($C = 10^{24}$)。副口径下同样的 $\Delta \bar{q} = 0.1$ 折合 $\Delta Q_B = 0.151$ ，对应 1.47、1.73、2.48 倍。固定 $D = 3 \times 10^{11}$ 、 $\delta = 0.1$ 时， $N = 10^9$ 处 Q 从 0.9 提到 1.0 等效 1.32 倍， $N = 10^{10}$ 处为 1.59 倍。同一份质量改进，模型越大价值越高；超过 $N_{\max}$ 后，任何有限的扩参都无法替代这次质量提升。

命题 3 (质量地板). $\lim_{N, D \rightarrow \infty} L = E + (1 - Q)k_0$ 。 $Q = 0.5$ 的地板比 $Q = 1$ 高 0.070 nats。这是半合成数据的生成特征，为问题三的付费提质提供机制，但不宜当成真实语料的观测下界。

命题 4 (算力最优配置随质量移动). 在约束 $6ND = C$ 且 $\mathbf{p} = \mathbf{p}^*$ 下，

$$N^*(C, Q) = \left[\frac{\alpha A h_N(Q)}{\beta B h_D(Q)} \right]^{\frac{1}{\alpha+\beta}} \left(\frac{C}{6} \right)^{\frac{\beta}{\alpha+\beta}}, \quad \frac{\beta}{\alpha + \beta} = 0.452. \quad (8)$$

因为 $\kappa_N > \kappa_D$ ，质量越低，最优模型越大： $Q_B = 0.3$ 时的 N^* 是 $Q_B = 1$ 时的 1.32 倍。 $C = 10^{22}$ 时，最优 *token*/参数比由 $Q = 0.3$ 时的 36 升至 $Q = 1$ 时的 63。这一命题是问题三结构性转移的机制来源。




图 10 解析理论三联图：等损失线（左）、等效参数倍数（中）、 $N^*(C, Q)$ （右）

单位算力的比较。在训练算力的最优点上，比较每 FLOP 用于提质与用于扩参数的边际损失下降， $R_{QN} = MU_Q/MU_N$ 。 $Q_0 = 0.661$ 时， $C = 10^{19}$ 的比值为 1.16/0.63/1.39（指数型/幂函数型/对数型）， $C = 10^{22}$ 为 40/22/49， $C = 10^{24}$ 为 502/275/604。低预算下“提质还是扩参数”取决于成本函数； $C \geq 10^{21}$ 后三种成本函数都是提质更划算。去掉地板后比值约减半，方向不变。地板在 Φ 中的份额随规模从 29% 升到 70%，所以大预算下的这一比较依赖 B6/B7 的地板项。

领域间的替代与互补。配比通道有两部分。第一部分是 $Q_B(\mathbf{p})$ ：换入质量较高的域，会同时降低 h_N 、 h_D 和地板项。第二部分是迁移矩阵 T （表 7）：13 个自域效应全部为负，各域补自己最有效；非对角负值是互补，最强的是 stackexchange 对 github（-0.32）与 github 对 stackexchange（-0.21）；正值是挤占，dm_mathematics 一列除 ubuntu_irc 外均为正。问题三的联立优化表明，联合降损几乎全部来自配比结构 $m(\mathbf{p})$ ，而不是 $Q_B(\mathbf{p})$ 这一条通道。

表 7 迁移矩阵 T_{iv} 中的代表性互补与替代关系（节选）

增配域 i	验证域 v	T_{iv}	关系
stackexchange	github	-0.32	互补（问答 → 代码）
github	stackexchange	-0.21	互补（代码 → 问答）
pubmed_central	pubmed_abstracts	-0.16	互补（全文 → 摘要）
stackexchange	arxiv	-0.15	互补
pile_cc	wikipedia_en	-0.11	互补（网页 → 百科）
enron_emails	dm_mathematics	+0.50	替代（挤占）
pile_cc	dm_mathematics	+0.26	替代（挤占）

5.4 问题三的模型建立与求解

5.4.1 模型建立

优化问题。以问题二的广义标度律式 (5) 为目标，建立

$$\begin{aligned} \min_{N,D,Q} L(N,D,Q) \\ \text{s.t. } 6ND + D[g(Q) - g(Q_0)]_+ + \eta NDL_{\text{ctx}} \leq C, \quad Q_0 \leq Q \leq 1, \end{aligned} \quad (9)$$

其中 $\eta = 2 \times 10^{-4}$ 。三种单位 token 提质成本函数为：指数型 $g_1 = 10^7 e^{6Q}$ ，幂函数型 $g_2 = 5 \times 10^9 Q^4$ ，对数型 $g_3 = 2 \times 10^9 \ln(1 + 10Q)$ 。基线质量 Q_0 取两个口径：主口径为式 (6) 的 $\bar{q}(\mathbf{p}^*) = 0.6609$ ；副口径取网页域 pile_cc 的域质量 0.676。不再使用已废弃的 $Q_{\text{ref}} = 0.5608$ 。

降维。三项成本都与 D 成正比，而 L 对 D 严格递减，所以最优时预算约束必取等。记 $\kappa = 6 + \eta L_{\text{ctx}}$ 、 $\Delta g(Q) = [g(Q) - g(Q_0)]_+$ ，则

$$D(N, Q) = \frac{C}{\kappa N + \Delta g(Q)}, \quad (10)$$

代回后，式 (9) 化为 $(\log N, Q)$ 上的二维无约束问题，不需要罚函数。

上下文长度的解析临界值。注意力项与训练项之比为 $\eta L_{\text{ctx}}/6$ ，二者相等时

$$L_{\text{ctx}}^{\text{crit}} = 6/\eta = 30000. \quad (11)$$

在不提质区域，把式 (8) 中的 6 换成 κ 即得闭式解 $N^* \propto (C/\kappa)^{\beta/(\alpha+\beta)}$ ，因此

$$N^*(L_{\text{ctx}}) / N^*(2048) = [(6 + 2048\eta)/\kappa]^{0.452}. \quad (12)$$

结构性转移的定义。

定义1 (结构性转移). 记 $x^*(C) = (N^*, D^*, Q^*)$ 为预算 C 下的最优解, 其 KKT 活跃约束集 $\mathcal{A}(C)$ 有三种状态: $\{Q \geq Q_0\}$ 活跃 (不提质)、内点 (部分提质)、 $\{Q \leq 1\}$ 活跃 (提满)。若 $\mathcal{A}(C)$ 在 C_{crit} 两侧不同, 则称预算在 C_{crit} 处发生结构性转移。

在 $Q = Q_0$ 处, “提质的边际收益”与“提质挤占数据的边际损失”之比为

$$\Phi(C) = \frac{(\kappa_N A N^{-\alpha} + \kappa_D B D^{-\beta} + k_0)(\kappa N + \Delta g)}{\beta B D^{-\beta} g'(Q)} \Big|_{x^*(C)}. \quad (13)$$

$\Phi < 1$ 时, 不提质就是 KKT 点; $\Phi(C) = 1$ 的解就是 C_{crit} , 用二分法求得 (口径 A)。另设两个辅助口径: 口径 B 取提质成本占比 s_Q 的峰值点; 口径 C 取 D^*/N^* 的对数斜率偏离常数 $(\alpha - \beta)/(\alpha + \beta)$ 最大的点。

5.4.2 求解方法

内层对 $\log N$ 做黄金分割搜索 (剖面损失关于 N 单峰), 外层对 Q 做三级网格加密, 最终步长小于 10^{-5} , 并对端点 Q_0 与 1 做保护。求解器全向量化 (附录 A.2)。求解范围为: 3 种 $g \times 7$ 档预算 (10^{19} – 10^{25}) $\times$ 5 档 L_{ctx} (取 C7 中的可行值 2k/4k/8k/32k/128k) $\times$ 2 种 Q_0 , 共 210 组。

求解器做两项互验。在 $\Delta g = 0$ 的 15 组中, 数值解与闭式 N^* 的相对误差不超过 1.83×10^{-7} ; 与粗网格穷举对比的 18 组中, Loss 差不超过 1.6×10^{-5} , 且区制判定一致。稳健性部分对问题二的联合 bootstrap 参数逐组重解 C_{crit} , 并对 η 做 $\pm 50\%$ 扰动。

5.4.3 结果与分析

关键预算下的最优配置。表 8 给出主口径、指数型、 $L_{\text{ctx}} = 2048$ 的结果。 D^*/N^* 由 18 升至 119, 符合 $\alpha > \beta$ 时“数据增长快于参数”的规律。 $C = 10^{19}$ 时已进入部分提质, 提质成本约占 8%; $C = 10^{22}$ 时已提满, 提质份额约 8.9%。

表 8 关键预算下的最优配置 (主口径 $Q_0 = 0.6609$, 指数型, $L_{\text{ctx}} = 2048$)

C	N^*	D^*	Q^*	L^*	D^*/N^*	s_Q	区制
10^{19}	2.78×10^8	5.13×10^9	0.706	3.164	18.4	8.4%	部分提质
10^{22}	5.59×10^9	2.54×10^{11}	1	2.150	45.6	8.9%	提满
10^{24}	4.07×10^{10}	3.78×10^{12}	1	1.914	92.8	1.3%	提满

对数型在 10^{19} 就已提满。起点降到 0.66 之后, 低预算下提质不再是可忽略的成本份额。




图 11 最优质量 Q^* 随预算的变化（三种成本函数，两种 Q_0 口径）




图 12 最优解中训练、提质、注意力三项成本的占比

结构性转移。表 9 给出三种识别口径下的 $\log_{10} C_{\text{crit}}$ 。主要发现有三点。

第一，主口径指数型在 2048 档上有约 1.29 dex 的部分提质区间（离开 Q_0 为 18.87，到达 $Q = 1$ 为 20.17）。全部 210 组中有 8 组停在 Q_0 、18 组为内点、184 组提满。对数型的离开点与到达点重合在 18.17，仍是跳变。

第二，成本函数的形式决定临界点。对数型最早提满，指数型的内点区间最宽。“是否提质”取决于成本函数，不能一概而论。

第三，主口径指数型 C_{crit} 的 bootstrap 90% 区间为 [18.85, 18.90]，宽度约 ± 0.02 dex。三种识别口径在指数型上的极差约 1.28 dex，因为部分提质区间变宽后， s_Q 峰值落在接近提满的一端。

表 9 结构性转移临界预算 $\log_{10} C_{\text{crit}}$ ($L_{\text{ctx}} = 2048$)

Q_0 口径	g	A: 离开 Q_0	A: 到达 $Q = 1$	A: $\Phi = 1$ 解析	B: s_Q 峰值	C: D/N 拐点	极差
主 0.661	指数型	18.874	20.168	18.833	20.15	18.95	1.276
	幂函数型	19.399	19.845	19.358	19.85	19.45	0.451
	对数型	18.166	18.166	18.669	18.20	18.15	0.050
副 0.676	指数型	18.956	20.174	18.916	20.15	19.00	1.194
	幂函数型	19.460	19.858	19.421	19.85	19.50	0.390
	对数型	18.173	18.173	18.655	18.20	18.15	0.050




图 13 结构性转移的三种识别口径（主口径）




图 14 Q_0 - C 相图: Q_0 越低, C_{crit} 越小, 内点区间越宽




图 15 C_{crit} 对 bootstrap 参数与 η 的敏感性

上下文长度的影响。表 10 给出 $C = 10^{22}$ 、已提满时的规模比。32k 档越过 $L_{\text{ctx}}^{\text{crit}} = 30000$ 后, 注意力成本接近一半。长上下文相当于给每个参数加价, 最优策略是缩小模型。主口径指数型的 C_{crit} 随 L_{ctx} 从 18.87 降到 18.14。该档提质份额约 9%, 所以数值规模比与 $\Delta g = 0$ 闭式略有偏差。

表 10 上下文长度敏感性（主口径，指数型， $C = 10^{22}$ ）

L_{ctx}	κ	N^*/N_{2048}^*	L^*	注意力成本占比
2 048	6.41	1.000	2.150	5.8%
4 096	6.82	0.969	2.154	11.0%
8 192	7.64	0.916	2.162	19.7%
32 768	12.55	0.716	2.198	48.8%
131 072	32.21	0.454	2.275	78.0%




图 16 L_{ctx} 对最优规模、 C_{crit} 与成本结构的影响

配比联立。把配比也纳入决策，联合目标为 $L_{\text{joint}} = L(N, D, Q) \cdot m(\mathbf{p})$ 。其中 $m(\mathbf{p})$ 用问题一求 $\mathbf{p}^*$ 时的同一组 13 个验证域梯度提升模型计算，并以 $\mathbf{p}^*$ 处为 1 归一化；提质起点改为 $Q_0(\mathbf{p}) = \sum_i p_i Q_{B,i}$ ；在 $\mathbf{p}^*$ 周围做 Dirichlet 采样，共 4000 个候选。结果显示，联合最优相对 $\mathbf{p}^*$ 可再降约 13.69%–13.72%，其中配比效应 $1 - m$ 贡献 13.69%，规模与提质通道不超过 0.03%。最优前 100 个点与 $\mathbf{p}^*$ 的全变差距离约 0.020–0.022，收益约 1.0%–2.2%。不同 (g, C) 下 4000 个候选的排序秩相关最小为 0.988（图 17）。因此配比决策与规模/质量决策近似可分离。




图 17 配比联立优化：降损来源分解与跨预算排序一致性

对《数据说明》中建议的核对。说明文档称“ $C = 10^{22}$ 时 $N^* = 1.2 \times 10^{-3}B$ 、 $D^* = 850B$ 、 $\text{Loss} = 3.41$ ”。该配置只用掉 0.06% 的预算，按本文标度律其损失为 5.361，而真实最优为

$L^* = 2.150$ 、 $N^* \approx 5.6 \times 10^9$ 。说明文档称“各档预算 $Q^* = 1$ ，无需比较成本函数”，与 8 组 Q_0 角点、18 组内点的结果矛盾。说明文档建议“穷举网格 + 罚系数取 1”，但由式 (10) 可解析消去约束；网格法与本文求解器的 Loss 差虽不超过 1.6×10^{-5} ，却无法连续识别 C_{crit} 。

5.5 问题四的模型建立与求解

5.5.1 模型建立

四项口径。赛题要求逐条说明的四项口径见表 11。按许可证分档后，permissive 与 community 两档的 base 前沿 (Top-5 Average 均值) 几乎持平 (34.24 与 33.60)，noncommercial 档样本少、前沿偏低 (9.58)。因此“开源前沿”取全部可下载权重的模型，不再按许可证剔除。

表 11 问题四的四项口径

口径	主口径	副口径 / 说明
能力度量	C1 Average (六维等权, 已扣随机基线, 0-100)	C8 逐任务重算的去饱和综合分
开源筛选	C1/C2 均来自 HF Hub, 权重可下载; 按许可证分三档	C4 中 Model accessibility 含 Open weights (1961 个 LM 中 901 个)
模型类型	base = pretrained 275 + continuously pretrained 58 = 333	chat = chat 718 + fine-tuned 1785 = 2503; merges / multimodal 剔除
时间轴	C2 真实发布日 (447 行有值)	C1 提交日中位滞后 103.5 天, 只用于月度窗口与回测

任务饱和与去饱和分。C8 的每个叶子任务按随机基线归一化, $\hat{s} = \max\{0, (s-c)/(1-c)\}$, 其中 c 为随机猜测得分。月度累计前沿按“终点前沿、剩余空间、关闭率、噪声门槛”四个判据, 把 39 个任务分为饱和、快速增长、常规增长、低位停滞四类。去饱和综合分剔除饱和任务, 其余任务按起点剩余空间加权、各 family 等权。

Loss-Benchmark 桥接。得分有底噪下界和上界, 因此采用 S 形映射

$$S = lo + \frac{hi - lo}{1 + e^{k(L-L_0)}}, \quad (14)$$

给定 (k, L_0) 时 (lo, hi) 可线性求解。C6 按可比性分层: High 层 (Pythia, 同模型同验证集, 7 条) 权重 1; Medium 层 (不同验证集, 近似可比, 68 条) 权重 0.5。High 层的 Val_Loss 与问题二标度律 $\hat{L}$ 的差小于 10^{-4} , 证明二者处于同一尺度。

分解模型。以问题二标度律 ($Q = 1$) 计算每个模型的 $\hat{L}(N, D)$, 作为“规模状态”。主模型 (M1b, 结构 · 加性) 为

$$S_m = lo + amp \cdot \sigma(k(\hat{L}_m - L_0)) + \tau(t_m - 2023) + \varepsilon_m, \quad (15)$$

其中 σ 为 logistic 函数。 τ 是每年的得分技术增益, 也就是“非规模技术进步”。副模型 M1c 把技术项写成等效降损, $\sigma(k(\hat{L}_m - \delta t_m - L_0))$ 。对照模型包括: M2 效率前沿 (Epoch 口径, 帕累托有效模型上的 $S = a + b \log_{10} C + ct$)、M3 分位数回归与全样本 OLS。前沿增量用

Shapley 值分解（两种顺序的平均）：“规模贡献”为只让前沿 $\hat{L}$ 按实际演进时的增量，“技术贡献”为只让 t 演进时的增量。

预测链条。预测不新增自由参数，四步依次为：算力情景 → 问题三最优配置 ($Q = 1$, $L_{\text{ctx}} = 4096$) 下的 $\Delta L^* \rightarrow$ 叠加到前沿 $\hat{L}$ 上（锚定增量：现有前沿并非算力最优，只借用 L^* 的斜率）→ 经式 (15) 与技术项得到 ΔS 。chat 前沿等于 chat 锚点加上 base 增量，再加上后训练增益增量。

5.5.2 求解方法

C8 共 1958 个 JSON，逐任务解析；重算的六个 family 分与 C1 的 Pearson 相关 ≥ 0.989 (MATH 为 0.801)，说明解析口径正确。式 (14) 采用“网格+两级加密+加权最小二乘”拟合（环境无 scipy），用留一交叉验证比较 sigmoid、线性与常数三种桥接。分解面板由 C2 与 C4 按（发布日，组织）联表得到：base 58 行，其中 23 行的 D 由 $C/(6N)$ 反解；chat 37 行，只保留同时发布了 base 的原厂组织。区间由模型簇重抽样 bootstrap（120 次）给出。预测部分做 4000 次蒙特卡洛，不确定性来源依次为：问题二 bootstrap 参数，分解 bootstrap（M1b 与 M1c 各半），后训练增益 bootstrap，前沿残差（sd 2.05）。回测只用 $t < 2024.5$ 的数据重估模型，再预测 2025.25 的前沿。

5.5.3 结果与分析

任务饱和。39 个任务中 10 个饱和(temporal_sequences 达到 1.00, 另有 IFEval、hyperbaton 等)，9 个快速增长（web_of_lies 由 0.20 升至 0.78），17 个常规增长，3 个低位停滞（gpqa_diamond 等）。表 12 显示，模型级去饱和分与 Average 的相关为 0.948，排序基本一致，但饱和任务稀释了增速：按相对增幅计，Average 低估前沿进展约 1.6 倍。

表 12 三种能力口径下的前沿变化（C1 提交日窗口）

口径	2024-06 前沿	2025-03 前沿	相对增幅	月斜率
C1 Average	38.52	49.89	+29.5%	1.285
C8 全任务重算	37.98	49.40	+30.1%	1.326
C8 去饱和分	26.36	39.06	+48.2%	1.536




图 18 39 个叶子任务的饱和度和分类




图 19 去饱和分与 Average 的前沿对比

桥接。Loss 与 Average 负相关：全体 $r = -0.510$ ，High 层 -0.397 ，Medium 层 -0.502 。base 主桥接为 $lo = 8.63$ 、 $hi = 21.57$ 、 $k = 46.1$ 、 $L_0 = 2.07$ 。留一 RMSE 为：sigmoid 8.08、线性 8.28、常数 9.51。只用系列内变异的固定效应斜率为 $dS/dL = -23.6$ （base）与 -36.7 （chat）。Medium 层权重取 0.25/0.5/1.0 时， $S(L = 1.85)$ 分别为 21.79/21.57/21.43，结果稳

定。但High层的7个点全部落在底噪区 ($L \in [2.09, 2.60]$)，只能锁定下界，S形的上升段依赖Medium层，这是C6数据的硬限制。




图 20 C6 分层Loss-Benchmark 桥接 (base 与 chat)

贡献分解。主模型M1b 的估计为 $\tau = 2.45$ 分/年， $R^2 = 0.870$ ；去掉 τ 后 R^2 降为 0.832；M1c 的 $\delta = 0.035$ Loss/年。主窗口 2023.5→2025.0 内，base 前沿由 12.54 升至 37.30 ($\Delta S = 24.76$)， $\hat{L}$ 由 2.006 降至 1.869， $\log_{10} C$ 由 23.35 升至 24.64。表 13 给出各方法的分解结果。

表 13 base 前沿增长的贡献分解 (2023.5→2025.0, Shapley)

类别	方法	规模贡献	技术贡献	技术占比	90% 区间
结构模型	M1b (主)	23.06	3.40	12.9%	6%–22%
	M1c	20.12	6.04	23.1%	4%–46%
线性对照	M2 效率前沿	7.36	6.19	45.7%	9%–60%
	M3 $q = 0.75$	7.40	4.45	37.5%	—
	M3 $q = 0.5$	6.24	5.88	48.5%	—
	OLS	7.72	3.24	29.5%	—
反例	M1a 桥接直接套用	0.63	4.84	88%	不可迁移

核心三法 (M1b、M2、M3 $q = 0.75$) 的极差为 32.8 个百分点，超过事先设定的 $\pm 15\text{pp}$ 一致性门槛，因此不强行给出单一数字。差异是结构性的：M2 与 M3 假设得分对 $\log C$ 线性，无法表达桥接的 S 形加速段，把“Loss 刚进入陡峭区带来的规模红利”部分记到了时间项上；M1b 与 M1c 用“标度律+ S 形桥接”吸收了这部分，拟合优度也明显更高 (R^2 0.87 对 0.66)。故主结论采用结构口径：规模扩张贡献约 **77%–87%**，非规模技术进步约 **13%–23%**；线性口径的 30%–46% 作为上界参考。所有方法在“规模为主”这一定性结论上一致。M1a 直接套用 C6 桥接 ($hi = 21.6$ ，低于面板前沿)，把桥接的非线性全部记为“技术”，得到 88%，与索洛余值法的偏差同源，只作为反例列出。

换算为算力等效，各方法的技术进步为：M1b 0.29、M1c 0.56、M2 0.78、OLS 0.39 dex/yr。这与 C1 窗口内回归的 0.44–0.77 dex/yr 同量级，两者相互印证。加入 C3 历史点做敏感性：权重 0.2 时为 0.50 dex/yr。C3 的 Average 与其六维均值的相关仅为 0.634，口径混杂，因此不进入主结果。

chat 与后训练。在 89 对同组织的 (base, chat) 配对中，后训练平均增益为 4.30 分；对有发布日的 31 对做回归，得 $G(t) = -0.40 + 3.35(t - 2023)$ ，说明后训练本身是一类逐年增强的非规模技术。chat 前沿在 2023.5→2025.0 由 8.76 升至 46.06：规模贡献 23.77，预训练技术 3.56，后训练技术 4.86，技术占比 26%。




图 21 分解面板：规模状态 $\hat{L}$ 、得分与时间




图 22 各方法、各窗口的规模/技术贡献

算力放缓情景与前沿预测。C4 中开源权重模型的年度最大训练算力，2019 年为 $10^{22.52}$ ，2025 年为 $10^{25.59}$ 。按最大值、Top-5、2022–25 与全部 LM 四种统计，斜率分别为 0.58/0.60/0.69/0.65 dex/yr。据此设三种情景：基线 0.60、减半 0.30、1/4 0.15 dex/yr。起点 $T_0 = 2025.25$ ，锚点 base $S = 37.30$ ($\hat{L} = 1.869$)，chat $S = 46.06$ 。预测结果见表 14。

表 14 开源前沿 (Average) 预测：中位数 [90% 区间]

情景	base			chat (24 个月)	
	12 个月	24 个月	技术占比	后训练增益延续	后训练增益停滞
基线 0.60	43.1 [37.4, 52.8]	46.2 [37.5, 68.5]	55%	61.6 [51.8, 79.6]	54.8 [46.4, 70.1]
减半 0.30	41.7 [37.0, 49.7]	45.2 [37.7, 58.3]	65%	60.7 [51.5, 75.3]	54.0 [46.2, 67.6]
1/4 0.15	41.1 [36.6, 47.6]	44.1 [37.5, 54.9]	77%	59.8 [50.9, 71.6]	52.7 [46.1, 63.3]

算力增速从 0.60 降到 0.15 dex/yr，24 个月的 base 中位数只减少约 2 分 ($46.2 \rightarrow 44.1$)。原因是规模增量本身被 S 形桥接的饱和段压缩（规模部分由 3.9 分降为 1.5 分），而技术项（约 5 分）基本不受影响。所以算力放缓时，技术进步成为增量主体（占比由 55% 升至

77%)。模型不确定性主要来自技术项的形式：基线情景下 M1b 的中位数为 46.6，M1c 为 44.7，后者上尾更宽。chat 前沿对“后训练增益是否延续”最敏感（相差约 7 分），这一差别大于算力情景之间的差别（约 2 分）。作为上界参考，M1b 的纯规模天花板为 44.2，“算力无限”时 24 个月为 49.2。




图 23 三种算力情景下 base/chat 开源前沿的 12/24 个月预测（阴影为 90% 区间）

回测。只用 $t < 2024.5$ 的 42 个 base 模型重估模型 ($\tau = 2.74$)，以 2024.5 的前沿 29.28 为锚点，预测 2025.25 的前沿（实际为 37.30）。M1b 在基线情景下的误差为 -0.78 ，用实际算力增速 (0.76 dex/yr) 时误差为 $+0.21$ ，朴素线性外推的误差为 $+2.65$ 。在提交日轴上，C1 月度前沿做纯时间序列外推，3 个月误差达到 $+7.91$ ，因为前沿在 49.89 附近进入平台。这是不直接用 ARIMA 外推的实证理由。

对《数据说明》中建议的核对。(i) 说明文档称“Loss-Benchmark 正相关 $r = +0.68$ ”，实测为 $r = -0.51$ 。(ii) 说明文档称“ $b_N = -6.2$ ，规模越大得分越低”，实测规模系数全部为正 (C1 窗口 7.41，面板 6.85，效率前沿 5.71)。(iii) 说明文档建议“年份独热编码”，但独热编码无法外推到未见年份，本文改用连续时间项，并以算力等效率互证。(iv) 索洛余值法把桥接的非线性全部记入技术项（即 M1a 的 88%），本文把它列为反例，并用结构模型修正。

6 模型的检验与灵敏度分析

6.1 模型检验

表 15 汇总了全文的检验。“互相验证”只用于同一问题、不同假设的方法对，判断取排序或数值的一致性；上下游分工衔接的方法之间不存在验证关系，本文也不作此类声称。

不一致的地方同样是结论。17 域质量与训练边际价值的 $\rho = -0.211$ 表明二者不能互相替代，不能据此断言完全无关；60M/1B 的绝对 Loss 预测误差扩大，说明跨尺度排序部分保持并不足以支持损失水平直接外推。A12-A15、B6-B8 与 B10 的证据等级（半合成、外推或估算）仍须在各自结果中保留。

6.2 灵敏度与稳健性分析

问题一。A1 的六来源分歧阈值取同域 P90/P95/P97.5 时，候选比例约为 10.00%/5.00%/2.50%，所以诊断阈值决定人工复核工作量，不能解释为真实冲突率变化。来源一致性加权实验分 Q_{v2} 与主分在 A1/A2/A3 的秩相关为 0.9547/0.9207/0.9395，但没有独立标签证明它更准确，主分不变。13 域等权与 pile_cc 单域目标产生不同搜索候选，故评价目标必须在搜索前确定。

表 15 全文检验清单

问题	检验对	类型	判据	结果
一	Huber vs 算术均值/PCA/TOPSIS	方法敏感性	样本级 Spearman	0.9936/0.8166/0.9588; 无质量真值
	A1 vs A2/A3	冻结扩展检验	KS 的 p 值	0.313/0.220; 未检出明显分布差异
	六来源候选跨集	冻结规则复检	候选比例与方向	5.00%/4.73%/4.99%; 方向有变化
	clr+Huber vs 原始份额 OLS	1M 留出	逐域/等权目标 R^2	0.772/0.260 vs 0.654/0.418
	A1→A18 质量桥接	五折与映射域对照	R^2 /六域 MAE	0.4106/0.0365; 非独立真值
	1M → 60M → 1B	跨尺度直接检验	等权目标 Spearman	0.523/0.467/0.677; 绝对 Loss 不可直接迁移
二	加性 vs 乘子族	形式选择	五折 cv-RMSE	0.051 vs 0.099–0.105
	解析解 vs 数值优化	互相验证	相对误差	$< 10^{-5}$
	标度律 vs 真实文献点	外部合理性	趋势 Spearman	0.959–0.983
三	数值解 vs 闭式 N^*	互相验证	相对误差	$\leq 1.83 \times 10^{-7}$ (15 组)
	求解器 vs 网格穷举	互相验证	Loss 差、区制	$\leq 1.6 \times 10^{-5}$, 区制一致
	C_{crit} 三口径	互相验证	极差	主口径 ≤ 0.05 dex
四	C8 重算 vs C1	口径核验	Pearson	≥ 0.989 (MATH 0.801)
	sigmoid vs 线性桥接	形式选择	留一 RMSE	8.08 vs 8.28
	分解 dex/yr vs 窗口回归	互相验证	同量级	0.29–0.78 vs 0.44–0.77
	预测回测	外部检验	2025.25 误差	M1b -0.78 , 线性外推 $+2.65$

问题二。主口径 $Q_0 = \bar{q}(\mathbf{p}^*) = 0.6609$ 与副口径 $Q_B = \bar{q}/0.6609$ 下, Q_B 从 0.5 提到 0.6 的等效参数倍数在算力最优点分别为 1.29/1.42/1.77 与 1.47/1.73/2.48 ($C = 10^{20}/10^{22}/10^{24}$)。“模型越大、质量越值钱”的方向不变, 倍数本身依赖口径。 κ_N, κ_D, k_0 的 95% CI 为 [0.390, 0.473]、[0.085, 0.195]、[0.114, 0.168], bootstrap 中 $P(\kappa_N > \kappa_D) = 1$ 。旧锚点 $Q_{\text{ref}} = 0.5608$ 与旧区间 [1.52, 1.77] 已废弃。

问题三。主口径 $Q_0 = 0.6609$ 下, 指数型 C_{crit} 的 bootstrap 90% 区间为 [18.85, 18.90]。 Q_0 相图 (图 14) 表明: Q_0 越低, C_{crit} 越小。指数型存在约 1.29 dex 的部分提质区间, 对数型仍是跳变。

问题四。C6 中 Medium 层的权重取 0.25–1.0 时, $S(1.85)$ 的变化不到 0.4 分。C3 历史点的权重取 0.2 与 1.0 时, 技术进步率分别为 0.50 与 0.21 dex/yr, 因此只作敏感性分析。分解换用 2024→2025 与 2024.5→2025.25 两个窗口, M1b 的技术占比为 7.1% 与 8.2%, M2 为 30.6% 与 24.3%, “规模为主”的定性结论不变。

7 模型的评价与推广

7.1 模型的优点

(1) 证据分层, 接口可追溯。问题一将 A1 拟合、A2/A3 扩展、A6/A7 留出、A8–A11 跨尺度检验和 A12–A15 估算表分开报告; 各问输入输出由接口文件记录。问题二的半合成拟合与后续接口仍需按现行 Spec 完成留出验收。

(2) 形式与阈值可追溯。问题一的六来源阈值取 A1 同域 P95, 质量桥接以分层五折比较 Ridge 和 GBDT; 质量项形式由候选式比较决定, 结构性转移由约束活跃状态定义。每一步均说明了训练数据和检验边界。

(3) 解析与数值互验。四条命题、 $L_{\text{ctx}}^{\text{crit}}$ 与 $\Phi(C) = 1$ 判据都有闭式表达, 并与数值解逐项对照, 结论可解释。

(4) 评分与诊断职责清楚。问题一先固定主质量分, 再报告六来源分歧与单指标候选; 阈值敏感性和实验权重分均不回写主评分, 避免把筛查预算误当成真实冲突率。

7.2 模型的局限与改进方向

(1) 11 个 inferred 域的质量分依赖文本桥接 (五折 $R^2 = 0.4106$), 条件区间未包含跨域偏差; 若增补这些域的质量标签与模型评分信号, 可重新校准并检验桥接误差。

(2) 附件 B 的 B6–B8 为半合成数据, κ_N, κ_D, k_0 的绝对数值不宜直接外推到真实训练体系, 应用时以趋势与结构结论为主。

(3) 问题三中 $g(Q)$ 的形式与参数取自赛题附录 B, “角点解”与“对数型早两个数量级提质”对成本函数的形式敏感, 本文已把三种形式并列给出。

(4) C6 的 High 层只有 7 点且全部位于底噪区, 桥接的上升段依赖 Medium 层; 问题四的结构口径与线性口径相差 32.8pp, 是全文最大的不确定性来源。若能获得更多同验证集的 Loss–Benchmark 对, 可以缩小这一分歧。

(5) 预测为情景条件预测, 不包含新架构等离散突破。

7.3 模型的推广

“基线+质量修正”的标度律结构，以及“约束取等后解析消元”的降维方法，可推广到含多种数据处理成本（去重、合成数据、多模态对齐）的资源配置问题。“S形桥接+连续时间项+Shapley分解”的框架也适用于其他存在能力饱和的技术演进分析。

8 结论

本文围绕“算力约束下如何配置资源以提升大模型能力”，建立了四个递进衔接的模型。

问题一把22个原始字段展开为25项指标，以冻结的CRITIC加权Huber方法得到文档、领域和语料质量；六来源诊断在A1标出约5%的高分歧复核候选，不把它当真实冲突率或据此改分。配比模型给出17域局部迁移效应；推荐候选相对均匀配比的9.915%降损是1M代理模型预测，仍需真实训练验证。域质量与训练边际价值的秩相关为-0.211，说明单凭质量分不能代替配比实验。

问题二以交叉验证选出的线性乘性耦合形式建立了广义标度律 $L = \{E + AN^{-\alpha}[1 + \kappa_N(1 - Q)] + BD^{-\beta}[1 + \kappa_D(1 - Q)] + k_0(1 - Q)\} \cdot e^{s(N)[\bar{f}(\mathbf{p}) - \bar{f}(\mathbf{p}^*)]}$ ($\kappa_N = 0.431$, $\kappa_D = 0.140$, $k_0 = 0.141$, $Q_0 = 0.6609$)，并推出四条解析结论：在 $(10^{10}, 10^{12}, 0.9)$ 处质量弹性约为参数弹性的3.7倍；质量提升0.1在算力最优点等效于参数扩大1.29–1.77倍 ($C = 10^{20} - 10^{24}$)，且随规模放大；存在规模无法弥补的质量地板（半合成数据内建，须标注）；质量越高，最优配置越偏向小模型、多数据。

问题三把约束优化解析降维为二维无约束问题，以KKT活跃集的改变定义结构性转移，并用 $\Phi(C) = 1$ 识别临界预算。主口径下，指数型、幂函数型、对数型离开 Q_0 的 $\log_{10} C_{\text{crit}}$ 为18.87/19.40/18.17。指数型有约1.29 dex的部分提质区间，对数型为跳变。上下文长度越过 $6/\eta = 30000$ 后，注意力成本占主导，最优模型随之缩小。配比与规模决策近似可分离。

问题四用“标度律+S形桥接+时间技术项”的结构模型分解前沿增长：规模扩张是主导，非规模技术进步占13%–23%（结构口径；线性口径的30%–46%为上界参考）。在算力增速放缓至0.15 dex/yr的情景下，24个月的base开源前沿中位数为44.1，技术进步在增量中的占比升至77%。

四问共同说明，数据质量与配比是与算力并列的一等资源：小预算时应把算力用在规模上，跨过临界预算后应把质量提满；算力增长放缓时，能力增长将越来越依赖非规模技术进步。

参考文献

- [1] Hoffmann J, Borgeaud S, Mensch A, et al. Training compute-optimal large language models[C]//Advances in Neural Information Processing Systems 35 (NeurIPS). 2022.
- [2] Bahri Y, Dyer E, Kaplan J, et al. Explaining neural scaling laws[J]. Proceedings of the National Academy of Sciences, 2024, 121(27): e2311878121.
- [3] Asai A, et al. Synthesizing scientific literature with retrieval-augmented language models[J]. Nature, 2026, 650: 857–863.

- [4] Xia M, et al. RegMix: Data mixture as regression for language model pre-training[C]//International Conference on Machine Learning (ICML). 2024.
- [5] Biderman S, et al. Pythia: A suite for analyzing large language models across training and scaling[C]//International Conference on Machine Learning (ICML). 2023.
- [6] Schaeffer R, Miranda B, Koyejo S. Are emergent abilities of large language models a mirage?[C]//Advances in Neural Information Processing Systems 36 (NeurIPS). 2023.
- [7] Muennighoff N, et al. Scaling data-constrained language models[C]//Advances in Neural Information Processing Systems 36 (NeurIPS). 2023.
- [8] Penedo G, et al. The FineWeb datasets: Decanting the web for the finest text data at scale[C]//NeurIPS Datasets and Benchmarks Track. 2024.
- [9] Aitchison J. The Statistical Analysis of Compositional Data[M]. London: Chapman & Hall, 1986.
- [10] Diakoulaki D, Mavrotas G, Papayannakis L. Determining objective weights in multiple criteria problems: The CRITIC method[J]. Computers & Operations Research, 1995, 22(7): 763–770.
- [11] Huber P J. Robust estimation of a location parameter[J]. The Annals of Mathematical Statistics, 1964, 35(1): 73–101.
- [12] Shapley L S. A value for n -person games[M]//Contributions to the Theory of Games II. Princeton: Princeton University Press, 1953: 307–317.

附录 A 补充材料与程序

A.1 支撑材料清单与运行说明

全部代码为 Python 3，只依赖 numpy、pandas、matplotlib，不依赖 scipy。各脚本在所在目录内运行，产出落盘到对应的 outputs_q* 目录，下游各问只读取上游的接口文件 (interface/)。

表 16 程序清单

目录	脚本	功能
code_q1/	q1_01-q1_07	指标展开、CRITIC 评分、冲突、桥接、clr 回归、跨尺度、 $\mathbf{p}^*$
code_q2/	q2_00_reverse_engineering	附件 B 生成公式逆向
	q2_01_fit, q2_02_theory	两步拟合与五形式交叉验证；四条命题的数值互验
code_q3/	q3_00_model	广义律、三项成本、向量化求解器、 Φ 判据
	q3_01-q3_03	210 组最优解、结构性转移与敏感性、配比联立
code_q4/	q4_01-q4_05	C8 解析、饱和度、桥接、分解、预测与回测
	q4_99_check_report	问题三、四的 76 项关键数字与输出文件自动核对

运行顺序为: code_q1(q1_01→q1_07)→code_q2→code_q3(q3_01→q3_03)→code_q4(q4_01→q4_05, 最后运行 q4_99)。

A.2 核心程序

(1) CRITIC 权重与加权 Huber 主分 (code_q1/q1_02_quality.py 节选)

```
def fit_critic(self, Z):
    sd = Z.std(axis=0, ddof=1)                # contrast intensity
    R = np.corrcoef(Z.T)                     # indicator correlation
    C = sd * (1 - R).sum(axis=1)              # information content C_j
    self.critic_w = C / C.sum()
    return self.critic_w

def fit_delta(self, Z):                       # A1 weighted-MAD rule
    center = weighted_median(Z, self.critic_w)
    dev = np.abs(Z - center[:, None])
    mad = weighted_median(dev, self.critic_w)
    self.delta = float(np.clip(1.345 * 1.4826 * np.median(mad), .01, 1.0))
    return self.delta

def score(self, Z):                           # fixed weights and delta
```

```
return weighted_huber_center(Z, self.critic_w, self.delta)
```

(2) 问题三向量化求解器 (code_q3/q3_00_model.py 节选)

```
def _profile(C, Q, dg, kappa, p, lo=1.0, hi=17.0, it=70):
    """golden-section search on log10 N for fixed Q; D solved from budget"""
    def f(x):
        N = 10.0 ** x
        D = C / (kappa * N + dg)          # budget binds: D eliminated
        return loss(N, D, Q, p)
    a = np.full(C.shape, lo); b = np.full(C.shape, hi)
    for _ in range(it):
        c = b - _GR * (b - a); d = a + _GR * (b - a)
        m = f(c) < f(d)
        b = np.where(m, d, b); a = np.where(m, a, c)
    x = (a + b) / 2
    return f(x), x

def solve(C, g, Lctx=2048, Q0=Q0_MAIN, p=PAR, eta=ETA, nQ=41, levels=3):
    kappa = 6 + eta * Lctx
    lo, hi = Q0, 1.0
    for _ in range(levels):          # 3-level grid refinement on Q
        Qg = lo + (hi - lo) * np.linspace(0, 1, nQ)
        dg = np.maximum(g(Qg) - g(Q0), 0.0)
        Lm, _ = _profile(C, Qg, dg, kappa, p)
        Qb = Qg[np.argmin(Lm)]; step = (hi - lo) / (nQ - 1)
        lo, hi = max(Qb - step, Q0), min(Qb + step, 1.0)
    # endpoint protection at Q0 and 1, then classify KKT active set
    ...

def phi_ratio(C, g, Lctx, Qeval, Q0, p=PAR, eta=ETA):
    """Phi = marginal gain of quality / marginal loss from crowding out D"""
    kappa = 6 + eta * Lctx
    dg = max(g(Qeval) - g(Q0), 0.0)
    _, x = _profile(C, Qeval, dg, kappa, p)
    N = 10.0 ** x; D = C / (kappa * N + dg)
    num = (p["k0"] + p["k1"] * N ** -p["al"]) * (kappa * N + dg)
    den = p["be"] * p["B"] * D ** -p["be"] * g_prime(Qeval)
    return num / den          # C_crit solves Phi(C) = 1
```

(3) 结构分解模型与 Shapley 分解 (code_q4/q4_04_decomp.py 节选)

```
def f_add(p, L, t):          # M1b: S-bridge + linear tech
    term
    return p["lo"] + p["amp"] * sig(L, p["k"], p["L0"]) + p["tau"] * t
```

```
def shapley(fun, L0, t0, L1, t1):
    """two-factor Shapley: scale (L_hat) vs technology (t)"""
    sc = 0.5 * ((fun(L1, t0) - fun(L0, t0)) + (fun(L1, t1) - fun(L0, t1)))
    te = 0.5 * ((fun(L0, t1) - fun(L0, t0)) + (fun(L1, t1) - fun(L1, t0)))
    return sc, te
```

A.3 AI 使用披露

依据赛题“AI 使用规范”，现披露如下。

所用工具：Claude (Anthropic)。

使用环节与贡献范围：(1) 资料整理与概念理解：梳理赛题附件的字段结构与《数据说明》中的条目；(2) 代码编写与调试：数据读取、向量化求解器、绘图脚本的编写与报错排查；(3) 结果核对：编写自动核对脚本，把报告中的数字与程序输出逐项比对；(4) 排版与文字：LaTeX 排版、图表整理与语句润色。

参赛队的工作与责任：模型路线的选择（证据分层、质量项形式由交叉验证裁决、结构性转移按 KKT 活跃集定义、分解方法并列报告等）、公式推导与结论判断由参赛队确定，并对 AI 输出的全部代码与数值逐项运行、核验。文中理论与公式均引用正式文献或由附件数据验证，未以 AI 输出作为学术依据。全部数值结果可由随文代码在附件数据上复现。