



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校 国防科技大学

参赛队号 26910020233

	1. 李重行
队员姓名	2. 李星谊
	3. 刘浩然

中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生

数学建模竞赛

题 目： 算力约束下提升大语言模型能力的资源配置建模

摘 要：

大语言模型的预训练能力随模型参数量 N (个) 与训练 token 数 D (token) 增长, 经典标度律以验证集交叉熵损失 $L_0(N, D) = E + AN^{-\alpha} + BD^{-\beta}$ 刻画这一过程 [1, 2]。在有限算力下, 可配置的资源并不只有规模: 语料质量 Q 与领域配比 $\mathbf{p}$ 同样决定同等投入的产出。本文按「数据如何衡量—资源如何发挥作用—资源如何分配—能力如何演进」的主线, 建立四个层层衔接的模型; 前一问的冻结结果经 P1-P4 接口文件进入后一问, 未通过留出检验的通道不进入下游主优化。

问题一建立数据质量与领域配比模型。本文把附件 A1 的 22 个原始字段展开为 25 项可比指标, 用域内冻结的预处理、CRITIC 客观权重与加权 Huber 中心得到唯一的文档质量分 $Q(x)$ (Huber 阈值 $\delta = 0.4034907$ 仅由 A1 确定并冻结), 再经 A16 映射与 A18 文本特征桥接到全部 17 个配比域。A1 七域质量中位数由高到低为 arxiv 0.7707、commoncrawl 0.6761、stackexchange 0.6600、c4 0.6545、book 0.6313、github 0.6172、wikipedia 0.5991; 冻结管线在扩展集 A2/A3 上保持稳定 (KS 检验 $p = 0.313/0.220$)。在评分之后, 本文用六来源分歧诊断在三集各圈定约 5% 的高分歧文档作为人工复核候选, 并以中心对数比稳健回归刻画 17×13 的领域迁移结构。在 1M 代理模型信赖域内选出的推荐配比 $\mathbf{p}^*$, 使预测等权损失较均匀配比下降 9.47% (bootstrap 中位数 9.54%, 95% 区间 [7.82%, 11.16%]), 配比加权语料质量 $\bar{Q}(\mathbf{p}^*) = 0.6624117$; 而域质量与训练边际价值的秩相关仅为 -0.211 , 表明质量分不能替代配比实验。

问题二建立含质量与配比的广义标度律。本文先在 B1 上估计经典基线 ($E = 1.6901$ 、 $A = 406.39$ 、 $\alpha = 0.34$ 、 $B = 410.59$ 、 $\beta = 0.28$), 再按有效规模的思路把质量写成可约损失上的幂次乘子, 并把质量缺陷带来的、不随 N, D 增大而消失的附加损失 $k_0(1 - Q)$ (本文称质量地板) 作为加项留在括号外; 理想质量与参照配比下模型退回经典式, 该约束的依据与检验在正文给出:

$$L = E + k_0(1 - Q) + [AN^{-\alpha}Q^{-\kappa_N} + BD^{-\beta}Q^{-\kappa_D}] \exp(s_{\text{red}}\tilde{\varphi}(\mathbf{p})),$$

其中 $\kappa_N = 0.1416$ 、 $\kappa_D = 0.0112$ 、 $k_0 = 0.2280$ 、 $s_{\text{red}} = 1.4996$ 、 $Q_0 = 0.6624117$ 。质量参数仅用 B6 的 360 个半合成样本拟合, B7 新增的 90 点作留出检验。在参照点上, 质量弹性约为参数弹性的 1.62 倍 (其中约 73% 来自质量地板); 固定数据量时质量提高 0.1 等效于把

参数扩大 1.30 ($N = 10^9$) 至 3.07 ($N = 10^{11}$) 倍；沿算力前沿，质量由 0.7 升至 0.8 等效于算力乘 1.191/1.485/2.134 ($C = 10^{19}/10^{22}/10^{24}$ FLOPs)。当预算 $C \geq 10^{20}$ 时，三种提质成本函数下提质都比扩大参数更有效地降低损失。

问题三求解算力约束下的最优资源配置。本文把训练、提质与长上下文三项成本纳入同一预算，利用三者对 D 的线性结构将预算约束取等并解析消元，把问题降为 $(\log_{10} N, Q)$ 的二维有界优化，并以质量约束的活跃状态定义最优策略的结构性转变。研究得到一个与预算、成本函数和规模均无关的解析结论：上下文长度临界值 $L_{ctx}^{crit} = 6/\eta = 30000$ token，越过该值后注意力开销占主导、最优模型随之缩小。数值结果表明：低预算 $C = 10^{19}$ 下，指数型与幂函数型提质成本对应的最优质量停留在下界（不提质），对数型成本则直接提满； $C = 10^{22}$ 、 10^{24} 时三种成本函数下均提满 $Q^* = 1$ 。离开质量下界的临界预算 $(\log_{10} C)$ 分别约为 19.06、19.53、18.58，随成本函数形状有序移动，为「何时该把算力投向提质」给出了明确的预算阈值。

问题四检验 Benchmark 并解释能力演进。本文用「标度律 + S 形桥接 + 连续时间项」的结构模型刻画开源能力前沿，并用双顺序 Shapley 分解把前沿增量拆分为规模贡献与技术贡献。在主窗口 2023.50 $\rightarrow$ 2025.00，base 前沿观测提高 24.759 分，其中模型解释的规模贡献为 23.063、技术贡献为 3.404，技术占比 12.86% (90% 区间 6.07%–21.96%)；剔除饱和和任务后的去饱和综合分在 2024-06 至 2025-03 由 26.36 升至 39.06 (+48.19%)，明显高于含饱和任务的 Average (+29.53%)。在算力增速由 0.60 降至 0.15 dex/yr 的情景下，24 个月 base 前沿中位数为 44.11，技术进步的增量占比由 54.94% 升至 76.70%。需说明，问题四的数值以 $T_0 = 2025.25$ 为历史锚点生成，属条件情景结果，更新数据截止日后需重新预测。

四问共同指向一个核心判断：数据质量与领域配比是与算力并列的一等资源。低预算阶段，边际投入主要应投向模型规模；当预算跨过质量收益与提质开销的平衡点后，提质与配比优化的优先级上升；而当算力增长放缓时，能力进步将越来越依赖非规模技术创新。全文定量结论的适用范围已在 11.2 集中说明。

关键词：数据质量；领域配比；广义标度律；算力约束优化；能力演进预测

1 问题重述

1.1 问题背景

大语言模型的预训练能力随模型参数量 N (个) 与训练 token 数 D (token) 增长, 经典标度律以验证集交叉熵损失 $L_0(N, D) = E + AN^{-\alpha} + BD^{-\beta}$ 刻画这一过程 [1, 2]。按本题采用的近似, 基础训练开销约为 $C \approx 6ND$ (FLOPs), 有限预算下必须权衡模型规模与数据量。仅用 N, D, C 不足以刻画真实训练: 语料质量与领域组成会显著改变同等投入的产出。为此, 需要先建立数据质量 Q 的可比口径与领域配比 $\mathbf{p}$ 的损失关系, 再将二者接入经典标度律, 形成统一的 $L(N, D, Q, \mathbf{p})$, 最终落到算力约束下的资源配置与能力演进判断。附件 A 提供质量信号与配比实验, 附件 B 提供标度律数据, 附件 C 提供模型、算力与能力评测信息。

1.2 问题描述

本题依次要求完成四项数学任务, 前一问的输出作为后一问的输入。

问题一: 数据质量与领域配比。建模对象为文档、领域与混合语料的质量, 以及 17 个训练领域配比对 13 个验证域损失的影响; 主要约束是质量信号方向与量纲不一、11 个配比域缺少直接质量映射, 且配比份额非负、总和为 1。本文用 A1 (51,230 篇) 拟合文档质量口径与全部预处理参数, 冻结后在扩展集 A2 (arxiv 17,523 篇)、A3 (github 203,752 篇) 上检验评分与诊断的稳定性; 用 A16 映射与 A18 文本特征把质量扩展到 17 域; A4/A5 按 index 连接作 1M 配比训练, A6/A7 作 1M 留出, A8/A9 作 60M 跨尺度检验与尺度修正标定, A10/A11 (各 64 行) 作 1B 独立检验, A12–A15 用于估算/外推情景讨论。

问题二: 广义标度律。建模对象为损失对 $N, D, Q, \mathbf{p}$ 的依赖; 若采用理想质量与参照配比下退回经典式的约束, 须说明依据; 且 A、B 两组损失的评测管线与质量尺度不可直接等同。本文以 B1 估计经典基线, 用 B6 (360 点, 半合成) 估计质量项并选择模型, 用 B7 相对 B6 新增的 90 点 ($Q = 0.5, 0.7$, 覆盖全部 45 个 (N, D) 格) 作留出; B2、B3、B4、B5、B8、B9、B10 分别用于半合成、插值、跨族、文献、方向冲突与估算对照, B11/B12 用于来源审计。问题一的域质量与配比关系经固定接口引入。

问题三: 算力约束下的资源配置。建模对象为给定预算 C (FLOPs) 与上下文长度 L_{ctx} (token) 下的 N, D, Q ; 约束包含训练、提质与长上下文三项成本, 质量下界由问题一推荐配比确定, 主方案固定该配比。本问读取问题一的质量与配比接口、问题二冻结的标度律参数, 不在本问重新拟合; C7 提供上下文长度的可行档位。

问题四: Benchmark 检验与能力演进。建模对象为开放权重模型的能力前沿及其规模与非规模来源; 要求能力、时间、模型类型与开放权重口径保持一致, 且损失与 Benchmark 得分不在同一尺度。C1/C2 提供榜单能力与发布日期, C4 补充规模与算力, C8 用于逐任务聚合与饱和度检查, C6 分层拟合损失到得分的桥梁, C3 仅作混合口径的敏感性对照。

2 问题分析

2.1 总体思路

四问按「测量数据—描述损失—优化训练—解释能力」层层递进：问题一从文档质量 $Q(x)$ 聚合到领域质量 Q_i ，再按配比得到语料质量 $Q(\mathbf{p})$ ；问题二在 $L_0(N, D)$ 上引入质量与配比，经典律正是广义律在 $Q = 1, \mathbf{p} = \mathbf{p}_{\text{ref}}$ 时的切片；问题三以标度律为目标，加入预算、提质与注意力成本约束求最优配置；问题四引入时间与 Benchmark 度量，把损失变化转化为能力前沿的解释与条件预测。各问的冻结结果通过 P1-P4 接口传递，未通过留出检验的配比通道不进入下游主优化。四问的参数、约束与接口传递关系在5的接口约定与6-9各问的模型建立中逐条说明。

2.2 各问题的关键难点

问题一：从异质指标得到唯一语料质量。logits、规则量与 DSIR 的方向和尺度各异，长度与领域基线会干扰质量判断，17 域中又有 11 域缺少直接评分。为避免冗余信号重复计权、避免单项极端指标支配整篇分数，本文采用 A1 冻结的域内预处理、CRITIC 权重与 Huber 中心；冲突在评分之后按来源诊断，不反向改分。领域质量以映射加文本桥接补齐，配比因份额闭约束采用中心对数比建模，并以 A6-A11 检验跨尺度边界。

问题二：统一跨附件质量口径并确定可推广的函数形式。A、B 两组损失的分词器与验证集可能不同，绝对值不可直接对齐，因此质量项不改动 B1 骨架的不可约项 E ，只乘在可约部分上，另加一项在 $Q = 1$ 处为零的地板。质量乘子的形状（幂次、指数、线性）不事先指定，本文在同一骨架上比较 M0-M4 与有无质量地板（不随规模消失的加项 $k_0(1 - Q)$ ）的嵌套族，用 B6 训练、B7 新增点留出。主式指定为幂次，以便把质量解释为有效规模；交叉验证表现更优的线性对照一并报告。配比效应仅有 1M 数据，无法识别其随规模的斜率，因此不估计尺度项，只设两个零新增参数的强度假设，再用 A6-A11 的观测斜率作事后比较。

问题三：处理非线性约束与边界转移。三项成本都与 D 成正比，而损失对 D 严格递减，故预算取等、可解析消去 D ，把问题降为 $(\log_{10} N, Q)$ 的二维有界优化。质量约束是否活跃构成质量状态的边界分类，其变化即最优策略的质变。三类提质成本函数的水平与边际曲率各不相同，单个成本项为凸不保证联合优化为凸，因此保留独立粗网格核对，并区分局部一阶根与全局状态切换。

问题四：界定能力演进的解释边界。Loss 与 Benchmark 得分尺度不同、任务会饱和、规模与时间共变、C3 口径混杂。本文采用可检验的 S 形损失—得分桥接与连续时间项，在一致的开放权重与模型类型口径下分解增长，并做窗口敏感性与回测。时间项只表示控制规模状态后的剩余关联，不直接解释为已识别的因果技术进步。

2.3 数据使用与证据分层

各附件的角色与证据性质见表 1，表中角色以对应 Spec 为准。

表 1 附件角色与证据性质（引自各问 Spec，非数据产物）

附件	内容	角色	证据性质
A1	七域质量信号抽样 51,230 篇	拟合与标准化参照（唯一）	真实
A2 / A3	arxiv 17,523 / github 203,752 篇	冻结评分与诊断的扩展检验	真实
A4 / A5	1M 配比与 13 域 Loss 各 512 组	配比主模型训练（唯一）	真实
A6 / A7	1M 配比与 Loss 各 256 组	同尺度留出	真实
A8 / A9	60M 配比与 Loss 各 256 组	跨尺度直接检验 + 尺度修正标定	真实
A10 / A11	1B 配比与 Loss 各 64 组	独立检验，不参与任何估计	真实
A12 - A15	10B/70B 配比（各 63 组）与 Loss	估算/外推情景对照	子集 / 外推，非观测
A16	17 域 → 7 质量域映射	映射参照	人工整理
A17	域统计摘要	背景与辅助	真实，未接入求解
A18	17 域原始文本 138,034 条（本轮有效 31,340 篇用于桥接预测）	桥接预测输入	真实
B1	Pythia 训练轨迹 1,176 行	经典基线拟合	真实训练设定，损失按公开公式生成（见审计）
B2	Cerebras 轨迹 1,029 行	族外趋势对照	半合成
B3	插值轨迹 4,000 行	轨迹对照	插值（B1 派生）
B4 / B5	跨族基准 57 行 / 文献点 44 行	外部趋势对照（ $Q = 1$ ）	真实 / 文献整理
B6	NQ 质量网格 360 行	质量项参数估计（唯一）	半合成
B7	扩展网格 450 行（新增 90 点）	留出检验	半合成， Q 方向插值
B8	大规模矩阵 1,704 行	方向冲突压力检查	半合成，与 B6/B7 方向相反
B9 / B10	100B+ 配置 132 行 / 预估 Loss 128 行	外推参照	真实元数据 / 估算
B11 / B12	模型族元数据 / Pythia 检查点索引	来源审计	真实
C1 / C2	榜单 4,576 行 + Epoch 匹配列	能力与发布日期	真实（同批榜单，非两套样本）
C3	历史时序 4,599 行	降权敏感性	混合口径
C4	全量模型元数据 3,523 行	规模、算力、开放权重	真实
C5 / C6	桥接表 43 / 75 行	损失—得分映射	混合口径，分层使用
C7	架构元数据 45 行	上下文长度档位	真实
C8	逐任务 JSON 1,958 个	逐任务聚合与饱和度	真实

3 模型假设

1. 质量信号可作相对测量。A 组指标经方向与域内尺度校正后，可比较同域文档的相对质量，不假定存在人工标注的绝对真值。该假设服务问题一的 $Q(x)$ ，并通过 A2/A3 冻结评分与删去极端指标的扰动检验其适用性。
2. 领域质量可按份额聚合。给定 A16 映射与桥接模型，混合语料质量取 17 域质量的份额加权值 $Q(\mathbf{p}) = \sum_i p_i Q_i$ ；配比对验证损失的额外影响单独建模。该假设服务问题一

至三，通过六个可映射域的桥接误差、A6/A7 留出与 A8-A11 检验其边界。

3. 评价目标预先固定。13 个验证域等权定义主目标，pile_cc 单域仅作敏感性口径，评价权重不随候选配比改变。该假设服务问题一配比搜索与问题三目标选择。
4. 质量刻度需要锚定。主口径取 $Q_B = Q(\mathbf{p})$ ，推荐配比处 $Q_0 = Q(\mathbf{p}^*) = 0.6624116679870492$ ； $Q = 1$ 且 $\mathbf{p} = \mathbf{p}_{\text{ref}}$ (A4 训练配比均值) 时广义式退回经典式，这是本文采用的约束，依据与检验见 7.5。副映射 $Q_B = Q(\mathbf{p})/Q_0$ 会使部分领域超出 $[0, 1]$ ，仅作敏感性处理。该假设服务问题二、三。
5. 成本按同一训练量计。训练、提质与注意力开销均以同一 D 计量，成本函数参数依赛题给定， $\eta = 2 \times 10^{-4}$ 为题设值。该假设服务问题三，并不预设三种成本函数下解的性质相同。
6. 非规模变化在窗口内平滑。问题四用连续时间项描述控制规模状态后的剩余得分变化，并以不同窗口与模型回测；遇到离散架构突破时该条件预测不适用。

4 符号说明

表2 主要符号及含义（含单位与角色）

符号	含义	单位	角色
N, D	模型参数量、训练 token 数	个, token	Q1/Q2 输入; Q3 决策变量
C	总训练算力预算	FLOPs	给定参数 (Q3)
$Q(x), Q_i$	文档主质量分、训练域 i 质量分	[0, 1]	估计量 (Q1)
$Q(\mathbf{p}), Q_B$	混合语料质量、B 组质量刻度; 主口径二者相同	无量纲	Q1 输出、Q2 输入
Q_0	推荐配比下的提质起点, 0.6624	无量纲	接口参数 (Q2/Q3)
$\mathbf{p} = (p_i)_{i=1}^{17}$	17 域训练份额, 非负且总和为 1	无量纲	决策变量 (Q1)
$z_j(x), w_j$	第 j 项标准化指标、冻结的 CRITIC 权重	[0, 1] / 无量纲	数据变换、估计参数
δ	Huber 中心阈值, 0.4034907036619329	[0, 1]	由 A1 确定的尺度规则
$B(x), u_s(x)$	六来源分歧度、来源 s 的 A1 参照分位	[0, 1]	诊断量
L_v, L	验证域 v 的损失、等权综合损失	nats	观测量或预测目标
T_{iv}	均匀配比附近域 i 份额对域 v 对数损失的局部效应	无量纲	估计参数 (Q1)
E, A, B, α, β	不可约损失、经典标度律幅度与指数	依公式	估计参数 (Q2, B1)
k_0, κ_N, κ_D	质量地板系数与两项质量幂次	nats, 无量纲	估计参数 (Q2, B6)
h_N, h_D	主式质量乘子 $Q^{-\kappa_N}, Q^{-\kappa_D}$	无量纲	函数 (Q2)
$s_{\text{red}}, \tilde{\varphi}(\mathbf{p})$	配比强度 (1M 训练定为 1.500)、配比偏离	无量纲	参数与由 Q1 给定的量
m_*	固定 $\mathbf{p}^*$ 的配比乘子 $\exp\{s_{\text{red}}\tilde{\varphi}(\mathbf{p}^*)\} \approx 0.899$	无量纲	Q3 的给定常数
$g(Q), L_{ctx}, \eta$	单位 token 提质成本、上下文长度、注意力成本系数 2×10^{-4}	FLOPs/token, token, —	给定函数与情景参数
S, t	Benchmark 综合得分、模型发布日期	分, 年	响应量、时间变量 (Q4)
L_{ctx}^{crit}	注意力与训练成本相等的上下文长度, $6/\eta = 30000$	token	解析结论

局部符号在首次出现处说明。

5 数据来源与接口约定

正文只使用三组附件的既有编号 (A1 – A18、B1 – B12、C1 – C10) , 单位纪律如下: N_params_B、D_tokens_B 的单位均为 10^9 , 代入 $C = 6ND$ 时须乘 10^{18} ; C_FLOPs_1e21 的单位为 10^{21} FLOPs, 不直接代入绝对预算 C 。跨问只传递已定义的质量分、配比与模型参数: 问题一输出 src/outputs_q1/interface/ 下的 P1_Q_domain.csv、P1_p_star.csv、P1_summary.json、P1_scale_calibration.csv 等; 问题二输出 src/outputs_q2/interface/P2_scaling_law.json 等; 问题三、问题四分别

输出 P3_*、P4_*。下游不读缓存文件。路径解析见 `src/code_q1/q1_00_common.py` 等脚本 (附件目录优先取仓库根目录附件/)。

6 问题一：数据质量与领域配比

问题一解决语料质量的量化评价与训练领域配比选择问题。本章依次完成三件事：建立可复现的文档及领域质量分，诊断评价指标之间的分歧，并在实验覆盖范围内建立配比与验证损失的关系、选出推荐配比。所得领域质量 Q_i 、推荐配比 $\mathbf{p}^*$ 、配比—损失关系与尺度校准信息经 P1 接口传入问题二，为广义标度律中的质量项和配比项提供输入，并为问题三的资源配置和问题四的检验预测提供基础。

6.1 任务一：数据质量评价

预训练语料的质量影响模型从数据中获取的信息，也是后续领域配比建模的重要输入。然而，语料质量缺少统一定义和人工标注真值，现有自动评价字段又存在形态、尺度与方向差异。A1 包含七个领域的 51,230 篇文档，用于确定质量评价方法及全部参数；A2 的 17,523 篇 arxiv 文档和 A3 的 203,752 篇 github 文档作为扩展集，在参数冻结后接受同一套评分，并用于检查评分分布的稳定性。

因此，任务一的本质是无人工真值条件下的多指标综合评价。我们先处理字段形态、评价方向、量纲和长度混杂，将原始字段转为可比指标；再依据指标的信息量及相关性确定权重，稳健合成为文档质量分，并汇总得到领域质量。以下依次说明数据预处理和综合评价模型。

6.1.1 数据预处理

数据预处理把 A1 的 22 个原始字段整理成 25 项方向一致、取值于 $[0, 1]$ 的可比指标。原始字段的输出形式不同，不能直接拼接或比较：四项 `modernbert_*` 各输出六档 logits，取 softmax 后的期望分；`qurater` 的四维向量拆成四项指标，是 22 项展开为 25 项的唯一来源；`ad_en` 与 `fluency_en` 取标签 1 的预测概率，其中前者的标签 1 表示「无广告」；`fineweb_edu` 从单元向量中取标量值。

11 项 `rps_*` 是规则型文本统计，其中词数、句数、平均词长和词熵四项不宜简单按「越高越好」处理，故以各域 A1 中位数为适宜中心，将偏离程度转为负值；其余指标按含义统一正负方向，对适用的重尾非负量作 $\log(1+x)$ 变换。这样既保留规则统计的信息，又避免把极端长度或熵值直接解释为更高质量。

DSIR 的三项重采样权重还存在明显的长度混杂。未经处理时，它们与词数的 Spearman 相关在 A1 七域中均为负，21 组「领域—指标」的绝对相关中位数达 0.957：若直接纳入评分，文档长短可能被误当成质量差异，影响文档排序和领域汇总。为削弱这一关系，先将 DSIR 除以 $\max(\text{词数}, 1)$ ，再在 A1 各域内对 $\log(1 + \text{词数})$ 回归并取残差；A2/A3 复用 A1 的回归系数。

图 1 把同一「领域—指标」在原始、除词数、残差化三个阶段的词数绝对相关连成一条线。中位数在除词数后降至 0.599，残差化后降至 0.095，说明长度关联明显减弱，但并未完全消失；book 域最高剩余 $|\rho| = 0.503$ ，该域仍需谨慎解释。相关降低只表明长度影响减少，不能据此断言指标更接近真实质量。




图1 A1 七域三项 DSIR 指标在长度校正前后的词数绝对 Spearman 相关（每条细线对应一组领域一指标，黑线为 21 组中位数）

最后，各域各指标用 A1 的 1%/99% 分位缩尾，按 A1 端点 Min-Max 归一到 $z_j(x) \in [0, 1]$ ，缺失值用 A1 同域同指标的标准化中位数填补。回归系数、适宜中心、缩尾分位、归一端点和填补值均只在 A1 上确定并冻结，A2/A3 仅作前向应用，使三集分数遵循同一评价规则。

6.1.2 数据质量综合评价模型

预处理后得到 25 项可比指标，首先要确定各项指标的权重。表 3 比较了三种常用赋权方法在本题无人工质量真值、多项指标同源的情况下各自能解决的问题与局限。

表 3 质量指标赋权方法在本题条件下的比较

方法	优点	在本题中的局限
层次分析法	可表达专家对不同质量维度的判断	缺少人工质量标注与稳定的专家判断依据，权重难以复现
熵权法	由指标离散程度客观定权，无需人工标注	同源且高度相关的指标可能因各自离散而被重复计权
CRITIC	同时考虑指标离散程度与指标间相关性，可减轻冗余计权	依据总体相关结构定权，不能单独处理某篇文档的极端或对立指标

本题需要一套只由 A1 确定、可冻结并应用于 A2/A3 的权重。CRITIC 方法 [3] 同时利用指标的区分能力和相关结构，适合抑制同源指标的重复贡献，因此采用它计算固定权重：

$$C_j = s_j \sum_{k=1}^{25} (1 - r_{jk}), \quad w_j = \frac{C_j}{\sum_k C_k}, \quad \sum_j w_j = 1. \quad (1)$$

其中 s_j 为 A1 标准化指标的样本标准差， r_{jk} 为指标 j, k 的 Pearson 相关系数。赋权解决的是总体冗余，逐篇合成仍要面对另一现象：部分指标远离同篇其余指标，低端极值若直接进入算术均值，可能把局部异常意见放大为整篇文档的低质量分；同一起来源组内部也可能出

现相反意见，下一任务将专门诊断这种冲突。普通中位数虽能削弱极值，却不利用权重和偏离幅度。因此本文用加权 Huber 中心 [4] 合成文档分数：在中心附近保留加权平方损失，对超过阈值 δ 的偏离限制边际影响，从而减弱单项极端指标拉低综合分的作用。

$$Q(x) = \arg \min_{q \in [0,1]} \sum_{j=1}^{25} w_j \rho_{\delta}(z_j(x) - q), \quad \rho_{\delta}(u) = \begin{cases} \frac{1}{2}u^2, & |u| \leq \delta, \\ \delta(|u| - \frac{1}{2}\delta), & |u| > \delta, \end{cases} \quad (2)$$

由方程 $\sum_j w_j \text{clip}(q - z_j, -\delta, \delta) = 0$ 在 $[0, 1]$ 上二分求解。阈值 δ 仅由 A1 确定：取每篇的加权指标中位数 m_x 与加权 MAD $a_x = \text{wmedian}_j |z_j - m_x|$ ，再令 $\delta = 1.345 \times 1.4826 \times \text{median}_{x \in A1} a_x \approx 0.4035$ (1.4826 为正态尺度校正、1.345 为 Huber 经典效率常数)。25 项权重介于 fineweb_edu 0.0359 与 modernbert_professionalism 0.0671 之间，没有任何单一指标主导评分。综合质量分确定后，任务二再按来源追查组内与组间的相反意见；该诊断不反向调整本式的权重或分数。

6.1.3 领域质量结果与稳健性检验

领域质量结果 领域质量取域内文档分数的中位数，并以 2,000 次文档 bootstrap 给出条件 95% 区间。表 4 同时列出 A1 七域、A2 的 arxiv 与 A3 的 github；扩展集只与 A1 的同名领域比较。

表 4 A1 抽样集与 A2/A3 扩展集的领域综合质量分（数据源：T2_domain_quality.csv）

数据集	领域	文档数	中位数 Q	bootstrap 95% 区间	相对 A1 同域差值
A1	arxiv	1,419	0.7707	[0.7671, 0.7754]	—
A2	arxiv	17,523	0.7697	[0.7688, 0.7705]	-0.0010
A1	commoncrawl	9,640	0.6761	[0.6739, 0.6784]	—
A1	stackexchange	10,000	0.6600	[0.6582, 0.6621]	—
A1	c4	10,000	0.6545	[0.6525, 0.6566]	—
A1	book	171	0.6313	[0.6138, 0.6500]	—
A1	github	10,000	0.6172	[0.6157, 0.6189]	—
A3	github	203,752	0.6158	[0.6154, 0.6162]	-0.0014
A1	wikipedia	10,000	0.5991	[0.5971, 0.6015]	—

A1 中 arxiv 的中位质量最高，wikipedia 最低；图 2 展示了七域的完整分布，说明只看一个域级点估计仍会遗漏域内变异。




图2 A1 七域的CRITIC 加权 Huber 综合质量分分布

抽样集与扩展集对照 A2 arxiv 与 A1 同域中位数相差 -0.0010 ，A3 github 与 A1 同域相差 -0.0014 ；两组分布的 KS 距离分别为 0.0265、0.0107。这表明在相同评分规则下，两域抽样结果与扩展集接近。A1 的对应文档包含在 A2/A3 中，因此该对照检查的是抽样代表性，不能当作独立质量真值验证。

稳健性核验 综合质量分与同权重算术均值、PCA、TOPSIS 的文档排序 Spearman 分别为 0.9936、0.8166、0.9588：它与算术均值的排序几乎一致，PCA 对部分文档的排序则有明显调整，不能说合成方法完全不影响结果。逐篇剔除最偏离的一个指标后，在极端程度最高 10% 的文档 (5,123 篇) 中，综合质量分的绝对变动中位数为 0.0260 (P90 0.0340)，算术均值为 0.0374 (P90 0.0488)。这些数值是 $[0, 1]$ 评分尺度上的变动，说明 Huber 中心对单项极端意见约少受 30% 影响，不说明它更接近未知的真实质量。

由于没有人工质量真值，本任务只能报告方法一致性与扰动稳健性，不能报告质量准确率；这一证据边界在后文模型评价部分继续讨论。

6.2 任务二：质量冲突消解

任务一发现，同一文档的质量指标可能给出相反评价，甚至同组指标也会分裂。这类分歧并不修改任务一得到的综合质量分，而是需要被识别出来并解释其来源，以判断单个质量分是否可靠、哪些文档值得优先复核。为此，本任务先在 6.2.1 定义冲突及筛查阈值，再在 6.2.2 划分类型并分析可能成因，最后比较折扣处理前后的质量分。

6.2.1 质量冲突的定义与识别

这里的质量冲突，指同一文档的指标在各自参照分布中处于明显相反的位置，而非文档质量已被证实有误。原始分数的量纲不同，不能直接相减。我们先按生成机制把 25 项指标分为 RPS (11 项)、DSIR (3 项)、轻量分类器 (2 项，即 `ad_en` 与 `fluency_en`)、FineWeb-Edu (1 项) [5]、QuRating (4 项) 和 ModernBERT (4 项)；每项只归入一个来源，避免指标多的来源在比较中自然占优。

对领域 d 的指标 j ，用 A1 同域经验分布将标准化分 $z_j(x)$ 转为百分位排名 $r_j(x) = F_{dj}^{A1, \text{mid}}(z_j(x))$ ，同值取中秩。再取来源 s 内指标排名的中位数 $m_s(x)$ ，并按 A1 同域的来源中心分布将其转为 $u_s(x)$ ；A2/A3 沿用 A1 的参照分布。这样六个来源各提供一个可比的相对评价，来源间冲突程度定义为

$$B(x) = \max_{s=1, \dots, 6} u_s(x) - \min_{s=1, \dots, 6} u_s(x). \quad (3)$$

$B(x)$ 越大，最高与最低来源的相对评价相距越远。以 A1 各域 B 的第 95 百分位为阈值 τ_d ，将 $B(x) > \tau_d$ 的文档列为高分歧候选；A2/A3 使用相应 A1 域的同一直值。P95 将 A1 每域的候选比例控制在约 5%，这是预设筛查范围，不是真实冲突率。图 3 比较 P90、P95、P97.5 三档：A1 候选比例依次约为 10.00%、5.00%、2.50%，A2 为 9.19%、4.73%、2.00%，A3 为 9.74%、4.99%、2.44%。阈值越严格，入选文档越少；三集变化方向一致，但这不能证明哪档阈值更准确。




图 3 A1 阈值分位变化对 A1-A3 高分歧候选比例的影响

6.2.2 冲突类型以及成因分析

6.2.1 已圈定高分歧文档，但还需分清分歧由多少来源支持。若高端 $u_s \geq 0.8$ 与低端 $u_s \leq 0.2$ 各有至少两个来源，记为「多来源对立」；其余高分歧文档记为「稀疏来源对立」。

另用来源内跨度和逐指标留一偏离，单列未达到来源间高分歧、仅一个指标在一个来源中明显偏离的「单指标独有」候选。前两类共同划分高分歧集合，第三类属于另一套筛查口径，不与前两类相加。

表 5 显示，A1 的 2,561 篇高分歧文档中，695 篇达到多来源对立条件，其余 1,866 篇属于稀疏来源对立。A2/A3 的高分歧比例接近 A1，分别为 4.73% 与 4.99%；这表明筛查工作量在扩展集上相近，不能解释为真实质量错误的比例。

表 5 A1-A3 质量冲突候选的类型与规模（数据源：T3_six_source_candidate_summary.csv）

候选类型	A1: 51,230 篇	A2: 17,523 篇	A3: 203,752 篇
来源间高分歧	2,561 (5.00%)	829 (4.73%)	10,167 (4.99%)
其中多来源对立	695 (1.36%)	277 (1.58%)	3,598 (1.77%)
其中稀疏来源对立	1,866 (3.64%)	552 (3.15%)	6,569 (3.22%)
单指标独有	2,879 (5.62%)	709 (4.05%)	8,606 (4.22%)

来源内部的不一致是第一种可能成因。图 4 以组内指标排名的 P90-P10 跨度比较六个来源：A1 的 RPS 跨度中位数为 0.625，远高于 DSIR 的 0.037；两组的 Kendall W 分别为 0.140 和 0.967。RPS 同时包含长度、重复和符号等不同侧面的规则统计，因而组内意见更容易分散；FineWeb-Edu 只有一项指标，内部跨度不定义。




图 4 A1 六来源内部跨度与一致性对照

A1 有 69.45% 的文档在 RPS 内同时出现低于 20% 和高于 80% 的指标排名，说明将 11 项规则统计压成一个来源中位数会遮住组内分歧；这些相反排名并不等于某项指标测量错

误。

第二种可能成因是不同评价机制关注的质量侧面不同。图 5 的纵轴为高评价来源、横轴为低评价来源，每篇高分歧文档的来源配对总权重为 1；A1 最常见的是「RPS 高、FineWeb-Edu 低」，占高分歧候选的 8.03%。A3 的同方向份额为 13.03%，A2 则以「ModernBERT 高、FineWeb-Edu 低」最高（9.89%）。主导方向随语料域变化，提示规则统计与模型评分器侧重不同，但没有人工真值，不能据此判定哪一方正确。




图 5 六来源对立方向的加权份额

与历史四组法比较时，原阈值选出的 A1/A2/A3 候选比例为 19.08%/24.52%/23.28%，明显高于六来源约 5%；直接比较两法会把阈值差异也算进去。按 A1 各域前 5% 对齐筛查比例后，两法在三集上的 Jaccard 为 0.324/0.283/0.259，说明即使入选规模相近，来源划分和排名方式仍会改变候选集合；重合度不能当作识别准确率。

6.2.3 折扣对照模型 Q_{v2}

为检验来源内部一致性对综合分的影响，本文另建一个折扣对照模型。其数学形式借鉴 Dempster-Shafer 证据理论中的可靠性折扣 [12]：将每个来源的指标意见视为证据，以该来源的 Kendall W 作为折扣系数，对原 CRITIC 权重作折扣后再归一化合成：

$$\tilde{w}_j = \frac{w_j W_{s(j)}}{\sum_k w_k W_{s(k)}}, \quad Q_{v2}(x) = \arg \min_q \sum_j \tilde{w}_j \rho_{\mathcal{S}}(z_j(x) - q). \quad (4)$$

Q_{v2} 与综合质量分在 A1/A2/A3 的全局 Spearman 为 0.9547/0.9207/0.9395，A1 七域中位数排序未变，但分数水平有所调整，例如 arxiv 上升 0.0303、wikipedia 下降 0.0583。A1 高分歧候选与其余文档的 $Q_{v2} - Q$ 中位数分别为 -0.0260、-0.0309，变化并未集中在候选文档上。因此该折扣模型只用于检查来源权重改变的影响，不能称为已验证的冲突消解效果；后续 P1 接口仍使用式 (2) 的综合质量分。

6.3 任务三：领域配比建模

前两项任务在 A1 的七个质量域上建立了文档和领域质量分，但配比实验使用 A16 所列的 17 个训练域。两套领域划分并不一致，其中 11 个训练域没有可直接对应的质量分，因而不能将七域结果直接用于 17 维配比。为衔接两类数据，本任务先依据 A16 的映射关系与 A18 的文本特征完成领域桥接，得到各训练域的质量分 Q_i 。

赛题要求在算力约束下配置训练语料，领域份额的改变会影响各验证域的交叉熵；领域质量高也不意味着增加其份额一定能更有效地降低损失。因此，还需利用配比实验建立份额与验证损失的定量关系，而将 $Q(\mathbf{p})$ 作为配比对应的数据质量描述，供后续广义标度律和资源配置模型使用。下文依次完成领域桥接、配比—损失建模、跨尺度检验与推荐配比选择。

6.3.1 语料质量的领域桥接

领域桥接要解决的是 A1–A3 的七个质量域与 A16 的 17 个训练域不一致的问题。A16 给出三类对应关系：3 个域同名直连（direct），3 个域语义接近（near_direct），另有 11 个域在 A1 中没有对应质量域（inferred）。表 6 将桥接类别、训练域、最终质量分 Q_i 与对应的 A1 质量域并列；横线表示没有直接对应域。

表 6 A16 训练域与 A1 质量域的桥接及最终质量分（数据源：T4_bridge_17domains.csv）

桥接类别	训练域（A16）	域级 Q_i	对应质量域（A1）
direct	arxiv	0.7707	arxiv
direct	stackexchange	0.6600	stackexchange
direct	github	0.6172	github
near_direct	pile_cc	0.6761	commoncrawl
near_direct	gutenberg_pg_19	0.6313	book
near_direct	wikipedia_en	0.5991	wikipedia
inferred	ubuntu_irc	0.7112	—
inferred	philpapers	0.7099	—
inferred	europarl	0.7091	—
inferred	nih_exporter	0.6928	—
inferred	hackernews	0.6902	—
inferred	uspto_backgrounds	0.6882	—
inferred	pubmed_central	0.6762	—
inferred	pubmed_abstracts	0.6701	—
inferred	freelaw	0.6303	—
inferred	enron_emails	0.5899	—
inferred	dm_mathematics	0.5087	—

桥接策略 A16 的人工映射为前六域提供语义依据：direct 与 near_direct 域取相应 A1 质量域的综合分中位数及同源 bootstrap 区间。对 11 个 inferred 域，仅靠名称无法指定质量分，故从 A1 和 A18 原文提取 11 项同名近似规则特征 $\Phi(\text{text})$ 。以 A1 的 21,590 篇原文及其已得 $Q(x)$ 为训练样本，按域分层五折比较 Ridge 与 GBDT，标准化参数只从各折训练部分估计；选定 GBDT 后，对 A18 的 31,340 篇文档预测并逐域取中位数和文档 bootstrap 区间。

由此，直接映射与模型推断的点估计和区间各自同源，不混用两套证据。配比的质量描述为

$$Q(\mathbf{p}) = \sum_{i=1}^{17} p_i Q_i, \quad p_i \geq 0, \quad \sum_i p_i = 1. \quad (5)$$

结果与风险 GBDT 的分层五折 R^2 均值为 0.4106 (Ridge 为 0.3415)；六个可映射域的预测与 A1 分数的 Spearman 为 0.7714、MAE 为 0.0365，但比较仅有六个域，不能视为独立质量真值验证。表 6 中最高为 arxiv 0.7707，最低为推断得到的 dm_mathematics 0.5087。主要风险在于 near_direct 的语义映射可能有偏差，inferred 域的 bootstrap 区间仅覆盖给定模型下的文档抽样波动，不包含模型选择或跨域误差；ubuntu_irc (16 篇) 和 philpapers (63 篇) 样本尤其少。我们保留桥接类别并为点估计附上同源区间，对这两域作低置信标记，后续使用 Q_i 时不把推断分数表述为直接观测。

6.3.2 配比—损失模型

得到 Q_i 后仍不能仅按质量高低分配训练份额：不同领域语料对 13 个验证域交叉熵的边际作用要由配比实验估计。借鉴配比回归的建模思路 [7]，将 A4 的 17 维份额与 A5 的验证 Loss 按 index 连接；份额之和恒为 1，故先用中心对数比 (clr) 变换处理闭约束 [6]，再对每个验证域拟合稳健的线性关系：

$$\xi_i(\mathbf{p}) = \log p_i - \frac{1}{17} \sum_{k=1}^{17} \log p_k, \quad \log L_v = b_v + \sum_{i=1}^{17} \beta_{vi} \xi_i(\mathbf{p}) + \varepsilon_v. \quad (6)$$

非正份额先以 10^{-4} 替换并重新闭合。式 (6) 的系数由 Huber 回归估计，是后续迁移矩阵和推荐配比的共同依据；另外用原始份额 OLS 作线性基准，以深度为 1 的决策树（树桩）构成的 GBDT 检查是否存在非线性响应。GBDT 可以拟合单个份额的非线性变化，但树桩不含领域间交互，不能据此解释领域组合效应。

训练与检验 三种模型均只用 A4/A5 的 512 组 1M 实验拟合。GBDT 的树数与学习率仅在这 512 组内部按五折交叉验证选定（网格为学习率 $\{0.03, 0.06, 0.12, 0.25\} \times$ 树数 $\{100, 250, 500, 1000\}$ ），选定 1,000 棵、学习率 0.12 后重拟合；A6/A7 的 256 组 1M 实验留作比较，A8–A11 的 60M、1B 结果只用于下一小节的跨尺度检查与校准，不调整 1M 配比系数。

表 7 给出 1M 留出结果。GBDT 的逐域拟合和等权目标排序均优于线性模型；clr+Huber 的优势是系数可解释，并与下游配比接口保持一致，故作为配比主模型，GBDT 用于预测能力和推荐配比的交叉检查。裸份额 OLS 的等权目标排序虽高于 clr+Huber，但逐域平均 R^2 较低，不能说 clr 在每项指标上都占优。

表 7 A6/A7 的 1M 留出集上配比模型的表现与用途

模型	逐域 R^2 均值	目标 Spearman	优点	局限
clr+Huber	0.772	0.523	系数可解释，可直接形成下游接口	等权目标排序弱于两个对照
裸份额 OLS	0.654	0.668	形式简单，可检验 clr 变换的作用	未处理份额闭合，逐域拟合较弱
树桩 GBDT	0.923	0.942	捕捉单域非线性，留出预测最好	无稳定线性系数，不能解释领域交互

图 6 展示主模型在 1M 留出集上各验证域的预测与实测对数交叉熵：散点整体贴近对角线，各域的对数空间 R^2 介于 0.68 与 0.88 之间，说明线性形式在实验覆盖范围内能较好刻画份额与损失的关系，拟合较弱的主要是 pile_cc、hackernews 等域。图中 R^2 为对数损失空间口径，与表 7 的原始损失空间逐域 R^2 均值 0.772 略有不同。




图 6 配比主模型在 1M 留出集上的逐域预测与实测对数交叉熵（对角线为完全一致，子图标注对数空间 R^2 ）

在线性模型的均匀配比处将系数投影到单纯形切空间，得到 17×13 迁移矩阵 $T_{iv} = 17(\beta_{vi} - \bar{\beta}_v)$ 。图 7 的主对角元均为负，表示在该局部位置提高某训练域份额时，其同名验

证域的预测损失倾向下降；这是局部关联，不是因果效应。另加入质量交互项后，仅 6/13 个验证域的 bootstrap 区间不含零且方向不一，说明 Q_i 无法代替配比实验来推断各域的训练边际价值。




图 7 17 × 13 迁移矩阵：各验证域对训练域份额的局部敏感度

6.3.3 跨尺度检验与尺度修正

跨规模问题 式 (6) 的系数来自百万参数模型的配比实验。把这一模型原样用于 6000 万和 10 亿参数模型时，需要分别检查两件事：它能否排出较优配比，以及它预测的交叉熵数值是否接近实测。后者存在明显的整体偏移，因此保留百万参数模型的配比系数，记 $g_v(\mathbf{p}) = \beta_v^{\text{IM}} \cdot \text{clr}(\mathbf{p})$ 、 $t = \ln(N/10^6)$ ，用下式修正不同参数规模下的预测：

$$\ln L_v(\mathbf{p}, N) = \underbrace{b_v^{\text{IM}} + \rho_v t}_{\text{截距漂移}} + \underbrace{s(N)}_{\text{效应缩放}} g_v(\mathbf{p}), \quad s(N) = \left(\frac{N}{10^6} \right)^{-\lambda} \quad (\text{本文采用}), \quad 1 + \kappa t (\text{对照}). \quad (7)$$

式中 $\rho_v t$ 调整各验证域交叉熵的整体水平， $s(N)$ 调整配比变化的影响幅度。 b_v^{IM} 与 $s(10^6) = 1$ 来自 A4/A5；A8/A9（6000 万参数）仅用于确定 13 个 ρ_v 与共同缩放参数（幂律 $\lambda = -\ln s(60\text{M})/t_{60}$ ），A10/A11（10 亿参数，各 64 组）不参与估计，只作独立检验。幂律形式在查看 10 亿参数结果前预先登记：它保持 $s(N) > 0$ 并随规模单调衰减；对照的 $1 + \kappa t$ 在很大规模下可能变负。

配比优劣顺序 图 8 比较同一批配比在“预测的 13 个验证域等权交叉熵”和实测交叉熵下的优劣次序；Spearman 相关系数越接近 1，越能把低损失配比排在前面，但它不衡量交叉熵数值预测是否准确。线性模型在 1M 留出、60M、1B 上分别为 0.523/0.467/0.677；GBDT 为 0.942/0.905/0.761。树模型在三个规模上排序更一致，但到 1B 已下降，且该档只有 64 组配比。




图 8 在百万参数模型实验上训练的领域配比模型：预测与实测配比优劣顺序的一致性

交叉熵数值 图 9 的每根柱表示该规模全部配比、13 个验证域的平均交叉熵，数值越低越好。6000 万参数是修正参数的标定集：实测均值 3.82，直接沿用百万参数模型预测为 5.31，修正后为 3.81，其接近实测属于同集标定效果。10 亿参数才是独立检验：实测 2.23，直接预测 5.18，修正后仍为 3.00。因此修正大幅缩小了水平误差，却未充分捕捉交叉熵随模型增大的下降幅度；A12-A15 的非观测估算不纳入该图。




图 9 6000 万参数标定集与 10 亿参数独立检验集的平均交叉熵：实测、直接预测与尺度修正后预测

逐组误差 表 8 的 MAE 是每组配比、每个验证域预测交叉熵与实测值的绝对差再取平均，区别于图 9 中仅比较总体均值。表中“未修正”即直接沿用百万参数模型；“同集拟合”使用了 10 亿参数数据估计参数，只作误差下界参照。独立检验上，修正使逐域 MAE 由 2.9525 降至约 0.77（约 74%），等权目标的排序相关由 0.677 升至约 0.713，但逐域 R^2 仍为负，说明数值外推仍不理想。

表 8 10 亿参数模型上的独立检验结果（A10/A11，各 64 组；数据源 T6_scale_correction.csv）

预测方法	逐域 MAE 均值	目标 MAE	逐域 R^2 均值	目标 Spearman	平均预测 Loss
未修正	2.9525	2.9525	-604.7	0.677	5.178
仅修正截距	0.7699	0.7684	-33.4	0.712	2.994
截距 + 幂律缩放	0.7711	0.7708	-35.2	0.713	2.996
截距 + 线性缩放	0.7714	0.7712	-35.3	0.713	2.997
同集拟合（参照）	0.0819	0.0287	0.624	0.702	2.222

形式选择与误差含义 按预先登记的规则，幂律修正在 10 亿参数上的逐域 MAE 为 0.7711，略低于对数线性对照的 0.7714，两者的等权目标排序相关同为 0.7127，故采用幂律形式。但 0.0003 的误差差距远小于 64 组样本的抽样波动，选择主要基于幂律保持正值且随规模衰减的结构性质，不能把这点差距解释为预测精度的可靠提升。

修正后的主要误差来自水平外推：观测交叉熵每增加一单位 $\ln N$ 的平均下降幅度，从 1M→60M 的约 0.08 增至 60M→1B 的约 0.19，两档数据无法识别这一曲率。配比效应的幂律外推为 0.858，而在 10 亿参数数据上同集拟合得到 0.612，表明配比影响实际衰减得更快；后者只用于定位偏差，不回填预测模型。同一函数形式直接在 10 亿参数上拟合时 MAE 约 0.08，它仅是同集误差下界，不代表跨规模预测能力。

校准接口与外推反例 固定百万参数模型系数计算的汇总校准斜率，在 1M 训练/留出/60M/1B 上为 1.004/0.995/0.913/0.612 (P1_scale_calibration.csv)。前两档接近 1，后两档下降，表示训练配比差异对交叉熵的影响随模型规模增大而减弱；该斜率不是质量准确率。A12-A15 是估算/外推表而非观测，其同配比目标排序相关为 -0.532/ - 0.588，与 1M→60M 实测的逐域 Spearman 均不低于 0.98 不一致，因此仅作为更大规模外推风险的反例。

6.3.4 推荐配比与接口输出

候选最优配比 以 A4 平均配比为基准、用四档浓度 Dirichlet 生成 99,996 个候选。本文在线性模型的信赖域内选取推荐配比：候选 clr 向量到 A4 训练配比的马氏距离（协方差加 $10^{-3}I$ 岭）不超过训练配比自身距离的 95% 分位，且每域份额不超过 A4 该域最大值。信赖域内分别按 13 域等权损失与 pile_cc 单域损失，取预测最优的前 100 个份额平均，得到 p_star_eqweight、p_star_pilecc；GBDT 在同一信赖域内另选 p_star_gbdx 作稳健对照。信赖域阈值取 clr 马氏距离 21.85，保留 46,168/99,996 个候选；不加信赖域时，线性模型会在远离训练分布的组合上给出不可信的低损失，故信赖域是必要的防外推设置。

推荐配比结果 表 9 给出各候选配比的对照。推荐配比 $\mathbf{p}^*$ 使预测等权损失降到 4.875，较均匀配比（5.385）下降 9.47%；线性模型与 GBDT 选出的配比高度一致（全变差距离 0.0344，即两配比各分量绝对差之和的一半；改用 GBDT 交叉评估线性模型所选配比，收

益同为 9.47%)。固定 $\mathbf{p}^*$ 的 bootstrap 收益中位数为 9.54%、95% 区间 [7.82%, 11.16%]，每次重选结果与推荐配比的全变差中位数仅 0.019（图 10）。该收益是 1M 代理模型内的预测差异，用于在真实训练前指导配比选择。

表 9 候选配比对照（数据源：T7_pstar_benchmark.csv、P1_p_star.csv）

配比	线性预测 等权 Loss	GBDT 预测 等权 Loss	线性 评估收益	GBDT 交叉评估收益	马氏距离	$\bar{Q}$
$\mathbf{p}^*$ 等权（线性，本文采用）	4.875	4.901	9.47%	9.47%	13.9	0.66241
$\mathbf{p}^*$ GBDT 对照	4.927	4.811	8.51%	11.12%	10.4	0.66297
$\mathbf{p}^*$ pile_cc（线性）	5.074	4.963	5.77%	8.31%	4.0	0.66393
训练配比均值	5.198	5.177	3.48%	4.36%	0.5	0.66399
均匀配比	5.385	5.413	0	0	2.7	0.66065




图 10 信赖域内候选配比分布与推荐配比、均匀配比位置

质量与训练边际价值的关系 17 域质量分与训练边际价值的 Spearman 仅为 -0.211 （图 11）：质量高的域其训练边际价值未必高，单凭质量分无法替代配比实验。推荐配比 $\mathbf{p}^*$ 的配比加权质量 $\bar{Q}(\mathbf{p}^*) \approx 0.6624$ ，训练配比均值处为 0.6640、均匀配比处为 0.6606（P1_summary.json）。




图 11 17 域质量分与训练边际价值的散点关系

6.4 本章小结

本章以 CRITIC 加权 Huber 模型量化文档质量，以六来源分歧模型识别指标间相反评价，再通过领域桥接和 clr+Huber 配比模型把质量与训练配比接入验证交叉熵。表 10 汇总各环节最能说明结果及其边界的指标。

表 10 问题一的关键结果及其实际含义

环节	关键指标	含义与边界
质量评价	A1 arxiv、wikipedia 的域级 Q 中位数分别为 0.7707、0.5991	在同一评分规则下两域有明显差异；无人工真值，不能解释为质量准确率
冲突识别	RPS 组内 Kendall $W = 0.140$ ；69.45% 的 A1 文档在该组同时出现高低两端指标	同一规则来源内部也会给出相反相对评价，不能仅用来源中位数概括全部指标
领域桥接	分层五折 $R^2 = 0.4106$	规则特征能保留部分质量排序；11 个 inferred 域的分值仍受模型与跨域偏差影响
配比选择	推荐配比在 1M 代理模型中预测等权交叉熵降低 9.47% (bootstrap 95% 区间 [7.82%, 11.16%])	这是实验覆盖区域内的模型预测收益，不是重新训练模型后的实测改善
跨规模检验	10 亿参数的逐域 MAE 由 2.9525 降至 0.7711；平均预测交叉熵仍为约 3.00，实测约 2.23	尺度修正减小了误差，但绝对损失水平的外推仍有明显偏差

领域质量 Q_i 、推荐配比 $\mathbf{p}^*$ 、配比—损失系数与尺度校准信息经 P1 接口传入问题二，为质量与配比进入广义标度律提供输入；问题三据此研究算力预算下的模型和语料配置，问题四再检验损失预测与 Benchmark 表现的联系。桥接估计及跨规模外推的局限需要在后续结论中继续保留。

7 问题二：含质量与配比的广义标度律

7.1 问题重述

问题二把经典标度律扩展为同时依赖参数量 N 、训练 token 数 D 、B 组质量 Q_B 与领域配比 $\mathbf{p}$ 的损失模型，并完成四项分析：估计各因素的边际效用与弹性；借助问题一的迁移结构讨论领域间的功能替代与覆盖互补；给出「提高质量」与「扩大参数或算力」相互替代的条件及数值例子；在附件 B 上完成参数估计、嵌套检验与留出检验，并把冻结参数交给后续问题。附件 A 仅通过问题一已输出的域质量与配比接口进入，本问直接使用附件 B。下文公式中的 Q 均指 Q_B 。

7.2 问题分析

经典基线。在 B1（8 个 Pythia 模型、1,176 行）上估计 $L_0(N, D) = E + AN^{-\alpha} + BD^{-\beta}$ [8]。B1 损失与 Hoffmann 等 [1] 的公开公式常数几乎重合，因此把其训练设定作为真实来源信

息、把损失数值作为公式生成的基线。参数用幂次网格搜索、 E, A, B 用线性最小二乘，并用 $C/(6ND)$ 核对算力记账。

质量项。题目允许采用「 $Q = 1$ 时退化为经典形式」一类约束，但须说明依据。本文采用该约束（ $Q_B = 1$ 且取参考配比时回到 L_0 ），依据在模型建立中从刻度锚定、可识别性与嵌套检验三方面给出，并用 B6 的 $Q = 1$ 切片事后检验。质量网格只出现在半合成的 B6、B7、B8，质量乘在参数项还是数据项、随质量变化的曲率如何，均由候选比较确定，且 B8 与 B6/B7 方向相反。本文在同一骨架上比较幂次、指数、线性三类乘子以及有无地板、 κ 是否可收缩的嵌套族，用 B6 训练、B7 新增点留出。主式固定为幂次 M4 加地板，把质量解释为有效参数量与有效数据量；该形状来自有效样本量的恒定弹性设定 [13]，而非交叉验证排名，留出误差更低的线性、指数对照一并报告。

两套实验的统一。附件 A 是固定小规模的比例实验，附件 B 是规模实验，二者都以交叉熵为观测量，但没有同一批 $(N, D, Q, \mathbf{p})$ 的联合试验。配比只能通过问题一在 1M 上估计的 clr 系数乘到 B 侧可约损失上。A4/A5 全部位于 1M，无法识别配比斜率随 N 的变化，因此不估计尺度项，只设两个零新增参数的强度假设，再用 A6–A11 的观测斜率作事后比较。

边际、替代与单位算力。目标写成闭式后，弹性、等损失曲线与 $6ND = C$ 上的最优参数量均可解析求出并用数值解核对。领域关系取自问题一迁移矩阵行向量的余弦；单位算力比较把提质成本 $g(Q)$ 与扩参数算力放在同一 FLOP 上，回答「一份算力投向质量还是参数」。

7.3 模型假设

1. 同一观测量。附件 A、B 的损失均为验证集交叉熵，可写入同一个 L ；通过 $Q = 1$ 切片与 B4、B5 的趋势相关核对。
2. 经典骨架。损失的规模部分取 $L_0 = E + AN^{-\alpha} + BD^{-\beta}$ ， $\alpha, \beta > 0$ ， E 为不可约损失；B1 由公开公式生成，用拟合残差和 $C/(6ND)$ 核对。
3. 退化条件（采用的约束）。 $Q = 1$ 且 $\mathbf{p} = \mathbf{p}_{\text{ref}}$ 时质量乘子、配比乘子均为 1 且质量加项为 0，广义式回到 L_0 。这是本文主动采用的约束而非题设给定，依据见 7.5「退化约束的依据」，并由 B6 的 $Q = 1$ 切片检验； $\mathbf{p}_{\text{ref}}$ 取 A4 训练配比均值，作为 B 隐含 Pile 配比的代理。
4. 质量的两条作用通道。质量缺陷一方面按比例放大随规模衰减的可约损失（乘性通道，即有效规模打折），另一方面留下一项不随 N, D 增大而消失的附加损失 $k_0(1 - Q)$ ， $k_0 \geq 0$ （加性通道，本文称为质量地板）。配比乘子只乘随规模衰减的两项，不乘 E 与地板。两条通道的依据见 7.5，是否都需要由嵌套 F 检验裁决。
5. 质量口径。主映射取 $Q_B = Q_A = \sum_i p_i Q_i$ ，推荐配比处 $Q_0 = 0.6624$ ；副映射 $Q_B = Q_A/Q_0$ 会使部分领域超出 $[0, 1]$ ，仅作敏感性处理。
6. 配比强度不随规模估计。主假设 H_{red} 把配比乘在可约损失上、强度 s_{red} 用 1M 训练集定死，上界 H_{tot} 把同一偏离乘在总损失上；A6–A11 只用于事后比较，不回头改参数。

7.4 符号说明

本节符号与 4 表 2 一致，额外中间量为 $T_N = AN^{-\alpha}h_N(Q)$ 、 $T_D = BD^{-\beta}h_D(Q)$ 、 $R = T_N + T_D$ 与弹性 $\varepsilon_N, \varepsilon_D, \varepsilon_Q$ ，均在下一小节定义处给出。

7.5 模型建立

经典基线。在 B1 ($N_{\text{params_B/D_tokens_B}}$ 乘 10^9) 上估计 $L_0(N, D) = E + AN^{-\alpha} + BD^{-\beta}$ 。 α 在 $[0.30, 0.38]$ 、 β 在 $[0.24, 0.32]$ 按步长 0.002 网格搜索， E, A, B 在每格点由线性最小二乘给出，取训练误差最小者；以 $C/(6ND)$ 中位比核对算力记账（ C 由 $C_{\text{FLOPs_1e21}}$ 乘 10^{21} ）。

广义标度律（主式）。在 L_0 的可约部分上乘质量与配比因子，质量地板留在括号外：

$$L(N, D, Q, \mathbf{p}) = E + k_0(1 - Q) + [AN^{-\alpha}Q^{-\kappa_N} + BD^{-\beta}Q^{-\kappa_D}] \exp(s_{\text{red}}\tilde{\varphi}(\mathbf{p})), \quad k_0 \geq 0.$$

该式满足三条性质： $Q = 1$ 时 κ 乘子为 1； $\kappa \geq 0$ 时 L 随 Q 单调不减； $N, D \rightarrow \infty$ 时 $L \rightarrow E + k_0(1 - Q)$ ，质量缺陷留下不随规模消失的地板。

为什么乘性与加性并存。乘性部分刻画「一份 token、一份参数能换来多少有效学习」：低质量语料相当于打了折扣的样本，把 $D_{\text{eff}} = Dg(Q)$ 代入 $BD^{-\beta}$ 即得乘在可约项上的因子 $g(Q)^{-\beta}$ ，其效应随 N, D 增大按同一幂律衰减。加性部分刻画规模无法消除的残余： E 是评测分布自身的熵，规模趋于无穷时模型逼近的是训练分布，质量缺陷（噪声、重复、低信息文本）使训练分布偏离评测分布，这一失配不随 N, D 消失；而任何乘在可约项上的因子在 $N, D \rightarrow \infty$ 时都随之趋于 0，无法表达它，只能作为 E 之外的加项，并取在 $Q = 1$ 处为零的一阶形式 $k_0(1 - Q)$ 。数据同时拒绝两种单一通道：纯加性（M0 + 地板）意味着质量收益与规模无关，但质量总收益与 $\ln N$ 的相关系数为 -0.767 ，其留一规模 CV 为 0.0781，高于主式的 0.0598；纯乘性（M4 去地板）留出 RMSE 升至 0.0839，嵌套检验中地板 $F = 307.11$ ；附加 $(1 - Q)^2$ 项不显著（ $p = 0.195$ ），一阶形式已足够（表 11）。配比乘子沿用主假设 H_{red} 只作用于可约项， E 与地板作为规模极限不设配比作用，其上界情景 H_{tot} 见 7.7。

乘子形状。幂次形状来自有效样本量视角 [13]，与数据受限标度律中「有效数据量」的处理一致 [9]：设质量为 Q 的语料在信息上等价于 $D_{\text{eff}} = Dg(Q)$ 个理想质量 token， g 单调不减且 $g(1) = 1$ 。若再设质量的作用具有恒定弹性，即 $d \ln g / d \ln Q = \gamma$ 不随 Q 变化，则唯一解为 $g(Q) = Q^\gamma$ ，数据项化为 $BD^{-\beta}Q^{-\gamma\beta}$ ，即幂次乘子 $Q^{-\kappa_D}$ （ $\kappa_D = \gamma\beta$ ），参数侧同理。恒定弹性与标度律本身的幂律结构一致，并给出 $g(0) = 0$ ，即不含信息的语料不贡献有效样本；线性与指数乘子在 $Q \rightarrow 0$ 时仍保留正的有效规模，没有这一边界含义。这是建模设定而非由数据推出，其留出误差代价在 7.7 与线性、指数对照并列报告。由此定义有效规模

$$N_{\text{eff}} = N Q^{\kappa_N / \alpha}, \quad D_{\text{eff}} = D Q^{\kappa_D / \beta}.$$

配比标量来自问题一 1M 的 clr 系数并在 $\mathbf{p}_{\text{ref}}$ 归一：

$$\varphi(\mathbf{p}) = \frac{1}{13} \sum_{v=1}^{13} \beta_v^{(1M)} \cdot \text{clr}(\mathbf{p}), \quad \tilde{\varphi}(\mathbf{p}) = \varphi(\mathbf{p}) - \varphi(\mathbf{p}_{\text{ref}}), \quad \mathbf{p}_{\text{ref}} = \text{A4 训练配比均值}.$$

$Q = 1$ 、 $\mathbf{p} = \mathbf{p}_{\text{ref}}$ 时两个乘子均为 1、地板为 0，式退化为 L_0 。

退化约束的依据。题目未强制该约束，本文采用它的理由有三。其一，刻度锚定：B1 不含质量变量，是在固定语料与固定配比下测得的经典律，本身就是「质量与配比不变」的切片；令 $Q_B = 1$ 、 $\mathbf{p} = \mathbf{p}_{\text{ref}}$ 对应这一切片，等于把 B 组质量刻度的上端锚定在 B1 基线上。其二，可识别性：质量乘子只以 $A h_N(Q)$ 、 $B h_D(Q)$ 的乘积形式出现，常数因子可在两者之间任意转移，地板常数也会与 E 混淆，必须在某一质量处归一；取 $h(1) = 1$ 、地板在

$Q = 1$ 为零, 使 E, A, B, α, β 保留 B1 上的经典含义, 质量参数只描述相对理想质量的偏离, 配比取 $\mathbf{p}_{\text{ref}}$ 归一同理。其三, 可检验性: 经典式成为嵌套零模型 M0, 质量项的每个自由度都可用 F 检验判断是否必要。该约束是否被数据接受由事后检验回答: B6 中 $Q = 1$ 的 45 点相对 B1 拟合的 L_0 平均残差 +0.0036, 95% 区间 $[-0.0120, 0.0193]$ 含 0 (7.7)。需要说明, 这一锚定只在 B 组刻度上成立; A 组质量能否等同于 B 组质量由假设 5 的质量口径单独承担, 并以副映射作敏感性分析。

嵌套候选族。每种乘子形状 (幂次 $Q^{-\kappa}$ 、指数 $e^{\kappa(1-Q)}$ 、线性 $1 + \kappa(1-Q)$) 下比较 M0 ($\kappa_N = \kappa_D = 0$)、M1 ($\kappa_N = 0$)、M2 ($\kappa_D = 0$)、M3 ($\kappa_N = \kappa_D$)、M4 (两项各一个 κ)、再交叉有无地板, 共 26 个候选。 κ 在 $[0, \kappa_{\max}]$ 上网格加密最小二乘 (幂次/指数为 1.2、线性为 3.0), k_0 在每个 κ 上闭式求出并截断为非负。

训练与留出边界。只用 B6 的 360 点估计参数、比较候选; B6 的 360 点全部出现在 B7 且同点损失相同, B7 中不在 B6 的 90 点 (全部 $Q = 0.5, 0.7$ 、覆盖 45 个 (N, D) 格) 作留出, 按 Q, N, D 分组报告 RMSE 与残差; 全 B7 450 点的拟合含训练点, 仅作对照 (fullB7_comparison)。主式固定为幂次 M4 加地板; 交叉验证规则选出的线性 M4+F 仅写入 cv_rule_choice, 不决定主式。

配比通道。A4/A5 全在 1M, 无法识别配比效应随 N 的变化, 故只设两个零新增参数假设: H_{red} (主) 令配比乘可约部分、强度恒定, $s_{\text{red}} = c_{\text{train}}/\sigma_{\text{train}}$; H_{tot} (上界) 令配比乘总损失。两假设参数只用 1M 训练行确定, A6-A11 只以冻结系数计算校准斜率作事后比较。

边际、弹性与替代闭式。记 $T_N = AN^{-\alpha}Q^{-\kappa_N}$ 、 $T_D = BD^{-\beta}Q^{-\kappa_D}$, 令配比乘子暂为 1:

$$\frac{\partial L}{\partial Q} = -\frac{\kappa_N T_N + \kappa_D T_D}{Q} - k_0, \quad \varepsilon_N = -\frac{\alpha T_N}{L}, \quad \varepsilon_D = -\frac{\beta T_D}{L}, \quad \varepsilon_Q = \frac{Q}{L} \frac{\partial L}{\partial Q}.$$

固定 D 把质量由 Q 提到 Q' , 若只靠增大 N 拉回损失, 则

$$t = \left(\frac{Q}{Q'}\right)^{\kappa_N} + \frac{T_D}{T_N} \left[\left(\frac{Q}{Q'}\right)^{\kappa_D} - 1\right] - \frac{k_0(Q' - Q)}{T_N}, \quad N' = N t^{-1/\alpha},$$

$t > 0$ 时该式给出所需参数倍数, $t \leq 0$ 时任何有限参数都补不回这次提质。在 $6ND = C$ 、配比乘子为 1 时, 最优参数与地板无关:

$$N^*(C, Q) = \left(\frac{\alpha A Q^{-\kappa_N}}{\beta B Q^{-\kappa_D}}\right)^{1/(\alpha+\beta)} \left(\frac{C}{6}\right)^{\beta/(\alpha+\beta)}, \quad D^* = \frac{C}{6N^*}.$$

$\kappa_N > \kappa_D$ 时质量越低、 N^* 越大。沿最优前沿, 质量由 Q 提到 Q' 等效于算力乘以

$$M = \left\{ \frac{R^*(C, Q') - k_0(Q' - Q)}{R^*(C, Q)} \right\}^{-1/a}, \quad a = \frac{\alpha\beta}{\alpha + \beta}, \quad R^* = L^* - E - k_0(1 - Q),$$

花括号内不大于 0 时再大算力也追不上。 $k_0 = 0$ 时 M 与 C 无关, $k_0 > 0$ 时 M 随预算上升。

单位算力取舍与领域关系。单位算力收益 $\text{MU}_x = -(\partial L/\partial x) \div (\partial C/\partial x)$, 总成本取

$$C = (6 + \eta L_{\text{ctx}})ND + D[g(Q) - g(Q_0)]_+, \quad \eta = 2 \times 10^{-4}, \quad L_{\text{ctx}} = 2048,$$

与问题三共用同一成本口径。配比边际 $\partial L/\partial p_i = s_{\text{red}} R \partial \varphi/\partial p_i$ 。领域关系由迁移矩阵行向量余弦定义: 余弦 > 0.7 记功能替代、 < -0.3 记覆盖互补; 线性 clr 模型无交互项, 超可加意义的互补不可识别。

7.6 模型求解

本问使用 Python 3.12.7、NumPy 1.26.4、pandas 2.2.2、SciPy 1.13.1，随机种子 2026，脚本为 q2_01_fit.py、q2_02_theory.py、q2_03_economics.py，只读问题一接口、不读附件 A 原始表与缓存。 α, β 网格搜索、 E, A, B 线性最小二乘；质量参数 κ 在 $[0, 1.2]$ （线性对照到 3.0）以步长 0.02 搜索并在最优点两侧加密两轮， k_0 闭式求出并截断非负；参数区间用 B1 行重抽样与 B6 (N, D) 格簇重抽样各 300 次， α, β 固定。闭式结果与数值解逐项对照。

7.7 结果分析

经典基线。B1 拟合结果为 $E = 1.6901$ 、 $A = 406.39$ 、 $\alpha = 0.34$ 、 $B = 410.59$ 、 $\beta = 0.28$ ，训练 RMSE 为 1.51×10^{-4} ，对 Hoffmann 常数的 RMSE 为 1.65×10^{-4} ， $C/(6ND)$ 中位比为 1.0000 (T20_baseline_fit.csv)，与公开公式吻合到 10^{-4} 量级，是可靠的基线锚点。

质量参数与留出表现。主式参数为 $\kappa_N = 0.1416$ 、 $\kappa_D = 0.0112$ 、 $k_0 = 0.2280$ ，95% 区间分别为 $[0.1264, 0.1568]$ 、 $[0.0000, 0.0408]$ 、 $[0.2013, 0.2554]$ ，且 $P(\kappa_N > \kappa_D) = P(k_0 > 0) = 1$ (T22_params_ci.csv、P2_bootstrap.npz)。嵌套检验中地板被强烈支持 ($F = 307.11$ ， $p < 10^{-15}$)， $\kappa_N = \kappa_D$ 被拒绝 ($F = 57.19$ ， $p = 3.4 \times 10^{-13}$)，而 $\kappa_D = 0$ 不能拒绝 ($F = 0.63$ ， $p = 0.43$)，数据侧质量幂次较弱，主式仍按 M4 保留该项 (T21b_nested_tests.csv)。

候选形式的比较与留出表现见表 11。B7 新增 90 点上，主式留出 RMSE 为 0.0531（平均偏差 -0.0219 ），按 Q 分组为 0.0538 ($Q = 0.5$) 与 0.0525 ($Q = 0.7$)，按规模分组以 70M 的 0.0865 最大；格内噪声代理为 0.0458。交叉验证选出的线性 M4+ 地板留出 RMSE 为 0.0416，比主式低约 22%。需说明两点：一是主式与线性、指数对照 (0.0421) 的留出 RMSE 都与噪声代理同量级，与线性的差值 0.0115 约为噪声代理的四分之一；二是留出点只位于 $Q = 0.5, 0.7$ 两档内部，只能检验插值精度，无法区分三种形状在 $Q \rightarrow 0$ 与 $Q \rightarrow 1$ 边界上的差异，而有效规模的解释和问题三中 D^*/N^* 随 Q 的幂律关系恰依赖这一部分。因此本文保留幂次主式，以约 0.01 的留出误差换取有效规模的解释与边界含义，线性、指数对照作为稳健性参照并列报告。

表 11 质量项候选比较 (B6 训练，留出为 B7 新增 90 点；源自 T21_form_selection.csv)

形状	模型	κ_N, κ_D, k_0	留一规模 CV	留出 RMSE	留出偏差
—	M0	0, 0, 0	0.2100	0.1616	-0.146
—	M0 + 地板	0, 0, 0.363	0.0781	0.0595	-0.001
幂次	M4 (去地板)	0.203, 0.153, 0	0.0813	0.0839	-0.070
幂次	M4 + 地板 (主)	0.142, 0.011, 0.228	0.05979	0.0531	-0.022
指数	M4 + 地板	0.370, 0.131, 0.144	0.05324	0.0421	-0.005
线性	M4 + 地板 (CV 对照)	0.430, 0.139, 0.142	0.05321	0.0416	-0.001




图 12 质量项候选比较与 B7 新增 90 点的留出表现

退化约束的事后检验：B6 中 $Q = 1$ 的 45 点相对 L_0 平均残差为 +0.0036、95% 区间 $[-0.0120, 0.0193]$ ；附加 $(1 - Q)^2$ 项不显著 ($p = 0.195$)。质量总收益 ΔL (Q 由 0.1 到 1) 范围为 $[0.107, 0.609]$ ，与 $\ln N$ 相关 -0.767 ，质量收益随参数规模变小，与 $\kappa_N > \kappa_D$ 方向一致 (T21c、T21d)。B8 在最低质量档平均损失仅 0.545、64.26% 的点低于 E ，方向相反，不并入拟合 (T21e)。

边际效用与弹性。在 $N = 10^9$ 、 $D = 3 \times 10^{11}$ 、 $Q = Q_0$ 处损失 $L = 2.3945$ ，三弹性为 $\varepsilon_N = -0.0533$ 、 $\varepsilon_D = -0.0295$ 、 $\varepsilon_Q = -0.0865$ ，质量弹性约为参数弹性的 1.62 倍（其中 72.97% 来自地板）；四个配比份额的弹性和仅 0.0072。规模越大、质量越敏感：在 $(10^{10}, 10^{12})$ 与 $(7 \times 10^{10}, 2 \times 10^{12})$ 、 $Q = 0.9$ 处 $\varepsilon_Q/\varepsilon_N$ 升至 4.13、7.60，地板占质量导数的 89.04%、93.76% (T26_elasticities.csv、T31)。

质量—参数替代。固定 $D = 3 \times 10^{11}$ ，质量提高 0.1 的等效参数倍数见表 12：模型越大、同样提质越难用堆参数补回；千亿参数处约需 3 倍参数，而去地板后降到 1.3–1.5，凸显地板只能靠提质消除。

表 12 质量提高 0.1 的等效参数倍数（固定 $D = 3 \times 10^{11}$ ；括号内为去地板对照；源自 T24_equiv_substitution.csv）

起点 Q	$N = 10^9$	$N = 10^{10}$	$N = 10^{11}$
0.5→0.6	1.299 (1.182)	1.648 (1.268)	2.996 (1.488)
0.7→0.8	1.282 (1.130)	1.641 (1.190)	3.066 (1.337)
0.9→1.0	1.274 (1.102)	1.644 (1.148)	3.144 (1.258)

质量—算力替代。沿算力前沿，质量由 0.7 提到 0.8 等效于算力乘 1.191/1.485/2.134 ($C = 10^{19}/10^{22}/10^{24}$)，无地板时恒为 1.165； $Q = 0.5$ 的 N^* 比 $Q = 1$ 大 15.7%， $C = 10^{24}$ 、 $Q = 0.5$ 时地板占可约损失 32.94% (T25、T27、T29，图 13)。高预算端的倍数与地板份额含外推成分，按假设使用。




图 13 等效参数倍数、等价算力倍数随预算变化与算力—质量前沿

单位算力取舍。表 13 给出 MU_Q/MU_N ：比值大于 1 表示一份算力用于提质更有效。 $C = 10^{19}$ 时指数型、幂函数型小于 1（应扩参数），对数型略大于 1；自 $C = 10^{20}$ 起三种成本函数下比值均大于 1（3.10/1.70/3.77）并随预算迅速增大。提质更划算的质量上界在 $C = 10^{19}$ 时为 0.64/0.53/0.99，即低预算下质量已较高时应转回扩参数。整体规律是：低预算结论对成本函数形式敏感，高预算结论稳健。

表 13 MU_Q/MU_N ($Q = Q_0$ 、 $L_{ctx} = 2048$ ；括号内去地板；源自 T33、T33b)

预算 C	指数型	幂函数型	对数型
10^{19}	0.868 (0.793)	0.477 (0.436)	1.057 (0.965)
10^{20}	3.10	1.70	3.77
10^{22}	42.48 (17.95)	23.34 (9.86)	51.71 (21.85)
10^{24}	627.30 (143.65)	344.59 (78.91)	763.61 (174.87)




图 14 域对余弦热力图、份额边际与 MU_Q/MU_N 随预算变化

领域关系。按迁移矩阵行向量余弦，17 域对中功能替代 4 对（最强 nih_exporter–enron_emails, 0.969）、覆盖互补 10 对（最强 dm_mathematics–philpapers, -0.725），其余 122 对弱相关（T32b）。把份额拨向 dm_mathematics 使等权损失下降最快（ $\partial L/\partial p = -0.1475$ ），拨向 enron_emails 上升最快（+0.1381）（T31b）。

配比通道的位置。通道参数为 $c_{train} = 1.0039$ 、 $Q_{ref} = 0.6640$ 、 $\sigma_{train} = 0.6694$ ，故 $s_{red} = 1.500$ ； $\tilde{\varphi}(\mathbf{p}^*) = -0.07104$ 、 $\tilde{\varphi}(\text{均匀}) = +0.03611$ ，推荐配比处乘子约为 0.899。表 14

显示，60M、1B 上的观测斜率落在 H_{red} 与 H_{tot} 两个预设值之间，构成已评估点上的情景包络，为下游提供配比敏感性的下、上情景。

表 14 两个配比通道假设与观测校准斜率对照（源自 T28_p_channel.csv）

尺度	观测斜率（评估）	H_{red}	H_{tot}	相对位置
1M 训练	1.004	1.004	1.004	—
1M 留出	0.995	0.998	1.004	—
60M	0.913	0.807	1.004	0.540
1B	0.612	0.309	1.004	0.436

7.8 模型检验

留出与嵌套。B7 新增 90 点作 Q 方向插值留出，主式留出 RMSE (0.0531) 与噪声代理 (0.0458) 同量级，略高于线性对照 (0.0416)。由于留出点只在 $Q = 0.5, 0.7$ 内部，该检验只判断插值精度，形状由有效规模设定决定 (7.5)。地板、 $\kappa_D = 0$ 、 $\kappa_N = \kappa_D$ 三个嵌套假设由 F 检验裁决； $Q = 1$ 切片残差区间含 0，退化约束未被数据拒绝。

跨来源对照。各对照均在 $Q = 1$ 切片上检查趋势：B2（半合成， $n = 1,029$ ）Spearman 0.788、偏差 +1.178；B3 为 B1 插值派生；B4 共 57 点、剔除 13 个近邻后 44 点 Spearman 0.975、偏差 +0.176；B5 的 44 点 Spearman 0.959；B9/B10 对齐 128 对，B10 与公式高相关是估算构造所致 (T23 系列)。这些对照核对了趋势的一致性，B2、B3、B10 不构成质量项可泛化到真实训练的证据。

来源审计与解析互验。B11/B12 确认 B1 的 8 个名义规模、每模型 147 步均被检查点记录覆盖， $D/(\text{steps} \times \text{batch})$ 中位比 0.9986；B11 仅覆盖 3/12 模型族 (T23e、T23f)。由此确认 B1 训练设定有来源记录，损失值按公开公式生成。替代条件、 N^* 与算力倍数的解析值与数值解误差小于 10^{-8} （替代倍数小于 10^{-13} ）。

7.9 评价与改进

本问主式在 $Q = 1$ 、 $\mathbf{p} = \mathbf{p}_{\text{ref}}$ 时回到经典式，把「提质能否被规模替代」写成 $t > 0$ 的可计算条件，并把 B6 拟合、B7 插值留出、跨源对照与来源审计分层报告。局限在于：质量参数来自最大约 12B 的半合成网格，高预算端地板份额与「提质远比扩参数划算」含外推成分；幂次形状来自恒定弹性的建模设定，线性、指数的留出误差低约 0.01，现有留出又无法检验 Q 边界处的形状差异； κ_D 较弱； $\mathbf{p}_{\text{ref}}$ 与恒定配比强度属建模假设。若后续取得真实跨质量训练日志，可替换 B6 重估参数并允许配比强度随 $\log N$ 变化。问题三已按幂次乘子重跑 (8)，问题四按 $Q = 1$ 切片使用。

8 问题三：算力约束下的资源配置优化

8.1 模型建立

给定总预算 C （绝对 FLOPs）与外生上下文长度 L_{ctx} （token），在参数规模 N 、训练 token 数 D 与质量 $Q \in [Q_0, 1]$ 上最小化问题二的幂次主式。主方案固定问题一在 A4/A5 训

练信赖域内选出的 17 域推荐配比 $\mathbf{p}^*$ ，这是题目允许的建模选择。记

$$\begin{aligned} m_* &= \exp\{s_{\text{red}}\tilde{\varphi}(\mathbf{p}^*)\} \approx 0.8989423, \\ T_N &= AN^{-\alpha}Q^{-\kappa_N}, \quad T_D = BD^{-\beta}Q^{-\kappa_D}, \\ L &= E + k_0(1 - Q) + m_*(T_N + T_D). \end{aligned}$$

配比乘子只作用于两项随规模变化的损失，不作用于 E 与质量地板。主质量映射按 P2 取 $Q_B = Q_A$ ，故提质起点 $Q_0 = 0.6624116679870492$ 。系数 $E, A, \alpha, B, \beta, \kappa_N, \kappa_D, k_0$ 全部读取冻结的 P2 接口，不在本问重拟合。预算约束为

$$6ND + D[g(Q) - g(Q_0)]_+ + \eta NDL_{\text{ctx}} \leq C, \quad Q_0 \leq Q \leq 1, \quad \eta = 2 \times 10^{-4}.$$

作为映射敏感性对照，P2 的锚点映射 $Q_B = Q_A/Q_A(\mathbf{p}^*)$ 在推荐配比处给出 $Q_0 = 1$ ，没有可行提质区间，记为 NO_QUALITY_RANGE；若域级质量超出 $[0, 1]$ 支持域，按 clip_policy=error 标记，不作静默截断。

提质成本函数。需比较题目附录 B 的三类单位 token 提质成本：指数型 $g = 10^7 e^{6Q}$ (凸)、幂函数型 $g = 5 \times 10^9 Q^4$ (凸)、对数渐近型 $g = 2 \times 10^9 \ln(1 + 10Q)$ (凹)。本问按单次训练的静态预算情景建模；题面建议预算 $C = 10^{19}, 10^{22}, 10^{24}$ ，硬要求是至少跨越三个数量级，本文自主采用 10^{19} 至 10^{25} 共七档网格并把三个建议档单列。 L_{ctx} 是情景输入，不由优化器自由选择；连续 N, D 与 $Q \geq Q_0$ 是为解析求解设定的建模口径。

优化结论继承问题一、二的证据边界： $\mathbf{p}^*$ 来自 1M 代理模型信赖域，候选收益为预测值；幂次 M4+ 地板是问题二指定主式，质量项由半合成 B6 的 360 点估计、B7 新增 90 点作插值留出，主式留出 RMSE 约 0.053 (线性对照约 0.042)， κ_D 较弱。因此最优配置是给定该标度律、映射与参数后的模型内方案，配比乘子通道亦为探索性假设。

降维与闭式对照。三项成本都与 D 成正比，而 $\partial L / \partial D = -m_* \beta T_D / D < 0$ ，故预算用尽。记 $K = 6 + \eta L_{\text{ctx}}$ 、 $\Delta g = [g(Q) - g(Q_0)]_+$ ，由约束取等得

$$D = \frac{C}{KN + \Delta g},$$

问题降为 $(\log_{10} N, Q)$ 的二维有界优化。固定 Q 、令 $\Delta g = 0$ 的解析对照为

$$N^* = \left[\frac{\alpha A Q^{-\kappa_N}}{\beta B Q^{-\kappa_D}} \right]^{1/(\alpha+\beta)} \left(\frac{C}{K} \right)^{\beta/(\alpha+\beta)}, \quad D^* = \frac{C}{KN^*},$$

式中 m_* 与地板因对固定 Q 求规模导数而抵消，但仍影响不同 Q 之间的选择。由此

$$\frac{D^*}{N^*} \propto \left(\frac{C}{K} \right)^{(\alpha-\beta)/(\alpha+\beta)} Q^{2(\kappa_N - \kappa_D)/(\alpha+\beta)},$$

两个指数在当前参数下约为 0.09677 与 0.42065；这是无提质开销对照，真实 $\Delta g > 0$ 情景由数值解给出。

上下文长度的解析临界值由注意力项与训练项之比 $\eta L_{\text{ctx}}/6$ 给出：

$$L_{\text{ctx}}^{\text{crit}} = \frac{6}{\eta} = 30000 \text{ token},$$

在固定 L_{ctx} 下该比值与 C, N, D 无关；C7 五档中 8192 在临界值以下、32768 在其以上，30000 本身不是 C7 实测档位。

结构性转移的定义与判据。本文把最优策略的质变操作化为全局最优解的质量约束活跃状态变化：LOWER ($Q^* = Q_0$)、INTERIOR、UPPER ($Q^* = 1$)；若两个内点局部极小分支交换全局最优地位，即使同属 INTERIOR 也单列全局分支切换。这一做法有直接的文献先例：Prescriptive Scaling Laws[15] 在数据受限前沿上发现 turn-back 现象——预算越过临界后最优策略由「加重重复次数」质变为「加大模型、减轮次」。对固定 Q 的规模最优解，令 $S = KN + \Delta g$ ，剖面目标的质量导数与边际比为

$$F_Q = -k_0 - \frac{m_*}{Q}(\kappa_N T_N + \kappa_D T_D) + \frac{m_* \beta T_D g'(Q)}{S}, \quad \Phi(C; Q) = \frac{\left[k_0 + \frac{m_*}{Q}(\kappa_N T_N + \kappa_D T_D) \right] S}{m_* \beta T_D g'(Q)}.$$

其中 N, D 均在该固定 Q 下优化。内层光滑且未触边界时， $\Phi(C; Q_0) \leq 1$ 、内点 $\Phi(C; Q) = 1$ 、 $\Phi(C; 1) \geq 1$ 分别为相应状态的局部一阶必要条件； $\Phi = 1$ 的根不是全局切换的充分条件，须分别输出局部根与全局临界点。 $Q_0 \geq 1 - 10^{-10}$ 时记 NO_QUALITY_RANGE，搜索区间未括根记 NOT_BRACKETED。公式正确性已作单点有限差分核验： $C = 10^{20}$ 、 $L_{ctx} = 2048$ 、指数型、 $Q = 0.8$ 处解析导数 -0.1164515205405 与差分 -0.1164515204932 的相对误差约 4.1×10^{-10} (对应 $\Phi = 1.63892372$)。

敏感性与验收。敏感性覆盖三类 g 、C7 五档 L_{ctx} 、 $\eta = 10^{-4}, 2 \times 10^{-4}, 3 \times 10^{-4}$ 、P2 参数重抽样、主/锚点两种质量映射、P1 域质量与配比不确定性，以及固定配比乘子 $m=1$ 、 H_{tot} 与无地板对照。固定 $\mathbf{p}^*$ 时 H_{tot} 对完整基线乘一个与 N, D, Q 无关的正常数，故其最优 N, D, Q 与 $m=1$ 相同、最优 Loss 按该常数缩放。验收阈值：预算超限与三项份额和误差均不大于 10^{-9} ，预算使用率与 1 之差小于 10^{-9} ，无提质时闭式 N^* 误差小于 10^{-5} ，关键 18 组求解 Loss 与独立粗网格之差不超过 2×10^{-5} 。P3_optimal_config.csv 的份额分母统一为实际总消耗，同时另报预算使用率。

8.2 求解方法

消去 D 后，在 $(\log_{10} N, Q)$ 上求解：固定 Q 的内层对 $\log_{10} N$ 作有界一维搜索并核对边界未截住解，外层对 Q 加密搜索、保护 Q_0 与 1 两个端点，同时比较多个内点候选与独立粗网格。局部 $\Phi = 1$ 根与全局状态切换分别识别，仅当区间已括根且确认为单次切换时才用二分定位临界预算。主网格为 3 种成本函数 $\times$ 7 档预算 $\times$ 5 档上下文长度 $\times$ 2 个起始质量对照，共 210 组；关键 18 组同时用粗网格与多起点 SLSQP 核对。对 $Q_0 = 1$ 、未括根情形分别记录 NO_QUALITY_RANGE、NOT_BRACKETED 与空数值。本问已按幂次主式重跑并生成运行 manifest (P3_run_manifest.json，北京时间 2026-09-26 11:37，含 P1/P2/C7 输入 SHA-256)；q3_03_mixture_joint.py 改为运行即退出，不作为主结论。

8.3 结果与分析

结果证据范围。目标式已固定为问题二的幂次 M4+ 质量地板并保留配比乘子 $m_* \approx 0.8989423$ ， $Q_0 = 0.6624116679870492$ 。src/code_q3/ 已按该口径重跑 (manifest 记录北京时间 2026-09-26)。主网格为 3 种成本函数 $\times$ 7 档预算 $\times$ 5 档 C7 上下文长度 $\times$ 2 个同映射下的起始质量对照，共 210 组；题面建议的三档预算 $10^{19}, 10^{22}, 10^{24}$ FLOPs 在结果中单列。标度律质量项拟合于 B6 (supplementary_NQ_experiment.csv，360 点，6ND 预算

$\log_{10} C \in [18.62, 22.63]$ 、 $N \leq 1.2 \times 10^{10}$ 、 $D \leq 6 \times 10^{11}$), B7 同域留出, B8 将观测扩展至 $\log_{10} C \approx 24.92$ ($N \leq 7 \times 10^{11}$ 、 $D \leq 2 \times 10^{12}$)。据此对每个最优解按其 N^*, D^* 相对支撑范围标注三级可靠性 IN_FIT / IN_OBS / EXTRAP (见高预算外推警告); 关键结论是所有临界预算均落在 **B6/B7** 拟合域内, 而 $\log_{10} C \geq 23.5$ 的高预算最优规模配置为纯外推。质量参数来自半合成 B6、配比通道为探索性, 证据边界与问题二一致。下文先给出可由主式推出的解析关系, 再给出数值最优配置、成本份额、配置比斜率诊断与临界预算。

上下文长度临界值。注意力项与训练项之比恒为 $\eta L_{ctx}/6$, 二者相等给出 $L_{ctx}^{crit} = 30000$ token, 与预算、成本函数和规模无关; 8192 在临界值以下、32768 在其以上。注意力份额随 L_{ctx} 增大而上升, $L_{ctx} = 32768$ 时已接近或超过训练份额, 越过临界值后最优模型随之缩小。成本交叉点与预算驱动的策略转移是两件事, 须分开陈述。

数值最优配置。表 15 给出 $L_{ctx} = 2048$ 、主口径下三档建议预算与三类提质成本对应的最优配置。低预算 $C = 10^{19}$ 时, 指数型与幂函数型成本下最优质量停留在下界 (LOWER, 不提质), 对数型成本因提质边际成本低而直接提满 (UPPER); 到 $C = 10^{22}$ 、 10^{24} , 三种成本函数下最优解均为 $Q^* = 1$, 最优 N, D 沿算力前沿增长、最优 Loss 稳步下降。 10^{22} 及以上超出 B6 训练覆盖, 属外推结果。

表 15 三档建议预算下的最优资源配置 ($L_{ctx} = 2048$, 主口径; 数据源 P3_optimal_config.csv, 2026-09-26 11:37)

成本 $g(Q)$	$\log_{10} C$	Q^*	N	D	最优 Loss	状态
指数型	19	0.6624	2.414×10^8	6.464×10^9	2.9780	LOWER
指数型	22	1	5.584×10^9	2.545×10^{11}	2.1038	UPPER
指数型	24	1	4.072×10^{10}	3.780×10^{12}	1.8914	UPPER
幂函数型	19	0.6624	2.414×10^8	6.464×10^9	2.9780	LOWER
幂函数型	22	1	5.663×10^9	2.479×10^{11}	2.1046	UPPER
幂函数型	24	1	4.082×10^{10}	3.764×10^{12}	1.8914	UPPER
对数型	19	1	3.167×10^8	3.620×10^9	2.9380	UPPER
对数型	22	1	5.140×10^9	2.969×10^{11}	2.0988	UPPER
对数型	24	1	4.023×10^{10}	3.867×10^{12}	1.8910	UPPER

成本份额。表 16 给出三档预算的训练、注意力与提质份额 (分母为实际总消耗, 预算使用率核验为 1)。 $C = 10^{19}$ 下训练成本占主导 (指数型约 93.6%); 对数型成本在 $C = 10^{19}$ 已把约 26.5% 投入提质, 与其低边际成本一致。注意力份额随 L_{ctx} 显著上升, 是 $L_{ctx}^{crit} = 30000$ 的直接体现。

表 16 三档预算下的成本份额 ($L_{ctx} = 2048$, 分母为实际总消耗; 数据源 P3_optimal_config.csv)

成本 $g(Q)$	$\log_{10} C$	训练份额	注意力份额	提质份额
指数型	19	93.61%	6.39%	0
指数型	22	85.27%	5.82%	8.91%
指数型	24	92.37%	6.31%	1.32%
幂函数型	19	93.61%	6.39%	0
幂函数型	22	84.24%	5.75%	10.01%
幂函数型	24	92.19%	6.29%	1.52%
对数型	19	68.77%	4.69%	26.54%
对数型	22	91.57%	6.25%	2.18%
对数型	24	93.34%	6.37%	0.28%

结构性转移与临界预算。 $L_{ctx} = 2048$ 主口径下, 质量状态随预算变化: 指数型在 $\log_{10} C \approx 19.059$ 离开下界、 ≈ 20.355 到达 $Q = 1$; 幂函数型为 19.529 与 20.106; 对数型离开下界与到达上界同发生于 ≈ 18.579 (局部 $\Phi = 1$ 根约 18.904, 与全局切换相差 0.325 dex)。P2 条件 bootstrap (300 次全部括根) 给出离开下界的 5%–95% 区间: 指数型 [19.038, 19.084]、幂函数型 [19.503, 19.560]、对数型 [18.539, 18.620]。由此得到清晰的预算阈值规律: 对数型成本阈值最低、指数型居中、幂函数型最高, 提质是否划算随成本函数形状有序移动。

P1 不确定性传播 (Q3-9)。进一步将问题一的域质量 Q_i 与配比 $\mathbf{p}^*$ 的 bootstrap 样本 (各 300 次) 逐样本重算 $Q_0(\mathbf{p}^*) = \sum_i p_i^* Q_i$ 并与 P2 参数样本联合, 向量化重新识别临界预算, 300 次全部括根。加权起始质量本身的抽样波动很小, $Q_0(\mathbf{p}^*) = 0.66237 \pm 0.00203$ (5%–95% 区间 [0.65904, 0.66553])。P1+P2 联合的离开下界 5%–95% 区间为指数型 [19.031, 19.091]、幂函数型 [19.501, 19.563]、对数型 [18.540, 18.621], 到达 $Q = 1$ 为指数型 [20.292, 20.428]、幂函数型 [20.039, 20.179]、对数型 [18.540, 18.621]。与仅含 P2 的区间相比, 加入 P1 通道仅使区间边界外扩约 0.003 dex (例如指数型离开下界由 [19.038, 19.084] 微展至 [19.031, 19.091]), 三种成本函数的阈值排序与“提质是否划算”的结论对配比 / 域质量抽样稳健。

求解核验。本轮预算残差 3.93×10^{-16} 、三项份额和误差 3.33×10^{-16} , 均小于 10^{-9} ; 无提质开销时闭式 N^* 相对误差 1.54×10^{-7} (阈值 10^{-5}); 关键组求解 Loss 与独立粗网格最大差 1.80×10^{-5} (阈值 2×10^{-5}); 搜索边界未截住主解。锚点映射 $Q_B = Q_A / Q_A(\mathbf{p}^*)$ 下 $Q_0 = 1$, 记为 NO_QUALITY_RANGE; pile_cc 单域映射质量越界记为 OUT_OF_SUPPORT 且不截断。

配置比斜率诊断 (Q3-10)。由主式可得无提质开销时最优规模比满足幂律 $D^*/N^* \propto (C/K)^{(\alpha-\beta)/(\alpha+\beta)}$, 即 $d \ln(D^*/N^*) / d \ln C$ 的理论基线为 $(\alpha - \beta) / (\alpha + \beta) = 0.09677$ ($\alpha = 0.34, \beta = 0.28$)。逐预算数值微分证实: 在低预算质量锁定于 Q_0 的区段, 斜率与基线偏离仅 $\sim 10^{-9}$; 而当预算跨过提质阈值、 Q^* 快速上行挤占数据预算时, 该斜率出现显著负向拐点。主口径 $L_{ctx} = 2048$ 下偏离绝对值最大处 (拐点) 为对数型 $\log_{10} C \approx 18.55$ 、幂函数型 ≈ 19.60 、指数型 ≈ 19.10 , 与前述质量约束切换预算 (对数型 18.58、幂函数型 19.53、指数型 19.06) 一致, 二者互为印证: 结构性转移既体现在质量约束状态的切换, 也体现在规模配置比增速的可观测拐折。诊断明细见 P3_dn_slope_diagnostic.csv 与 P3_dn_slope_kink.csv。

高预算外推警告。标度律质量项拟合于 B6 ($\log_{10} C \in [18.62, 22.63]$ 、 $N \leq 1.2 \times 10^{10}$ 、 $D \leq 6 \times 10^{11}$)，B7 同域留出，B8 将观测扩展至 $\log_{10} C \approx 24.92$ 。按每个最优解的 N^* 、 D^* 相对该支撑标注：题面三档中 10^{19} 、 10^{22} FLOPs 及全部临界预算（离开下界 18.58–19.53、到达 $Q = 1$ 18.58–20.36）均落在 B6/B7 拟合域内，故结构性转移与提质阈值结论非外推；纯外推（EXTRAP）起点约 $\log_{10} C \approx 23.5$ （主口径 $L_{ctx} = 2048$ ，指数/幂函数型 23.55、对数型 23.5）， 10^{24} 档已进入外推区。每条成本函数在主网格 7 档预算 $\times 5$ 档上下文共 35 组中，IN_FIT / IN_OBS / EXTRAP 分别为 21/5/9；因此 10^{24} 及以上的最优规模配置须谨慎解读。标注明细见 P3_extrapolation_by_config.csv 与 P3_extrapolation_warning.json。

证据闭合说明（问题三）。问题一已提供域质量 Q_i 与配比 $\mathbf{p}^*$ 的逐次 bootstrap 接口 (P1_bootstrap_Q_domain.npz、P1_bootstrap_p_star.npz)，Q3-9 已据此完成固定配比（仅 P2）与重选配比（P1+P2）两类不确定性的分别传播，全链条区间已闭合（见上“P1 不确定性传播”）；结论对配比 / 域质量抽样稳健。质量参数仍来自半合成 B6、配比通道为探索性，此为与问题二一致的数据边界，非方法缺口。

9 问题四：Benchmark 检验与能力演进

问题四把 Benchmark 表现、训练规模与时间变化纳入统一口径，分析开放权重模型能力前沿中规模扩张与非规模因素的贡献，并在算力增速放缓情景下讨论能力演进。需先说明本章结果的数据时点：能力分解基于 2023.50 $\rightarrow$ 2025.00 的历史窗口，情景预测以 $T_0 = 2025.25$ 为锚点，属条件情景结果；更新数据截止日后需重新预测，相关验收边界集中列于 11.2。

9.1 模型建立

9.1.1 数据口径与样本边界

主能力指标为 C1/C2 的 Average，由六项 Benchmark 维度等权汇总，量纲为 0–100 分。C2 在 C1 榜单上增加 Epoch 匹配信息，二者属同一批榜单记录。模型类型按榜单标签区分：base 含 pretrained 与 continuously pretrained，chat 含 chat 与 fine-tuned；merges、multimodal 与 other 不纳入两类主回归。C2 发布日期用于模型时间轴，C1 提交日用于 C8 月度汇总，两类日期不互换。

本问关注开放权重模型，「权重可获得」与许可证允许的用途是两个字段，许可证未知时保留未知状态。C2 与 C4 先按发布日期和组织匹配，再要求参数量差异小于 50%；训练 token 缺失时由 $D = C/(6N)$ 反解并标记为估算量。C3 混合了不同评测口径，仅作时间趋势敏感性材料，不并入主面板；C5/C6 按可比性分层使用。

9.1.2 两套实现流程

本问沉淀了两套实现流程，其来源与状态见表 17，二者共同保证方法可对照、结果可追溯。

表 17 问题四两套实现流程的来源与状态

流程	数据、时间轴与产物	当前状态
主链	q4_01_c8_parse 至 q4_05_forecast; 预测接口以 $T_0 = 2025.25$ 为起点, 对应目标日期 2026.25、2027.25; C1/C8 提交日序列截止于 2025-03-13。产物位于 src/outputs_q4/。	现存结果生成于代码与公共接口修订之前, 作为历史分析结果使用, 更新输入后重跑即可刷新。
补充独立实现	入口 src/code_q4/independent/run_q4_independent.py, 配置 config_q4.json; 来源报告记录预测起点 2024-12-31、数据截止 2025-03-13。	作为代码实现对照, 数值资源链标记 DEFERRED_Q3, 在本仓库独立运行后用于交叉核对。

9.1.3 逐任务饱和度与去饱和分

为降低已接近任务上限的维度对汇总分变化的压缩, 先按叶子任务随机基线 c_j 归一化得分:

$$\hat{s}_j = \max \left\{ 0, \frac{s_j - c_j}{1 - c_j} \right\},$$

再按 C1 提交日构造任务级累计 Top-5 前沿 $F_{t,j}$ 。去饱和和剔除饱和任务, 以起点剩余空间为家族内权重、令六个任务家族等权:

$$S_{\text{desat},t} = 100 \sum_j w_j \hat{s}_{j,t}, \quad w_j \propto 1 - F_{\text{start},j}.$$

该分是 Average 的敏感性口径, 用于更灵敏地反映尚未饱和任务上的进展。




图 15 C8 叶子任务的饱和度分类

P4_task_saturation.csv 含 39 个任务: 饱和 10 个、快速增长 9 个、常规增长 17 个、低位停滞 3 个。

表 18 能力口径的历史窗口比较 (2024-06 至 2025-03; 源自 T5_desat_vs_average.csv)

口径	起点前沿	终点前沿	相对变化	月斜率
C1 Average	38.52	49.89	29.53%	1.285
C8 全任务重算	37.98	49.40	30.08%	1.326
C8 去饱和分	26.36	39.06	48.19%	1.536

去饱和分相对变化明显高于 Average，更充分地显现了未饱和任务上的进步速度。模型级重算与 C1 的一致性中，除 MATH 外五个任务族 Pearson 不低于 0.989; MATH 为 0.801、MAE 3.497 分 (T5_c8_vs_c1_check.csv)，该差异原因有待进一步解释。

图10 去饱和和综合分 vs 榜单 Average




图 16 去饱和分与 C1 Average 的历史窗口比较

9.1.4 Loss-Benchmark 桥接

C6 的损失与 Benchmark 得分按可比性分层后，用有界 S 形函数描述二者关系：

$$S(L) = lo + \frac{hi - lo}{1 + \exp[k(L - L_0)]}, \quad 0 \leq lo \leq hi \leq 100, \quad k > 0,$$

High 层为同模型、同验证集记录 (权重 1)，Medium 层验证集不同但近似可比 (权重 0.5)。base|Average 的参数为 $(lo, hi, k, L_0) = (8.626, 21.572, 46.119, 2.070)$ (44 行; C6 含 High 7、Medium 68)。留一比较中 S 形、线性、常数模型 RMSE 为 8.079、8.283、9.514 分，S 形桥接表现最好。High 层主要约束下界、覆盖底噪区，上升段由 Medium 层决定；面板分解会重估得分映射，C6 固定映射仅作对照。

图11 Loss→Benchmark 桥接映射 (High 权重 1, Medium 权重 0.5)




图 17 C6 分层 Loss-Benchmark 桥接拟合

9.1.5 规模与非规模因素的模型内分解

每个面板观测把 C2 能力分与 C4 配置连接，再用问题二标度律计算规模状态 $\hat{L}_i$ 。主模型 M1b 将非线性映射与时间项相加：

$$S_i = lo + \frac{amp}{1 + \exp[k(\hat{L}_i - L_0)]} + \tau(t_i - 2023) + \varepsilon_i,$$

τ 表示控制规模状态后的年度时间关联。对照 M1c 把时间项写入等效年降损 δ ：

$$S_i = lo + \frac{amp}{1 + \exp[k(\hat{L}_i - \delta(t_i - 2023) - L_0)]} + \varepsilon_i.$$

另有效率前沿线性模型 M2、分位数回归 M3 与以 $\log_{10} C$ 为解释变量的 OLS。对两端点状态采用双顺序 Shapley 分配 [11]：

$$\begin{aligned}\Delta S_{\text{scale}} &= \frac{1}{2}\{[f(\hat{L}_1, t_0) - f(\hat{L}_0, t_0)] + [f(\hat{L}_1, t_1) - f(\hat{L}_0, t_1)]\}, \\ \Delta S_{\text{time}} &= \frac{1}{2}\{[f(\hat{L}_0, t_1) - f(\hat{L}_0, t_0)] + [f(\hat{L}_1, t_1) - f(\hat{L}_1, t_0)]\}, \\ \Delta S_{\text{model}} &= \Delta S_{\text{scale}} + \Delta S_{\text{time}}.\end{aligned}$$

技术份额定义为 $\Delta S_{\text{time}} / \Delta S_{\text{model}}$ 。时间项可能吸收数据质量、后训练、架构与样本构成变化，是控制规模后的条件关联。

9.2 求解方法

主链按 q4_01_c8_parse、q4_02_saturation、q4_03_bridge、q4_04_decomp、q4_05_forecast 顺序运行，末尾由 q4_99_check_report 检查接口与报告字段。C8 先解析叶子任务再与榜单匹配；C6 桥接用分层加权最小二乘并以留一法比较形式；C2/C4 按发布日、组织与参数量差异匹配。预测脚本以算力情景更新 C ，在 $Q = 1$ 、 $L_{\text{ctx}} = 4096$ 的 P2 损失切片上计算规模变化，再锚定到前沿并经 M1b/M1c 映射为分；该计算是 Q2 标度律在 $Q = 1$ 切片上的情景推演，不读取 P3 最优配置。

9.3 结果与分析

9.3.1 历史窗口的增长分解

base 历史窗口的模型内贡献分解见表 19。主口径 M1b 给出规模贡献 23.063、技术贡献 3.404，技术占模型解释增量的 12.86%（90% 区间 6.07%–21.96%）；观测变化为 24.759，与模型变化 26.467 相差 -1.708。不同模型的技术份额存在明显差异，本文并列报告、不宣称唯一拆分。

表 19 base 历史窗口的模型内贡献分解（2023.50→2025.00， $\Delta S_{\text{obs}} = 24.759$ ；源自 P4_decomposition.csv）

方法	规模项	时间项	模型变化	时间项占比	90% 区间
M1b	23.063	3.404	26.467	12.86%	6.07%–21.96%
M1c	20.115	6.037	26.153	23.09%	4.17%–45.49%
M2	7.358	6.186	13.544	45.67%	8.68%–59.88%
M3 ($q = 0.75$)	7.398	4.445	11.844	37.53%	-47.38%–58.24%
OLS	7.722	3.235	10.957	29.53%	10.94%–46.13%




图 18 面板中的规模状态、能力分数与时间

M1b、M1c 的面板 R^2 为 0.870、0.868，OLS 为 0.660 (T7_decomp_fit_quality.csv)，结构模型对能力分具有良好的解释力。




图 19 不同模型与窗口下的规模项与时间项

C3 敏感性显示，仅用 C2×C4 base 样本时算力等效速率为 0.781 dex/年，加入 C3（权重 0.2、1.0）时为 0.499、0.205 dex/年，时间趋势对历史口径较敏感，故 C3 仅作对照 (T7_c3_sensitivity.csv)。换用 2024 → 2025、2024.5 → 2025.25 窗口时 M1b 技术占比为 7.06%、8.18%，「规模扩张为主」的定性结论在各窗口下保持稳定。

9.3.2 算力情景与回溯

锚点 base 得分为 37.302、chat 为 46.057。表 20 给出三种算力增速下的 base 条件分数：算力增速由 0.60 降至 0.15 dex/年时，24 个月 base 中位数由 46.19 降至 44.11，而时间项占模型变化的比例由 54.94% 升至 76.70%——算力增长越慢，技术进步越成为能力增量的主体。

表 20 按算力增速的 base 条件分数情景（中位数及 5%–95% 分位；起点 $T_0 = 2025.25$ ；源自 P4_frontier_forecast.csv）

算力增速	base 12 个月	base 24 个月	24 个月时间项占比
0.60 dex/年	43.07 [37.35, 52.83]	46.19 [37.55, 68.49]	54.94%
0.30 dex/年	41.73 [36.95, 49.66]	45.25 [37.75, 58.28]	65.49%
0.15 dex/年	41.09 [36.63, 47.59]	44.11 [37.53, 54.86]	76.70%

chat 的 24 个月中位数在后训练线性延续情景为 61.62[51.79, 79.62]、平台情景为 54.85[46.43, 70.12]，差异来自情景设定。回测方面，以 2024.5 前的 42 个 base 记录重估并预测 2025.25，M1b 在 0.60 dex/年情景下误差为 -0.784 分、采用实际算力增速时为 +0.212 分，均明显优于朴素线性外推 (+2.651 分) (T8_backtest.csv)。




图 20 算力情景分数模拟与回测记录

上述区间混合了P2 参数抽样、分解模型簇抽样、后训练增益与面板残差，C6 桥接的跨域迁移误差尚未单独传播；个别低算力情景的下界低于锚点，与累计前沿不下降的定义存在张力，重跑时需先修复单调性。这些条件性质已集中列入11.2，不影响「规模扩张为主、技术进步约占一成到两成、算力放缓时技术贡献上升」这一核心结论。

10 模型的检验与灵敏度分析

10.1 模型检验

全文检验汇总于表 21。「互相验证」用于同一问题、不同假设的方法对，判据取排序或数值的一致性；上下游分工衔接的方法之间不构成验证关系。

表 21 全文检验清单

问	检验对	类型	判据	结果
一	Huber 主分 vs 均值/PCA/TOPSIS	方法敏感性	样本 Spearman	0.9936/0.8166/0.9588
一	A1 vs A2/A3	扩展检验	KS 的 p 值	0.313/0.220, 未检出分布差异
一	六来源候选跨集	规则复检	候选比例与方向	5.00%/4.73%/4.99%, 主导方向有变化
一	clr+Huber vs 裸份额 OLS vs GBDT	1M 留出	逐域/目标 R^2	0.772/0.260、0.654/0.418、0.923/0.870
一	A1→A18 质量桥接	五折 + 六映射域	R^2 、MAE	0.4106、0.0365 ($n = 6$)
一	1M → 60M → 1B	跨尺度 (1B 独立)	目标 Spearman	0.523/0.467/0.677
一	尺度修正 (幂律主口径)	1B 独立检验	逐域 MAE	2.953 → 0.770, 降幅约 74%
一	A12-A15 估算表	一致性对照	排序	与实测相反, 作反例
二	有地板 vs 无地板	嵌套 F 检验	F 、 p	$F = 307.11$, $p < 10^{-15}$
二	$\kappa_N = \kappa_D$ 、 $\kappa_D = 0$	嵌套 F 检验	F 、 p	57.19 (3.4×10^{-13}) 拒绝; 0.63 (0.43) 不拒绝
二	B7 新增 90 点	留出 (插值)	RMSE、偏差	0.0531、+0.0219; 噪声代理 0.0458
二	解析式 vs 数值解	互相验证	相对误差	$< 10^{-14}$ (替代倍数)、 $< 10^{-8}$
二	$Q = 1$ 切片 vs L_0	退化核对	残差区间	+0.0036, [-0.0120, 0.0193]
二	B4/B5/B2/B10	外部趋势对照	Spearman	0.983/0.959/0.788/1.000, 水平不可比
二	B11/B12 来源审计	元数据核对	覆盖、 D 记账	步数覆盖 100%, 中位比 0.9986
三	数值解 vs 闭式 N^*	互相验证	相对误差	1.54×10^{-7}
三	求解器 vs 粗网格	互相验证	Loss 差	最大差 1.80×10^{-5}
三	剖面导数	有限差分	相对误差	4.1×10^{-10}
四	C8 重算 vs C1 榜单	口径核验	Pearson、MAE	0.9893-0.9995; MATH 0.8009/3.4974
四	S 形 vs 线性 vs 常数	留一	RMSE	8.079/8.283/9.514
四	分解三口径	方法敏感性	技术占比极差	32.81 pp
四	预测回测	事后回测	2025.25 误差	M1b -0.784; 朴素线性 +2.651

问题一。检验分三层：A2/A3 为冻结评分的扩展检验，A6/A7 为配比模型的同尺度留出，A8-A11 为跨尺度检验，其中 A10/A11 (1B) 完全不参与估计、A8/A9 承担尺度修正标定。GBDT 依据 A6/A7 表现选为交叉评估器，该留出不再重复充当候选收益的独立验证。A12-A15 为估算/外推表，其隐含的大尺度排序反转与实测排序保持相矛盾，作反例使用。

问题二。质量参数只用 B6 (半合成) 估计，留出只用 B7 新增 90 点 (Q 方向插值)。B2 为半合成、B3 由 B1 插值派生、B10 为公式估算，二者用于核对实现与趋势；B4 的 57 点剔除 13 个近邻后 44 点结果稳定 (Spearman 0.975)。B8 与 B6/B7 方向相反 (64.26% 低于 E)，作反例。B11/B12 审计确认 B1 的 8 个名义规模、每模型 147 步均被覆盖，B1 训练设定真

实、损失按公开公式生成。

问题三。数值最优解与闭式 N^* 、求解器与独立粗网格、剖面解析导数与有限差分三组互验，相对误差分别为 1.54×10^{-7} 、最大 Loss 差 1.80×10^{-5} 、 4.1×10^{-10} ，预算残差与份额和误差均小于 10^{-9} ；锚点映射与单域越界均按规范标记。

问题四。C8 重算与 C1 为同批数据的口径核验（MATH 差异待解释），桥接为同域留一，分解差异为方法敏感性，回测为事后回测且重估样本未严格截在起点前。问题四目前没有独立的时间外检验层，结论归属拟合层与条件外推层，这一边界在 11.2 说明。

10.2 灵敏度与稳健性分析

问题一。六来源阈值取 P90/P95/P97.5 时候选比例约 10.00%/5.00%/2.50%（A2 9.19%/4.73%/2.00%，A3 9.74%/4.99%/2.44%），阈值直接决定人工复核工作量。折扣对照分 Q_{v2} 与主分秩相关达 0.9547/0.9207/0.9395、域级排序不变。单指标极端扰动下主分变动约小 30%；13 域等权与 pile_cc 单域两目标给出不同候选，评价目标在搜索前固定；质量交互项仅 6/13 域显著。

问题二。去地板后质量 +0.1 在千亿参数处的等效倍数由约 3.0 降到 1.3–1.5，方向不变； κ_N 、 k_0 的 95% 区间为 [0.1264, 0.1568]、[0.2013, 0.2554]， κ_D 区间含 0；主式形状代价为留出 RMSE 0.0531（线性对照 0.0416、噪声 0.0458）。 $C = 10^{19}$ 时提质是否划算取决于成本函数， $C \geq 10^{20}$ 后三种 $g(Q)$ 下提质都更有效。

问题三。敏感性覆盖三类成本、C7 五档上下文、 η 三档、P2 重抽样、两种质量映射与配比不确定性，以及 $m=1$ 、 H_{tot} 、无地板对照。与预算和规模无关的解析结论是 $L_{\text{ctx}}^{\text{crit}} = 30000$ token；仅含 P2 时，离开下界的 bootstrap 区间为指数型 [19.038, 19.084]、幂函数型 [19.503, 19.560]、对数型 [18.539, 18.620]。Q3-9 已将 P1 域质量与配比 bootstrap 与 P2 联合传播，离开下界区间外扩约 0.003 dex，三种成本函数的阈值排序不变。

问题四。Medium 层权重在 0.25–1.0 时 $S(1.85)$ 变化不足 0.4 分，仅用 High 层时上平台降到 6.349，上升段依赖 Medium 层。C3 权重取 0.2、1.0 时技术率为 0.499、0.205 dex/年（不含 C3 为 0.781）。换窗口后 M1b 技术占比为 7.06%、8.18%，「规模为主」稳定。预测对后训练增益是否延续最敏感（约 6.8 分），大于算力情景差异（约 2 分）。

11 模型的评价与推广

11.1 模型的优点

1. 唯一质量口径与清晰证据分层。文档、领域、桥接标签与配比加权质量统一使用 CRITIC 加权 Huber 主分；A1 拟合、A2/A3 扩展、A6/A7 留出、A8/A9 标定、A10/A11 独立检验、A12–A15 估算分层报告。
2. 训练与检验边界可追溯。问题二只用 B6 估计质量参数、选模型，B7 新增 90 点作留出；配比通道参数只由 1M 训练行确定，A6–A11 仅用于评估。
3. 形式与阈值可检验。六来源阈值取 A1 同域 P95，桥接以分层五折比较 Ridge 与 GBDT；结构性转移由质量约束活跃状态定义并区分局部根与全局切换；主式显式指定并同时报告交叉验证更优的线性对照。
4. 解析与数值互验。替代条件、 N^* 与算力等价倍数、降维闭式与 Φ 判据、S 形桥接与

Shapley 分解均有闭式或可核验形式，并与数值结果逐项对照。

5. 职责分离、避免循环论证。先固定主分再报告分歧诊断与旧法对照，阈值敏感性与折扣对照分均不回写主评分，筛查预算不被当作真实冲突率。

11.2 模型的局限与改进方向

本研究的证据边界集中说明如下，凡正文结论涉及这些条件时均以此为准。

1. 无独立质量真值。问题一以方法一致性、扰动稳健性与下游敏感性刻画质量口径，不给出质量准确率；17 域中 11 域质量依赖文本桥接（五折 $R^2 = 0.4106$ ），区间不含模型选择与跨域偏差，ubuntu_irc（16 篇）、philpapers（63 篇）低置信使用。
2. 质量参数来自半合成数据。 κ_N, κ_D, k_0 只由 B6（半合成，最大约 12B）估计，B7 留出为 Q 方向插值；主式为指定幂次，留出 RMSE（0.0531）高于线性对照（0.0416）与噪声代理（0.0458）， κ_D 较弱；高预算端地板份额（约 33%）与「提质远比扩参数划算」含地板外推成分。
3. 跨尺度外推幅度不足。1B 检验显示尺度修正把绝对误差降低约 74%，但平均预测仍高于观测，配比效应幅度在 1B 缩至约六成；两档规模下单参数缩放（对数线性或幂律）刻画不出曲率，曲率参数欠定。
4. 问题三的数据边界。Q3-9 已闭合固定配比与重选配比两类抽样；质量参数仍来自半合成 B6，配比通道为探索性， $\log_{10} C \geq 23.5$ 的最优规模配置为外推。
5. 问题四口径尚未由重跑固定。主面板未执行严格开放权重纳入与许可证审计，C6 桥接迁移误差未单独进入预测区间，预测以历史锚点 $T_0 = 2025.25$ 为起点且原面板含前视数据，主链未在路径修复后重跑，补充独立实现尚未在本仓库运行（DEFERRED_Q3）。
6. 问题四方法分歧与占比口径。C6 的 High 层仅 7 点且全在底噪区，上升段依赖 Medium 层；分解三口径技术占比极差达 32.81 pp，是最大不确定性来源；占比分母为模型解释增量而非观测增量，观测与模型增量不完全闭合。
7. 预测不含离散突破。条件预测不含新架构等非平滑变化；个别低算力情景区间下界低于锚点，与累计前沿不下降定义存在张力，需先修复单调性。

改进方向。

1. 为 11 个 inferred 域增补质量标签或模型评分信号，重新校准并检验桥接误差；补齐 P1 逐次重抽样接口，使两类配比不确定性可分别传播到问题三。
2. 取得真实跨质量、跨规模训练日志后替换 B6 重估 k_0 与 κ_N ，并允许配比强度随 $\log N$ 变化；在获得真正跨尺度配比试验前对 H_{red} 、 H_{tot} 各算一遍。
3. 问题四重跑时执行明确的开放权重纳入规则（报告纳入前后样本量与敏感性），把建模、校准与回测样本全部截在各自起点之前，将 C6 桥接的 bootstrap 与残差作为独立不确定性通道，并统一占比分母与前沿单调性。
4. 取得更多同验证集的 Loss-Benchmark 对，缩小结构口径与线性口径的技术占比分歧。

11.3 模型的推广

「经典基线 + 质量修正 + 配比乘子」的标度律结构可推广到其他数据受限的资源配置问题（去重、合成数据、多模态对齐均可写成可约损失上的乘子与不随规模消失的地板）；「约束取等后解析消元 + 活跃约束状态分类」的降维方法适用于含多种数据处理成本的预算优化；「分层 S 形桥接 + 连续时间项 + Shapley 分解」框架适用于其他存在能力饱和

的技术演进分析。推广时保持同一纪律：明确数据证据等级，把半合成、估算与外推数据标注为假设支撑而非观测验证。

12 结论

本文围绕「算力约束下如何配置资源以提升大语言模型能力」，建立四个层层衔接的模型，主要结论如下。

问题一。以 A1 冻结的 CRITIC 加权 Huber 中心作为唯一质量口径，把 22 个字段展开为 25 项指标，得到文档、领域与语料质量；六来源诊断在三集各圈定约 5% 的高分歧复核候选，主导对立方向随语料变化；17 域质量由映射与文本桥接补齐（五折 $R^2 = 0.4106$ ）。配比模型给出 17×13 迁移结构，推荐配比 $\mathbf{p}^*$ 在 1M 代理模型下较均匀配比预测降损 9.47% (95% 区间 [7.82%, 11.16%])；域质量与训练边际价值秩相关仅 -0.211，质量分不能替代配比实验。

问题二。建立幂次广义标度律 $L = E + k_0(1 - Q) + [AN^{-\alpha}Q^{-\kappa_N} + BD^{-\beta}Q^{-\kappa_D}] \exp(s_{\text{red}}\tilde{\varphi}(\mathbf{p}))$ ，其中经典参数 $E = 1.6901$ 、 $A = 406.39$ 、 $\alpha = 0.34$ 、 $B = 410.59$ 、 $\beta = 0.28$ ，质量参数 $\kappa_N = 0.1416$ 、 $\kappa_D = 0.0112$ 、 $k_0 = 0.2280$ 、 $Q_0 = 0.6624117$ 。参照点上质量弹性约为参数弹性的 1.62 倍；质量提高 0.1 等效于参数扩大 1.30–3.07 倍；沿算力前沿等效算力乘 1.191/1.485/2.134。 $C \geq 10^{20}$ 后提质比扩参数更有效；配比通道受单一尺度限制，按探索性下、上情景报告。

问题三。约束取等后解析消元，把问题降为 $(\log_{10} N, Q)$ 二维有界优化，以质量约束活跃状态定义结构性转移，以 $\Phi = 1$ 作为固定 Q 下的局部一阶必要条件（导数核验误差约 4.1×10^{-10} ）。上下文长度临界值为 $L_{\text{ctx}}^{\text{crit}} = 30000$ token。数值上， $C = 10^{19}$ 时指数型、幂函数型成本下不提质、对数型直接提满， $C = 10^{22}, 10^{24}$ 时均提满；离开下界的临界预算 $(\log_{10} C)$ 约为 19.06/19.53/18.58，为「何时投向提质」给出随成本函数移动的明确阈值。

问题四。用「标度律 + S 形桥接 + 连续时间项」分解历史前沿：2023.50 $\rightarrow$ 2025.00 窗口 base 观测提高 24.759 分，规模贡献 23.063、技术贡献 3.404，技术占比 12.86% (90% 区间 6.07%–21.96%)；去饱和综合分同期提高 48.19%，更灵敏地反映进展。算力增速由 0.60 降至 0.15 dex/年时，24 个月 base 中位数为 44.11，技术增量占比由 54.94% 升至 76.70%。该结果以 $T_0 = 2025.25$ 为历史锚点，更新数据后需重作。

四问共同指向核心判断：数据质量与领域配比是与算力并列的一等资源。低预算阶段边际投入主要投向模型规模，预算跨过质量收益与提质开销的平衡点后，提质与配比优化优先级上升；算力增长放缓时，能力进步将越来越依赖非规模技术创新。上述定量判断的适用条件已在 11.2 逐条界定。

参考文献

- [1] Hoffmann J, Borgeaud S, Mensch A, et al. Training compute-optimal large language models[C]//Advances in Neural Information Processing Systems 35 (NeurIPS). 2022.
- [2] Bahri Y, Dyer E, Kaplan J, et al. Explaining neural scaling laws[J]. Proceedings of the National Academy of Sciences, 2024, 121(27): e2311878121.

- [3] Diakoulaki D, Mavrotas G, Papayannakis L. Determining objective weights in multiple criteria problems: The CRITIC method[J]. Computers & Operations Research, 1995, 22(7): 763–770.
- [4] Huber P J. Robust estimation of a location parameter[J]. The Annals of Mathematical Statistics, 1964, 35(1): 73–101.
- [5] Penedo G, et al. The FineWeb datasets: Decanting the web for the finest text data at scale[C]//NeurIPS Datasets and Benchmarks Track. 2024.
- [6] Aitchison J. The Statistical Analysis of Compositional Data[M]. London: Chapman & Hall, 1986.
- [7] Xia M, et al. RegMix: Data mixture as regression for language model pre-training[C]//International Conference on Machine Learning (ICML). 2024.
- [8] Biderman S, et al. Pythia: A suite for analyzing large language models across training and scaling[C]//International Conference on Machine Learning (ICML). 2023.
- [9] Muennighoff N, et al. Scaling data-constrained language models[C]//Advances in Neural Information Processing Systems 36 (NeurIPS). 2023.
- [10] Schaeffer R, Miranda B, Koyejo S. Are emergent abilities of large language models a mirage?[C]//Advances in Neural Information Processing Systems 36 (NeurIPS). 2023.
- [11] Shapley L S. A value for n -person games[M]//Contributions to the Theory of Games II. Princeton: Princeton University Press, 1953: 307–317.
- [12] Shafer G. A Mathematical Theory of Evidence[M]. Princeton: Princeton University Press, 1976.
- [13] Subramanyam A, Chen Y, Grossman R L. Scaling laws revisited: Modeling the role of data quality in language model pretraining[J]. arXiv preprint arXiv:2510.03313, 2025.
- [14] Xu Z, Wu S, Cho H, et al. Data-constrained language model pretraining: Improved regularization and scaling laws[J]. arXiv preprint arXiv:2606.06888, 2026.
- [15] Lovelace J, Belardi C, Kundurthy S, et al. Prescriptive scaling laws for data constrained training[J]. arXiv preprint arXiv:2605.01640, 2026.

附录 A 补充材料与程序

A.1 支撑材料清单与运行说明

正文各结论均按证据分层陈述：解析推导、拟合估计、尺度标定、留出检验、独立检验、评分后诊断、半合成数据、外推或估算，以及历史口径对照，其性质与边界已在正文相应处注明；半合成、估算与外推数据不作为观测验证。正文中*.csv、*.json、*.npz形式的文件名是相应结果的落盘名称：数据表在src/outputs_qN/tables/，跨问接口在src/outputs_qN/interface/，图在src/outputs_qN/figures/；每张表与每幅图的标题内注明其数据来源文件。

问题一：src/code_q1/q1_00_common.py（公共路径与工具）→ q1_01_extract.py → q1_02_quality.py → q1_03_conflict.py、q1_04_bridge.py → q1_05_mixture.py → q1_06_scale.py、q1_07_optimal.py → q1_08_audit.py；环境Python 3.12.13、NumPy 2.4.4、pandas 3.0.2，不依赖SciPy与scikit-learn。

问题二：src/code_q2/q2_01_fit.py、q2_02_theory.py、q2_03_economics.py；环境Python 3.12.7、NumPy 1.26.4、pandas 2.2.2、SciPy 1.13.1，随机种子2026；只读src/outputs_q1/interface/，不读附件A原始表。

问题三：src/code_q3/q3_00_model.py、q3_01_optimize.py、q3_02_transition.py、q3_03_mixture_joint.py；已按幂次目标式与固定配比乘子 $m_* \approx 0.8989423$ 重跑，P3主网格为210行（运行清单P3_run_manifest.json，2026-09-26 11:37）；运行清单的输入/输出哈希因后续上游文件更新需重新生成。

问题四：src/code_q4/q4_01_c8_parse.py → q4_02_saturation.py → q4_03_bridge.py → q4_04_decomp.py → q4_05_forecast.py → q4_99_check_report.py；该自检（16项）当前3项未通过：P3输入哈希、P3输出哈希一致性，以及P4目标日期（历史锚点2026.25已过去）。

注：以上脚本路径与随机种子以各问Spec的「当前实现差异」与修订历史为准；本节只登记，不复述Spec。

A.2 核心程序

(1) CRITIC 权重与加权Huber主分（code_q1/q1_02_quality.py节选）

```
def fit_critic(self, Z):
    sd = Z.std(axis=0, ddof=1)                # contrast intensity
    R = np.corrcoef(Z.T)                     # indicator correlation
    C = sd * (1 - R).sum(axis=1)              # information content C_j
    self.critic_w = C / C.sum()
    return self.critic_w

def fit_delta(self, Z):                      # A1 weighted-MAD rule
    center = weighted_median(Z, self.critic_w)
    dev = np.abs(Z - center[:, None])
    mad = weighted_median(dev, self.critic_w)
    self.delta = float(np.clip(1.345 * 1.4826 * np.median(mad), .01, 1.0))
```

```
return self.delta
```

```
def score(self, Z):
    # fixed weights and delta
    return weighted_huber_center(Z, self.critic_w, self.delta)
```

(2) 问题三向量化求解器 (code_q3/q3_00_model.py 节选)

注：下列节选即现行实现——幂次质量乘子 $Q^{-\kappa}$ 与固定配比乘子 $m_* = \exp\{s_{\text{red}}\tilde{\varphi}(\mathbf{p}^*)\} \approx 0.8989423$ ，质量地板 $k_0(1-Q)$ 留在括号外；内层 $\log_{10} N$ 黄金分割与三级网格加密的结构不变，此处列出质量式与 Φ 判据函数。

```
def hN(Q, p=PAR):
    # v5 power multiplier (drop linear 1+k
    (1-Q))
    return Q ** -p["kappa_N"]

def hD(Q, p=PAR):
    return Q ** -p["kappa_D"]

def loss(N, D, Q, p=PAR, m=M_STAR):
    """v5: floor k0(1-Q) outside bracket; mixture multiplier m only on scale
    terms"""
    return (p["E"] + p["k0"] * (1.0 - Q)
            + m * (p["A"] * hN(Q, p) * N ** -p["al"]
                    + p["B"] * hD(Q, p) * D ** -p["be"]))

def phi_ratio(C, g, Lctx, Qeval, Q0, p=PAR, eta=ETA, m=M_STAR):
    """v5 complete Phi at the fixed-Q optimal (N,D):
    Phi = [k0 + (m/Q)(kN TN + kD TD)] * S / [m * beta * TD * g'(Q)],
    S = (6+eta*L_ctx)N + dg,  TN = A N^-al Q^-kN,  TD = B D^-be Q^-kD"""
    kappa = 6 + eta * Lctx
    dg = max(g(Qeval) - g(Q0), 0.0)
    _, x = _profile(C, Qeval, dg, kappa, p, m=m) # inner golden section (
    unchanged)
    N = 10.0 ** x; D = C / (kappa * N + dg)
    TN = p["A"] * N ** -p["al"] * hN(Qeval, p) # TN = A N^-al Q^-kN
    TD = p["B"] * D ** -p["be"] * hD(Qeval, p) # TD = B D^-be Q^-kD
    S = kappa * N + dg
    num = (p["k0"] + m / Qeval * (p["kappa_N"] * TN + p["kappa_D"] * TD)) * S
    den = m * p["be"] * TD * g_prime(Qeval)
    return float(num / den) # C_crit solves Phi(C) = 1
```

(3) 结构分解模型与 Shapley 分解 (code_q4/q4_04_decomp.py 节选)

```
def f_add(p, L, t):
    # M1b: S-bridge + linear tech
    term
    return p["lo"] + p["amp"] * sig(L, p["k"], p["L0"]) + p["tau"] * t
```

```
def shapley(fun, L0, t0, L1, t1):
    """two-factor Shapley: scale (L_hat) vs technology (t)"""
    sc = 0.5 * ((fun(L1, t0) - fun(L0, t0)) + (fun(L1, t1) - fun(L0, t1)))
    te = 0.5 * ((fun(L0, t1) - fun(L0, t0)) + (fun(L1, t1) - fun(L1, t0)))
    return sc, te
```

A.3 AI 使用披露

依据赛题“AI 使用规范”，现披露如下。

所用工具：Claude (Anthropic)、Kimi Code (Kimi)。

使用环节与贡献范围：(1) 资料整理与概念理解：梳理赛题附件的字段结构与《数据说明》中的条目；(2) 代码编写与调试：数据读取、向量化求解器、绘图脚本的编写与报错排查；(3) 结果核对：编写自动核对脚本，把报告中的数字与程序输出逐项比对；(4) 排版与文字：LaTeX 排版、图表整理与语句润色。上述 AI 产出的代码、数值与文字均经参赛队逐项复核。

参赛队的工作与责任：模型路线的选择（证据分层、质量项形式由交叉验证裁决、结构性转移按 KKT 活跃集定义、分解方法并列报告等）、公式推导与结论判断由参赛队确定，并对 AI 输出的全部代码与数值逐项运行、核验。文中理论、公式与结论均引用正式文献或由附件数据验证，未以 AI 输出作为学术依据。全部数值结果可由随文代码在附件数据上复现。