



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校 国防科技大学

参赛队号 26910020233

	1. 李重行
队员姓名	2. 李星谊
	3. 刘浩然

中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生

数学建模竞赛

题 目： 算力约束下提升大语言模型能力的资源配置建模

摘 要：

大语言模型的预训练能力随模型参数量 N (个) 与训练 token 数 D (token) 增长, 经典标度律以验证集交叉熵损失 $L_0(N, D) = E + AN^{-\alpha} + BD^{-\beta}$ 描述这一过程 [1, 2]。在有限算力下可分配的不仅是规模: 语料质量 Q 与领域配比 $\mathbf{p}$ 同样改变同等投入的效果。本文按「数据如何衡量—资源如何发挥作用—资源如何分配—能力如何演进」的顺序建立四个递进衔接的模型, 前一问的冻结结果经 P1–P4 接口文件进入后一问, 未通过留出检验的通道不进入下游主优化。

针对问题一, 把附件 A1 的 22 个原始质量字段展开为 25 项可比指标, 以域内冻结的预处理、CRITIC 权重与加权 Huber 中心得到唯一的文档质量分 $Q(x)$ (Huber 阈值 $\delta = 0.4034907036619329$ 只由 A1 确定并冻结), 再由 A16 映射与 A18 文本特征桥接到 17 个配比域。A1 七域主分中位数由高到低为 arxiv 0.7707、commoncrawl 0.6761、stackexchange 0.6600、c4 0.6545、book 0.6313、github 0.6172、wikipedia 0.5991; 冻结管线在扩展集 A2/A3 上未检出明显分布差异 (KS 的 p 值 0.313/0.220), 但没有人工质量真值, 故不报告准确率。评分之后的六来源分歧诊断在三集标出约 5% 的高分歧复核候选 (5.00%/4.73%/4.99%), 该比例来自预设的 P95 筛查预算, 不是真实冲突率, 诊断结果不回写主评分。17 域质量由映射与文本桥接补齐 (分层五折 $R^2 = 0.4106$, 六个映射域的 MAE 0.0365 但 $n = 6$)。配比以中心对数比稳健回归建模, 得到 17×13 的局部迁移结构; 在 1M 代理模型的信赖域内选出的推荐配比 $\mathbf{p}^*$, 其预测等权损失比均匀配比低 9.47% (bootstrap 中位数 9.54%、95% 区间 [7.82%, 11.16%]), 配比加权语料质量 $\bar{Q}(\mathbf{p}^*) = 0.6624116679870492$ 。域质量与训练边际价值的秩相关仅 -0.211, 说明单凭质量分不能代替配比实验。

针对问题二, 先在 B1 上估计经典基线 ($E = 1.6901$ 、 $A = 406.39$ 、 $\alpha = 0.34$ 、 $B = 410.59$ 、 $\beta = 0.28$), 再把质量写成可约损失上的幂次乘子、把不随规模消失的地板留在括号外: $L = E + k_0(1 - Q) + [AN^{-\alpha}Q^{-\kappa_N} + BD^{-\beta}Q^{-\kappa_D}] \exp(s_{\text{red}}\tilde{\varphi}(\mathbf{p}))$, 其中 $\kappa_N = 0.1416$ 、 $\kappa_D = 0.0112$ 、 $k_0 = 0.2280$ 、 $s_{\text{red}} = 1.4996207320397785$ 、 $Q_0 = 0.6624116679870492$ 。质量参数只用半合成的 B6 训练, B7 相对 B6 新增的 90 点作留出 (RMSE 0.0531, 高于同格噪声代理 0.0458 与交叉验证更优的线性对照 0.0416, 这是把质量写成「有效规模」的代价)。在主式下, 参照点上质量弹性约为参数弹性的 1.62 倍 (约 73% 来自地板); 固定 $D = 3 \times 10^{11}$ 时质量提高 0.1 需把参数扩大为原来的 1.299 倍 ($N = 10^9$) 至约 3.07 倍 ($N = 10^{11}$); 沿算力前沿,

Q 由 0.7 升到 0.8 相当于算力乘 1.191/1.485/2.134 ($C = 10^{19}/10^{22}/10^{24}$ FLOPs, 无地板时恒为 1.165)。 $C = 10^{19}$ 时是否提质取决于提质成本函数的形式, 自 $C = 10^{20}$ 起三种成本函数下提质都比扩参数下降更多损失。 配比通道受 1M 单一尺度的限制, 只作探索性通道, 并以两个零新增参数的强度假设给出下界与上界。

针对问题三, 把训练、提质与注意力三项成本放入同一预算, 利用三项成本对 D 的线性结构把预算约束取等并解析消元, 使问题降为 $(\log_{10} N, Q)$ 的二维有界优化; 以最优解处质量约束的活跃状态定义结构性转移, 并在固定 Q 的意义下给出局部一阶必要条件 (已做单点有限差分核验, 相对误差约 4.1×10^{-10})。 与预算、成本函数和规模都无关的解析结论是上下文长度的临界值 $L_{ctx}^{crit} = 6/\eta = 30000$ token, 越过它之后注意力开销占主导、最优模型随之缩小。 按现行 Spec 的数值重算 (各档预算的最优配置、临界预算与成本份额) 尚未执行, 故本文只报告上述解析结论, 不引用旧口径数值。

针对问题四, 用「标度律 + S 形桥接 + 连续时间项」的结构模型解释开源能力前沿的增长: 先把 C6 的损失—得分关系按可比性分层拟合成 S 形桥接, 再以问题二标度律给出的规模状态为自变量、加入连续时间项, 用双顺序 Shapley 分解把前沿增量分为规模贡献与技术贡献。 在主窗口 2023.50 $\rightarrow$ 2025.00, base 前沿观测变化 24.759 分, 模型解释的规模贡献 23.063、技术贡献 3.404, 技术占比 12.86% (90% 区间 6.07%–21.96%); 线性对照口径的技术占比为 29.5%–48.5%, 三口径极差 32.81 个百分点, 故结论只表述为「规模扩张为主、非规模技术进步约 13%–23% (结构口径)」, 且占比的分母是模型解释增量而非观测增量。 能力口径上, 剔除饱和和任务后的去饱和综合分在 2024-06 至 2025-03 由 26.36 升至 39.06 (+48.19%), 高于含饱和任务的 Average (+29.53%)。 在算力增速由 0.60 降至 0.15 dex/yr 的情景下, 24 个月 base 前沿中位数为 44.11, 技术进步的增量占比由 54.94% 升至 76.70%。 问题四的数字来自 **2026-09-24** 生成的旧产物, 主链尚未在附件路径修复后重跑, 且预测起点 $T_0 = 2025.25$ 已是历史锚点、预测区间未含 C6 桥接的迁移误差, 故只能作为条件情景参考。

四问共同指向一个判断: 数据质量与领域配比是与算力并列的一等资源——低预算段的边际价值主要体现在模型规模上, 预算跨过质量收益与提质开销的平衡点后, 提质与配比优化的优先级上升; 而算力增长放缓时, 能力增长将越来越依赖非规模技术进步。 本文所有定量结论的适用范围 (半合成数据、探索性配比通道、历史预测锚点、问题三与问题四尚未重跑) 已在 7.2 逐条写明。

关键词: 数据质量; 领域配比; 广义标度律; 算力约束优化; 能力演进预测

1 问题重述

1.1 问题背景

大语言模型的预训练能力随模型参数量 N (个) 与训练 token 数 D (token) 增长, 经典标度律以验证集交叉熵损失 $L_0(N, D) = E + AN^{-\alpha} + BD^{-\beta}$ 描述这一过程 [1, 2]。按本题采用的近似, 基础训练开销约为 $C \approx 6ND$ (FLOPs), 在有限预算下必须权衡模型规模与数据量。仅比较 N, D, C 不足以描述真实训练: 语料质量与领域组成会改变同等投入的效果, 因此需要先建立数据质量 Q 的可比口径与领域配比 $\mathbf{p}$ 的损失关系, 再把二者接入经典标度律, 形成 $L(N, D, Q, \mathbf{p})$, 最终落到算力约束下的资源配置与能力演进判断上。附件 A 提供质量信号与配比实验, 附件 B 提供标度律数据, 附件 C 提供模型、算力与能力评测信息。

1.2 问题描述

本题依次要求完成四项数学任务, 前一问的输出是后一问的输入。

问题一: 数据质量与领域配比。建模对象是文档、领域与混合语料的质量, 以及 17 个训练领域配比对 13 个验证域损失的影响; 约束是质量信号方向与量纲不一、11 个配比域缺少直接质量映射, 且配比份额非负、总和为 1。用 A1 (51,230 篇) 拟合文档质量口径与全部预处理参数, 冻结后在扩展集 A2 (arxiv 17,523 篇)、A3 (github 203,752 篇) 上检验评分与冲突诊断的稳定性; 用 A16 的映射与 A18 的文本特征把质量扩展到 17 域; A4/A5 按 index 连接作 1M 配比训练, A6/A7 作 1M 留出, A8/A9 作 60M 直接检验与尺度修正标定, A10/A11 (各 64 行) 作 1B 独立检验, A12–A15 只作估算/外推情景讨论。

问题二: 广义标度律。建模对象是损失对 $N, D, Q, \mathbf{p}$ 的依赖; 约束是理想质量与参照配比下须退回经典式, 且 A、B 两组损失的评测管线与质量尺度不能直接等同。以 B1 估计经典基线, B6 (360 点, 半合成) 估计质量项并选择模型, B7 相对 B6 新增的 90 点 ($Q = 0.5, 0.7$, 覆盖全部 45 个 (N, D) 格) 作留出; B2、B3、B4、B5、B8、B9、B10 分别作半合成、插值、跨族、文献、方向冲突与估算对照, B11/B12 作来源审计。问题一的域质量与配比关系经固定接口引入。

问题三: 算力约束下的资源配置。建模对象是给定预算 C (FLOPs) 与上下文长度 L_{ctx} (token) 下的 N, D, Q ; 约束包括训练、提质与长上下文三项成本, 质量下界由问题一推荐配比确定, 主方案固定该配比。读取问题一的质量与配比接口、问题二冻结的标度律参数, 不在本问重新拟合; C7 提供上下文长度的可行档位。

问题四: Benchmark 检验与能力演进。建模对象是开放权重模型的能力前沿及其规模与非规模来源; 约束是能力、时间、模型类型与开放权重口径必须一致, 且损失与 Benchmark 得分不在同一尺度。C1/C2 提供榜单能力与发布日期, C4 补充规模与算力, C8 用于逐任务聚合与饱和度检查, C6 分层拟合损失到得分的桥接, C3 只作混合口径的敏感性对照。

2 问题分析

2.1 总体思路

四问按”测量数据—描述损失—优化训练—解释能力”递进：问题一从文档质量 $Q(x)$ 聚合到领域质量 Q_i ，再按配比得到语料质量 $Q(\mathbf{p})$ ；问题二在 $L_0(N, D)$ 上引入质量与配比，经典律是广义律在 $Q = 1, \mathbf{p} = \mathbf{p}_{\text{ref}}$ 时的切片；问题三以标度律为目标，加入预算、提质与注意力成本约束求最优配置；问题四引入时间与 Benchmark 度量，把损失变化转成能力前沿的解释与条件预测。各问的冻结结果通过 P1-P4 接口传递，未通过留出检验的配比通道不进入下游主优化。四问的参数、约束与接口传递关系在 5.1 的接口约定与 5.2-5.5 各问的模型建立中逐条说明。

2.2 各问题的关键难点

问题一：从异质指标得到唯一语料质量。难点在于 logits、规则量与 DSIR 的方向和尺度不一，长度与领域基线会干扰质量判断，17 域又有 11 域缺少直接评分。为避免冗余信号重复计权、避免单项极端指标支配整篇分数，采用 A1 冻结的域内预处理、CRITIC 权重与 Huber 中心；冲突只在评分之后按来源诊断，不反向改分。领域质量以映射加文本桥接补齐，配比因份额闭约束采用中心对数比建模，并以 A6-A11 检查跨尺度边界。

问题二：跨附件质量口径与可推广的函数形式。A、B 两组损失的分词器与验证集可能不同，绝对值不能直接对齐，因此质量项只作用在 B1 骨架的可约部分上。质量乘子的形状（幂次、指数、线性）不能事先指定，故在同一骨架上比较 M0-M4 与有无地板的嵌套族，用 B6 训练、B7 新增点留出。主式指定为幂次，是为把质量写成有效规模；交叉验证更优的线性对照一并报告，其代价写清。配比效应只有 1M 数据，无法识别其随规模的斜率，故不估计尺度项，只设两个零新增参数的强度假设，再用 A6-A11 的观测校准斜率做事后比较。

问题三：非线性约束与边界转移。三项成本都与 D 成正比，而损失对 D 严格递减，故预算取等，可解析消去 D ，把问题降为 $(\log_{10} N, Q)$ 的二维有界优化。质量约束是否活跃构成质量状态的边界分类，其变化即”最优策略的质变”。三种提质成本函数的水平与边际曲率都不同，单个成本项凸不保证联合优化凸，故须保留独立粗网格核对，并区分局部一阶根与全局状态切换。

问题四：能力演进的解释边界。难点是 Loss 与 Benchmark 得分尺度不同、任务会饱和、规模与时间共变、C3 口径混杂。故采用可检验的 S 形损失—得分桥接与连续时间项，在一致的开放权重与模型类型口径下分解增长，并做窗口敏感性与回测。时间项只表示控制规模状态后的剩余关联，不解释为已识别的因果技术进步。

2.3 数据使用与证据分层

各附件的角色与证据性质见表 1。表中”角色”以对应 Spec 为准，不自行升格或降格。

表 1 附件角色与证据性质（引自各问 Spec，非数据产物）

附件	内容	角色	证据性质
A1	七域质量信号抽样 51,230 篇	拟合与标准化参照（唯一）	真实
A2 / A3	arxiv 17,523 / github 203,752 篇	冻结评分与诊断的扩展检验	真实
A4 / A5	1M 配比与 13 域 Loss 各 512 组	配比主模型训练（唯一）	真实
A6 / A7	1M 配比与 Loss 各 256 组	同尺度留出	真实
A8 / A9	60M 配比与 Loss 各 256 组	跨尺度直接检验 + 尺度修正标定	真实
A10 / A11	1B 配比与 Loss 各 64 组	独立检验，不参与任何估计	真实
A12 - A15	10B/70B 配比（各 63 组）与 Loss	估算/外推情景对照	子集 / 外推，非观测
A16	17 域 $\rightarrow$ 7 质量域映射	映射参照	人工整理
A17	域统计摘要	背景与辅助	真实，未接入求解
A18	17 域原始文本 138,034 条（本轮有效 31,340 篇用于桥接预测）	桥接预测输入	真实
B1	Pythia 训练轨迹 1,176 行	经典基线拟合	真实（损失按公开公式生成，见审计）
B2	Cerebras 轨迹 1,029 行	族外趋势对照	半合成
B3	插值轨迹 4,000 行	轨迹对照	插值（B1 派生）
B4 / B5	跨族基准 57 行 / 文献点 44 行	外部趋势对照（ $Q = 1$ ）	真实 / 文献整理
B6	NQ 质量网格 360 行	质量项参数估计（唯一）	半合成
B7	扩展网格 450 行（新增 90 点）	留出检验	半合成， Q 方向插值
B8	大规模矩阵 1,704 行	方向冲突压力检查	半合成，与 B6/B7 方向相反
B9 / B10	100B+ 配置 132 行 / 预估 Loss 128 行	外推参照	真实元数据 / 估算
B11 / B12	模型族元数据 / Pythia 检查点索引	来源审计	真实
C1 / C2	榜单 4,576 行 + Epoch 匹配列	能力与发布日期	真实（同批榜单，非两套样本）
C3	历史时序 4,599 行	降权敏感性	混合口径
C4	全量模型元数据 3,523 行	规模、算力、开放权重	真实
C5 / C6	桥接表 43 / 75 行	损失—得分映射	混合口径，分层使用
C7	架构元数据 45 行	上下文长度档位	真实
C8	逐任务 JSON 1,958 个	逐任务聚合与饱和度	真实

3 模型假设

1. 质量信号可作相对测量。A 组指标经方向与域内尺度校正后可比较同域文档的相对质量，不假定存在人工标注的绝对真值。服务问题一的 $Q(x)$ ；以 A2/A3 冻结评分与删去极端指标的扰动检查适用性。2. 领域质量可按份额聚合。给定 A16 映射与桥接模型，混合语料质量取 17 域质量的份额加权值 $Q(\mathbf{p}) = \sum_i p_i Q_i$ ；配比对验证损失的额外影响单独建模。服务问题一至三；以六个可映射域的桥接误差、A6/A7 留出与 A8–A11 检验检查边界。3. 评价目标预先固定。13 个验证域等权定义主目标，pile_cc 单域只作敏感性口径，评价权

重不随候选配比改变。服务问题一配比搜索与问题三目标选择。4. 质量刻度需要锚定。主口径取 $Q_B = Q(\mathbf{p})$ ，推荐配比处 $Q_0 = Q(\mathbf{p}^*) = 0.6624116679870492$ ； $Q = 1$ 且 $\mathbf{p} = \mathbf{p}_{\text{ref}}$ (A4 训练配比均值) 时广义式退回经典式。副映射 $Q_B = Q(\mathbf{p})/Q_0$ 会使部分领域超出 $[0, 1]$ ，只作敏感性且不静默截断。服务问题二、三。5. 成本按同一训练量计。训练、提质与注意力开销均以同一 D 计量，成本函数参数依赛题给定； $\eta = 2 \times 10^{-4}$ 为题设值。服务问题三；不预设三种成本函数下解的性质相同。6. 非规模变化在窗口内平滑。问题四用连续时间项描述控制规模状态后的剩余得分变化，并以不同窗口与模型回测；遇到离散架构突破时该条件预测不适用。

4 符号说明

表 2 主要符号及含义（含单位与角色）

符号	含义	单位	角色
N, D	模型参数量、训练 token 数	个, token	Q1/Q2 输入; Q3 决策变量
C	总训练算力预算	FLOPs	给定参数 (Q3)
$Q(x), Q_i$	文档主质量分、训练域 i 质量分	$[0, 1]$	估计量 (Q1)
$Q(\mathbf{p}), Q_B$	混合语料质量、B 组质量刻度; 主口径二者相同	无量纲	Q1 输出、Q2 输入
Q_0	推荐配比下的提质起点, 0.6624116679870492	无量纲	接口参数 (Q2/Q3)
$\mathbf{p} = (p_i)_{i=1}^{17}$	17 域训练份额, 非负且总和为 1	无量纲	决策变量 (Q1)
$z_j(x), w_j$	第 j 项标准化指标、冻结的 CRITIC 权重	$[0, 1]$ / 无量纲	数据变换、估计参数
δ	Huber 中心阈值, 0.4034907036619329	$[0, 1]$	由 A1 确定的尺度规则
$B(x), u_s(x)$	六来源分歧度、来源 s 的 A1 参照分位	$[0, 1]$	诊断量
L_v, L	验证域 v 的损失、等权综合损失	nats	观测量或预测目标
T_{iv}	均匀配比附近域 i 份额对域 v 对数损失的局部效应	无量纲	估计参数 (Q1)
E, A, B, α, β	经典标度律地板、幅度与指数	依公式	估计参数 (Q2, B1)
k_0, κ_N, κ_D	质量地板系数与两项质量幂次	nats, 无量纲	估计参数 (Q2, B6)
h_N, h_D	主式质量乘子 $Q^{-\kappa_N}, Q^{-\kappa_D}$	无量纲	函数 (Q2)
$s_{\text{red}}, \tilde{\varphi}(\mathbf{p})$	配比强度 (1M 训练定为 1.4996207320397785)、配比偏离	无量纲	参数与由 Q1 给定的量
m_*	固定 $\mathbf{p}^*$ 的配比乘子 $\exp\{s_{\text{red}} \tilde{\varphi}(\mathbf{p}^*)\} \approx 0.8989423$	无量纲	Q3 的给定常数
$g(Q), L_{\text{ctx}}, \eta$	单位 token 提质成本、上下文长度、注意力成本系数 2×10^{-4}	FLOPs/token, token, —	给定函数与情景参数
S, t	Benchmark 综合得分、模型发布日期	分, 年	响应量、时间变量 (Q4)
$L_{\text{ctx}}^{\text{crit}}$	注意力与训练成本相等的上下文长度, $6/\eta = 30000$	token	解析结论

局部符号在首次出现处说明。

5 模型的建立与求解

5.1 数据来源与接口约定

正文只使用三组附件的既有编号 (A1 – A18、B1 – B12、C1 – C10) , 单位纪律如下: N_params_B、D_tokens_B 的单位均为 10^9 , 代入 $C = 6ND$ 时须乘 10^{18} ; C_FLOPs_1e21 的单位为 10^{21} FLOPs, 不得直接代入绝对预算 C 。跨问只传递已定义的质量分、配比与模型参数: 问题一输出 src/outputs_q1/interface/ 下的 P1_Q_domain.csv、P1_p_star.csv、P1_summary.json、P1_scale_calibration.csv 等; 问题二输出 src/outputs_q2/interface/P2_scaling_law.json 等; 问题三、问题四分别输出 P3_*、P4_*。下游不读缓存文件。推理过程见 src/code_q1/q1_00_common.py 等脚本的路径解析 (附件目录优先仓库根目录附件/)。

5.2 问题一的模型建立与求解

本问按 sec5_q1.tex 的三项任务组织: 任务一建立唯一的文档与领域质量口径; 任务二在评分之后诊断指标与来源之间的分歧; 任务三把质量桥接到 17 个训练域、建立配比—损失模型并选出推荐配比, 输出 P1 接口。三项共用同一套冻结参数, 任务一与任务二的产物进入任务三与后续问题。

5.2.1 任务一: 数据质量评估

A1 的 22 个原始字段按输出形态展开为 25 项: 4 个 modernbert_* 六档 logits 各取 softmax 后的期望分; qurater 拆为四维; ad_en、fluency_en 取标签 1 的概率 (ad_en 的标签 1 表示无广告); fineweb_edu 取单元素值; 3 个 DSIR 与 11 个 rps_* 取原标量。词数、句数、平均词长与词熵按 A1 域内中位数转为适宜区间型 $-|h_j(x) - m_{dj}|$; 正向指标保留、负向指标取负; 重尾非负值按规则取 $\log(1 + x)$ 。三个 DSIR 分量先除以 $\max(\text{word_count}, 1)$, 再在 A1 各域内以 $\log(1 + \text{word_count})$ 拟合带截距 OLS 并使用残差; A2/A3 复用 A1 的回归系数。各域各指标用 A1 的 1%/99% 分位缩尾, 再按 A1 端点 Min–Max 归一到 $z_j(x) \in [0, 1]$, 缺失值用 A1 同域同指标标准化中位数填补。

长度校正的效果: A1 七域 $\times$ 三 DSIR 的词数 Spearman 绝对相关中位数由原量 0.957 降至除词数后的 0.599、再降至残差化后的 0.095, 逐项见 T2_dsir_length_diagnostic.csv。book 域剩余相关最高 ($|\rho| = 0.503$), 提示该域分数仍可能受长度影响。这是与长度混杂有关的测量假设, 不表示相关下降即去掉了无用信息。

唯一主质量口径: **CRITIC** 加权 **Huber** 中心。在 A1 的标准化矩阵上, 以 CRITIC 的离散度与指标间非冗余性确定固定权重 [3]:

$$C_j = s_j \sum_{k=1}^{25} (1 - r_{jk}), \quad w_j = \frac{C_j}{\sum_k C_k}, \quad \sum_j w_j = 1.$$

文档主质量分取加权 Huber 中心 [4]

$$Q(x) = \arg \min_{q \in [0, 1]} \sum_{j=1}^{25} w_j \rho_\delta(z_j(x) - q), \quad \rho_\delta(u) = \begin{cases} \frac{1}{2}u^2, & |u| \leq \delta, \\ \delta(|u| - \frac{1}{2}\delta), & |u| > \delta, \end{cases}$$

由导数方程 $\sum_j w_j \text{clip}(q - z_j, -\delta, \delta) = 0$ 在 $[0, 1]$ 上二分求解。 δ 只由 A1 确定：取每篇的加权指标中位数 m_x 、加权 MAD $a_x = \text{wmedian}_j |z_j - m_x|$ ，再取 $\delta = 1.345 \times 1.4826 \times \text{median}_{x \in A1} a_x$ ，得 $\delta = 0.4034907036619329$ （1.4826 为正态尺度校正，1.345 为经典 Huber 效率常数）。这是一条不依赖质量真值与下游损失、也不依赖冲突类型的 A1 尺度规则，A2/A3 复用同一数值。25 项 CRITIC 权重逐项见 T2_critic_weights.csv（最小 fineweb_edu 0.0359，最大 modernbert_professionalism 0.0671）， δ 的确定过程见 T2_delta_selection.csv。所有 A1 参数（方向、缩尾端点、Min-Max 端点、填补值、权重、 δ ）一经确定即冻结，A2/A3 只应用、不重估。

对照口径 $Q_{\text{mean}} = \sum_j w_j z_j$ （同权重算术均值）、PCA 与 TOPSIS 只用于方法一致性比较：A1 主分与三者的 Spearman 分别为 0.9936、0.8166、0.9588（T2_method_agreement.csv）。这些是方法一致性，不是独立质量标签验证。极端指标扰动：逐篇剔除距加权中位数最远的一个指标后，极端程度最高 10% 的文档（5,123 篇）中，主分的绝对变动中位数为 0.0260（P90 为 0.0340），算术均值为 0.0374（P90 为 0.0488），即主分对同一扰动的典型变动约小 30%（T2_extreme_influence.csv）。该实验只覆盖“删除最偏离一项”，不覆盖全部异常模式。

质量分求解。25 项标准化矩阵在 A1 上一次算出，然后在 A2/A3 上只做前向应用；主分按导数方程二分求根，权重与 δ 随之冻结。

求解设置与复现。问题一为纯 NumPy/Pandas 实现（不依赖 SciPy 或 scikit-learn），运行环境为 Python 3.12.13、NumPy 2.4.4、pandas 3.0.2；标准运行顺序为 q1_01_extract.py $\rightarrow$ q1_02_quality.py $\rightarrow$ q1_03_conflict.py、q1_04_bridge.py $\rightarrow$ q1_05_mixture.py $\rightarrow$ q1_06_scale.py、q1_07_optimal.py $\rightarrow$ q1_08_audit.py，本轮全链耗时约 5 分钟（其中桥接约 160 秒）。随机种子在质量评分、桥接、配比拟合与候选搜索中分别固定为 2026、42、2026、1234（另：A1 域内聚类子步用 42，冲突抽样子步用 0 与 7，来源一致性实验用 42）。关键求解参数：质量中心的导数二分固定 28 次；配比 Huber 回归以最小二乘初始化，标准化残差阈值 1.35，IRLS 最多 50 次、以最大系数变化小于 10^{-8} 停止；桥接按域分层五折、只在训练折估计特征标准化参数，GBDT 用深度 1 树桩与学习率 0.06，五折比较用 250 棵、最终拟合用 300 棵；配比对照的 GBDT 用五折交叉验证在 {学习率} $\times$ {树数} 网格上选参。以上参数与脚本路径见 src/code_q1/q1_00_common.py 及各 Step 脚本。树数与候选数是预设计算上限，不应误写为已证明的优化收敛。

主质量分与领域质量。A1 七个领域的 CRITIC 加权 Huber 主分中位数由高到低为：arxiv 0.7707、commoncrawl 0.6761、stackexchange 0.6600、c4 0.6545、book 0.6313、github 0.6172、wikipedia 0.5991（T2_domain_quality.csv，图 1）。图 1 显示七域主分的分布区间，可见 arxiv 与 wikipedia 的域内分布几乎不重叠，领域间差异大于多数域内差异，这是按域建尺度、再按域汇总的必要性依据。领域分取文档中位数，并以 2,000 次文档 bootstrap 给出条件区间；book 域仅 171 篇，域内细分比例须谨慎使用。




图1 A1 七个领域的CRITIC 加权Huber 主分分布

扩展集的表现：A2 的 arxiv 中位数为 0.7697，对应 A1 子集为 0.7707；A3 的 github 中位数为 0.6158，对应 A1 子集为 0.6172；两组 KS 检验的 p 值为 0.313 与 0.220 (T2_sampling_check.csv)。 p 值只能说明在冻结管线下未检出明显分布差异，不能证明抽样完全无偏或分数具有独立准确性。

方法一致性与扰动稳健性：主分与同权重算术均值、PCA、TOPSIS 的文档排序 Spearman 分别为 0.9936、0.8166、0.9588 (T2_method_agreement.csv)；删除最偏离一项指标后，极端程度最高 10% 文档的主分绝对变动中位数为 0.0260、P90 为 0.0340，算术均值对应为 0.0374 与 0.0488 (T2_extreme_influence.csv)。这些数值是 [0, 1] 评分尺度上的绝对变动，即 2.6 与 3.7 个百分点，不是质量提升率；对同一项极端指标扰动，Huber 的典型变动约小 30%，这是把 Huber 中心作为主分的稳健性依据，但仍不能替代人工质量标签。

检验与边界。本任务的结果分三层检查（设计与结论汇总见 6.1）：A2/A3 是冻结评分的扩展检验，KS 的 p 值只说明在冻结管线下未检出明显分布差异，不等于抽样无偏或分数准确；主分与算术均值、PCA、TOPSIS 的秩相关是方法一致性，不是与人工标签的吻合度；删除最偏离一项指标的扰动只覆盖一种异常模式。因此本任务不报告质量准确率，只报告排序口径、稳健性与适用边界。

5.2.2 任务二：质量指标冲突的诊断与消解

诊断在 5.2.1 的主分之后进行，不参与 CRITIC 权重、Huber 中心、桥接标签或任何 P1 接口。按指标生成机制固定六个来源：RPS (11 项)、DSIR (3 项)、轻量分类器 (2 项)、FineWeb-Edu (1 项) [5]、QuRating (4 项)、ModernBERT (4 项)，每项指标恰好归属一处。对 A1 每个领域、每项指标保存标准化分的完整经验分布 F_{dj}^{A1} ，文档的指标排名取 $r_j(x) = F_{dj}^{A1, \text{mid}}(z_j(x))$ （同值取中秩）；A2/A3 按对应领域查同一份冻结分布，不重新排名、不重估阈值，未见领域报错而不临时拟合。

来源中心 $m_s(x) = \text{median}_{j \in I_s} r_j(x)$ 经 A1 同域同来源的中心分布转成 $u_s(x)$ ，六来源分歧度为

$$B(x) = \max_{s=1,\dots,6} u_s(x) - \min_{s=1,\dots,6} u_s(x).$$

阈值取 A1 每域 B 的第 95 百分位（同域同来源跨度与最大留一偏离同样取 P95），并报告 P90/P95/P97.5 与高低端立场 10%/20%/25% 的敏感性。第 95 百分位使 A1 每域约 5% 的文档入选，这是预先选定的筛查预算，不是真实冲突的发现率。仅当 B 超阈值、且高端（ $u_s \geq 0.8$ ）与低端（ $u_s \leq 0.2$ ）各有至少两个来源支持时，才记为“多来源对立候选”；仅一侧或多个来源不足时单列为稀疏来源对立。另用来源内跨度 $P_{90}(r_j) - P_{10}(r_j)$ 与逐指标留一中位数偏离 e_j 识别孤立指标，单独记为“单指标独有候选”，不与来源间候选相加。来源配对方向按每篇文档的高端 $\times$ 低端组合平均分配总权重 1。

诊断求解。诊断阶段对 A1 每域、每指标保存有序经验分布作为参照，对 A2/A3 查表排名；A1 固定随机抽样 8,000 篇计算各来源 Kendall W ；阈值取 A1 同域分位数，逐集逐域输出候选比例、重合度与方向份额。

六来源分歧诊断的结果。

表 3 三个数据集上的六来源诊断候选规模（数据源：T3_six_source_candidate_summary.csv）

候选类型	A1: 51,230 篇	A2: 17,523 篇	A3: 203,752 篇
来源间高分歧	2,561 (5.00%)	829 (4.73%)	10,167 (4.99%)
其中多来源对立	695 (1.36%)	277 (1.58%)	3,598 (1.77%)
其中稀疏来源对立	1,866 (3.64%)	552 (3.15%)	6,569 (3.22%)
单指标独有	2,879 (5.62%)	709 (4.05%)	8,606 (4.22%)

表中百分比的分母均为该数据集的全部文档数。A1 的约 5% 来自预设的 P95 筛查预算，不能称为测得的真实冲突率；多来源对立与稀疏来源对立互斥，单指标独有候选是另一类筛查，不与来源间候选相加为“总冲突率”。

来源内部一致性差异明显：A1 的 Kendall W 依次为 RPS 0.140、DSIR 0.967、轻量分类器 0.691、QuRating 0.675、ModernBERT 0.579，FineWeb-Edu 只有一项指标故不定义；A1 文档内指标排名 $P_{90} - P_{10}$ 的中位数 RPS 为 0.625，DSIR 为 0.037，QuRating 为 0.277，ModernBERT 为 0.315；A1 有 69.45% 的文档在 RPS 内部同时存在低于 20% 与高于 80% 的指标（T3_six_source_consistency.csv、T3_source_internal.csv，图 17）。图 17 显示六来源内部跨度的量级差异，说明同一“规则型”来源内部就可能给出相反意见，因此把 11 项 RPS 压成一个中位数会掩盖意见分裂。这表示不同规则统计量给出相反的相对排序，不能直接判为测量错误或真实质量矛盾。

来源间的对立方向：A1 与 A3 的最高加权方向均为“RPS 高 $\times$ FineWeb-Edu 低”，份额为 8.03% 与 13.03%；A2 为“ModernBERT 高 $\times$ FineWeb-Edu 低”，9.89%（分母均为该集的六来源高分歧候选，且每篇文档的来源对总权重为 1，T3_source_opposition_pairs.csv，图 18）。映回旧四组时，原“模型评分器”组内部的新方向在三集占 4.44%、19.33%、3.68%（T3_direction_stability.csv），即旧的四组口径无法显示这一类来源之间的分歧。

阈值与旧法对照：固定高低端立场为两端 20% 时，A1 的 B 阈值取 P90/P95/P97.5 对应候选比例约 10.00%/5.00%/2.50%，A2 为 9.19%/4.73%/2.00%，A3 为 9.74%/4.99%/2.44%

(T3_threshold_sensitivity.csv, 图 19)。历史四组口径的候选比例为 19.08%/24.52%/23.28%，与六来源候选集合的 Jaccard 为 0.188/0.130/0.155；按 A1 各域前 5% 配平预算后旧四组选出 5.00%/4.42%/4.78%，Jaccard 提高至 0.324/0.283/0.259、Kappa 为 0.463/0.415/0.381 (T3_legacy_stability.csv, 图 20、图 21)。Kappa 不是准确率；历史阈值与新 P95 的选择预算不同，这组重合度不能单独解释为分组效果。

来源一致性加权对照实验：以各来源 Kendall W 作先验可靠性乘数调整 CRITIC 权重 ($\tilde{w}_j = w_j \cdot W_{s(j)}$ ，其余环节不变)，得到的实验分 Q_{v2} 与主分在 A1/A2/A3 的全局 Spearman 为 0.9547/0.9207/0.9395，A1 七域的中位数排序与主分完全一致 (T3_Q_v2_summary.csv、T3_Q_v2_weight_comparison.csv, 图 22)。Spearman 只衡量排序相似度，不是 Q_{v2} 更准确的证据；该分不替换主质量口径，也不写入任何 P1 接口。

检验与边界。三集复现的是诊断结构而不是逐篇冲突类型：候选比例稳定 (5.00%/4.73%/4.99%)，但最高加权对立方向在 A2 与 A1/A3 不同；Jaccard 与 Kappa 只用于比较两套候选集合的重合度 (**Kappa** 不是准确率)；阈值敏感性反映的是人工复核工作量的变化。诊断层产物不参与 CRITIC 权重、Huber 中心、桥接标签或任何 P1 接口，筛查预算也不解释为真实冲突率。

5.2.3 任务三：领域配比、语料质量与损失

桥接到 17 个配比域。A16 的 17 个配比域中 3 个为 direct、3 个为 near_direct、11 个为 inferred。对 11 个无直接质量信号的域，从 A1/A18 原文各自复算 11 项同名近似规则特征 $\Phi(\text{text})$ (不保证逐位复现附件 rps_*)。在 A1 的 21,590 篇原文上以 5.2.1 的同一 $Q(x)$ 为标签，按领域分层五折比较 Ridge 与 GBDT (每折的特征均值与标准差仅用训练折估计，避免折间泄漏)，选较优者对 A18 的 31,340 篇预测并逐域聚合。六个 direct/near_direct 映射域的 Q_{final} 取对应 A1 质量域主分中位数， $CI_{\text{lo/hi}}$ 同取该 A1 域主分 bootstrap；11 个 inferred 域取 A18 预测中位数与文档 bootstrap。 Q_{tokenw} 按最终来源取值。语料质量按份额聚合：

$$Q(\mathbf{p}) = \sum_{i=1}^{17} p_i Q_i, \quad p_i \geq 0, \quad \sum_i p_i = 1.$$

桥接模型的五折表现与六个映射域的一致性见本小节下文；区间口径与点估计必须同源，不能用 A1 点估计配 A18 预测区间，17 域逐行断言点估计落在同源区间内。

桥接求解。A1 的 21,590 篇按域分层五折，折内标准化参数只用训练折估计；五折比较 Ridge 与 GBDT 后取较优者用全部训练子集拟合，再对 A18 的 31,340 篇预测并逐域取中位数与文档 bootstrap 区间。

从文档质量到 17 域质量。桥接模型在 A1 上的分层五折 R^2 均值为 0.4106 (Ridge 为 0.3415, T4_calibration_cv.csv)；六个可映射域的预测与 A1 主分的 Pearson 为 0.6571、Spearman 为 0.7714、MAE 为 0.0365，但 $n = 6$ (T4_bridge_validation.csv)。17 域 Q_{final} 最高为 arxiv 0.7707、最低为 dm_mathematics 0.5087 (T4_bridge_17domains.csv, 图 2)。图 2 显示 17 个域的质量分与按来源构造的条件区间，六个 direct/near_direct 域的点估计与区间同取 A1 主分，11 个 inferred 域取 A18 预测中位数与文档 bootstrap。使用边界有三条：映射域区间以 A16 映射成立为条件，尤其不覆盖 near_direct 的映射偏差；inferred 区间只反映给定桥接模型下的文档抽样变动，不涵盖模型选择与跨域偏差；ubuntu_irc (16 篇) 与 philpapers (63 篇) 须低置信使用。桥接 R^2 与六域一致性都不是独立质量准确率。




图 2 17 个配比域的质量分与条件区间

配比—损失模型与迁移结构。A4/A5 按 index 连接后作 1M 配比训练集（非正份额替换为 10^{-4} 并重新闭合）。配比份额受闭约束，直接回归会有闭合效应，故作中心对数比变换

$$\xi_i(\mathbf{p}) = \log p_i - \frac{1}{17} \sum_{k=1}^{17} \log p_k, \quad \log L_v = b_v + \sum_{i=1}^{17} \beta_{vi} \xi_i(\mathbf{p}) + \varepsilon_v,$$

对 13 个验证域分别拟合 Huber 回归 [6, 7]，这是唯一主模型；原始份额 OLS 检验变换的作用，深度 1 的树桩 GBDT 检验线性形式是否漏掉重要非线性。在均匀配比处把系数投影到单纯形切空间，得 17×13 迁移矩阵 $T_{iv} = 17(\beta_{vi} - \bar{\beta}_v)$ ，其中 $\bar{\beta}_v = 17^{-1} \sum_i \beta_{vi}$ 。另拟合质量交互项 $\lambda_v \sum_i p_i(1 - Q_{i,\text{final}})$ ，用 400 次案例 bootstrap 给区间并在 A6/A7 检查预测。

GBDT 的树数与学习率只在 A4/A5 内部用五折交叉验证选定：折号由固定种子随机置换得到，网格为学习率 $\{0.03, 0.06, 0.12, 0.25\} \times$ 树数 $\{100, 250, 500, 1000\}$ ，准则为 13 域留折 $\ln L$ RMSE 的均值，选定后用全部 512 组重拟合；A6–A11 不参与选参。GBDT 在 A4/A5 上按等权 Loss 另选一个 $\mathbf{p}^*$ 作交叉评估，用于检验线性模型的最优配比是否稳健，不作主模型（理由是可解释性与接口一致性，而非预测更差）。

配比与跨尺度求解。clr+Huber 回归对 13 个验证域分别拟合；迁移矩阵由 clr 链式法则折算到单纯形切空间；GBDT 选参只在 A4/A5 内部完成；尺度修正的 ρ_v, κ 只由 A4/A5 与 A8/A9 闭式确定；1M 留出、60M、1B 与估算表全部用冻结模型评估，不做二次拟合。

配比—损失关系与迁移结构。在 A6/A7 的 1M 留出（256 组）上，13 域平均逐域 R^2 为 clr+Huber 0.772、原始份额 OLS 0.654、GBDT（选参后）0.923；目标 Spearman 为 GBDT 0.942、线性 0.523；但 13 域等权目标 R^2 上裸 OLS 的 0.418 高于 clr+Huber 的 0.260 (T5_model_comparison.csv)。因此本文保留 clr+Huber 解释局部迁移效应，同时以留出目标表现更好的 GBDT 作交叉评估，不声称 clr 在所有目标上都更优。GBDT 的五折选参结果

为1,000 棵、学习率 0.12，留折 $\ln L$ RMSE 为 0.0421；学习率 0.25 在 500 棵时为 0.0422、到 1,000 棵回升至 0.0426，说明最优点在网络内部，且最优点附近曲线很平 (T5_gbd_t_cv.csv)。质量交互项在 13 域中仅 6 域的系数区间不含零，且系数有正有负，只能说明质量与配比损失存在混杂关联，不构成质量因果效应 (T5_lambda_interaction.csv)。17×13 迁移矩阵的各域主对角元均为负 (T5_transfer_matrix.csv，图 3)，图 3 显示各验证域对训练域份额的局部敏感度结构。




图 3 17 × 13 迁移矩阵：各验证域对训练域份额的局部敏感度

跨尺度检验与尺度修正。冻结检验：在 A4/A5 上拟合后冻结线性模型与 GBDT，直接预测 1M 留出、60M 与 1B，报告绝对误差与排序。尺度修正保持 1M 配比系数 β_v^{1M} 不变，记 $g_v(\mathbf{p}) = \beta_v^{1M} \cdot \text{clr}(\mathbf{p})$ 、 $t = \ln(N/10^6)$ ：

$$\ln L_v(\mathbf{p}, N) = \underbrace{b_v^{1M} + \rho_v t}_{\text{截距漂移}} + \underbrace{(1 + \kappa t)}_{s(N)} g_v(\mathbf{p}).$$

b_v^{1M} 与 $s(10^6) = 1$ 来自 A4/A5；在 A8/A9 (60M) 上求汇总斜率 $s(60M) = \sum_v \text{cov}(y_v, g_v) / \sum_v \text{var}(y_v)$ 与逐域截距 $b_v(60M) = \bar{y}_v - s(60M)\bar{g}_v$ ，由两点闭式得到 13 个 ρ_v 与 1 个共同 κ 。**A10/A11 (1B, 各 64 行)** 不参与任何估计，只用于比较冻结模型、仅截距修正与截距加缩放修正三种口径；另报“1B 同集拟合”作为该函数形式的误差下界参照，不作结论。估算表 A12–A15 是 10B/70B 的估算或外推 Loss，与冻结模型、尺度修正模型和同配比 1M 实测 Loss 并列对照，不是观测。

跨尺度检验的结果。冻结 1M 模型的等权目标 Spearman 在 1M 留出/60M/1B 上为线性 0.523/0.467/0.677、GBDT 0.942/0.905/0.761；GBDT 的目标 MAE 为 0.078/1.466/2.713 (T6_cross_scale_validation.csv、T6_gbdx_cross_scale.csv, 图 4)。图 4 显示冻结模型在三档规模上的排序保持度：排序信息基本保持，但 60M/1B 的绝对 Loss 有大幅平移 (R^2 为负)，排序部分保持不等于损失水平可直接迁移。1B 只有 64 组，Spearman 的抽样误差约 ± 0.1 ，GBDT 在 1B 的领先幅度只能算中等证据。




图 4 冻结 1M 配比模型在 1M 留出、60M 与 1B 上的排序保持度

尺度修正由 1M 训练与 60M 标定给出 $s(60M) = 0.913$ 、 $\kappa = -0.0212$ ，外推到 1B 为 $s(1B) = 0.854$ (T6_scale_correction_params.csv, 图 5)。




图 5 尺度修正前后的绝对 Loss 对照（1M + 60M 标定，1B 独立检验）

表 4 给出 1B 独立检验（A10/A11，各 64 组，不参与任何估计）的结果（数据源：T6_scale_correction.csv）

1B 口径	逐域 MAE 均值	目标 MAE	逐域 R^2 均值	目标 Spearman	平均预测 Loss
冻结 1M	2.953	2.953	-604.7	0.677	5.178
仅截距修正	0.770	0.768	-33.4	0.712	2.994
截距 + 缩放修正	0.771	0.771	-35.3	0.713	2.997
1B 同集拟合（误差下界参照，不作结论）	0.082	0.029	0.624	0.702	2.222

1B 的观测平均 Loss 为 2.226。由此得到三条结论：方向对、幅度不足——修正把 1B 绝对误差降低约 74% ($2.95 \rightarrow 0.77$)，但平均预测 2.99 仍明显高于观测 2.23，1M $\rightarrow$ 60M 每单位 $\ln N$ 的 Loss 降幅约 0.08、60M $\rightarrow$ 1B 段约 0.19，两档规模的对数线性外推无法捕捉该曲率；效应缩放的外推偏差更大（预测 $s(1B) = 0.854$ ，同集拟合为 0.612，加缩放项对 MAE 没有帮助，下游若用 1M 配比效应推断大尺度收益应以 0.61 为 1B 的实测幅度）；误差来源是水平外推而非配比结构（同一函数形式直接在 1B 上拟合时 MAE 仅 0.08）。在 60M 标定集上（同集，不作检验），修正把逐域 MAE 从 1.490 降到 0.206（仅截距）/ 0.208（截距 + 缩放）。

跨尺度校准接口（仅评估）：冻结 1M 系数的汇总斜率在 1M 训练/1M 留出/60M/1B 上为 1.004/0.995/0.913/0.612，观测平均 Loss 为 5.345/5.282/3.823/2.226（interface/P1_scale_calibration.csv，T6_scale_correction.csv）。配比效应的方向跨尺度保持，幅度在 1B 缩到约六成。

估算表 A12-A15 (外推/估算, 非观测): 在同样 63 组配比上, 冻结线性预测的 10B/70B 目标 Spearman 为 $-0.532/-0.588$ 、逐域 MAE 为 3.53/3.91, 尺度修正后为 $-0.537/-0.576$ 与 0.86/0.88; 估算表本身的平均 Loss 为 1.797 (10B)、1.415 (70B), 低于修正模型的外推, 方向与 1B 上”实际下降快于两档外推”一致 (T6_extrapolation.csv)。估算表的目标 Loss 排序与 1M 实测几乎相反 (同配比从 1M 到 60M 的实测排序逐域 Spearman ≥ 0.98 , T6_domain_stability_rank.csv), 因此估算表隐含的”大尺度排序反转”没有观测支持, 只作为稳健性讨论的反例。注意 A12/A14 的 63 组配比逐行等于 A4 的子集 (代码断言), 冻结模型在这些配比上并非样本外; A13/A15 本身由三尺度幂律外推生成, 与修正模型的接近只是一致性对照, 不构成独立验证。

候选最优配比。以 A4 平均配比为中心、四档浓度 Dirichlet 生成 99,996 个候选。主口径由线性 clr+Huber 模型在信赖域内选取: 候选的 clr 向量到 A4 训练配比的马氏距离 (协方差加 $10^{-3}I$ 岭) 不超过训练配比自身距离的 95% 分位, 且每域份额不超过 A4 该域最大值。信赖域内分别按 13 域等权 Loss 与 pile_cc Loss 取预测最优的前 100 个份额平均, 得 p_star_eqweight 与 p_star_pilecc, 并核对平均后的 $\mathbf{p}^*$ 仍在信赖域内; GBDT 在同一信赖域内按等权 Loss 另选 p_star_gbd_t_eqweight 作稳健性对照, 报告两者的全变差距离与交叉评估。不确定性有两项: 固定线性 $\mathbf{p}^*$ 的 200 次案例 bootstrap 重拟合收益分布, 以及每次 bootstrap 在同一信赖域内重选 $\mathbf{p}^*$ 与主 $\mathbf{p}^*$ 的全变差距离分布。每个候选的 Q_{domain} 从本轮 Q_{final} 按域名连接, $\bar{Q} = \sum_i p_i Q_i$ 。不加信赖域时线性模型会在远离训练分布的组合上给出不可信的低 Loss (前 100 个候选的马氏距离中位数约 3.1×10^4 , 预测等权 Loss 中位数低至 0.84, 而均匀配比为 5.39), 故信赖域是本方案的建模选择而非数据结论。

候选配比求解。99,996 个 Dirichlet 候选先按 clr 马氏距离与份额上限筛入信赖域, 再按 13 域等权预测损失 (或 pile_cc 单域损失) 取前 100 个份额平均; 线性模型选主口径, GBDT 在同信赖域内另选作对照与交叉评估。

推荐配比与配比加权质量。信赖域阈值取 clr 马氏距离 21.85 (A4 训练配比距离的 95% 分位), 保留 46,168/99,996 个候选。

表 5 候选配比的对照 (数据源: T7_pstar_benchmark.csv、interface/P1_p_star.csv)

配比	线性预测 等权 Loss	GBDT 预测 等权 Loss	线性 评估收益	GBDT 交叉评估收益	马氏距离	$\bar{Q}$
$\mathbf{p}^*$ 等权 (线性, 主口径)	4.875	4.901	9.47%	9.47%	13.9	0.66241
$\mathbf{p}^*$ GBDT 对照	4.927	4.811	8.51%	11.12%	10.4	0.66297
$\mathbf{p}^*$ pile_cc (线性)	5.074	4.963	5.77%	8.31%	4.0	0.66393
训练配比均值	5.198	5.177	3.48%	4.36%	0.5	0.66399
均匀配比	5.385	5.413	0	0	2.7	0.66065

表中收益的分母为均匀配比的预测等权 Loss (5.385), 是 1M 代理模型在同一模型内的预测差异, 不是重新训练后的实测改善。三点结论: 两种模型选出的配比几乎相同 (全变差距离 0.0344, GBDT 独立评估线性 $\mathbf{p}^*$ 的收益为 9.47%, 与线性自评一致, 故主口径改用线性不损失收益); 收益的不确定性为固定 $\mathbf{p}^*$ 的 bootstrap 收益中位数 9.54%、95% 区间 [7.82%, 11.16%], 每次重选 $\mathbf{p}^*$ 与主 $\mathbf{p}^*$ 的全变差中位数 0.019、P95 0.027 (T7_gain_ci.csv,

图 6)；pile_cc 口径较弱（按线性模型只把pile_cc Loss 从 5.576 降到 5.569，GBDT 评估反而更高，只能称搜索候选）。图 6显示两个目标口径下信赖域内候选的分布与主 $\mathbf{p}^*$ 、均匀配比的位置。




图 6 信赖域内候选配比的分布与推荐配比 $\mathbf{p}^*$ 、均匀配比的位置

质量与训练边际价值在 17 域上的 Spearman 为 -0.211 (T7_quality_vs_value.csv, 图 7), 说明单凭域质量分不能代替配比实验：质量高不等于该域的训练边际价值高。图 7 显示 17 域质量分与边际价值的散点关系，两轴方向相反但并非单调替代关系，该相关性不是因果结论。主 $\mathbf{p}^*$ 的配比加权质量 $\bar{Q}(\mathbf{p}^*) = 0.6624116679870492$ ；训练配比均值处为 0.6639855669942757 ，均匀配比处为 0.6606498405290009 (interface/P1_summary.json)。注意候选配比的预测损失不随 Q 改变：配比搜索只依赖配比与 Loss，质量分只改变 $\bar{Q}$ 的数值口径。




图 7 17 域质量分与训练边际价值的散点关系

检验与边界。本任务的检验层次依次为：桥接的分层五折 ($R^2 = 0.4106$) 与六个映射域的一致性 ($n = 6$)；配比模型的 1M 留出 (A6/A7)、60M 直接检验 (A8/A9) 与 1B 独立检验 (A10/A11)；估算表 A12–A15 只作一致性对照。其中 A8/A9 承担尺度修正的标定，A10/A11 不参与任何估计。由于依据 A6/A7 的表现选择了 GBDT 作交叉评估，该留出集不再充当最终候选收益的独立验证，候选收益仍是 1M 代理模型内的预测差异。

5.3 问题二：含质量与配比的广义标度律

5.3.1 问题重述

问题二把经典标度律扩展为同时依赖参数量 N 、训练 token 数 D 、数据质量 Q 与领域配比 $\mathbf{p}$ 的损失模型，并完成四项可计算分析：估计各因素的边际效用与弹性；用问题一的迁移结构讨论领域之间的功能替代与覆盖互补；给出「提高质量」与「扩大参数或算力」可以互相替代的条件及数值例子；在附件 B 上完成参数估计、嵌套检验与留出验证，并把冻结参数交给后续问题。附件 A 只通过问题一已经输出的域质量与配比接口进入，本问直接使用的数据是附件 B。

5.3.2 问题分析

经典基线。目标是在 B1 上估计 $L_0(N, D) = E + AN^{-\alpha} + BD^{-\beta}$ 。输入是 8 个 Pythia 模型、共 1,176 行的验证损失 [8]。难点是 B1 与 Hoffmann 等 (2022) 的常数几乎重合，宜先审计其生成方式，再决定它能否充当「真实语料且 $Q = 1$ 」的观测。方法上固定幂次网格、对 E, A, B 做线性最小二乘，并用 $C/(6ND)$ 核对算力记账。

质量项。目标是让 Q 进入损失，且 $Q = 1$ 时回到 L_0 。质量网格只出现在 B6、B7、B8，三者均为半合成。难点有三：质量乘在参数项、数据项还是两者之上，不能事先指定；损失随 Q 下降的曲率未知；B8 与 B6/B7 的方向相反。因此在同一骨架上比较幂次、指数、线

性三种乘子，以及有无地板、 κ 是否可收缩的嵌套族，用 B6 训练、用 B7 中 B6 没有的点做留出。主式取幂次，是为了把质量写成有效参数与有效数据；线性对照的留出误差更小，这一差别在结果中单独报告。

两套实验的统一。附件 A 是固定小规模上的配比实验，附件 B 是规模实验，两边都以交叉熵为观测量，但没有同一批 $(N, D, Q, \mathbf{p})$ 的联合试验。配比只能通过问题一在 1M 上估计的 clr 系数，乘到 B 侧损失的可约部分上。A4/A5 全部位于 1M，训练数据看不出配比斜率如何随 N 变化，所以不估计 $s(N)$ ，只设两个零新增参数的强度假设，再用 A6–A11 的校准斜率做事后比较。

边际、替代与单位算力。目标函数一旦写成闭式，弹性、等损失曲线和 $6ND = C$ 上的最优参数量都可以解析求出，再用数值解核对。领域关系不从 B 侧回归，因为 B 没有配比列；它来自问题一迁移矩阵行向量的余弦。单位算力比较把提质成本 $g(Q)$ 与扩参数的算力放在同一 FLOP 上，用来回答「多花的一份算力给质量还是给参数」。

5.3.3 模型假设

1. 同一观测量。附件 A 与附件 B 的损失都是验证集交叉熵，因而可以写入同一个 L 。该假设服务两源统一；检验见 $Q = 1$ 切片与 B4、B5 的趋势相关。2. 经典骨架。 $Q = 1$ 时损失具有 $E + AN^{-\alpha} + BD^{-\beta}$ 的形式， $\alpha, \beta > 0$ 。该假设服务基线，依据是 B1 的生成公式与题面的退化要求；检验是 B1 的拟合残差和 $C/(6ND)$ 。3. 退化条件。 $Q = 1$ 且 $\mathbf{p} = \mathbf{p}_{\text{ref}}$ 时，质量乘子与配比乘子都等于 1，广义式回到 L_0 。 $\mathbf{p}_{\text{ref}}$ 取问题一的 A4 训练配比均值，作为附件 B 隐含 Pile 配比的代理。该假设服务题面约束；可检验的部分是 $Q = 1$ 切片相对 L_0 的残差。4. 质量地板与乘子分工。质量缺陷留下不随 N, D 消失的加项 $k_0(1 - Q)$ ， $k_0 \geq 0$ ；配比乘子只乘随规模衰减的两项，不乘 E 和地板。该假设服务「规模不能无限弥补质量」以及后文的替代上限；地板是否需要由嵌套 F 检验裁决。5. 质量口径。主映射取题面语义 $Q_B = Q_A = \sum_i p_i Q_i$ ，当前推荐配比处 $Q_0 = \bar{q}(\mathbf{p}^*) = 0.6624116679870492$ 。幂次乘子下，这一映射是假设，不能由「质量惩罚对 Q 仿射」推出。副映射 $Q_B = Q_A/Q_0$ 会使部分领域超出 $[0, 1]$ ，只作敏感性，不做静默截断。6. 配比强度不随规模估计。主假设 H_{red} 把配比乘在可约损失上，强度 s_{red} 用 1M 训练集定死；上界 H_{tot} 把同一偏离乘在总损失上。该假设服务配比通道；A6–A11 只用来观观测斜率落在哪一侧，不回头改参数。

5.3.4 符号说明

5.3 的解释变量与参数符号与 4 表 2 一致 $(N, D, Q, \mathbf{p}; E, A, \alpha, B, \beta; \kappa_N, \kappa_D, k_0; h_N, h_D; s_{\text{red}}, \tilde{\varphi}, m_*)$ 。本问额外使用的中间量为 $T_N = AN^{-\alpha}h_N(Q)$ 、 $T_D = BD^{-\beta}h_D(Q)$ 、 $R = T_N + T_D$ 与弹性 $\varepsilon_N, \varepsilon_D, \varepsilon_Q$ ，均在 5.3.5 的定义处给出。完整论文 sec5_q2.tex 另设一张本问符号表 (tab:q2sym)，本稿不重复该表，以 4 表 2 为唯一符号表。

5.3.5 模型建立

经典基线。在 B1 (8 个 Pythia 模型、1,176 行， $N_{\text{params_B/D_tokens_B}}$ 乘 10^9) 上估计

$$L_0(N, D) = E + AN^{-\alpha} + BD^{-\beta},$$

α 在 $[0.30, 0.38]$ 、 β 在 $[0.24, 0.32]$ 上按步长 0.002 网格搜索， E, A, B 在每个格点由线性最小二乘给出，取训练误差最小的格点。以 $C/(6ND)$ 中位比核对算力记账 (B 侧 C 由

C_FLOPs_1e21 乘 10^{21} 得绝对FLOPs)。

广义标度律 (主式)。在 L_0 的可约部分上乘质量与配比因子, 质量地板留在括号外 [9]:

$$L(N, D, Q, \mathbf{p}) = E + k_0(1 - Q) + [AN^{-\alpha}Q^{-\kappa_N} + BD^{-\beta}Q^{-\kappa_D}] \exp(s_{\text{red}} \tilde{\varphi}(\mathbf{p})),$$

其中 $k_0 \geq 0$ 。三条性质: $Q_B = 1$ 时 κ 项乘子为 1; $\kappa \geq 0$ 时 L 随 Q 单调不增; $N, D \rightarrow \infty$ 时 $L \rightarrow E + k_0(1 - Q)$, 即质量缺陷留下不随规模消失的地板。有效规模为

$$N_{\text{eff}} = N Q^{\kappa_N/\alpha}, \quad D_{\text{eff}} = D Q^{\kappa_D/\beta}.$$

配比标量来自问题一 1M 的 clr 系数并在 $\mathbf{p}_{\text{ref}}$ 处归一:

$$\varphi(\mathbf{p}) = \frac{1}{13} \sum_{v=1}^{13} \beta_v^{(1M)} \cdot \text{clr}(\mathbf{p}), \quad \tilde{\varphi}(\mathbf{p}) = \varphi(\mathbf{p}) - \varphi(\mathbf{p}_{\text{ref}}), \quad \mathbf{p}_{\text{ref}} = \text{A4 训练配比均值}.$$

$Q_B = 1$ 且 $\mathbf{p} = \mathbf{p}_{\text{ref}}$ 时两个乘子均为 1, 式退化为 L_0 , 满足题面退化要求。 $\mathbf{p}_{\text{ref}}$ 作为附件 B 隐含 Pile 配比的代理, 属假设 (见 7.2)。

嵌套候选族与主式的确定。每种乘子形状 (幂次 $Q^{-\kappa}$ 、指数 $e^{\kappa(1-Q)}$ 、线性 $1 + \kappa(1-Q)$) 下比较: M0 ($\kappa_N = \kappa_D = 0$)、M1 ($\kappa_N = 0$)、M2 ($\kappa_D = 0$)、M3 ($\kappa_N = \kappa_D$)、M4 (两项各自一个 κ), 再交叉有无地板, 共 26 个候选。 κ 在 $[0, \kappa_{\text{max}}]$ 上网格加密最小二乘 (幂次/指数型 1.2, 线性型 3.0), k_0 在每个 κ 上闭式求解并截断为非负。

训练与留出边界。只用 B6 的 360 点估计参数与选择模型; 断言 B6 的 360 点全部出现在 B7 且同点 Loss 相同, B7 中不在 B6 的 90 点 (全部为 $Q = 0.5$ 与 $Q = 0.7$, 覆盖全部 45 个 (N, D) 格) 为留出集, 报告 RMSE、平均偏差与按 Q, N, D 分组的残差; 全 B7 450 点的拟合只作含训练点的对照, 写入接口 fullB7_comparison。主式指定为幂次 M4 加地板 (两项 κ 都不收缩); 交叉验证规则会选出的线性 M4+F 只写入 cv_rule_choice 作对照, 不决定主式。

配比通道。A4/A5 全部位于 1M, 训练数据无法识别配比效应随 N 的变化, 故不估计尺度项, 只设两个零新增参数假设: H_{red} (主) 令配比乘可约部分且强度恒定, $s_{\text{red}} = c_{\text{train}}/\sigma_{\text{train}}$, 其中 c_{train} 为冻结系数在 1M 训练集上的汇总校准斜率, $\sigma_{\text{train}} = (\bar{L}_{\text{train}} - E - k_0(1 - Q_{\text{ref}}))/\bar{L}_{\text{train}}$; H_{tot} (上界) 令配比乘总损失。两个假设的参数只用 1M 训练行确定, A6-A11 只以冻结系数计算各尺度校准斜率作事后比较, 不重估任何参数。

边际、弹性、替代条件与闭式解。记 $T_N = AN^{-\alpha}Q^{-\kappa_N}$ 、 $T_D = BD^{-\beta}Q^{-\kappa_D}$ 、 $R = T_N + T_D$, 令配比乘子暂为 1:

$$\frac{\partial L}{\partial Q} = -\frac{\kappa_N T_N + \kappa_D T_D}{Q} - k_0, \quad \varepsilon_N = -\frac{\alpha T_N}{L}, \quad \varepsilon_D = -\frac{\beta T_D}{L}, \quad \varepsilon_Q = \frac{Q}{L} \frac{\partial L}{\partial Q}.$$

固定 D 把质量从 Q 提到 Q' 后, 若只想靠增大 N 把损失拉回, 需要

$$t = \left(\frac{Q}{Q'}\right)^{\kappa_N} + \frac{T_D}{T_N} \left[\left(\frac{Q}{Q'}\right)^{\kappa_D} - 1 \right] - \frac{k_0(Q' - Q)}{T_N} > 0, \quad N' = N t^{-1/\alpha},$$

$t \leq 0$ 时任何有限参数量都补不回这次提质。在 $6ND = C$ 且配比乘子为 1 时，最优参数量与地板无关：

$$N^*(C, Q) = \left(\frac{\alpha A Q^{-\kappa_N}}{\beta B Q^{-\kappa_D}} \right)^{1/(\alpha+\beta)} \left(\frac{C}{6} \right)^{\beta/(\alpha+\beta)}, \quad D^* = \frac{C}{6N^*}.$$

$\kappa_N > \kappa_D$ 时质量越低、 N^* 越大。沿最优前沿，质量从 Q 提到 Q' 等价于把算力乘以

$$M = \left\{ \frac{R^*(C, Q') - k_0(Q' - Q)}{R^*(C, Q)} \right\}^{-1/a}, \quad a = \frac{\alpha\beta}{\alpha + \beta}, \quad R^* = L^* - E - k_0(1 - Q);$$

花括号内不大于 0 时，再大的算力也追不上这次提质。 $k_0 = 0$ 时 M 与 C 无关； $k_0 > 0$ 时 M 随预算上升。配比乘子不为 1 时闭式一般不成立，需数值求解。

单位算力取舍与领域关系。单位算力收益定义为 $MU_x = -(\partial L / \partial x) \div (\partial C / \partial x)$ ，其中总成本取

$$C = (6 + \eta L_{ctx})ND + D[g(Q) - g(Q_0)]_+, \quad \eta = 2 \times 10^{-4}, \quad L_{ctx} = 2048,$$

并与问题三共用同一成本口径。配比边际为 $\partial L / \partial p_i = s_{red} R \partial \varphi / \partial p_i$ ， $\partial \varphi / \partial p_i$ 取问题一迁移矩阵的 13 域等权平均。领域之间的关系由迁移矩阵行向量余弦定义：余弦大于 0.7 记为功能替代，小于 -0.3 记为覆盖互补。线性 clr 模型没有交互项，因此超可加意义上的互补不可识别，”+ 加量”式交互不作声称。

5.3.6 模型求解

问题二使用 Python 3.12.7、NumPy 1.26.4、pandas 2.2.2、SciPy 1.13.1，随机种子 2026，脚本为 `src/code_q2/q2_01_fit.py`、`q2_02_theory.py`、`q2_03_economics.py`。只读问题一接口目录，不读附件 A 原始表、不读 P1 缓存。

基线。 α, β 网格搜索、 E, A, B 线性最小二乘；用 $C/(6ND)$ 中位比核对算力记账。

质量参数。 κ 在 $[0, 1.2]$ （线性对照到 3.0）上以初始步长 0.02 搜索，在最优点两侧加密两轮、步长每次除以 5； k_0 在每个 κ 上闭式求解并截断为非负；训练数组取自 B6，模型选择在同一 B6 上完成，留出用 B7 新增点。参数区间用 B1 行重抽样与 B6 的 (N, D) 格簇重抽样各 300 次， α, β 固定。

解析与数值互验。弹性、替代条件式与 N^* 、 M 的闭式在数值点上与直接求导/求解结果逐项对照；配比乘子不为 1 时不使用这些闭式。

5.3.7 结果分析

经典基线。B1 共 1,176 行的拟合结果为 $E = 1.6901$ 、 $A = 406.39$ 、 $\alpha = 0.34$ 、 $B = 410.59$ 、 $\beta = 0.28$ ，训练 RMSE 为 1.51×10^{-4} ；对 Hoffmann 等（2022）常数的 RMSE 为 1.65×10^{-4} ， $C/(6ND)$ 中位比为 1.0000（T20_baseline_fit.csv）。B1 的损失数值与公开公式吻合到 10^{-4} 量级，因此它适合作为”真实训练设定、公式生成损失”的基线锚点；来源审计见 5.3.8。

主式参数与留出表现。主式（幂次 M4 + 地板）的参数为 $\kappa_N = 0.1416$ 、 $\kappa_D = 0.0112$ 、 $k_0 = 0.2280$ ；95% 区间依次为 $[0.1264, 0.1568]$ 、 $[0.0000, 0.0408]$ 、 $[0.2013, 0.2554]$ ，且 $P(\kappa_N > \kappa_D) = P(k_0 > 0) = 1$ （T22_params_ci.csv，interface/P2_bootstrap.npz，300 次重抽

样)。 κ_D 的区间含0，收缩检验 $F = 0.63$ 、 $p = 0.43$ ，数据侧质量幂次没有被单独识别；主式仍保留该项，是因为指定的M4 给数据项自己的指数。 $\kappa_N = \kappa_D$ 被拒绝 ($F = 57.19$, $p = 3.4 \times 10^{-13}$)，地板被强烈支持 ($F = 307.11$, $p < 10^{-15}$) (T21b_nested_tests.csv)。

表6 质量项候选比较 (B6 训练；源自 T21_form_selection.csv，正文表格；留出为 B7 新增90 点)

形状	模型	κ_N, κ_D, k_0	留一规模 CV	留出 RMSE	留出偏差
—	M0	0, 0, 0	0.2100	0.1616	-0.146
—	M0 + 地板	0, 0, 0.363	0.0781	0.0595	-0.001
幂次	M4 (去地板敏感性)	0.203, 0.153, 0	0.0813	0.0839	-0.070
幂次	M4 + 地板 (主)	0.142, 0.011, 0.228	0.0598	0.0531	-0.022
指数	M4 + 地板	0.370, 0.131, 0.144	0.0532	0.0421	-0.005
线性	M4 + 地板 (CV 对照)	0.430, 0.139, 0.142	0.0532	0.0416	-0.001

表中”留出偏差”为预测减观测的均值 (接口 holdout_bias 为 -0.0219, T21g_holdout_by_group.csv 的同名列取相反符号为 +0.0219, 引用时须注明定义方向)。B7 新增90 点 ($Q = 0.5$ 与 0.7 各45 点、覆盖全部45 个 (N, D) 格) 的留出 RMSE 为 0.0531，按 Q 分组的 RMSE 为 0.0538 ($Q = 0.5$ ，平均残差 +0.0236) 与 0.0525 ($Q = 0.7$ ，+0.0202)；按规模分组时 70M 的 RMSE 最大 (0.0865) (T21f_holdout_points.csv、T21g_holdout_by_group.csv，图 8)。格内对 Q 做二次拟合的残差标准差中位数 (噪声代理) 为 0.0458，留出误差高于噪声代理，也高于线性对照的 0.0421。这是本问最主要的证据边界：主式是指定的幂次，不是交叉验证选出的最佳预测模型；交叉验证规则会选出的线性 M4 + 地板留出 RMSE 为 0.0416，比主式低约 12%，这是换取”有效规模”解释的代价。图 8 的三个面板分别显示 $\Delta L(Q=0.1 \rightarrow 1)$ 随 N 的下降 (实测点与主式曲线)、B7 新增 90 点的观测—预测散点 (标注 RMSE 0.053) 与配比通道的观测斜率对照。




图8 质量项候选比较与B7 新增90 点的留出表现

退化与其他诊断: $Q = 1$ 的45 个点相对 L_0 的平均残差为 +0.0036，95% 区间 $[-0.0120, +0.0193]$ ，退化条件在该切片上成立；主式再加 $(1 - Q)^2$ 项的系数为 -0.0095、 $p = 0.195$ ，没有显著的额外曲率； $\Delta L(Q$ 从 0.1 到 1 的损失降幅) 范围为 $[0.107, 0.609]$ ，与 $\ln N$ 的相关为 -0.767、与 $\ln D$ 的相关为 -0.278，即质量收益主要随参数规模变小，与 $\kappa_N > \kappa_D$ 的方向一致 (T21c_deltaL_diagnostic.csv、T21d_shape_degeneration_tests.csv)。全

B7 450 点的对照拟合为 $\kappa_N = 0.142$ 、 $\kappa_D = 0.006$ 、 $k_0 = 0.238$ ，方向一致（该组含训练点，仅作对照，interface/P2_scaling_law.json 的 fullB7_comparison）。B8（1,704 行）在最低质量档的平均损失为 0.545、 $Q = 1$ 时为 2.307，且 64.26% 的点低于 E ，与 B6/B7 方向相反，故不并入拟合（T21e_B8_check.csv）。

边际效用、弹性与替代条件。取 $N = 10^9$ 、 $D = 3 \times 10^{11}$ 、 $Q = Q_0$ 、配比乘子为 1，损失 $L = 2.3945$ ，三个弹性为 $\varepsilon_N = -0.0533$ 、 $\varepsilon_D = -0.0295$ 、 $\varepsilon_Q = -0.0865$ ：质量弹性约为参数弹性的 1.62 倍，其中 72.97% 来自地板（T31_marginal_utility_elasticity.csv）。四个配比份额的弹性绝对值之和为 0.0072，远小于质量弹性。规模加大后这一对比更强：在 $(10^{10}, 10^{12})$ 、 $(7 \times 10^{10}, 2 \times 10^{12})$ 处、 $Q = 0.9$ 时， $\varepsilon_Q/\varepsilon_N$ 为 4.13 与 7.60，地板占 $|\partial L/\partial Q|$ 的 89.04% 与 93.76%（T26_elasticities.csv）。在 $N = 10^9$ 、 $D = 3 \times 10^{11}$ 、 $Q = 0.6$ 处去掉地板后该比值降到 0.908（T26_elasticities.csv），说明“大模型上质量更敏感”在很大程度上依赖半合成数据中的地板项，外推时按假设使用。

表 7 质量提高 0.1 的等效参数倍数（固定 $D = 3 \times 10^{11}$ ；源自 T24_equiv_substitution.csv，正文表格；括号内为去地板敏感性）

起点 Q	$N = 10^9$	$N = 10^{10}$	$N = 10^{11}$
0.5→0.6	1.299 (1.182)	1.648 (1.268)	2.996 (1.488)
0.7→0.8	1.282 (1.130)	1.641 (1.190)	3.066 (1.337)
0.9→1.0	1.274 (1.102)	1.644 (1.148)	3.144 (1.258)

表中倍数即替代条件式 $t > 0$ 时的 N'/N ，取值的分母为原参数量 N ；去地板一列的 $N = 10^{10}$ 值取自 T24_equiv_substitution.csv 的 law=nofloor 行。模型越大，同样的 0.1 提质越难用堆参数补回，因为地板在损失中的份额上升，而地板只能靠提质消掉；无地板时千亿参数处的倍数降到 1.26–1.49。沿 $6ND = C$ 的最优前沿，质量从 0.7 提到 0.8 相当于算力乘 1.191 ($C = 10^{19}$)、1.485 (10^{22})、2.134 (10^{24})，无地板时该倍数恒为 1.165、与预算无关（T29_quality_compute_exchange.csv，图 9）。可替代的算力上限约 2.95×10^{30} FLOPs。 $Q = 0.5$ 时的 N^* 比 $Q = 1$ 大 15.7%（ $Q = 0.7$ 为 7.8%、 $Q = 0.9$ 为 2.2%），该比例与 C 无关； $C = 10^{24}$ 、 $Q = 0.5$ 时地板占可约损失的 32.94%（T25_compute_optimal.csv、T27_quality_floor.csv）。图 9 的三个面板分别给出等效参数倍数、等价算力倍数随预算的变化（实线主式、虚线无地板）与算力—质量前沿及渐近地板。高预算端的倍数与地板份额依赖半合成地板的外推，应作为假设下的推论。




图9 等效参数倍数、等价算力倍数随预算的变化与算力—质量前沿

单位算力取舍与领域关系。

表8 MU_Q/MU_N ($Q = Q_0$, $L_{ctx} = 2048$; 数据源: T33_cost_adjusted_N_vs_Q.csv; 括号内为去地板敏感性)

预算 C	指数型	幂函数型	对数型
10^{19}	0.868 (0.793)	0.477 (0.436)	1.057 (0.965)
10^{22}	42.48 (17.95)	23.34 (9.86)	51.71 (21.85)
10^{24}	627.30 (143.65)	344.59 (78.91)	763.61 (174.87)

大于1表示把一份FLOP用于提质比用于增加参数下降更多损失。 $Q = Q_0$ 时 $C = 10^{19}$ 的指数型与幂函数型小于1、应优先扩参数，对数型略大于1；T33b_quality_breakeven.csv的R_at_Q0列显示 $C = 10^{20}$ 起三种成本函数的比值都大于1（指数型3.10、幂函数型1.70、对数型3.77），且比值随预算迅速增大。提质更划算的质量区间上界（T33b_quality_breakeven.csv的Q_favor_hi列）在 $C = 10^{19}$ 时为指数型0.64、幂函数型0.53、对数型0.99；即低预算下质量已较高时应转而扩参数。图10的三个面板分别给出17×17域对余弦热力图、 $\partial L/\partial p_i$ 边际与 MU_Q/MU_N 随预算的变化（横线为1）。低预算结论对 $g(Q)$ 的形式敏感，高预算结论对成本函数不敏感。




图10 域对余弦热力图、份额边际与 MU_Q/MU_N 随预算的变化

领域关系：按迁移矩阵行向量余弦，17个域对中功能替代4对（最强nih_exporter-enron_emails，余弦0.969）、覆盖互补10对（最强dm_mathematics-philpapers，-0.725）、

其余 122 对为弱相关 (T32b_domain_pair_relation.csv)。在 $N = 10^9$ 、 $D = 3 \times 10^{11}$ 、 $Q = Q_0$ 下，把份额拨向 dm_mathematics 使等权损失下降最快 ($\partial L / \partial p_i = -0.1475$)，拨向 enron_emails 上升最快 (+0.1381) (T31b_p_marginal_by_domain.csv)。这是“增配后在各验证域上的梯度方向是否同号”，不是两个域同时加量的交互效应；线性 clr 模型无交互项，超可加意义的互补不可识别。

配比通道的证据位置。配比通道的参数为 $c_{\text{train}} = 1.0039$ 、 $Q_{\text{ref}} = 0.6640$ 、地板扣除 0.0766、 $\sigma_{\text{train}} = 0.6694$ ，故 $s_{\text{red}} = 1.4996207320397785$ ； $\tilde{\varphi}(\mathbf{p}^*) = -0.07104$ 、 $\tilde{\varphi}(\text{均匀}) = +0.03611$ ，推荐配比处的配比乘子为 $\exp(s_{\text{red}}\tilde{\varphi}(\mathbf{p}^*)) \approx 0.89894$ ，即配比效应使可约损失约为参照配比的 90% (T28_p_channel.csv、interface/P2_scaling_law.json 的 p_channel)。

表 9 两个配比通道假设与观测校准斜率的对照 (数据源: T28_p_channel.csv)

尺度	观测校准斜率 (仅评估)	H_red 预测	H_tot 预测	相 对 位 置 (0 = H_red, 1 = H_tot)
1M 训练	1.004	1.004	1.004	—
1M 留出	0.995	0.998	1.004	—
60M	0.913	0.807	1.004	0.540
1B	0.612	0.309	1.004	0.436

表中 1M 训练行为参数来源 (role=train)，其余三档仅为评估 (role=eval)，未重估任何系数。跨尺度观测斜率都落在两个假设之间、约在中点，因此下游应把 H_red 与 H_tot 当作配比效应的下界与上界，而不把 1.500 外推成随规模上升的函数。

5.3.8 模型检验

检验与拟合分开：质量参数只用 B6 估计，下面的留出、外源与解析对照都不再改 κ 与 k_0 。三组检验的设计与边界如下，数值已在 5.3.7 给出。

留出与嵌套。B7 相对 B6 新增的 90 点 ($Q = 0.5, 0.7$ ，覆盖全部 45 个 (N, D) 格，属 Q 方向插值) 作留出；留出 RMSE 高于同格的噪声代理与交叉验证更优的线性对照，因此主式的幂次形状是指定的，不是交叉验证选出的最佳预测模型。地板、 $\kappa_D = 0$ 、 $\kappa_N = \kappa_D$ 三个嵌套假设用 F 检验裁决； $Q = 1$ 切片相对 L_0 的平均残差用于核对退化条件。

换数据。B2 为半合成、B3 由 B1 插值派生、B10 本身即公式估算，这三项只能核对实现与趋势，不能证明质量项可泛化到真实训练；B4/B5 在 $Q = 1$ 上检验基线趋势，水平不可比；B8 与 B6/B7 的 Loss 方向相反 (64.26% 的点低于 E)，只作反例。

来源审计与解析互验。B11/B12 审计表明 B1 的 8 个名义规模与 147 个步数均被覆盖、 $D/(\text{steps} \times \text{batch})$ 的中位比为 0.9986，因此 B1 的训练设定是真实的而损失数值是按公开公式生成的；替代条件式、 N^* 与算力等价倍数的解析值与数值解误差小于 10^{-8} (替代倍数小于 10^{-13})。配比乘子不为 1 时不使用这些闭式。

5.3.9 评价与改进

本问的主式同时含有 $N, D, Q, \mathbf{p}$ ，在 $Q = 1$ 、 $\mathbf{p} = \mathbf{p}_{\text{ref}}$ 时回到经典式，并把「提质能否被规模替代」写成 $t > 0$ 这一可计算条件；地板、留出与跨源趋势都有单独的检验，半合成与估算数据没有被写成实验观测。

局限同样明确。质量参数只来自最大约 12B 的半合成网格； $C = 10^{24}$ 上「地板占可约损失约 33%」「提质远比扩参数划算」是把该地板外推出去的结果，应作为假设下的推论；外推到 $Q < 0.1$ 时三种乘子形状会分开。幂次是为有效规模解释而指定的，线性与指数的留出误差更小。 κ_D 未被单独识别。 $\mathbf{p}_{\text{ref}}$ 等于 Pile 配比、用 B1 的 E 与 B6 的 k_0 计算可约份额、以及 $Q_B = \bar{q}(\mathbf{p})$ ，都不能由本题数据单独证实；60M 与 1B 的配比斜率落在两个假设中间，恒定强度只是下界。

可做的修正：若后续有真实的跨质量训练日志，用它替换 B6 重估 k_0 与 κ_N ，并允许 s 随 $\log N$ 变化；在得到真正的跨尺度配比试验之前，问题三应对 H_{red} 与 H_{tot} 各算一遍。问题三、问题四若仍按线性乘子 $1 + \kappa(1 - Q)$ 读取 κ_N, κ_D ，会用错形状，需要按 $Q^{-\kappa}$ 重算后再引用本问接口——这正是问题三尚未重跑的原因之一（见 5.4.3）。

5.4 问题三的模型建立与求解

5.4.1 模型建立

给定总预算 C （绝对 FLOPs）与外生上下文长度 L_{ctx} （token），在 N （个）、 D （token）、 $Q \in (0, 1]$ 上最小化问题二的幂次主式。**主方案固定问题一在 A4 训练信赖域内选出的 17 域推荐配比 $\mathbf{p}^{***}$ （赛题允许的建模选择，不是“配比与规模精确可分离”的定理），此时

$$m_* = \exp\{s_{\text{red}}\tilde{\varphi}(\mathbf{p}^*)\} \approx 0.8989423, \quad L = E + k_0(1 - Q) + m_*(AN^{-\alpha}Q^{-\kappa_N} + BD^{-\beta}Q^{-\kappa_D}),$$

乘子只作用于两项随规模变化的损失，不作用于 E 或地板；系数 $E, A, \alpha, B, \beta, \kappa_N, \kappa_D, k_0$ 全部读取 P2 接口，不在本问重拟合。约束为

$$6ND + D[g(Q) - g(Q_0)]_+ + \eta NDL_{\text{ctx}} \leq C, \quad Q_0 \leq Q \leq 1, \quad \eta = 2 \times 10^{-4},$$

必须比较题目附录 B 的三类单位 token 提质成本：指数型 $g = 10^7 e^{6Q}$ （凸）、幂函数型 $g = 5 \times 10^9 Q^4$ （凸）、对数渐近型 $g = 2 \times 10^9 \ln(1 + 10Q)$ （凹）。本问按单次训练的静态预算情景建模；题面未给训练起止日期、逐期预算、GPU 数、工期或碳排放等约束，不能把它们写成硬要求。题面建议 $C = 10^{19}, 10^{22}, 10^{24}$ FLOPs，硬要求是至少三个不同量级；本项目自主采用 10^{19} 至 10^{25} 共七档网格，并把三个建议档单列。 L_{ctx} 是情景输入，不由优化器自由选择。连续 N, D 与 $Q \geq Q_0$ 是为解析求解设定的建模假设。

降维与闭式对照。三项成本都与 D 成正比，而 $\partial L / \partial D = -m_* \beta T_D / D < 0$ ，故在无额外 D 上限的本模型内预算用尽。记 $K = 6 + \eta L_{\text{ctx}}$ 、 $\Delta g = [g(Q) - g(Q_0)]_+$ ，由约束取等得

$$D = \frac{C}{KN + \Delta g},$$

问题降为 $(\log_{10} N, Q)$ 的二维有界优化，仍须满足 $Q_0 \leq Q \leq 1$ 。固定 Q 且令 $\Delta g = 0$ 的解析对照为 $N^* = [\alpha A Q^{-\kappa_N} / (\beta B Q^{-\kappa_D})]^{1/(\alpha+\beta)} (C/K)^{\beta/(\alpha+\beta)}$ 、 $D^* = C/(KN^*)$ ；式中 m_* 与地板因对固定 Q 的规模求导而抵消，其值仍影响不同 Q 之间的最优选择。由此得

$$\frac{D^*}{N^*} \propto \left(\frac{C}{K}\right)^{(\alpha-\beta)/(\alpha+\beta)} Q^{2(\kappa_N - \kappa_D)/(\alpha+\beta)},$$

两个指数在当前参数下约为 0.09677 与 0.42065；这只是无提质开销对照，真实 $\Delta g > 0$ 情景的比值与预算斜率须由数值最优解计算。上下文长度的解析临界值由注意力项与训练项之比 $\eta L_{ctx}/6$ 给出： $L_{ctx}^{crit} = 6/\eta = 30000$ token，在固定 L_{ctx} 下该比值与 C, N, D 无关；C7 五档中 8192 在临界值以下、32768 在其以上，30000 本身不是 C7 的实测档位。

结构性转移的定义与判据。本项目把“最优策略的质变”操作化为全局最优解的质量约束活跃状态变化：LOWER ($Q^* = Q_0$)、INTERIOR、UPPER ($Q^* = 1$)，并注明扫描预算区间、离散化精度与边界分类容差；若两个内点局部极小分支交换全局最优地位，即使仍同属 INTERIOR 也单列“全局分支切换”。对固定 Q 的规模最优解，令 $S = KN + \Delta g$ ，剖面目标的质量导数与边际比为

$$F_Q = -k_0 - \frac{m_*}{Q}(\kappa_N T_N + \kappa_D T_D) + \frac{m_* \beta T_D g'(Q)}{S}, \quad \Phi(C; Q) = \frac{\left[k_0 + \frac{m_*}{Q}(\kappa_N T_N + \kappa_D T_D) \right] S}{m_* \beta T_D g'(Q)},$$

其中 N, D 均在该固定 Q 下优化，不能代入其他质量点的全局规模解。内层解光滑且未触及搜索边界时， $\Phi(C; Q_0) \leq 1$ 、内点 $\Phi(C; Q) = 1$ 、 $\Phi(C; 1) \geq 1$ 分别是相应状态的局部一阶必要条件； $\Phi = 1$ 的根不是全局状态切换的充分条件，须核对剖面曲线与端点并分别输出局部根与全局临界点，二分只用于已括根且已检查单次切换的区间。 $Q_0 \geq 1 - 10^{-10}$ 时只有唯一质量状态，记 NO_QUALITY_RANGE，临界预算用 JSON null；搜索区间未括根返回 NOT_BRACKETED 与 null，不返回上界。公式正确性已做单点有限差分核对： $C = 10^{20}$ 、 $L_{ctx} = 2048$ 、指数型成本、 $Q = 0.8$ 处解析导数 -0.1164515205405 与差分 -0.1164515204932 的相对误差约 4.1×10^{-10} （对应 $\Phi = 1.63892372$ ），见 doc/Q3/新式子影响文档审查.md。

敏感性设计与输出要求。敏感性至少覆盖：三类 g 、C7 五档 L_{ctx} 、 $\eta = 10^{-4}, 2 \times 10^{-4}, 3 \times 10^{-4}$ （题设固定 2×10^{-4} ，另两值只是本项目扰动情景）、P2 参数重抽样、主/锚点两种质量映射、P1 域质量与配比不确定性，以及固定配比乘子 $m=1$ 、 H_{tot} 与 P2 无地板参数对照。其中 H_{tot} 在固定 $\mathbf{p}^*$ 时对完整基线 Loss 乘一个与 N, D, Q 无关的正常数，故其最优 N, D, Q 与 $m=1$ 对照相同、最优 Loss 按该常数缩放，须专门核验这一同配置关系。验收阈值：预算超限相对误差不大于 10^{-9} ，三项份额和误差小于 10^{-9} ， $N, D > 0$ 且 $Q \in [Q_0, 1]$ ，预算使用率与 1 之差小于 10^{-9} ，无提质开销时闭式 N^* 相对误差小于 10^{-5} ，关键 18 组求解 Loss 不劣于独立粗网格且差不超过 2×10^{-5} 。P3_optimal_config.csv 的份额分母统一为实际总消耗，同时另报预算使用率，不得混用分母； C, N, D 均为绝对量。

5.4.2 求解方法

问题三的求解器与接口脚本位于 src/code_q3/ (q3_00_model.py、q3_01_optimize.py、q3_02_transition.py、q3_03_mixture_joint.py)，联立配比探索性脚本的随机种子为 2026。**本版 Spec v5 的目标式（幂次 M4+ 地板并含 m_* ）尚未在代码与 P3 接口中实现，因此 5.4.3 只给出求解方案与解析对照，数值结果待重跑；现有 src/outputs_q3/ 产物为旧线性口径，只作对照。

按 5.4.1 消去 D ，在 $(\log_{10} N, Q)$ 上求解：内层对 $\log_{10} N$ 用黄金分割搜索（约束取等后的剖面损失关于 N 单峰），外层对 Q 用网格加密并保护端点 Q_0 与 1，同时保留独立粗网格穷举核对，并分别输出局部 $\Phi = 1$ 根与全局状态切换点。主网格为 3 种成本函数 $\times 7$ 档

预算 $\times 5$ 档 C7 上下文长度 $\times 2$ 个同映射下的起始质量对照，共 210 组（本项目设计，不是赛题规定的组数）。临界预算的搜索用二分，且仅在已括根、已验证单次切换的区间内使用；未括根与 $Q_0 = 1$ 两种情形显式返回 NOT_BRACKETED/NO_QUALITY_RANGE 与 null。

5.4.3 结果与分析

本节写作限制。doc/Q3/问题三_SPEC.md v5 已把目标式改为问题二的幂次 M4 + 地板并保留固定配比乘子 $m_* \approx 0.8989423$ ，但 src/code_q3/ 与 src/outputs_q3/ 尚未按该版重跑：现有产物生成于 2026-09-25 15:02，当时读取的是线性质量式的 $\kappa_N = 0.4315$ 、 $\kappa_D = 0.1405$ 、 $k_0 = 0.1407$ 与 $Q_0 = 0.6608889991$ 。因此本小节依次给出：规范目标下的解析结论；现有落盘结果的旧口径对照（明确不作结论）；待补证据清单。

预算取等与降维。三项成本都与 D 成正比，且 $\partial L / \partial D = -m_* \beta T_D / D < 0$ ，故在无额外 D 上限的本模型内预算用尽， $D = C / (KN + \Delta g)$ ，其中 $K = 6 + \eta L_{ctx}$ 、 $\Delta g = [g(Q) - g(Q_0)]_+$ ；问题降为 $(\log_{10} N, Q)$ 的二维有界优化。

上下文长度的解析临界值。注意力项与训练项之比为 $\eta L_{ctx} / 6$ ，在固定 L_{ctx} 下与 C, N, D 无关；两者相等给出 $L_{ctx}^{crit} = 6 / \eta = 30000$ token。C7 的五档可行值中有 8192（临界值以下）与 32768（临界值以上）；30000 本身不是 C7 的实测档位，因此”成本交叉”与”预算驱动的最优策略转移”是两件事，须分开陈述。

质量状态的分类与判据。质量约束的活跃状态分 LOWER ($Q^* = Q_0$)、INTERIOR、UPPER ($Q^* = 1$) 三类，离开下界与到达上界是两个不同的临界事件； $\Phi(C; Q_0) \leq 1$ 、内点 $\Phi(C; Q) = 1$ 、 $\Phi(C; 1) \geq 1$ 只是固定 Q 意义下的局部一阶必要条件，全局切换可能发生在两个内点分支相等处。因此求解须同时输出局部根与全局临界点。该 Φ 表达式的正确性已有单点有限差分依据： $C = 10^{20}$ 、 $L_{ctx} = 2048$ 、指数型成本、 $Q = 0.8$ 处解析导数 -0.1164515205405 与差分 -0.1164515204932 的相对误差约 4.1×10^{-10} （对应 $\Phi = 1.63892372$ ，见 doc/Q3/新式子影响文档审查.md）。这属于公式正确性证据，不是任何配置或临界预算的结果。

配比乘子的处理。主情景按 P2 的 p_channel 读取 $m_* = 0.8989423$ （由 s_red_main=1.4996207320397785 与 phi_tilde_pstar=-0.07104223742472571 给出），参考点是 $\mathbf{p}_{ref} = \mathbf{p}_{train_mean}$ 而非 $\mathbf{p}^*$ ；忽略配比效应的对照须单独标记 m=1。由于 P2 把跨规模配比通道标为 exploratory，含 m_* 的结论必须报告这一条件性来源并给出 m=1 对照。固定 $\mathbf{p}^*$ 时 H_{tot} 对完整基线 Loss 乘一个与 N, D, Q 无关的正常数，故其最优 N, D, Q 应与 m=1 完全一致、最优 Loss 按该常数缩放——这一同配置关系是可核验的，而不是可优化出来的差异。

现有落盘结果：旧口径对照（不作结论）。src/outputs_q3/ 现有产物对应线性质量式与旧 Q_0 。为便于后续核对，仅列出其结构而不作为本文结论。

表 10 现有 P3 产物的口径与状态计数（数据源：interface/P3_optimal_config.csv、T1_optimal_all.csv,）

项目	现有落盘值	与 v5 目标规范的差异
质量式	线性 $1 + \kappa(1 - Q)$	v5 要求幂次 $Q^{-\kappa}$
κ_N, κ_D, k_0	0.4315, 0.1405, 0.1407	当前 P2 为 0.1416, 0.0112, 0.2280
Q_0	0.6608889991	当前 P1/P2 为 0.6624116679870492
配比乘子 m_*	未使用	v5 要求 0.8989423 并另报 $m=1$
主网格状态计数	8 组 Q_0 角点、18 组内点、184 组提满	须按 v5 重算
临界预算（指数型/幂函数型/对数型）	离开 Q_0 为 18.874/19.399/18.166；到达 $Q = 1$ 为 20.168/19.845/18.166	须按 v5 重算
$\Phi = 1$ 解析根	18.833/19.358/18.669	须按 v5 重算
求解器 vs 粗网格	最大 Loss 差 2.37×10^{-5}	已超出 v5 验收阈值 2×10^{-5}
闭式 N^* 互验	最大相对误差 1.89×10^{-7}	满足 $< 10^{-5}$

上表的三档预算列（ $10^{19}/10^{22}/10^{24}$ FLOPs）与”七档网格（ $10^{19} - 10^{25}$ ）”都是本项目设计；题面只建议前三档并要求至少三个量级。现有产物还缺 P3 manifest、缺三项绝对成本与预算使用率字段、缺 $H_{\text{tot}}/m=1$ /映射情景与 P1 不确定性传播，且 P3_sensitivity_Lctx.csv、P3_structural_transition.json 的字段与 Spec v5 要求不一致（后者为 GBK 编码，下游读取有隐患）。上述任何数值都不得被引用为本版结论。

待补证据清单（问题三）。

1. 按 v5 目标式改写 src/code_q3/q3_00_model.py (h_N, h_D, Φ 、闭式对照) 后重跑全链，生成 P3_optimal_config.csv、P3_sensitivity_Lctx.csv、P3_structural_transition.json 与 P3_run_manifest.json（含 P1/P2/C7 输入 SHA-256）。【需补证据：Q3-1、Q3-2、Q3-5】 2. 主情景读取 m_* 并另报 $m=1$ 、 H_{tot} 与 P2 无地板参数的对照；同一场景下比较四种口径的 N, D, Q, L 。【需补证据：Q3-6、Q3-9】 3. 分别输出局部 $\Phi = 1$ 根与全局状态切换点，并对 $Q_0 = 1$ 、未括根、多根三种情形做专用验收。【需补证据：Q3-7】 4. 补三项成本绝对值、总消耗与预算使用率字段，统一份额分母为实际总消耗，并把三个题面建议档单列。【需补证据：Q3-8】 5. P1 质量与配比误差、P2 锚点映射误差进入敏感性；缺少逐次重抽样接口时，把全链区间标注为未完成。【需补证据：Q3-3、Q3-9】

5.5 问题四的模型建立与求解

5.5.1 模型建立

主能力分为 C1/C2 的 Average（六维等权，0-100 分）。C2 是 C1 加 Epoch 匹配列，两者是同批榜单，不构成两套独立样本，不作互相验证。base 定义为 pretrained 与 continuously pretrained，chat 为 chat 与 fine-tuned，merges/multimodal 排除出主回归。主时间轴取 C2 的

Epoch 发布日，C1 提交日只用于 C8 月度对照与短窗回测（覆盖 2024-06-08 ~ 2025-03-13）。开放权重的 permissive/community/noncommercial/unknown 与权重是否可获得分别记录：C2 的 Hub License 缺失 1,753 行，“在 Hub 有记录”不足以证明权重可下载或允许复现。任何预测表须写明数据截止日、预测起点 T_0 与目标日期。主面板的严格开放权重纳入规则尚未执行，见 7.2。

任务饱和与去饱和综合分。C8 的每个叶子任务按随机基线 c_j 归一化 $\hat{s}_j = \max\{0, (s_j - c_j)/(1 - c_j)\}$ ，按提交日构造月度累计 top-5 前沿 F_t ；按“终点水平、剩余空间、关闭率、噪声门槛”四个判据把 39 个任务分为饱和、快速增长、常规增长、低位停滞四类 [10]。去饱和和综合分剔除判为饱和的任务后，以起点剩余空间作家族内权重、六个任务家族等权：

$$S_{\text{desat}} = 100 \sum_j \hat{s}_j w_j, \quad w_j \propto (1 - F_{\text{start},j}), \text{ 家族内归一后家族等权.}$$

副分依赖 2024-06 起点、39 个叶子任务的选择与随机基线设定，不可当作与 Average 同尺度的独立真值。

Loss-Benchmark 分层桥接。得分存在底噪下界与上界，故采用 S 形映射

$$S(L) = lo + \frac{hi - lo}{1 + \exp[k(L - L_0)]}, \quad 0 \leq lo \leq hi \leq 100, k > 0,$$

给定 (k, L_0) 时 (lo, hi) 可线性求解。C6 的 75 行按可比性分层：High 层（7 行，同模型同验证集）权重 1，Medium 层（68 行，验证集不同、近似可比）权重 0.5；对 base/chat 与各得分维度分别拟合，主接口为 base|Average。另做 Medium 权重 0.25/1.0、High-only、系列内斜率、留一检验与 200 次案例 bootstrap。C6 的 Loss 来源与验证集不完全统一，High 层 7 点全部落在底噪区，只能锁定下界 lo ，上升段依赖 Medium 层。

规模与非规模贡献的分解。面板每行由 C2 模型、C4 匹配配置与问题二的 $\hat{L}(N, D, Q = 1)$ 组成。主模型（M1b，结构·加性）为

$$S_i = lo + \text{amp} \sigma(k[\hat{L}_i - L_0]) + \tau(t_i - 2023) + \varepsilon_i, \quad \sigma(x) = \frac{1}{1 + e^{-x}},$$

其中 τ 是控制规模状态后的年度得分增量。M1c 把技术项写成等效年降损 δ ： $S_i = lo + \text{amp} \sigma(k[\hat{L}_i - \delta t_i - L_0]) + \varepsilon_i$ 。对照模型包括 M2 效率前沿（帕累托有效模型上的 $S = a + b \log_{10} C + ct$ ）、M3 分位数回归（ $q = 0.5, 0.75, 0.9$ ）与全样本 OLS。对两个前沿状态用双顺序 **Shapley** 分配模型预测的变化 [11]：“规模贡献”为只让前沿 $\hat{L}$ 按实际演进时的增量，“技术贡献”为只让 t 演进时的增量。 τ 与 δ 是控制当前模型状态后的时间关联，不能直接解释为已识别的因果技术效应；数据质量、后训练、架构与测量口径变化都可能进入时间项。chat 前沿另设后训练增益 $G(t)$ ，由 base/chat 同组织配对回归得到。

预测链条。预测不新增自由参数，四步依次为：算力情景 → 由问题三成本式在 $Q = 1$ 、 $L_{ctx} = 4096$ 下求 $L^*(C)$ 得 $\Delta L^* \rightarrow$ 叠加到观测前沿 $\hat{L}$ 上（锚定增量：现有前沿并非算力最优，只借用 L^* 的斜率）→ 经 M1b/M1c 得到 ΔS 。chat 前沿等于 chat 锚点加 base 增量，再加后训练增益增量（“延续/停滞”两种情景）。不确定性由 4,000 次蒙特卡洛混合问题二参数 bootstrap、分解簇 bootstrap（120 次）、后训练增益 bootstrap 与面板残差给出。注意两处口径限制：预测脚本未读取 **P3** 已存最优配置接口、未乘 $m(\mathbf{p}^*)$ 、未验证四变量联合律（独立实现将其记为 DEFERRED_Q3）；预测区间未包含 **C6** 桥接的迁移误差。

5.5.2 求解方法

问题四使用 `src/code_q4/` 的 `q4_01_c8_parse.py` → `q4_02_saturation.py` → `q4_03_bridge.py` → `q4_04_decomp.py` → `q4_05_forecast.py` → `q4_99_check_report.py`, 解释器用仓库虚拟环境; 桥接拟合因环境无 SciPy, 采用“网格+两级加密+加权最小二乘”。现有 `src/outputs_q4/` 产物生成于 2026-09-24, 而公共模块的附件路径修复与质量项更新发生在 2026-09-25, 主链尚未在修复后重跑, 因此 5.5.3 的数字是修复前的旧产物, 须重跑核验后才可用于定稿。

C8 的 1,958 个 JSON 逐任务解析并缓存 (含 1,861 个模型、39 个叶子任务), 与 C1 榜单按模型名连接 (进入 T5 的交集 1,859 个模型); 月度前沿按提交日构造。C6 桥接用加权最小二乘拟合, 留一交叉验证比较 S 形、线性与常数三种形式。分解面板由 C2 与 C4 按发布日期与组织连接得到, 匹配规则为“同日同组织+参数差小于 50%”, 无法匹配的行单列缺失原因; 分解的区间由按 C4 模型簇重抽样 120 次给出。预测做 4,000 次蒙特卡洛; 回测只用 $t < 2024.5$ 的数据重估模型后预测 2025.25。

5.5.3 结果与分析

本节写作限制。现有 `src/outputs_q4/` 产物生成于 2026-09-24, 早于公共模块的附件路径修复 (2026-09-25), 主链尚未在修复后重跑, 故本节数字属修复前旧产物; 另有三处未关闭项: 预测起点 $T_0 = 2025.25$ 的 12 个月目标 (2026.25) 在本轮核查时已成过去, 只能称历史情景预测; 主面板含发布日晚于 T_0 的模型 (THUDM/glm-4-9b, 2025-04-14) 且 2025 年 112 个开放权重点中 83 个发布于 2025-04-01 之后, 故非严格起点前冻结; 主面板未执行严格的开放权重纳入规则。以下数字只在上述边界内陈述。

能力口径与任务饱和。C8 共解析 1,958 个 JSON (缓存含 1,861 个模型、39 个叶子任务, 与 C1 交集的模型为 1,859 个)。39 个任务按四类判据分为: 饱和 10 个、快速增长 9 个、常规增长 17 个、低位停滞 3 个 (`interface/P4_task_saturation.csv`, 图 11)。图 11 显示各任务的起点水平与剩余空间关闭率, 饱和任务的终点水平已达上界 (如 `temporal_sequences` 达到 1.00), 快速增长任务仍有较大剩余空间 (如 `web_of_lies` 由 0.20 升至 0.78)。

图9 C8 逐任务饱和度分析




图 11 39 个叶子任务的饱和度分类

表 11 三种能力口径下的前沿变化（C1 提交日窗口 2024-06~2025-03；源自 T5_desat_vs_average.csv，正文表格）

口径	起点前沿	终点前沿	相对增幅	月斜率
C1 Average	38.52	49.89	+29.53%	1.285
C8 全任务重算	37.98	49.40	+30.08%	1.326
C8 去饱和分	26.36	39.06	+48.19%	1.536

表中相对增幅的分母为该口径的起点前沿。模型级去饱和分与 Average 的相关系数为 0.9479（T5_model_desat_scores.csv，图 12），即两者排序基本一致，但按相对增幅计，包含饱和任务的 Average 低估前沿进展约 1.6 倍。图 12 的两个面板分别显示三个口径的归一化前沿与模型级散点。C8 重算与 C1 榜单的一致性核对（T5_c8_vs_c1_check.csv）为：五个任务族的 Pearson 在 0.9893–0.9995、MAE 在 0.049–0.243，例外是 MATH（Pearson 0.8009、MAE 3.4974）；这是同批评测数据的重算一致性核对，不是独立检验，MATH 例外的原因尚未解释。




图 12 去饱和综合分与 Average 口径的前沿对比

损失到得分的分层桥接。C6 共 75 行，High 层 7 行、Medium 层 68 行。主桥接 base|Average(44 行)的参数为 $lo = 8.626$ 、 $hi = 21.572$ 、 $k = 46.12$ 、 $L_0 = 2.07$ ；chat|Average(31 行)为 $lo = 12.096$ 、 $hi = 35.112$ 、 $k = 13.857$ 、 $L_0 = 2.155$ （T6_bridge_fits.csv、interface/P4_bridge_params.json，图 13）。C6 全体的 Loss 与 Average 相关系数为 -0.510 （High -0.397 、Medium -0.502 ），符号为负，与“损失越低、得分越高”的方向一致。留一 RMSE 为 S 形 8.079、线性 8.283、常数 9.514，即 S 形略优于线性与常数（T6_bridge_loo.csv）。系列内固定效应斜率为 base -23.58 、chat -36.65 。Medium 层权重取 0.25/0.5/1.0 时， $S(1.85)$ 分别为 21.79/21.57/21.43，结果稳定；仅用 High 层时只能得到 $lo = 5.448$ 、 $hi = 6.349$ ，因为 High 层 7 点的损失全部落在 $[2.09, 2.60]$ 的底噪区、对应得分仅 5.1–6.1（T6_bridge_tier_sensitivity.csv）。因此只能锁定下界 lo ，S 形的上升段依赖 **Medium** 层，这是 C6 数据的硬限制；表中的 $hi = 21.572$ 是 C6 样本上拟合出的上平台，不是榜单或未来能力的硬上限。




图 13 C6 分层 Loss-Benchmark 桥接 (base 与 chat)

规模与非规模贡献的分解。面板由 C2 与 C4 按 (发布日期, 组织) 连接得到: base 58 行、chat 37 行; base 的 58 行中 35 行的 D 来自 C4 数据量、23 行由 $C/(6N)$ 反解得到 (后者是近似反解, 不是实测数据量)。拟合优度为 M1b $R^2 = 0.8701$ 、M1c 0.8684、仅规模重估 0.8320、OLS 0.6603、M1a 0.5603 (T7_decomp_fit_quality.csv)。主模型参数为 $\tau = 2.4526$ 分/年 (M1c 的 $\delta = 0.035$ nats/年)。

表 12 base 前沿增长的贡献分解 (窗口 2023.50→2025.00, 观测变化 $\Delta S_{\text{obs}} = 24.759$; 源自 interface/P4_decomposition.csv, 正文表格)

类别	方法	规模贡献	技术贡献	模型变化	技术占比	90% 区间
结构模型	M1b (主)	23.063	3.404	26.467	12.86%	6.07%–21.96%
结构模型	M1c	20.115	6.037	26.153	23.09%	4.17%–45.49%
线性对照	M2 效率前沿	7.358	6.186	13.544	45.67%	8.68%–59.88%
线性对照	M3 $q = 0.75$	7.398	4.445	11.844	37.53%	-47.38%–58.24%
线性对照	M3 $q = 0.90$	10.186	-3.149	7.037	-44.75%	跨零
线性对照	M3 $q = 0.50$	6.241	5.875	12.116	48.49%	9.15%–62.50%
线性对照	OLS	7.722	3.235	10.957	29.53%	10.94%–46.13%
反例	M1a (直接套用 C6 桥接)	0.632	4.835	5.467	88.44%	80.04%–92.08%

表中技术占比的分母是各方法自身的模型变化 ΔS_{model} , 不是观测增量 ΔS_{obs} ; 观测增量与模型增量并不闭合 (base 为 24.759 对 26.467), 残差未分配, 故这些百分比只能表述为“模型解释增量内部的份额”。图 14 显示面板中规模状态 $\hat{L}$ 、得分与时间的关系以及 M1b 在不同时间的曲线, 图 15 给出各方法、各窗口的规模与技术贡献对比 (含 8 个方法的技术占比标注与观测增量参考线)。核心三法 (M1b、M2、M3 $q = 0.75$) 的技术占比极差为 32.81 个百分点, 方法分歧是结构性的: M2 与 M3 假设得分对 $\log_{10} C$ 线性, 无法表达桥接的 S 形加速段, 会把“损失刚进入陡峭区带来的规模红利”部分记入时间项; M1b/M1c 用“标度律 + S 形桥接”吸收这部分, 拟合优度也明显更高 (0.87 对 0.66)。因此本文保留方法分歧, 不给出唯一数字: 结构口径的技术占比为 12.9%–23.1% (主口径 12.9%), 线性口径的 29.5%–48.5% 作为上界参考; 所有方法在“规模扩张为主”这一定性结论上一致。M1a 直接套用 C6 桥接 (其 $hi = 21.572$ 低于面板前沿 37.302), 把桥接的非线性全部记入“技术”, 得到 88.4%, 与索洛余值法的偏差同源, 仅作参考。




图 14 分解面板：规模状态 $\hat{L}$ 、得分与时间




图 15 各方法、各窗口的规模贡献与技术贡献

窗口敏感性：换用 2024.00→2025.00 时 M1b 的技术占比为 7.06%；换用 2024.50→2025.25 时为 8.18%（M1a 在该窗口为 99.30%，M3 $q = 0.90$ 为负）。换算为算力等效速率，各方法的技术进步为 M1b 0.290、M1c 0.561、M2 0.781、M3 $q = 0.75$ 0.558、M3 $q = 0.50$ 0.875、OLS 0.389 dex/yr（M3 $q = 0.90$ 为 -0.287 ）（T7_compute_equiv_rate.csv）。C3 历史点的降权敏感性：仅用 C2×C4 时为 0.781 dex/yr（ $n = 58$ ），加入 C3 历史点、权重 0.2 时为 0.499、权重 1.0 时为 0.205（T7_c3_sensitivity.csv）。C3 的 Average 与其六维均值的相关仅为 0.6337，口径混杂，故只作有标记的敏感性、不并入主面板。C1 九个月窗口的短窗回归（同一批数据，非留出）给出 base 的月度等效 0.722 dex/yr（Average 口径）/ 0.766（去饱和口径）与 chat 的 0.444/0.572，与上述量级一致（T7_c1_window_check.csv）。

chat 与后训练：在 89 对同组织的 (base, chat) 配对中平均增益为 4.304 分、中位数 3.696 分；对有发布日的 31 对回归得 $G(t) = -0.405 + 3.348(t - 2023)$ ，说明后训练本身是一类逐年增强的非规模技术（T7_chat_posttrain_pairs.csv）。chat 前沿在 2023.50→2025.00 由 8.76 升至 46.06（观测增量 37.293），其中规模贡献 23.766、预训练技术 3.563、后训练技术 4.863，模型变化合计 32.191、技术占比 26.17%（T7_chat_decomposition.csv）。chat 同样须报告观测增量与模型增量的不闭合。

算力情景与前沿预测。C4 中开放权重模型的年度训练算力：2025 年有 112 个点（open_max_log10C 为 25.592、Top-5 均值为 25.049）；斜率按不同统计口径为 0.579（open_max, 2019–2025）、0.598（open_top5）、0.688（open_max, 2022–2025）、0.646

(all_max) dex/yr (T8_compute_trend.csv)。据此设三种情景：基线 0.60、减半 0.30、四分之一 0.15 dex/yr。起点 $T_0 = 2025.25$ ，锚点 base $S = 37.302$ 、chat $S = 46.057$ ，12/24 个月的目标日期为 2026.25/2027.25。

表 13 开源前沿 (Average) 的条件情景外推：中位数 [5% - 95% 区间] (数据源：interface/P4_frontier_forecast.csv)

情景	base 12 个月	base 24 个月	base 24 个月 技术占比	chat 24 个月 (后训练延续)	chat 24 个月 (后训练停滞)
基线 0.60	43.07 [37.35, 52.83]	46.19 [37.55, 68.49]	54.94%	61.62 [51.79, 79.62]	54.85 [46.43, 70.12]
减半 0.30	41.73 [36.95, 49.66]	45.25 [37.75, 58.28]	65.49%	—	—
四分之一 0.15	41.09 [36.63, 47.59]	44.11 [37.53, 54.86]	76.70%	—	—

算力增速从 0.60 降到 0.15 dex/yr，24 个月的 base 中位数只减少约 2 分 (46.19 $\rightarrow$ 44.11)：规模增量本身被 S 形桥接的饱和段压缩，而技术项基本不受算力情景影响，因此算力放缓时技术进步成为增量主体 (24 个月技术占比由 54.94% 升至 76.70%)。图 16 的左、中面板给出三情景下 base/chat 的区间扇形与 M1b 的纯规模天花板 (44.195)，右面板给出回测误差。模型不确定性主要来自技术项形式：基线情景下 24 个月的 M1b 中位数为 46.590、M1c 为 44.719；chat 对”后训练增益是否延续”最敏感 (61.62 对 54.85，相差约 6.8 分)，这一差别大于算力情景之间的差别 (约 2 分)。作为上界参考，”算力无限”时 24 个月的 M1b 为 49.177 (T8_forecast_by_techform.csv, T8_forecast_meta.json 的 caps)。预测区间只包含问题二参数、分解簇 bootstrap、后训练增益与面板残差，不包含 C6 桥接的迁移误差；另有累计前沿区间下界在部分情景低于锚点 (如减半情景 12 个月 base 的 5% 分位为 36.95、低于锚点 37.302)，与”累计前沿不下降”的定义冲突，须按”当期新模型前沿”重新定义或修正模拟。




图 16 三种算力情景下 base/chat 前沿的条件外推

回测。在发布日轴上只用 $t < 2024.5$ 的 42 个 base 模型重估模型 ($\tau = 2.741$)，以 2024.5 的前沿 29.277 为锚点预测 2025.25 的实际前沿 37.302：基线情景 M1b 的误差为 -0.784、M1c 为 -1.867；用实际算力增速 0.758 dex/yr 时 M1b 误差为 +0.212；用实际前沿的规模状态 (神谕规模) 时 M1b 误差为 -0.054；朴素线性外推的误差为 +2.651 (T8_backtest.csv)。在提交日轴上，对 C1 月度前沿做纯时间序列外推，3 个月误差达到 +7.907，因为前沿已在 49.891 附近进入平台，这是不直接用 ARIMA 类外推的实证理由。回测的重估样本并非严

格的起点前冻结样本（见本节开头限制），故只能称“事后回测表现”，不能称独立预测验证。

6 模型的检验与灵敏度分析

6.1 模型检验

表 14 汇总了全文的检验。「互相验证」只用于*同一问题、不同假设*的方法对，判断取排序或数值的一致性；上下游分工衔接的方法之间不存在验证关系，本文也不作此类声称。

表 14 全文检验清单

问题	检验对	类型	判据	结果
一	Huber 主分 vs 算术均值/PCA/TOPSIS	方法敏感性	样本级 Spearman	0.9936/0.8166/0.9588; 无质量真值
一	A1 vs A2/A3	冻结扩展检验	KS 的 p 值	0.313/0.220; 未检出明显分布差异
一	六来源候选跨集	冻结规则复检	候选比例与方向	5.00%/4.73%/4.99%; 主要方向有变化
一	clr+Huber vs 裸份额 OLS vs GBDT	1M 留出 (A6/A7)	逐域/等权目标 R^2	0.772/0.260、0.654/0.418、0.923/0.870
一	A1→A18 质量桥接	分层五折 + 六映射域对照	R^2 与 六域 MAE	0.4106 与 0.0365 ($n = 6$); 非独立真值
一	冻结 1M 模型 → 60M → 1B	跨尺度检验 (1B 为独立检验)	等权目标 Spearman	0.523/0.467/0.677; 绝对 Loss 不可直接迁移
一	尺度修正 (1M + 60M 标定)	1B 独立检验	逐域 MAE 均值	2.953 → 0.770; 平均预测 Loss 2.99 仍高于观测 2.23
一	A12-A15 估算表	一致性对照 (非验证)	排序与绝对误差	目标 Spearman 与 1M 实测相反, 只作反例
二	有地板 vs 无地板 (幂次 M4)	嵌套 F 检验	F 、 p	$F = 307.11$, $p < 10^{-15}$
二	$\kappa_N = \kappa_D$ 、 $\kappa_D = 0$	嵌套 F 检验	F 、 p	57.19 ($p = 3.4 \times 10^{-13}$) 拒绝; 0.63 ($p = 0.43$) 不能拒绝
二	B7 新增 90 点	留出 (半合成插值)	RMSE、偏差	RMSE 0.0531, 平均残差 +0.0219; 高于噪声代理 0.0458
二	解析式 vs 数值解	互相验证	相对误差	替代/闭式误差 $< 10^{-14}$ (替代倍数) / $< 10^{-8}$
二	$Q = 1$ 切片 vs L_0	退化条件核对	平均残差与区间	+0.0036, [-0.0120, +0.0193]
二	B4/B5/B2/B10	外部趋势对照 (仅 $Q = 1$)	Spearman、偏差	0.983/0.959/0.788/1.000; 水平不可比
二	B11/B12 来源审计	元数据核对	步数覆盖、 D 记账	步数覆盖 100%, $D/(\text{steps} \times \text{batch})$ 中位比 0.9986
三	数值解 vs 闭式 N^*	互相验证	相对误差	旧产物最大 1.89×10^{-7} ; 待按 v5 重算
三	求解器 vs 粗网格穷举	互相验证	Loss 差与状态一致	旧产物最大差 2.37×10^{-5} , 已超 v5 阈值 2×10^{-5}
三	剖面导数	有限差分核对	相对误差	4.1×10^{-10} (单点, $C = 10^{20}$)
四	C8 重算 vs C1 榜单	口径核验 (同批数据)	Pearson、MAE	0.9893 – 0.9995; MATH 例外 0.8009/3.4974
四	S 形 vs 线性 vs 常数桥接	留一 (同域)	RMSE	8.079 vs 8.283 vs 9.514
四	分解三口径 (M1b/M2/M3q75)	方法敏感性	技术占比极差	32.81 个百分点, 未过 ± 15 pp 门槛
四	预测回测 (发布日轴)	事后回测	2025.25 误差	M1b -0.784; 朴素线性 +2.651

以下按问题分别说明检验的角色、判据与边界，数值与检验对见表 14。

问题一。检验分三层且互不混用：A2/A3 是冻结评分的扩展检验（ p 值只说明未检出分布差异）；A6/A7 是配比模型的同尺度留出；A8–A11 是跨尺度检验，其中只有 A10/A11 (1B) 完全不参与估计，A8/A9 承担尺度修正的标定。需特别说明的是，由于依据 A6/A7 的表现选择 GBDT 作搜索交叉评估，该留出集不能再充当最终候选收益的独立验证；候选收益仍是 1M 代理模型内的预测差异。A12–A15 是估算/外推表（A12/A14 的配比逐行取自 A4 子集，A13/A15 由三尺度幂律外推生成），与修正模型的接近只是一致性对照，不是独立验证；估算表还隐含一个“大尺度排序反转”，而同一批配比从 1M 到 60M 的实测排序是保持的，该反转没有观测支持。

问题二。质量参数只用 B6（半合成）估计，留出只用 B7 相对 B6 新增的 90 点（ $Q = 0.5$ 、 0.7 ，覆盖全部 45 个 (N, D) 格，属 Q 方向插值）。B2 为半合成、B3 由 B1 插值派生、B10 本身即公式估算，因此这三项只能核对实现与趋势，不能证明质量项可泛化到真实训练；B4 的 57 点中有 13 点在对数尺度上距 B1 小于 0.05 dex，剔除后 44 点结果不变（Spearman 0.975、偏差 +0.176）。B8 与 B6/B7 的 Loss 方向相反（64.26% 的点低于 E ），只作反例。B11/B12 审计确认 B1 的 8 个名义规模、147 个步数均被 B12 覆盖且 8 个模型都在 B11 中，因此 B1 的训练设定是真实的，而损失数值是按公开公式生成的；B11 只含 3 个模型族，B4 的 12 族中仅覆盖 8.33%。

问题三。互验设计为：数值最优解与 $\Delta g = 0$ 的闭式 N^* 对照；求解器与独立粗网格穷举对照（Loss 差与状态判定）； Φ 的剖面导数与有限差分对照。按 v5 目标式的重算尚未执行，故本节只登记检验设计，不引用旧产物的检验数值作为本版结论。【需补证据：Q3-5、Q3-7】

问题四。C8 重算与 C1 的一致性是同批数据的口径核验（MATH 例外未解释）；桥接的留一是同一数据域内的留一，不是时间外留出；分解的三口径差异是方法敏感性而非验证；回测是事后回测，且重估样本未严格截在预测起点之前。因此问题四没有独立检验层结论，所有结论均标注为拟合层或条件外推层。

6.2 灵敏度与稳健性分析

问题一。六来源分歧阈值取同域 P90/P95/P97.5 时，候选比例约为 10.00%/5.00%/2.50%（A2 为 9.19%/4.73%/2.00%，A3 为 9.74%/4.99%/2.44%），数量级随阈值显著变化，说明这些数值只指导人工复核工作量，不能解释为真实冲突率随阈值变化。来源一致性加权实验分 Q_{v2} 与主分的秩相关为 0.9547/0.9207/0.9395、域级排序不变，但由于没有独立标签证明新权重更准确，主分不因此改变（T3_Q_v2_conflict_diff.csv，图 23）。分子与方法层面：单指标极端扰动下主分变动约小 30%；配比搜索在 13 域等权与 pile_cc 单域两个目标下给出不同候选，故评价目标必须在搜索前确定；质量交互项仅在 6/13 域显著且方向不一，故不构成质量效应结论。

问题二。去掉地板后，质量 +0.1 在 $N = 10^{11}$ 、 $D = 3 \times 10^{11}$ 处的等效参数倍数由约 3.0 降到 1.3–1.5，方向不变； κ_N 、 k_0 的 95% 区间为 [0.1264, 0.1568]、[0.2013, 0.2554]， κ_D 的区间含 0；主式的形状代价是留出 RMSE 高于线性对照（0.0531 对 0.0416）与噪声代理（0.0458）； $C = 10^{19}$ 时提质是否划算取决于成本函数， $C \geq 10^{20}$ 后三种 $g(Q)$ 都是提质更划算（T33b_quality_breakeven.csv 的 R_at_Q0 列）。高预算端的倍数与地板份额依赖半合

成地板的外推，属假设下的推论。

问题三。计划中的敏感性包括三类成本函数、C7 五档上下文长度、 η 的三档扰动（题设固定 2×10^{-4} ，另两档为本项目扰动情景）、P2 参数重抽样、主/锚点两种质量映射、固定配比乘子 $m=1$ 与 H_{tot} 对照。已可确认的解析结论只有一条与预算、成本函数和规模都无关：注意力与训练成本之比恒为 $\eta L_{\text{ctx}}/6$ ，其临界值为 $L_{\text{ctx}}^{\text{crit}} = 30000$ token。其余敏感性数值须按 v5 重跑后填入。【需补证据：Q3-2、Q3-3、Q3-6、Q3-9】

问题四。桥接的 Medium 层权重取 0.25–1.0 时 $S(1.85)$ 的变化不到 0.4 分，但仅用 High 层时上平台降到 6.349，说明上升段完全依赖 Medium 层。C3 历史点的权重取 0.2 与 1.0 时，技术进步率为 0.499 与 0.205 dex/yr（不含 C3 时为 0.781），因此时间估计对是否纳入混杂口径的历史点很敏感，C3 只作有标记的敏感性。分解换用 2024→2025 与 2024.5→2025.25 两个窗口时，M1b 的技术占比为 7.06% 与 8.18%，”规模为主”的定性结论不变。预测对后训练增益是否延续最敏感（约 6.8 分），大于算力情景之间的差异（约 2 分）。

7 模型的评价与推广

7.1 模型的优点

1. 唯一质量口径与证据分层。问题一的文档、领域、桥接标签与配比加权质量使用同一 CRITIC 加权 Huber 主分；A1 拟合、A2/A3 扩展、A6/A7 留出、A8/A9 标定、A10/A11 独立检验、A12–A15 估算表分开报告，A12–A15 明确标注为非观测。2. 训练与检验边界可追溯。问题二只用 B6 估计质量参数并选择模型，B7 相对 B6 新增的 90 点作留出；配比通道的参数只由 1M 训练行确定，A6–A11 只用于评估。3. 形式与阈值可追溯。问题一的六来源阈值取 A1 同域 P95，桥接以分层五折比较 Ridge 与 GBDT；问题三的结构转移由质量约束的活跃状态定义，并区分局部一阶根与全局切换；问题二的主式是显式指定的并同时报告交叉验证更优的线性对照。4. 解析与数值互验。问题二的替代条件、 N^* 与算力等价倍数、问题三的降维闭式与 Φ 判据、问题四的 S 形桥接与 Shapley 分解都有闭式或可核验形式，并与数值结果逐项对照。5. 职责分离。问题一先固定主分，再报告六来源分歧与旧法对照；阈值敏感性与实验加权分均不回写主评分，避免把筛查预算当作真实冲突率。

7.2 模型的局限与改进方向

1. 无独立质量真值。问题一只报告方法一致性、扰动稳健性与下游敏感性，不能给出质量准确率；17 域中 11 域的质量依赖文本桥接（五折 $R^2 = 0.4106$ ），其区间不含模型选择与跨域偏差，ubuntu_irc（16 篇）、philpapers（63 篇）须低置信使用。2. 质量参数的证据来自半合成数据。 κ_N, κ_D, k_0 只由 B6（半合成，最大规模约 12B）估计，B7 留出也是 Q 方向插值；主式是指定的幂次，其留出 RMSE 高于线性对照与噪声代理； κ_D 未被单独识别。高预算端的”地板占可约损失约 33%”与”提质远比扩参数划算”是把该地板外推出去的结果。3. 跨尺度外推的幅度偏差。1B 独立检验显示尺度修正把绝对误差降低约 74%，但平均预测仍高于观测，且配比效应幅度在 1B 缩到约六成，说明两档规模的对数线性外推不足以刻画曲率。4. 问题三、四的口径尚未由重跑固定。问题三的代码与 P3 接口仍是旧线性质量式，缺 manifest、绝对成本与预算使用率字段，缺 m_* 、 $m=1$ 、 H_{tot} 与上游不确定性传播；问题四主面板未执行严格的开放权重纳入规则，C6 桥接的迁移误差未进入预测区间，预测起点为历史锚点且存在前视，主链未在路径修复后重跑。5. 问题四的方法分歧与占比口

径。C6 的 High 层只有 7 点且全部位于底噪区，上升段依赖 Medium 层；分解三口径的技术占比极差为 32.81 个百分点，是本文最大的不确定性来源；所有占比的分母是模型解释增量而非观测增量，观测与模型增量不闭合。6. 预测不含离散突破。问题四的条件预测不包含新架构等非平滑变化；累计前沿区间在部分情景出现下界低于锚点，与累计定义冲突。

改进方向。

1. 为 11 个 inferred 域增补质量标签或模型评分信号，重新校准并检验桥接误差；补齐 P1 的逐次重抽样接口，使固定配比与重选配比两类不确定性可分别传播到问题三。2. 取得真实的跨质量、跨规模训练日志后替换 B6 重估 k_0 与 κ_N ，并允许配比强度随 $\log N$ 变化；在得到真正的跨尺度配比试验前，问题三应对 H_{red} 与 H_{tot} 各算一遍。3. 按问题三 Spec v5 改写 src/code_q3/ 并重跑全链，生成含输入哈希的运行 manifest，同时输出三项绝对成本、总消耗与预算使用率，并单独验收 $Q_0 = 1$ 与未括根两种状态。4. 问题四先执行明确的开放权重纳入规则（报告纳入前后样本量与结果敏感性），把建模、情景校准与回测样本全部截在各自预测起点之前，把 C6 桥接的 bootstrap 与残差作为独立不确定性通道进入区间，并统一占比的分母声明。5. 获得更多同验证集的 Loss-Benchmark 对，以缩小问题四的结构口径与线性口径分歧。

7.3 模型的推广

“经典基线 + 质量修正 + 配比乘子”的标度律结构可推广到其他数据受限的资源配置问题（去重、合成数据、多模态对齐都能写成可约损失上的乘子与不随规模消失的地板）；“约束取等后解析消元 + 活跃约束状态分类”的降维方法适用于含多种数据处理成本的预算优化；“分层 S 形桥接 + 连续时间项 + Shapley 分解”的框架适用于其他存在能力饱和的技术演进分析。推广时须保持同一纪律：明确数据的证据等级，把半合成、估算与外推数据标注为假设支撑，而不是观测验证。

8 结论

本文围绕“算力约束下如何配置资源以提升大语言模型能力”，建立了四个递进衔接的模型，结论及其证据范围如下。

问题一。以 A1 冻结的 CRITIC 加权 Huber 中心作为唯一质量口径，把 22 个字段展开为 25 项指标，得到文档、领域与语料质量；六来源诊断在 A1 标出约 5% 的高分歧复核候选（多来源对立 1.36%），在三集上的候选比例稳定（5.00%/4.73%/4.99%），但主要对立方向有变化，且没有人工质量真值，不把它当作真实冲突率或据此改分。17 域质量由映射与文本桥接补齐（五折 $R^2 = 0.4106$ ，六映射域 MAE 0.0365）。配比模型给出 17×13 局部迁移效应；推荐候选 $\mathbf{p}^*$ 在 1M 代理模型下相对均匀配比预测降损 9.47%（bootstrap 中位数 9.54%、95% 区间 [7.82%, 11.16%]），这是代理模型预测，不是重新训练的实测收益。域质量与训练边际价值的秩相关为 -0.211，说明单凭质量分不能代替配比实验。

问题二。建立了幂次广义标度律 $L = E + k_0(1 - Q) + [AN^{-\alpha}Q^{-\kappa_N} + BD^{-\beta}Q^{-\kappa_D}] \exp(s_{\text{red}}\tilde{\varphi}(\mathbf{p}))$ ，其中 $E = 1.6901$ 、 $A = 406.39$ 、 $\alpha = 0.34$ 、 $B = 410.59$ 、 $\beta = 0.28$ 由 B1 估计， $\kappa_N = 0.1416$ 、 $\kappa_D = 0.0112$ 、 $k_0 = 0.2280$ 、 $s_{\text{red}} = 1.4996$ 、 $Q_0 = 0.6624116679870492$ （质量参数来自半合成 B6，留出误差高于噪声代理）。在参照点上质量弹性约为参数弹性的 1.62 倍（其中约 73% 来自地板）；固定 $D = 3 \times 10^{11}$ ，质量提高 0.1 在 $N = 10^9$ 处须把参数

扩大为原来的 1.299 倍、在 $N = 10^{11}$ 处约 3.07 倍；沿算力前沿， Q 从 0.7 到 0.8 相当于算力乘 1.191/1.485/2.134 ($C = 10^{19}/10^{22}/10^{24}$)。 $C = 10^{19}$ 时指数型与幂函数型成本下扩参数更划算， $C \geq 10^{20}$ 后三者都是提质更划算。跨尺度上，配比效应的观测强度落在两个假设之间（60M 为 0.913、1B 为 0.612），故其作用只作探索性通道并以下界/上界报告。

问题三。把约束取等后解析消元，问题降为 $(\log_{10} N, Q)$ 的二维有界优化；以质量约束的活跃状态定义结构性转移，并以 $\Phi(C; Q) = 1$ 作为固定 Q 下的局部一阶必要条件（其导数已做单点有限差分核验，相对误差约 4.1×10^{-10} ）。上下文长度存在与预算无关的解析临界值 $L_{ctx}^{crit} = 6/\eta = 30000$ token。按现行 **Spec v5** 的数值结果（各档预算的最优配置、临界预算、成本份额）尚未重跑，本文不引用旧口径数值【需补证据：Q3-1、Q3-2、Q3-5】。

问题四。用”标度律 + S 形桥接 + 连续时间项”的结构模型分解历史前沿增长：在 2023.50 $\rightarrow$ 2025.00 窗口，base 前沿观测变化 24.759 分，模型解释的规模贡献 23.063、技术贡献 3.404，技术占比 12.86%（90% 区间 6.07%–21.96%）；换算为算力等效速率约 0.290 dex/yr。线性对照口径的技术占比为 29.5%–48.5%，三口径极差 32.81 个百分点，故结论表述为”规模扩张为主、非规模技术进步约 13%–23%（结构口径），线性口径为其上界参考”，且占比分母为模型解释增量。能力口径上，去饱和综合分在 2024-06 ~ 2025-03 由 26.36 升至 39.06（+48.19%），比包含饱和任务的 Average（+29.53%）反映更快的真实进展，但该副分依赖起点与任务选择。在算力增速由 0.60 降至 0.15 dex/yr 的情景下，24 个月 base 中位数为 44.11，技术进步的增量占比由 54.94% 升至 76.70%，即算力放缓时非规模技术进步成为增量主体；该结果是以 $T_0 = 2025.25$ 为起点的历史情景外推，不含 C6 桥接迁移误差，须在更新数据与截止日后重做。

四问共同指向一个判断：数据质量与领域配比是与算力并列的一等资源。在低预算段，预算的边际价值主要体现在模型规模上；当预算提高到质量收益足以补偿提质开销后，提质与配比优化的优先级上升；而算力增长放缓时，能力增长将越来越依赖非规模技术进步。上述判断中，涉及质量参数、配比通道与预测的定量部分都受半合成数据、探索性通道与历史锚点的限制，其适用范围已在 7.2 逐条写明。

参考文献

- [1] Hoffmann J, Borgeaud S, Mensch A, et al. Training compute-optimal large language models[C]//Advances in Neural Information Processing Systems 35 (NeurIPS). 2022.
- [2] Bahri Y, Dyer E, Kaplan J, et al. Explaining neural scaling laws[J]. Proceedings of the National Academy of Sciences, 2024, 121(27): e2311878121.
- [3] Diakoulaki D, Mavrotas G, Papayannakis L. Determining objective weights in multiple criteria problems: The CRITIC method[J]. Computers & Operations Research, 1995, 22(7): 763–770.
- [4] Huber P J. Robust estimation of a location parameter[J]. The Annals of Mathematical Statistics, 1964, 35(1): 73–101.
- [5] Penedo G, et al. The FineWeb datasets: Decanting the web for the finest text data at scale[C]//NeurIPS Datasets and Benchmarks Track. 2024.
- [6] Aitchison J. The Statistical Analysis of Compositional Data[M]. London: Chapman & Hall, 1986.

- [7] Xia M, et al. RegMix: Data mixture as regression for language model pre-training[C]//International Conference on Machine Learning (ICML). 2024.
- [8] Biderman S, et al. Pythia: A suite for analyzing large language models across training and scaling[C]//International Conference on Machine Learning (ICML). 2023.
- [9] Muennighoff N, et al. Scaling data-constrained language models[C]//Advances in Neural Information Processing Systems 36 (NeurIPS). 2023.
- [10] Schaeffer R, Miranda B, Koyejo S. Are emergent abilities of large language models a mirage?[C]//Advances in Neural Information Processing Systems 36 (NeurIPS). 2023.
- [11] Shapley L S. A value for n -person games[M]//Contributions to the Theory of Games II. Princeton: Princeton University Press, 1953: 307–317.

附录 A 补充材料与程序

A.1 支撑材料清单与运行说明

正文各结论均按证据分层陈述：解析推导、拟合估计、尺度标定、留出检验、独立检验、评分后诊断、半合成数据、外推或估算，以及历史口径对照，其性质与边界已在正文相应处注明；半合成、估算与外推数据不作为观测验证。正文中*.csv、*.json、*.npz形式的文件名是相应结果的落盘名称：数据表在src/outputs_qN/tables/，跨问接口在src/outputs_qN/interface/，图在src/outputs_qN/figures/；每张表与每幅图的标题内注明其数据来源文件。

问题一：src/code_q1/q1_00_common.py（公共路径与工具）→ q1_01_extract.py → q1_02_quality.py → q1_03_conflict.py、q1_04_bridge.py → q1_05_mixture.py → q1_06_scale.py、q1_07_optimal.py → q1_08_audit.py；环境Python 3.12.13、NumPy 2.4.4、pandas 3.0.2，不依赖SciPy 与 scikit-learn。

问题二：src/code_q2/q2_01_fit.py、q2_02_theory.py、q2_03_economics.py；环境Python 3.12.7、NumPy 1.26.4、pandas 2.2.2、SciPy 1.13.1，随机种子 2026；只读src/outputs_q1/interface/，不读附件A 原始表。

问题三：src/code_q3/q3_00_model.py、q3_01_optimize.py、q3_02_transition.py、q3_03_mixture_joint.py；现行**Spec v5**的幂次目标式与 m_* 尚未落到这些脚本与**P3**接口，须重跑后本附录与其数值才成立（见5.4.3的待补证据清单）。

问题四：src/code_q4/q4_01_c8_parse.py → q4_02_saturation.py → q4_03_bridge.py → q4_04_decomp.py → q4_05_forecast.py → q4_99_check_report.py；q4_99_check_report.py的15项自检中现有3项未通过（P3主质量基线、P3 manifest、P4目标日期）。

注：以上脚本路径与随机种子以各问Spec的「当前实现差异」与修订历史为准；本节只登记，不复述Spec。

A.2 核心程序

(1) CRITIC 权重与加权Huber 主分 (code_q1/q1_02_quality.py 节选)

```
def fit_critic(self, Z):
    sd = Z.std(axis=0, ddof=1)                # contrast intensity
    R = np.corrcoef(Z.T)                      # indicator correlation
    C = sd * (1 - R).sum(axis=1)              # information content C_j
    self.critic_w = C / C.sum()
    return self.critic_w

def fit_delta(self, Z):                      # A1 weighted-MAD rule
    center = weighted_median(Z, self.critic_w)
    dev = np.abs(Z - center[:, None])
    mad = weighted_median(dev, self.critic_w)
    self.delta = float(np.clip(1.345 * 1.4826 * np.median(mad), .01, 1.0))
    return self.delta
```

```
def score(self, Z):
    # fixed weights and delta
    return weighted_huber_center(Z, self.critic_w, self.delta)
```

(2) 问题三向量化求解器 (code_q3/q3_00_model.py 节选, 按Spec v5 目标式)

注: 下列节选是问题三 Spec v5 规定的目标实现形式——幂次质量乘子 $Q^{-\kappa}$ 与固定配比乘子 $m_* = \exp\{s_{\text{red}}\tilde{\varphi}(\mathbf{p}^*)\} \approx 0.8989423$; 现有 src/code_q3/q3_00_model.py 仍为线性乘子 $1 + \kappa(1 - Q)$, 须按此改写并重跑后本附录才可复现 (见5.4.3 的待补证据清单)。内层 $\log_{10} N$ 黄金分割与三级网格加密的结构不变, 此处只列出质量式与 Φ 判据中随 v5 变化的函数。

```
def hN(Q, p=PAR):
    # v5 power multiplier (drop linear 1+k
    (1-Q))
    return Q ** -p["kappa_N"]

def hD(Q, p=PAR):
    return Q ** -p["kappa_D"]

def loss(N, D, Q, p=PAR, m=M_STAR):
    """v5: floor k0(1-Q) outside bracket; mixture multiplier m only on scale
    terms"""
    return (p["E"] + p["k0"] * (1.0 - Q)
            + m * (p["A"] * hN(Q, p) * N ** -p["al"]
                  + p["B"] * hD(Q, p) * D ** -p["be"]))

def phi_ratio(C, g, Lctx, Qeval, Q0, p=PAR, eta=ETA, m=M_STAR):
    """v5 complete Phi at the fixed-Q optimal (N,D):
    Phi = [k0 + (m/Q)(kN TN + kD TD)] * S / [m * beta * TD * g'(Q)],
    S = (6+eta*L_ctx)N + dg,  TN = A N^-al Q^-kN,  TD = B D^-be Q^-kD"""
    kappa = 6 + eta * Lctx
    dg = max(g(Qeval) - g(Q0), 0.0)
    _, x = _profile(C, Qeval, dg, kappa, p, m=m) # inner golden section (
    unchanged)
    N = 10.0 ** x; D = C / (kappa * N + dg)
    TN = p["A"] * N ** -p["al"] * hN(Qeval, p) # TN = A N^-al Q^-kN
    TD = p["B"] * D ** -p["be"] * hD(Qeval, p) # TD = B D^-be Q^-kD
    S = kappa * N + dg
    num = (p["k0"] + m / Qeval * (p["kappa_N"] * TN + p["kappa_D"] * TD)) * S
    den = m * p["be"] * TD * g_prime(Qeval)
    return float(num / den) # C_crit solves Phi(C) = 1
```

(3) 结构分解模型与Shapley 分解 (code_q4/q4_04_decomp.py 节选)

```
def f_add(p, L, t):
    # M1b: S-bridge + linear tech
    term
```

```

return p["lo"] + p["amp"] * sig(L, p["k"], p["L0"]) + p["tau"] * t

def shapley(fun, L0, t0, L1, t1):
    """two-factor Shapley: scale (L_hat) vs technology (t)"""
    sc = 0.5 * ((fun(L1, t0) - fun(L0, t0)) + (fun(L1, t1) - fun(L0, t1)))
    te = 0.5 * ((fun(L0, t1) - fun(L0, t0)) + (fun(L1, t1) - fun(L1, t0)))
    return sc, te

```

A.3 诊断与敏感性图表

本节的图记录筛查阈值、来源一致性、历史口径对照与尺度修正的过程量，正文只引用其结论，不参与评分、筛选或参数估计。




图 17 A1 六来源内部跨度与一致性对照




图 18 六来源对立方向的加权份额




图 19 候选比例对筛查阈值的敏感性




图 20 六来源候选与历史四组候选的重合度




图 21 按前 5% 配平预算后的重合度与 Kappa




图 22 来源一致性加权实验分与主分的域级中位数对照




图 23 来源一致性加权实验分与主分的冲突文档差值分布

A.4 AI 使用披露

依据赛题“AI 使用规范”，现披露如下。

所用工具：Claude（Anthropic）、Kimi Code（Kimi）。

使用环节与贡献范围：(1) 资料整理与概念理解：梳理赛题附件的字段结构与《数据说明》中的条目；(2) 代码编写与调试：数据读取、向量化求解器、绘图脚本的编写与报错排查；(3) 结果核对：编写自动核对脚本，把报告中的数字与程序输出逐项比对；(4) 排版与文字：LaTeX 排版、图表整理与语句润色。上述 AI 产出的代码、数值与文字均经参赛队逐项复核。

参赛队的工作与责任：模型路线的选择（证据分层、质量项形式由交叉验证裁决、结构性转移按 KKT 活跃集定义、分解方法并列报告等）、公式推导与结论判断由参赛队确定，并对 AI 输出的全部代码与数值逐项运行、核验。文中理论、公式与结论均引用正式文献或由附件数据验证，未以 AI 输出作为学术依据。全部数值结果可由随文代码在附件数据上复现。