



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校 国防科技大学

参赛队号 26910020233

	1. 李重行
队员姓名	2. 李星谊
	3. 刘浩然

中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生

数学建模竞赛

题 目： 算力约束下提升大语言模型能力的资源配置建模

摘 要：

大语言模型的预训练能力随模型参数量 N (个) 与训练 token 数 D (token) 增长, 经典标度律以验证集交叉熵损失 $L_0(N, D) = E + AN^{-\alpha} + BD^{-\beta}$ 描述这一过程 [1, 2]。在有限算力下可分配的不仅是规模: 语料质量 Q 与领域配比 $\mathbf{p}$ 同样改变同等投入的效果。本文按「数据如何衡量—资源如何发挥作用—资源如何分配—能力如何演进」的顺序建立四个递进衔接的模型, 前一问的冻结结果经 P1–P4 接口文件进入后一问, 未通过留出检验的通道不进入下游主优化。

针对问题一, 把附件 A1 的 22 个原始质量字段展开为 25 项可比指标, 以域内冻结的预处理、CRITIC 权重与加权 Huber 中心得到唯一的文档质量分 $Q(x)$ (Huber 阈值 $\delta = 0.4034907036619329$ 只由 A1 确定并冻结), 再由 A16 映射与 A18 文本特征桥接到 17 个配比域。A1 七域主分中位数由高到低为 arxiv 0.7707、commoncrawl 0.6761、stackexchange 0.6600、c4 0.6545、book 0.6313、github 0.6172、wikipedia 0.5991; 冻结管线在扩展集 A2/A3 上未检出明显分布差异 (KS 的 p 值 0.313/0.220), 但没有人工质量真值, 故不报告准确率。评分之后的六来源分歧诊断在三集标出约 5% 的高分歧复核候选 (5.00%/4.73%/4.99%), 该比例来自预设的 P95 筛查预算, 不是真实冲突率, 诊断结果不回写主评分。17 域质量由映射与文本桥接补齐 (分层五折 $R^2 = 0.4106$, 六个映射域的 MAE 0.0365 但 $n = 6$)。配比以中心对数比稳健回归建模, 得到 17×13 的局部迁移结构; 在 1M 代理模型的信赖域内选出的推荐配比 $\mathbf{p}^*$, 其预测等权损失比均匀配比低 9.47% (bootstrap 中位数 9.54%、95% 区间 [7.82%, 11.16%]), 配比加权语料质量 $\bar{Q}(\mathbf{p}^*) = 0.6623836418229694$ 。域质量与训练边际价值的秩相关仅 -0.211, 说明单凭质量分不能代替配比实验。

针对问题二, 先在 B1 上估计经典基线 ($E = 1.6901$ 、 $A = 406.39$ 、 $\alpha = 0.34$ 、 $B = 410.59$ 、 $\beta = 0.28$), 再把质量写成可约损失上的幂次乘子、把不随规模消失的地板留在括号外: $L = E + k_0(1 - Q) + [AN^{-\alpha}Q^{-\kappa_N} + BD^{-\beta}Q^{-\kappa_D}] \exp(s_{\text{red}}\tilde{\varphi}(\mathbf{p}))$, 其中 $\kappa_N = 0.1416$ 、 $\kappa_D = 0.0112$ 、 $k_0 = 0.2280$ 、 $s_{\text{red}} = 1.4996207320397785$ 、 $Q_0 = 0.6623836418229694$ 。质量参数只用半合成的 B6 训练, B7 相对 B6 新增的 90 点作留出 (RMSE 0.0531, 高于同格噪声代理 0.0458 与交叉验证更优的线性对照 0.0416, 这是把质量写成「有效规模」的代价)。在主式下, 参照点上质量弹性约为参数弹性的 1.62 倍 (约 73% 来自地板); 固定 $D = 3 \times 10^{11}$ 时质量提高 0.1 需把参数扩大为原来的 1.299 倍 ($N = 10^9$) 至约 3.07 倍 ($N = 10^{11}$); 沿算力前沿,

Q 由 0.7 升到 0.8 相当于算力乘 1.191/1.485/2.134 ($C = 10^{19}/10^{22}/10^{24}$ FLOPs, 无地板时恒为 1.165)。 $C = 10^{19}$ 时是否提质取决于提质成本函数的形式, 自 $C = 10^{20}$ 起三种成本函数下提质都比扩参数下降更多损失。 配比通道受 1M 单一尺度的限制, 只作探索性通道, 并以两个零新增参数的强度假设给出下界与上界。

针对问题三, 把训练、提质与注意力三项成本放入同一预算, 利用三项成本对 D 的线性结构把预算约束取等并解析消元, 使问题降为 $(\log_{10} N, Q)$ 的二维有界优化; 以最优解处质量约束的活跃状态定义结构性转移, 并在固定 Q 的意义下给出局部一阶必要条件 (已做单点有限差分核验, 相对误差约 4.1×10^{-10})。 与预算、成本函数和规模都无关的解析结论是上下文长度的临界值 $L_{ctx}^{crit} = 6/\eta = 30000$ token。 数值上, $C = 10^{19}$ 时指数型与幂函数型成本下最优质量停留在下界 (不提质), 对数型成本函数的提质边际成本远低于前两者 (凹、随 Q 递减) 而直接提满; 到 $C = 10^{22}, 10^{24}$ 三种成本函数下均提满 $Q^* = 1$ 。 $L_{ctx} = 2048$ 下离开下界的临界预算 ($\log_{10} C$) 约为 19.06 (指数型)、19.53 (幂函数型)、18.58 (对数型), 说明“提质是否划算”存在随成本函数形状移动的预算阈值。

针对问题四, 用「标度律 + S 形桥接 + 连续时间项」的结构模型解释开源能力前沿的增长: 先把 C6 的损失—得分关系按可比性分层拟合成 S 形桥接, 再以问题二标度律给出的规模状态为自变量、加入连续时间项, 用双顺序 Shapley 分解把前沿增量分为规模贡献与技术贡献。 在主窗口 2023.50 $\rightarrow$ 2025.00, base 前沿观测变化 24.759 分, 模型解释的规模贡献 23.063、技术贡献 3.404, 技术占比 12.86% (90% 区间 6.07%–21.96%); 线性对照口径的技术占比为 29.5%–48.5%, 三口径极差 32.81 个百分点, 故结论只表述为「规模扩张为主、非规模技术进步约 13%–23% (结构口径)」, 且占比的分母是模型解释增量而非观测增量。 能力口径上, 剔除饱和和任务后的去饱和综合分在 2024-06 至 2025-03 由 26.36 升至 39.06 (+48.19%), 高于含饱和任务的 Average (+29.53%)。 在算力增速由 0.60 降至 0.15 dex/yr 的情景下, 以 $T_0 = 2026.75$ (现在) 为起点的 24 个月 base 前沿中位数为 49.38, 技术进步的增量占比由 63.07% 升至 77.88%。 因数据截止 **2025-03**, **2026-09** 的起点状态本身为约 1.5 年的模型外推, 且预测区间未单独传播 C6 桥接的迁移误差, 故属条件情景预测而非已验收的全链条区间。

四问共同指向一个判断: 数据质量与领域配比是与算力并列的一等资源——低预算段的边际价值主要体现在模型规模上, 预算跨过质量收益与提质开销的平衡点后, 提质与配比优化的优先级上升; 而算力增长放缓时, 能力增长将越来越依赖非规模技术进步。 本文所有定量结论的适用范围 (半合成数据、探索性配比通道、问题四预测含数据缺口外推与未传播的桥接误差) 已在 7.2 逐条写明。

关键词: 数据质量; 领域配比; 广义标度律; 算力约束优化; 能力演进预测

1 问题重述

1.1 问题背景

大语言模型的预训练能力随模型参数量 N (个) 与训练 token 数 D (token) 增长, 经典标度律以验证集交叉熵损失 $L_0(N, D) = E + AN^{-\alpha} + BD^{-\beta}$ 描述这一过程 [1, 2]。按本题采用的近似, 基础训练开销约为 $C \approx 6ND$ (FLOPs), 在有限预算下必须权衡模型规模与数据量。仅比较 N, D, C 不足以描述真实训练: 语料质量与领域组成会改变同等投入的效果, 因此需要先建立数据质量 Q 的可比口径与领域配比 $\mathbf{p}$ 的损失关系, 再把二者接入经典标度律, 形成 $L(N, D, Q, \mathbf{p})$, 最终落到算力约束下的资源配置与能力演进判断上。附件 A 提供质量信号与配比实验, 附件 B 提供标度律数据, 附件 C 提供模型、算力与能力评测信息。

1.2 问题描述

本题依次要求完成四项数学任务, 前一问的输出是后一问的输入。

问题一: 数据质量与领域配比。建模对象是文档、领域与混合语料的质量, 以及 17 个训练领域配比对 13 个验证域损失的影响; 约束是质量信号方向与量纲不一、11 个配比域缺少直接质量映射, 且配比份额非负、总和为 1。用 A1 (51,230 篇) 拟合文档质量口径与全部预处理参数, 冻结后在扩展集 A2 (arxiv 17,523 篇)、A3 (github 203,752 篇) 上检验评分与冲突诊断的稳定性; 用 A16 的映射与 A18 的文本特征把质量扩展到 17 域; A4/A5 按 index 连接作 1M 配比训练, A6/A7 作 1M 留出, A8/A9 作 60M 直接检验与尺度修正标定, A10/A11 (各 64 行) 作 1B 独立检验, A12–A15 只作估算/外推情景讨论。

问题二: 广义标度律。建模对象是损失对 $N, D, Q, \mathbf{p}$ 的依赖; 约束是理想质量与参照配比下须退回经典式, 且 A、B 两组损失的评测管线与质量尺度不能直接等同。以 B1 估计经典基线, B6 (360 点, 半合成) 估计质量项并选择模型, B7 相对 B6 新增的 90 点 ($Q = 0.5, 0.7$, 覆盖全部 45 个 (N, D) 格) 作留出; B2、B3、B4、B5、B8、B9、B10 分别作半合成、插值、跨族、文献、方向冲突与估算对照, B11/B12 作来源审计。问题一的域质量与配比关系经固定接口引入。

问题三: 算力约束下的资源配置。建模对象是给定预算 C (FLOPs) 与上下文长度 L_{ctx} (token) 下的 N, D, Q ; 约束包括训练、提质与长上下文三项成本, 质量下界由问题一推荐配比确定, 主方案固定该配比。读取问题一的质量与配比接口、问题二冻结的标度律参数, 不在本问重新拟合; C7 提供上下文长度的可行档位。

问题四: Benchmark 检验与能力演进。建模对象是开放权重模型的能力前沿及其规模与非规模来源; 约束是能力、时间、模型类型与开放权重口径必须一致, 且损失与 Benchmark 得分不在同一尺度。C1/C2 提供榜单能力与发布日期, C4 补充规模与算力, C8 用于逐任务聚合与饱和度检查, C6 分层拟合损失到得分的桥接, C3 只作混合口径的敏感性对照。

2 问题分析

2.1 总体思路

四问按”测量数据—描述损失—优化训练—解释能力”递进：问题一从文档质量 $Q(x)$ 聚合到领域质量 Q_i ，再按配比得到语料质量 $Q(\mathbf{p})$ ；问题二在 $L_0(N, D)$ 上引入质量与配比，经典律是广义律在 $Q = 1, \mathbf{p} = \mathbf{p}_{\text{ref}}$ 时的切片；问题三以标度律为目标，加入预算、提质与注意力成本约束求最优配置；问题四引入时间与 Benchmark 度量，把损失变化转成能力前沿的解释与条件预测。各问的冻结结果通过 P1-P4 接口传递，未通过留出检验的配比通道不进入下游主优化。四问的参数、约束与接口传递关系在 5.1 的接口约定与 5.2-5.5 各问的模型建立中逐条说明。

2.2 各问题的关键难点

问题一：从异质指标得到唯一语料质量。难点在于 logits、规则量与 DSIR 的方向和尺度不一，长度与领域基线会干扰质量判断，17 域又有 11 域缺少直接评分。为避免冗余信号重复计权、避免单项极端指标支配整篇分数，采用 A1 冻结的域内预处理、CRITIC 权重与 Huber 中心；冲突只在评分之后按来源诊断，不反向改分。领域质量以映射加文本桥接补齐，配比因份额闭约束采用中心对数比建模，并以 A6-A11 检查跨尺度边界。

问题二：跨附件质量口径与可推广的函数形式。A、B 两组损失的分词器与验证集可能不同，绝对值不能直接对齐，因此质量项只作用在 B1 骨架的可约部分上。质量乘子的形状（幂次、指数、线性）不能事先指定，故在同一骨架上比较 M0-M4 与有无地板的嵌套族，用 B6 训练、B7 新增点留出。主式指定为幂次，是为把质量写成有效规模；交叉验证更优的线性对照一并报告，其代价写清。配比效应只有 1M 数据，无法识别其随规模的斜率，故不估计尺度项，只设两个零新增参数的强度假设，再用 A6-A11 的观测校准斜率做事后比较。

问题三：非线性约束与边界转移。三项成本都与 D 成正比，而损失对 D 严格递减，故预算取等，可解析消去 D ，把问题降为 $(\log_{10} N, Q)$ 的二维有界优化。质量约束是否活跃构成质量状态的边界分类，其变化即”最优策略的质变”。三种提质成本函数的水平与边际曲率都不同，单个成本项凸不保证联合优化凸，故须保留独立粗网格核对，并区分局部一阶根与全局状态切换。

问题四：能力演进的解释边界。难点是 Loss 与 Benchmark 得分尺度不同、任务会饱和、规模与时间共变、C3 口径混杂。故采用可检验的 S 形损失—得分桥接与连续时间项，在一致的开放权重与模型类型口径下分解增长，并做窗口敏感性与回测。时间项只表示控制规模状态后的剩余关联，不解释为已识别的因果技术进步。

2.3 数据使用与证据分层

各附件的角色与证据性质见表 1。表中”角色”以对应 Spec 为准，不自行升格或降格。

表 1 附件角色与证据性质（引自各问 Spec，非数据产物）

附件	内容	角色	证据性质
A1	七域质量信号抽样 51,230 篇	拟合与标准化参照（唯一）	真实
A2 / A3	arxiv 17,523 / github 203,752 篇	冻结评分与诊断的扩展检验	真实
A4 / A5	1M 配比与 13 域 Loss 各 512 组	配比主模型训练（唯一）	真实
A6 / A7	1M 配比与 Loss 各 256 组	同尺度留出	真实
A8 / A9	60M 配比与 Loss 各 256 组	跨尺度直接检验 + 尺度修正标定	真实
A10 / A11	1B 配比与 Loss 各 64 组	独立检验，不参与任何估计	真实
A12 - A15	10B/70B 配比（各 63 组）与 Loss	估算/外推情景对照	子集 / 外推，非观测
A16	17 域 $\rightarrow$ 7 质量域映射	映射参照	人工整理
A17	域统计摘要	背景与辅助	真实，未接入求解
A18	17 域原始文本 138,034 条（本轮有效 31,340 篇用于桥接预测）	桥接预测输入	真实
B1	Pythia 训练轨迹 1,176 行	经典基线拟合	真实（损失按公开公式生成，见审计）
B2	Cerebras 轨迹 1,029 行	族外趋势对照	半合成
B3	插值轨迹 4,000 行	轨迹对照	插值（B1 派生）
B4 / B5	跨族基准 57 行 / 文献点 44 行	外部趋势对照（ $Q = 1$ ）	真实 / 文献整理
B6	NQ 质量网格 360 行	质量项参数估计（唯一）	半合成
B7	扩展网格 450 行（新增 90 点）	留出检验	半合成， Q 方向插值
B8	大规模矩阵 1,704 行	方向冲突压力检查	半合成，与 B6/B7 方向相反
B9 / B10	100B+ 配置 132 行 / 预估 Loss 128 行	外推参照	真实元数据 / 估算
B11 / B12	模型族元数据 / Pythia 检查点索引	来源审计	真实
C1 / C2	榜单 4,576 行 + Epoch 匹配列	能力与发布日期	真实（同批榜单，非两套样本）
C3	历史时序 4,599 行	降权敏感性	混合口径
C4	全量模型元数据 3,523 行	规模、算力、开放权重	真实
C5 / C6	桥接表 43 / 75 行	损失—得分映射	混合口径，分层使用
C7	架构元数据 45 行	上下文长度档位	真实
C8	逐任务 JSON 1,958 个	逐任务聚合与饱和度	真实

3 模型假设

1. 质量信号可作相对测量。A 组指标经方向与域内尺度校正后可比较同域文档的相对质量，不假定存在人工标注的绝对真值。服务问题一的 $Q(x)$ ；以 A2/A3 冻结评分与删去极端指标的扰动检查适用性。2. 领域质量可按份额聚合。给定 A16 映射与桥接模型，混合语料质量取 17 域质量的份额加权值 $Q(\mathbf{p}) = \sum_i p_i Q_i$ ；配比对验证损失的额外影响单独建模。服务问题一至三；以六个可映射域的桥接误差、A6/A7 留出与 A8–A11 检验检查边界。3. 评价目标预先固定。13 个验证域等权定义主目标，pile_cc 单域只作敏感性口径，评价权

重不随候选配比改变。服务问题一配比搜索与问题三目标选择。4. 质量刻度需要锚定。主口径取 $Q_B = Q(\mathbf{p})$ ，推荐配比处 $Q_0 = Q(\mathbf{p}^*) = 0.6623836418229694$ ； $Q = 1$ 且 $\mathbf{p} = \mathbf{p}_{\text{ref}}$ (A4 训练配比均值) 时广义式退回经典式。副映射 $Q_B = Q(\mathbf{p})/Q_0$ 会使部分领域超出 $[0, 1]$ ，只作敏感性且不静默截断。服务问题二、三。5. 成本按同一训练量计。训练、提质与注意力开销均以同一 D 计量，成本函数参数依赛题给定； $\eta = 2 \times 10^{-4}$ 为题设值。服务问题三；不预设三种成本函数下解的性质相同。6. 非规模变化在窗口内平滑。问题四用连续时间项描述控制规模状态后的剩余得分变化，并以不同窗口与模型回测；遇到离散架构突破时该条件预测不适用。

4 符号说明

表 2 主要符号及含义（含单位与角色）

符号	含义	单位	角色
N, D	模型参数量、训练 token 数	个, token	Q1/Q2 输入; Q3 决策变量
C	总训练算力预算	FLOPs	给定参数 (Q3)
$Q(x), Q_i$	文档主质量分、训练域 i 质量分	$[0, 1]$	估计量 (Q1)
$Q(\mathbf{p}), Q_B$	混合语料质量、B 组质量刻度; 主口径二者相同	无量纲	Q1 输出、Q2 输入
Q_0	推荐配比下的提质起点, 0.6623836418229694	无量纲	接口参数 (Q2/Q3)
$\mathbf{p} = (p_i)_{i=1}^{17}$	17 域训练份额, 非负且总和为 1	无量纲	决策变量 (Q1)
$z_j(x), w_j$	第 j 项标准化指标、冻结的 CRITIC 权重	$[0, 1]$ / 无量纲	数据变换、估计参数
δ	Huber 中心阈值, 0.4034907036619329	$[0, 1]$	由 A1 确定的尺度规则
$B(x), u_s(x)$	六来源分歧度、来源 s 的 A1 参照分位	$[0, 1]$	诊断量
L_v, L	验证域 v 的损失、等权综合损失	nats	观测量或预测目标
T_{iv}	均匀配比附近域 i 份额对域 v 对数损失的局部效应	无量纲	估计参数 (Q1)
E, A, B, α, β	经典标度律地板、幅度与指数	依公式	估计参数 (Q2, B1)
k_0, κ_N, κ_D	质量地板系数与两项质量幂次	nats, 无量纲	估计参数 (Q2, B6)
h_N, h_D	主式质量乘子 $Q^{-\kappa_N}, Q^{-\kappa_D}$	无量纲	函数 (Q2)
$s_{\text{red}}, \tilde{\varphi}(\mathbf{p})$	配比强度 (1M 训练定为 1.4996207320397785)、配比偏离	无量纲	参数与由 Q1 给定的量
m_*	固定 $\mathbf{p}^*$ 的配比乘子 $\exp\{s_{\text{red}} \tilde{\varphi}(\mathbf{p}^*)\} \approx 0.8989423$	无量纲	Q3 的给定常数
$g(Q), L_{\text{ctx}}, \eta$	单位 token 提质成本、上下文长度、注意力成本系数 2×10^{-4}	FLOPs/token, token, —	给定函数与情景参数
S, t	Benchmark 综合得分、模型发布日期	分, 年	响应量、时间变量 (Q4)
$L_{\text{ctx}}^{\text{crit}}$	注意力与训练成本相等的上下文长度, $6/\eta = 30000$	token	解析结论

局部符号在首次出现处说明。

5 模型的建立与求解

5.1 数据来源与接口约定

正文只使用三组附件的既有编号 (A1 – A18、B1 – B12、C1 – C10) , 单位纪律如下: N_params_B、D_tokens_B 的单位均为 10^9 , 代入 $C = 6ND$ 时须乘 10^{18} ; C_FLOPs_1e21 的单位为 10^{21} FLOPs, 不得直接代入绝对预算 C 。跨问只传递已定义的质量分、配比与模型参数: 问题一输出 src/outputs_q1/interface/ 下的 P1_Q_domain.csv、P1_p_star.csv、P1_summary.json、P1_scale_calibration.csv 等; 问题二输出 src/outputs_q2/interface/P2_scaling_law.json 等; 问题三、问题四分别输出 P3_*、P4_*。下游不读缓存文件。推理过程见 src/code_q1/q1_00_common.py 等脚本的路径解析 (附件目录优先仓库根目录附件/)。

5.2 问题一的模型建立与求解

本问按 sec5_q1.tex 的三项任务组织: 任务一建立唯一的文档与领域质量口径; 任务二在评分之后诊断指标与来源之间的分歧; 任务三把质量桥接到 17 个训练域、建立配比一损失模型并选出推荐配比, 输出 P1 接口。三项共用同一套冻结参数, 任务一与任务二的产物进入任务三与后续问题。

5.2.1 任务一: 数据质量评估

A1 的 22 个原始字段按输出形态展开为 25 项: 4 个 modernbert_* 六档 logits 各取 softmax 后的期望分; qurater 拆为四维; ad_en、fluency_en 取标签 1 的概率 (ad_en 的标签 1 表示无广告); fineweb_edu 取单元素值; 3 个 DSIR 与 11 个 rps_* 取原标量。词数、句数、平均词长与词熵按 A1 域内中位数转为适宜区间型 $-|h_j(x) - m_{dj}|$; 正向指标保留、负向指标取负; 重尾非负值按规则取 $\log(1 + x)$ 。三个 DSIR 分量先除以 $\max(\text{word_count}, 1)$, 再在 A1 各域内以 $\log(1 + \text{word_count})$ 拟合带截距 OLS 并使用残差; A2/A3 复用 A1 的回归系数。各域各指标用 A1 的 1%/99% 分位缩尾, 再按 A1 端点 Min-Max 归一到 $z_j(x) \in [0, 1]$, 缺失值用 A1 同域同指标标准化中位数填补。

长度校正的效果: A1 七域 $\times$ 三 DSIR 的词数 Spearman 绝对相关中位数由原量 0.957 降至除词数后的 0.599、再降至残差化后的 0.095, 逐项见 T2_dsir_length_diagnostic.csv。book 域剩余相关最高 ($|\rho| = 0.503$), 提示该域分数仍可能受长度影响。这是与长度混杂有关的测量假设, 不表示相关下降即去掉了无用信息。

唯一主质量口径: **CRITIC** 加权 **Huber** 中心。在 A1 的标准化矩阵上, 以 CRITIC 的离散度与指标间非冗余性确定固定权重 [3]:

$$C_j = s_j \sum_{k=1}^{25} (1 - r_{jk}), \quad w_j = \frac{C_j}{\sum_k C_k}, \quad \sum_j w_j = 1.$$

文档主质量分取加权 Huber 中心 [4]

$$Q(x) = \arg \min_{q \in [0, 1]} \sum_{j=1}^{25} w_j \rho_\delta(z_j(x) - q), \quad \rho_\delta(u) = \begin{cases} \frac{1}{2}u^2, & |u| \leq \delta, \\ \delta(|u| - \frac{1}{2}\delta), & |u| > \delta, \end{cases}$$

由导数方程 $\sum_j w_j \text{clip}(q - z_j, -\delta, \delta) = 0$ 在 $[0, 1]$ 上二分求解。 δ 只由 A1 确定：取每篇的加权指标中位数 m_x 、加权 MAD $a_x = \text{wmedian}_j |z_j - m_x|$ ，再取 $\delta = 1.345 \times 1.4826 \times \text{median}_{x \in A1} a_x$ ，得 $\delta = 0.4034907036619329$ （1.4826 为正态尺度校正，1.345 为经典 Huber 效率常数）。这是一条不依赖质量真值与下游损失、也不依赖冲突类型的 A1 尺度规则，A2/A3 复用同一数值。25 项 CRITIC 权重逐项见 T2_critic_weights.csv（最小 fineweb_edu 0.0359，最大 modernbert_professionalism 0.0671）， δ 的确定过程见 T2_delta_selection.csv。所有 A1 参数（方向、缩尾端点、Min-Max 端点、填补值、权重、 δ ）一经确定即冻结，A2/A3 只应用、不重估。

对照口径 $Q_{\text{mean}} = \sum_j w_j z_j$ （同权重算术均值）、PCA 与 TOPSIS 只用于方法一致性比较：A1 主分与三者的 Spearman 分别为 0.9936、0.8166、0.9588（T2_method_agreement.csv）。这些是方法一致性，不是独立质量标签验证。极端指标扰动：逐篇剔除距加权中位数最远的一个指标后，极端程度最高 10% 的文档（5,123 篇）中，主分的绝对变动中位数为 0.0260（P90 为 0.0340），算术均值为 0.0374（P90 为 0.0488），即主分对同一扰动的典型变动约小 30%（T2_extreme_influence.csv）。该实验只覆盖“删除最偏离一项”，不覆盖全部异常模式。

质量分求解。25 项标准化矩阵在 A1 上一次算出，然后在 A2/A3 上只做前向应用；主分按导数方程二分求根，权重与 δ 随之冻结。

求解设置与复现。问题一为纯 NumPy/Pandas 实现（不依赖 SciPy 或 scikit-learn），运行环境为 Python 3.12.13、NumPy 2.4.4、pandas 3.0.2；标准运行顺序为 q1_01_extract.py $\rightarrow$ q1_02_quality.py $\rightarrow$ q1_03_conflict.py、q1_04_bridge.py $\rightarrow$ q1_05_mixture.py $\rightarrow$ q1_06_scale.py、q1_07_optimal.py $\rightarrow$ q1_08_audit.py，本轮全链耗时约 5 分钟（其中桥接约 160 秒）。随机种子在质量评分、桥接、配比拟合与候选搜索中分别固定为 2026、42、2026、1234（另：A1 域内聚类子步用 42，冲突抽样子步用 0 与 7，来源一致性实验用 42）。关键求解参数：质量中心的导数二分固定 28 次；配比 Huber 回归以最小二乘初始化，标准化残差阈值 1.35，IRLS 最多 50 次、以最大系数变化小于 10^{-8} 停止；桥接按域分层五折、只在训练折估计特征标准化参数，GBDT 用深度 1 树桩与学习率 0.06，五折比较用 250 棵、最终拟合用 300 棵；配比对照的 GBDT 用五折交叉验证在 {学习率} $\times$ {树数} 网格上选参。以上参数与脚本路径见 src/code_q1/q1_00_common.py 及各 Step 脚本。树数与候选数是预设计算上限，不应误写为已证明的优化收敛。

主质量分与领域质量。A1 七个领域的 CRITIC 加权 Huber 主分中位数由高到低为：arxiv 0.7707、commoncrawl 0.6761、stackexchange 0.6600、c4 0.6545、book 0.6313、github 0.6172、wikipedia 0.5991（T2_domain_quality.csv，图 1）。图 1 显示七域主分的分布区间，可见 arxiv 与 wikipedia 的域内分布几乎不重叠，领域间差异大于多数域内差异，这是按域建尺度、再按域汇总的必要性依据。领域分取文档中位数，并以 2,000 次文档 bootstrap 给出条件区间；book 域仅 171 篇，域内细分比例须谨慎使用。




图1 A1 七个领域的CRITIC 加权 Huber 主分分布

扩展集的表现: A2 的 arxiv 中位数为 0.7697, 对应 A1 子集为 0.7707; A3 的 github 中位数为 0.6158, 对应 A1 子集为 0.6172; 两组 KS 检验的 p 值为 0.313 与 0.220 (T2_sampling_check.csv)。 p 值只能说明在冻结管线下未检出明显分布差异, 不能证明抽样完全无偏或分数具有独立准确性。

方法一致性与扰动稳健性: 主分与同权重算术均值、PCA、TOPSIS 的文档排序 Spearman 分别为 0.9936、0.8166、0.9588 (T2_method_agreement.csv); 删除最偏离一项指标后, 极端程度最高 10% 文档的主分绝对变动中位数为 0.0260、P90 为 0.0340, 算术均值对应为 0.0374 与 0.0488 (T2_extreme_influence.csv)。这些数值是 $[0, 1]$ 评分尺度上的绝对变动, 即 2.6 与 3.7 个百分点, 不是质量提升率; 对同一项极端指标扰动, Huber 的典型变动约小 30%, 这是把 Huber 中心作为主分的稳健性依据, 但仍不能替代人工质量标签。

检验与边界。本任务的结果分三层检查 (设计与结论汇总见 6.1): A2/A3 是冻结评分的扩展检验, KS 的 p 值只说明在冻结管线下未检出明显分布差异, 不等于抽样无偏或分数准确; 主分与算术均值、PCA、TOPSIS 的秩相关是方法一致性, 不是与人工标签的吻合度; 删除最偏离一项指标的扰动只覆盖一种异常模式。因此本任务不报告质量准确率, 只报告排序口径、稳健性与适用边界。

5.2.2 任务二: 质量指标冲突的诊断与消解

诊断在 5.2.1 的主分之后进行, 不参与 CRITIC 权重、Huber 中心、桥接标签或任何 P1 接口。按指标生成机制固定六个来源: RPS (11 项)、DSIR (3 项)、轻量分类器 (2 项)、FineWeb-Edu (1 项) [5]、QuRating (4 项)、ModernBERT (4 项), 每项指标恰好归属一处。对 A1 每个领域、每项指标保存标准化分的完整经验分布 F_{dj}^{A1} , 文档的指标排名取 $r_j(x) = F_{dj}^{A1, \text{mid}}(z_j(x))$ (同值取中秩); A2/A3 按对应领域查同一份冻结分布, 不重新排名、不重估阈值, 未见领域报错而不临时拟合。

来源中心 $m_s(x) = \text{median}_{j \in I_s} r_j(x)$ 经 A1 同域同来源的中心分布转成 $u_s(x)$, 六来源分歧度为

$$B(x) = \max_{s=1,\dots,6} u_s(x) - \min_{s=1,\dots,6} u_s(x).$$

阈值取 A1 每域 B 的第 95 百分位（同域同来源跨度与最大留一偏离同样取 P95），并报告 P90/P95/P97.5 与高低端立场 10%/20%/25% 的敏感性。第 95 百分位使 A1 每域约 5% 的文档入选，这是预先选定的筛查预算，不是真实冲突的发现率。仅当 B 超阈值、且高端（ $u_s \geq 0.8$ ）与低端（ $u_s \leq 0.2$ ）各有至少两个来源支持时，才记为“多来源对立候选”；仅一侧或多个来源不足时单列为稀疏来源对立。另用来源内跨度 $P_{90}(r_j) - P_{10}(r_j)$ 与逐指标留一中位数偏离 e_j 识别孤立指标，单独记为“单指标独有候选”，不与来源间候选相加。来源配对方向按每篇文档的高端 $\times$ 低端组合平均分配总权重 1。

诊断求解。诊断阶段对 A1 每域、每指标保存有序经验分布作为参照，对 A2/A3 查表排名；A1 固定随机抽样 8,000 篇计算各来源 Kendall W ；阈值取 A1 同域分位数，逐集逐域输出候选比例、重合度与方向份额。

六来源分歧诊断的结果。

表 3 三个数据集上的六来源诊断候选规模（数据源：T3_six_source_candidate_summary.csv）

候选类型	A1: 51,230 篇	A2: 17,523 篇	A3: 203,752 篇
来源间高分歧	2,561 (5.00%)	829 (4.73%)	10,167 (4.99%)
其中多来源对立	695 (1.36%)	277 (1.58%)	3,598 (1.77%)
其中稀疏来源对立	1,866 (3.64%)	552 (3.15%)	6,569 (3.22%)
单指标独有	2,879 (5.62%)	709 (4.05%)	8,606 (4.22%)

表中百分比的分母均为该数据集的全部文档数。A1 的约 5% 来自预设的 P95 筛查预算，不能称为测得的真实冲突率；多来源对立与稀疏来源对立互斥，单指标独有候选是另一类筛查，不与来源间候选相加为“总冲突率”。

来源内部一致性差异明显：A1 的 Kendall W 依次为 RPS 0.140、DSIR 0.967、轻量分类器 0.691、QuRating 0.675、ModernBERT 0.579，FineWeb-Edu 只有一项指标故不定义；A1 文档内指标排名 $P_{90} - P_{10}$ 的中位数 RPS 为 0.625，DSIR 为 0.037，QuRating 为 0.277，ModernBERT 为 0.315；A1 有 69.45% 的文档在 RPS 内部同时存在低于 20% 与高于 80% 的指标（T3_six_source_consistency.csv、T3_source_internal.csv，图 17）。图 17 显示六来源内部跨度的量级差异，说明同一“规则型”来源内部就可能给出相反意见，因此把 11 项 RPS 压成一个中位数会掩盖意见分裂。这表示不同规则统计量给出相反的相对排序，不能直接判为测量错误或真实质量矛盾。

来源间的对立方向：A1 与 A3 的最高加权方向均为“RPS 高 $\times$ FineWeb-Edu 低”，份额为 8.03% 与 13.03%；A2 为“ModernBERT 高 $\times$ FineWeb-Edu 低”，9.89%（分母均为该集的六来源高分歧候选，且每篇文档的来源对总权重为 1，T3_source_opposition_pairs.csv，图 18）。映回旧四组时，原“模型评分器”组内部的新方向在三集占 4.44%、19.33%、3.68%（T3_direction_stability.csv），即旧的四组口径无法显示这一类来源之间的分歧。

阈值与旧法对照：固定高低端立场为两端 20% 时，A1 的 B 阈值取 P90/P95/P97.5 对应候选比例约 10.00%/5.00%/2.50%，A2 为 9.19%/4.73%/2.00%，A3 为 9.74%/4.99%/2.44%

(T3_threshold_sensitivity.csv, 图 19)。历史四组口径的候选比例为 19.08%/24.52%/23.28%，与六来源候选集合的 Jaccard 为 0.188/0.130/0.155；按 A1 各域前 5% 配平预算后旧四组选出 5.00%/4.42%/4.78%，Jaccard 提高至 0.324/0.283/0.259、Kappa 为 0.463/0.415/0.381 (T3_legacy_stability.csv, 图 20、图 21)。Kappa 不是准确率；历史阈值与新 P95 的选择预算不同，这组重合度不能单独解释为分组效果。

来源一致性折扣对照模型：题目要求冲突消解「建立相应的综合评价模型」，本文的回应分两层——主口径在评分后只诊断、不改分，诊断层产物不回写主分；在此之上建立一个折扣对照模型 Q_{v2} 。其数学本质即 Dempster-Shafer 证据理论的可靠性折扣 (discounting) [12]：每个来源对文档质量的指标意见视为一条证据，以各来源 Kendall W 作该来源证据的折扣系数，将原 CRITIC 权重调整为 $\tilde{w}_j = w_j \cdot W_{s(j)}$ 后再归一化合成 (其余环节不变)。得到的折扣分 Q_{v2} 与主分在 A1/A2/A3 的全局 Spearman 为 0.9547/0.9207/0.9395，A1 七域的中位数排序与主分完全一致 (T3_Q_v2_summary.csv、T3_Q_v2_weight_comparison.csv, 图 22)。Spearman 只衡量排序相似度，不是 Q_{v2} 更准确的证据；该对照模型不替换主质量口径，也不写入任何 P1 接口。

检验与边界。三集复现的是诊断结构而不是逐篇冲突类型：候选比例稳定 (5.00%/4.73%/4.99%)，但最高加权对立方向在 A2 与 A1/A3 不同；Jaccard 与 Kappa 只用于比较两套候选集合的重合度 (**Kappa** 不是准确率)；阈值敏感性反映的是人工复核工作量的变化。诊断层产物不参与 CRITIC 权重、Huber 中心、桥接标签或任何 P1 接口，筛查预算也不解释为真实冲突率。

5.2.3 任务三：领域配比、语料质量与损失

桥接到 17 个配比域。A16 的 17 个配比域中 3 个为 direct、3 个为 near_direct、11 个为 inferred。对 11 个无直接质量信号的域，从 A1/A18 原文各自复算 11 项同名近似规则特征 $\Phi(\text{text})$ (不保证逐位复现附件 rps_*)。在 A1 的 21,590 篇原文上以 5.2.1 的同一 $Q(x)$ 为标签，按领域分层五折比较 Ridge 与 GBDT (每折的特征均值与标准差仅用训练折估计，避免折间泄漏)，选较优者对 A18 的 31,340 篇预测并逐域聚合。六个 direct/near_direct 映射域的 Q_{final} 取对应 A1 质量域主分中位数， $CI_{\text{lo/hi}}$ 同取该 A1 域主分 bootstrap；11 个 inferred 域取 A18 预测中位数与文档 bootstrap。 Q_{tokenw} 按最终来源取值。语料质量按份额聚合：

$$Q(\mathbf{p}) = \sum_{i=1}^{17} p_i Q_i, \quad p_i \geq 0, \quad \sum_i p_i = 1.$$

桥接模型的五折表现与六个映射域的一致性见本小节下文；区间口径与点估计必须同源，不能用 A1 点估计配 A18 预测区间，17 域逐行断言点估计落在同源区间内。

桥接求解。A1 的 21,590 篇按域分层五折，折内标准化参数只用训练折估计；五折比较 Ridge 与 GBDT 后取较优者用全部训练子集拟合，再对 A18 的 31,340 篇预测并逐域取中位数与文档 bootstrap 区间。

从文档质量到 17 域质量。桥接模型在 A1 上的分层五折 R^2 均值为 0.4106 (Ridge 为 0.3415, T4_calibration_cv.csv)；六个可映射域的预测与 A1 主分的 Pearson 为 0.6571、Spearman 为 0.7714、MAE 为 0.0365，但 $n = 6$ (T4_bridge_validation.csv)。17 域 Q_{final} 最高为 arxiv 0.7707、最低为 dm_mathematics 0.5087 (T4_bridge_17domains.csv, 图 2)。图 2 显示 17 个域的质量分与按来源构造的条件区间，六个 direct/near_direct 域的点估计与

区间同取 A1 主分，11 个 inferred 域取 A18 预测中位数与文档 bootstrap。使用边界有三条：映射域区间以 A16 映射成立为条件，尤其不覆盖 near_direct 的映射偏差；inferred 区间只反映给定桥接模型下的文档抽样变动，不涵盖模型选择与跨域偏差；ubuntu_irc（16 篇）与 philpapers（63 篇）须低置信使用。桥接 R^2 与六域一致性都不是独立质量准确率。




图 2 17 个配比域的质量分与条件区间

配比—损失模型与迁移结构。 A4/A5 按 index 连接后作 1M 配比训练集（非正份额替换为 10^{-4} 并重新闭合）。配比份额受闭约束，直接回归会有闭合效应，故作中心对数比变换

$$\xi_i(\mathbf{p}) = \log p_i - \frac{1}{17} \sum_{k=1}^{17} \log p_k, \quad \log L_v = b_v + \sum_{i=1}^{17} \beta_{vi} \xi_i(\mathbf{p}) + \varepsilon_v,$$

对 13 个验证域分别拟合 Huber 回归 [6, 7]，这是唯一主模型；原始份额 OLS 检验变换的作用，深度 1 的树桩 GBDT 检验线性形式是否漏掉重要非线性。在均匀配比处把系数投影到单纯形切空间，得 17×13 迁移矩阵 $T_{iv} = 17(\beta_{vi} - \bar{\beta}_v)$ ，其中 $\bar{\beta}_v = 17^{-1} \sum_i \beta_{vi}$ 。另拟合质量交互项 $\lambda_v \sum_i p_i(1 - Q_{i,\text{final}})$ ，用 400 次案例 bootstrap 给区间并在 A6/A7 检查预测。

GBDT 的树数与学习率只在 A4/A5 内部用五折交叉验证选定：折号由固定种子随机置换得到，网格为学习率 $\{0.03, 0.06, 0.12, 0.25\} \times$ 树数 $\{100, 250, 500, 1000\}$ ，准则为 13 域留折 $\ln L$ RMSE 的均值，选定后用全部 512 组重拟合；A6–A11 不参与选参。GBDT 在 A4/A5 上按等权 Loss 另选一个 $\mathbf{p}^*$ 作交叉评估，用于检验线性模型的最优配比是否稳健，不作主模型（理由是可解释性与接口一致性，而非预测更差）。

配比与跨尺度求解。 clr+Huber 回归对 13 个验证域分别拟合；迁移矩阵由 clr 链式法则折算到单纯形切空间；GBDT 选参只在 A4/A5 内部完成。尺度修正的 ρ_v 与效应缩放参数（幂律 λ 为主口径，对数线性 κ 为对照）由 A4/A5 与 A8/A9（60M）标定确定；A10/A11

(1B) 不参与估计、形式选择或阈值调整，只用于独立检验。A12–A15 仅作估算/外推对照，不作为观测检验。

配比—损失关系与迁移结构。在 A6/A7 的 1M 留出 (256 组) 上, 13 域平均逐域 R^2 为 clr+Huber 0.772、原始份额 OLS 0.654、GBDT (选参后) 0.923; 目标 Spearman 为 GBDT 0.942、线性 0.523; 但 13 域等权目标 R^2 上裸 OLS 的 0.418 高于 clr+Huber 的 0.260 (T5_model_comparison.csv)。因此本文保留 clr+Huber 解释局部迁移效应, 同时以留出目标表现更好的 GBDT 作交叉评估, 不声称 **clr** 在所有目标上都更优。GBDT 的五折选参结果为 1,000 棵、学习率 0.12, 留折 $\ln L$ RMSE 为 0.0421; 学习率 0.25 在 500 棵时为 0.0422、到 1,000 棵回升至 0.0426, 说明最优点在网络内部, 且最优点附近曲线很平 (T5_gbd_t_cv.csv)。质量交互项在 13 域中仅 6 域的系数区间不含零, 且系数有正有负, 只能说明质量与配比损失存在混杂关联, 不构成质量因果效应 (T5_lambda_interaction.csv)。17×13 迁移矩阵的各域主对角元均为负 (T5_transfer_matrix.csv, 图 3), 图 3 显示各验证域对训练域份额的局部敏感度结构。




图 3 17 × 13 迁移矩阵: 各验证域对训练域份额的局部敏感度

跨尺度检验与尺度修正。冻结检验: 在 A4/A5 上拟合后冻结线性模型与 GBDT, 直接预测 1M 留出、60M 与 1B, 报告绝对误差与排序。尺度修正保持 1M 配比系数 β_v^{1M} 不变, 记 $g_v(\mathbf{p}) = \beta_v^{1M} \cdot \text{clr}(\mathbf{p})$ 、 $t = \ln(N/10^6)$:

$$\ln L_v(\mathbf{p}, N) = \underbrace{b_v^{1M} + \rho_v t}_{\text{截距漂移}} + \underbrace{s(N)}_{\text{效应缩放}} g_v(\mathbf{p}), \quad s(N) = (N/10^6)^{-\lambda} \text{ (主口径)}, \quad 1 + \kappa t \text{ (对照)}.$$

b_v^{1M} 与 $s(10^6) = 1$ 来自 A4/A5；在 A8/A9 (60M) 上求汇总斜率 $s(60M) = \sum_v \text{cov}(y_v, g_v) / \sum_v \text{var}(g_v)$ 与逐域截距 $b_v(60M) = \bar{y}_v - s(60M)\bar{g}_v$ ，由两点闭式得到 13 个 ρ_v 与 1 个共同缩放参数（幂律 $\lambda = -\ln s(60M)/t_{60}$ ；对数线性 $\kappa = (s(60M) - 1)/t_{60}$ ），两形式估计自由度相同（13 + 1）。幂律形式是先验选定的：标度律文献中规模依赖性以 N 的幂律进入（Chinchilla 的 $L = E + AN^{-\alpha}$ ；Data Mixing Laws 的嵌套管线正是把配比律系数按规模幂律外推），而 $1 + \kappa t$ 是 $\ln N$ 的线性函数、不是幂律，且 $\kappa < 0$ 时在 $N \geq 10^{26}$ 变负，结构上不适合外推；幂律形式保持 $s > 0$ 、单调、渐近为 0，对应配比效应随规模衰减至消失而非反号。截距漂移不加曲率项：两档规模下曲率参数欠定，且带不可约底的形式与冻结 1M 模型的乘法结构 $L = e^{b_v + g_v}$ 不兼容。主/对照归属按先登记、后检验的规则决定：幂律在 1B 的逐域 MAE 均值更低且排序指标不退化，则幂律为主口径，否则回退对数线性（Q1 Spec v9 登记于查看新形式 1B 结果之前）。**A10/A11 (1B, 各 64 行)** 不参与任何估计，只用于比较冻结模型、仅截距修正与两种截距加缩放修正口径；另报“1B 同集拟合”作为该函数形式的误差下界参照，不作结论。估算表 A12–A15 是 10B/70B 的估算或外推 Loss，与冻结模型、尺度修正模型和同配比 1M 实测 Loss 并列对照，不是观测。

本项还存在需登记的数据角色边界：赛题将 A6–A11 统称为检验数据，而 v7 方案使用 A8/A9 估计尺度修正参数；这与仓库对留出和独立检验数据不得参与参数估计的通用约束存在文字张力。因此本文只把 A8/A9 称为尺度修正的标定集，不能把其修正后表现称为独立检验；A10/A11 是该修正唯一未参与估计的尺度检验集。该口径仍需按项目约定核查，1B 检验本身不消除这一规范边界。**【待核：A8/A9 标定与项目级留出约束的适用边界】**

跨尺度检验的结果。冻结 1M 模型的等权目标 Spearman 在 1M 留出/60M/1B 上为线性 0.523/0.467/0.677、GBDT 0.942/0.905/0.761；GBDT 的目标 MAE 为 0.078/1.466/2.713 (T6_cross_scale_validation.csv、T6_gbd_t_cross_scale.csv, 图 4)。图 4 显示冻结模型在三档规模上的排序保持度：排序信息基本保持，但 60M/1B 的绝对 Loss 有大幅平移 (R^2 为负)，排序部分保持不等于损失水平可直接迁移。1B 只有 64 组，Spearman 的抽样误差约 ± 0.1 ，GBDT 在 1B 的领先幅度只能算中等证据。




图 4 冻结 1M 配比模型在 1M 留出、60M 与 1B 上的排序保持度

尺度修正由 1M 训练与 60M 标定给出 $s(60M) = 0.9132$ ；幂律 $\lambda = 0.0222$ （主口径）、对数线性 $\kappa = -0.0212$ （对照），外推到 1B 分别为 $s(1B) = 0.858$ 与 0.854 (T6_scale_correction_params.csv, 图 5)。




图 5 尺度修正前后的绝对 Loss 对照 (1M + 60M 标定，1B 独立检验；幂律为主口径，对数线性为对照)

表 4 给出 1B 独立检验 (A10/A11, 各 64 组, 不参与任何估计) 的结果 (数据源: T6_scale_correction.csv)

1B 口径	逐域 MAE 均值	目标 MAE	逐域 R^2 均值	目标 Spearman	平均预测 Loss
冻结 1M	2.9525	2.9525	-604.7	0.677	5.178
仅截距修正	0.7699	0.7684	-33.4	0.712	2.994
截距 + 缩放修正 (幂律, 主口径)	0.7711	0.7708	-35.2	0.713	2.996
截距 + 缩放修正 (对数线性, 对照)	0.7714	0.7712	-35.3	0.713	2.997
1B 同集拟合 (误差下界参照, 不作结论)	0.0819	0.0287	0.624	0.702	2.222

1B 的观测平均 Loss 为 2.226。按先登记的判定规则, 幂律形式 1B 逐域 MAE 均值 0.7711 低于对数线性的 0.7714、目标 Spearman 同为 0.7127 不退化, 故幂律为主口径; 改善幅度 0.0003 远低于 64 组样本的抽样噪声, 采用依据同等在于幂律形式恒正、不反号、与标度律文献一致的结构合理性, 不把这 0.0003 读作预测更准的证据。由此得到三条结论: 方向对、幅度不足——修正把 1B 绝对误差降低约 74% ($2.95 \rightarrow 0.77$), 但平均预测约 3.00 仍明显高于观测 2.23, 1M $\rightarrow$ 60M 每单位 $\ln N$ 的 Loss 降幅约 0.08、60M $\rightarrow$ 1B 段约 0.19, 无论对数线性还是幂律, 单参数缩放形式的两档外推都无法捕捉该曲率, 而曲率参数在两档数据下欠定; 效应缩放的外推偏差更大 (预测 $s(1B) = 0.858$ (幂律) / 0.854 (对数线性), 同集拟合为 0.612, 两种单参数形式都预测不到效应衰减的加速, 加缩放项对 MAE 没有帮助, 该 0.612 由独立检验集同集拟合得到, 只能作为诊断, 不回填模型或供下游使用); 误差来源是水平外推而非配比结构 (同一函数形式直接在 1B 上拟合时 MAE 仅 0.08)。在 60M 标定集上 (同集, 不作检验), 修正把逐域 MAE 从 1.490 降到 0.206 (仅截距) / 0.208 (截距 + 缩放, 两形式按构造相同)。

跨尺度校准接口 (仅评估) : 冻结 1M 系数的汇总斜率在 1M 训练/1M 留出/60M/1B 上为 1.004/0.995/0.913/0.612, 观测平均 Loss 为 5.345/5.282/3.823/2.226 (interface/P1_scale_calibration.csv, T6_scale_correction.csv)。冻结 1M 配比系数在 A10/A11 上的描述性汇总斜率为 0.612; 该独立检验统计量只作诊断, 不作为下游输入。

估算表 A12–A15 (外推/估算, 非观测) : 在同样 63 组配比上, 冻结线性预测的 10B/70B 目标 Spearman 为 $-0.532/-0.588$ 、逐域 MAE 为 3.53/3.91, 尺度修正 (幂律主口径) 后为 $-0.538/-0.576$ 与 0.86/0.88 (对数线性对照为 $-0.537/-0.576$ 与 0.86/0.88, 基本相同); 估算表本身的平均 Loss 为 1.797 (10B)、1.415 (70B), 低于修正模型的外推, 方向与 1B 上“实际下降快于两档外推”一致 (T6_extrapolation.csv)。估算表的目标 Loss 排序与 1M 实测几乎相反 (同配比从 1M 到 60M 的实测排序逐域 Spearman ≥ 0.98 , T6_domain_stability_rank.csv), 因此估算表隐含的“大尺度排序反转”没有观测支持, 只作为稳健性讨论的反例。注意 A12/A14 的 63 组配比逐行等于 A4 的子集 (代码断言), 冻结模型在这些配比上并非样本外; A13/A15 本身由三尺度幂律外推生成, 与修正模型的接近只是一致性对照, 不构成独立验证。

候选最优配比。以 A4 平均配比为中心、四档浓度 Dirichlet 生成 99,996 个候选。主口

经由线性 clr+Huber 模型在信赖域内选取：候选的 clr 向量到 A4 训练配比的马氏距离（协方差加 $10^{-3}I$ 岭）不超过训练配比自身距离的 95% 分位，且每域份额不超过 A4 该域最大值。信赖域内分别按 13 域等权 Loss 与 pile_cc Loss 取预测最优的前 100 个份额平均，得 $p_star_eqweight$ 与 p_star_pilecc ，并核对平均后的 p^* 仍在信赖域内；GBDT 在同一信赖域内按等权 Loss 另选 $p_star_gbdt_eqweight$ 作稳健性对照，报告两者的全变差距离与交叉评估。不确定性有两项：固定线性 p^* 的 200 次案例 bootstrap 重拟合收益分布，以及每次 bootstrap 在同一信赖域内重选 p^* 与主 p^* 的全变差距离分布。每个候选的 Q_domain 从本轮 Q_{final} 按域名连接， $\bar{Q} = \sum_i p_i Q_i$ 。不加信赖域时线性模型会在远离训练分布的组合上给出不可信的低 Loss（前 100 个候选的马氏距离中位数约 3.1×10^4 ，预测等权 Loss 中位数低至 0.84，而均匀配比为 5.39），故信赖域是本方案的建模选择而非数据结论。

候选配比求解。99,996 个 Dirichlet 候选先按 clr 马氏距离与份额上限筛入信赖域，再按 13 域等权预测损失（或 pile_cc 单域损失）取前 100 个份额平均；线性模型选主口径，GBDT 在同信赖域内另选作对照与交叉评估。

推荐配比与配比加权质量。信赖域阈值取 clr 马氏距离 21.85（A4 训练配比距离的 95% 分位），保留 46,168/99,996 个候选。

表 5 候选配比的对照（数据源：T7_pstar_benchmark.csv、interface/P1_p_star.csv）

配比	线性预测 等权 Loss	GBDT 预测 等权 Loss	线性 评估收益	GBDT 交叉评估收益	马氏距离	$\bar{Q}$
p^* 等权（线性，主口径）	4.875	4.901	9.47%	9.47%	13.9	0.66241
p^* GBDT 对照	4.927	4.811	8.51%	11.12%	10.4	0.66297
p^* pile_cc（线性）	5.074	4.963	5.77%	8.31%	4.0	0.66393
训练配比均值	5.198	5.177	3.48%	4.36%	0.5	0.66399
均匀配比	5.385	5.413	0	0	2.7	0.66065

表中收益的分母为均匀配比的预测等权 Loss（5.385），是 1M 代理模型在同一模型内的预测差异，不是重新训练后的实测改善。三点结论：两种模型选出的配比几乎相同（全变差距离 0.0344，GBDT 交叉评估线性 p^* 的收益为 9.47%，与线性自评一致，故主口径改用线性不损失收益）；收益的不确定性为固定 p^* 的 bootstrap 收益中位数 9.54%、95% 区间 [7.82%, 11.16%]，每次重选 p^* 与主 p^* 的全变差中位数 0.019、P95 0.027（T7_gain_ci.csv，图 6）；pile_cc 口径较弱（按线性模型只把 pile_cc Loss 从 5.576 降到 5.569，GBDT 评估反而更高，只能称搜索候选）。图 6 显示两个目标口径下信赖域内候选的分布与主 p^* 、均匀配比的位置。




图 6 信赖域内候选配比的分布与推荐配比 p^* 、均匀配比的位置

质量与训练边际价值在 17 域上的 Spearman 为 -0.211 (T7_quality_vs_value.csv, 图 7), 说明单凭域质量分不能代替配比实验: 质量高不等于该域的训练边际价值高。图 7 显示 17 域质量分与边际价值的散点关系, 两轴方向相反但并非单调替代关系, 该相关性不是因果结论。主 p^* 的配比加权质量 $\bar{Q}(p^*) = 0.6623836418229694$; 训练配比均值处为 0.6639493940373198 , 均匀配比处为 0.6606409880734977 (interface/P1_summary.json)。注意候选配比的预测损失不随 Q 改变: 配比搜索只依赖配比与 Loss, 质量分只改变 $\bar{Q}$ 的数值口径。




图 7 17 域质量分与训练边际价值的散点关系

检验与边界。本任务的检验层次依次为: 桥接的分层五折 ($R^2 = 0.4106$) 与六个映射

域的一致性 ($n = 6$)；配比模型的 1M 留出 (A6/A7)、冻结模型在 60M 的直接评估 (A8/A9) 与尺度修正模型在 1B 的独立检验 (A10/A11)；估算表 A12–A15 只作一致性对照。A8/A9 同时用于尺度参数标定，故不是修正模型的独立检验；其角色与项目级通用留出约束的张力仍待核。GBDT 的树数和学习率由 A4/A5 内五折确定，但论文又依据 A6/A7 的表现选择其作为交叉评估器，因此该留出集上的模型比较与候选收益不作为最终独立的性能优越性证据，候选收益仍是 1M 代理模型内的预测差异。

5.3 问题二：含质量与配比的广义标度律

5.3.1 问题重述

问题二把经典标度律扩展为同时依赖参数量 N 、训练 token 数 D 、附件 B 的质量 Q_B 与领域配比 $\mathbf{p}$ 的损失模型，并完成四项可计算分析：估计各因素的边际效用与弹性；用问题一的迁移结构讨论领域之间的功能替代与覆盖互补；给出「提高质量」与「扩大参数或算力」可以互相替代的条件及数值例子；在附件 B 上完成参数估计、嵌套检验与留出检验，并把冻结参数交给后续问题。附件 A 只通过问题一已经输出的域质量与配比接口进入，本问直接使用的数据是附件 B。下文公式中的 Q 均指 Q_B 。

5.3.2 问题分析

经典基线。目标是在 B1 上估计 $L_0(N, D) = E + AN^{-\alpha} + BD^{-\beta}$ 。输入是 8 个 Pythia 模型、共 1,176 行的损失记录 [8]。B1 的损失与 Hoffmann 等 (2022) 的公开公式常数几乎重合，因此先审计生成方式：后文将其训练设定作为真实来源信息，将损失数值作为公式生成的基线，不称为实测训练损失。参数采用幂次网格搜索、 E, A, B 采用线性最小二乘，并用 $C/(6ND)$ 核对算力记账。

质量项。目标是让 Q_B 进入损失，且 $Q_B = 1$ 时在参考配比下回到 L_0 。质量网格只出现在半合成的 B6、B7、B8。质量乘在参数项、数据项还是两者之上，损失随质量变化的曲率如何，均需由候选比较和诊断考察；同时 B8 与 B6/B7 的方向相反。因此在同一骨架上比较幂次、指数、线性三种乘子，以及有无地板、 κ 是否可收缩的嵌套族，用 B6 训练、用 B7 中 B6 没有的点作留出。按 Spec，主式固定为幂次 M4 加地板，以质量表示有效参数量与有效数据量；该函数形式选择有有效样本量与信息论的理论依据和独立文献支撑 [13] (数据受限 regime 下加性形式错误设定、 N - D 耦合的改进形式列为后续工作 [14])，并非交叉验证选出的预测最优形式。理论依据不替代经验检验：线性对照的留出误差更小，这一代价在结果中单独报告。

两套实验的统一。附件 A 是固定小规模上的配比实验，附件 B 是规模实验，两边都以交叉熵为观测量，但没有同一批 $(N, D, Q, \mathbf{p})$ 的联合试验。配比只能通过问题一在 1M 上估计的 clr 系数，乘到 B 侧损失的可约部分上。A4/A5 全部位于 1M，训练数据看不出配比斜率如何随 N 变化，所以不估计 $s(N)$ ，只设两个零新增参数的强度假设，再用 A6–A11 的校准斜率做事后比较。

边际、替代与单位算力。目标函数一旦写成闭式，弹性、等损失曲线和 $6ND = C$ 上的最优参数量都可以解析求出，再用数值解核对。领域关系不从 B 侧回归，因为 B 没有配比列；它来自问题一迁移矩阵行向量的余弦。单位算力比较把提质成本 $g(Q)$ 与扩参数的算力放在同一 FLOP 上，用来回答「多花的一份算力给质量还是给参数」。

5.3.3 模型假设

1. 同一观测量。附件A与附件B的损失都是验证集交叉熵，因而可以写入同一个 L 。该假设服务两源统一；检验见 $Q = 1$ 切片与B4、B5的趋势相关。2. 经典骨架。 $Q = 1$ 时损失具有 $E + AN^{-\alpha} + BD^{-\beta}$ 的形式， $\alpha, \beta > 0$ 。该假设服务基线，依据是B1的生成公式与题面的退化要求；检验是B1的拟合残差和 $C/(6ND)$ 。3. 退化条件。 $Q = 1$ 且 $\mathbf{p} = \mathbf{p}_{\text{ref}}$ 时，质量乘子与配比乘子都等于1，广义式回到 L_0 。 $\mathbf{p}_{\text{ref}}$ 取问题一的A4训练配比均值，作为附件B隐含Pile配比的代理。该假设服务题面约束；可检验的部分是 $Q = 1$ 切片相对 L_0 的残差。4. 质量地板与乘子分工。质量缺陷留下不随 N, D 消失的加项 $k_0(1 - Q)$ ， $k_0 \geq 0$ ；配比乘子只乘随规模衰减的两项，不乘 E 和地板。该假设服务「规模不能无限弥补质量」以及后文的替代上限；地板是否需要由嵌套 F 检验裁决。5. 质量口径。主映射取题面语义 $Q_B = Q_A = \sum_i p_i Q_i$ ，当前推荐配比处 $Q_0 = \bar{q}(\mathbf{p}^*) = 0.6623836418229694$ 。幂次乘子下，这一映射是假设，不能由「质量惩罚对 Q 仿射」推出。副映射 $Q_B = Q_A/Q_0$ 会使部分领域超出 $[0, 1]$ ，只作敏感性，不做静默截断。6. 配比强度不随规模估计。主假设 H_{red} 把配比乘在可约损失上，强度 s_{red} 用1M训练集定死；上界 H_{tot} 把同一偏离乘在总损失上。该假设服务配比通道；A6-A11只用来看观测斜率落在哪一侧，不回头改参数。

5.3.4 符号说明

5.3的解释变量与参数符号与4表2一致（ $N, D, Q, \mathbf{p}; E, A, \alpha, B, \beta; \kappa_N, \kappa_D, k_0; h_N, h_D; s_{\text{red}}, \tilde{\varphi}, m_*$ ）。本问额外使用的中间量为 $T_N = AN^{-\alpha}h_N(Q)$ 、 $T_D = BD^{-\beta}h_D(Q)$ 、 $R = T_N + T_D$ 与弹性 $\varepsilon_N, \varepsilon_D, \varepsilon_Q$ ，均在5.3.5的定义处给出。完整论文sec5_q2.tex另设一张本问符号表（tab:q2sym），本稿不重复该表，以4表2为唯一符号表。

5.3.5 模型建立

经典基线。在B1（8个Pythia模型、1,176行， $N_{\text{params_B/D_tokens_B}}$ 乘 10^9 ）上估计

$$L_0(N, D) = E + AN^{-\alpha} + BD^{-\beta},$$

α 在 $[0.30, 0.38]$ 、 β 在 $[0.24, 0.32]$ 上按步长0.002网格搜索， E, A, B 在每个格点由线性最小二乘给出，取训练误差最小的格点。以 $C/(6ND)$ 中位比核对算力记账（B侧 C 由 $C_{\text{FLOPs_1e21}}$ 乘 10^{21} 得绝对FLOPs）。

广义标度律（主式）。在 L_0 的可约部分上乘质量与配比因子，质量地板留在括号外[9]：

$$L(N, D, Q, \mathbf{p}) = E + k_0(1 - Q) + [AN^{-\alpha}Q^{-\kappa_N} + BD^{-\beta}Q^{-\kappa_D}] \exp(s_{\text{red}} \tilde{\varphi}(\mathbf{p})),$$

其中 $k_0 \geq 0$ 。三条性质： $Q_B = 1$ 时 κ 项乘子为1； $\kappa \geq 0$ 时 L 随 Q 单调不减； $N, D \rightarrow \infty$ 时 $L \rightarrow E + k_0(1 - Q)$ ，即质量缺陷留下不随规模消失的地板。幂次形状并非纯经验指定，而有有效样本量推导支撑[13]：设质量为 Q 的语料在信息上等价于 $D_{\text{eff}} = Dg(Q)$ 个完美质量token， g 单调不减且 $g(1) = 1$ ；若 g 在 $Q = 1$ 处正则变化（ $g(Q) = cQ^\gamma(1 + o(1))$ ， $Q \rightarrow 1$ ），归一化给出 $c = 1$ ，于是 $g(Q) \approx Q^\gamma$ ，数据项化为 $BD^{-\beta}Q^{-\gamma\beta}$ ，即幂次乘子 $Q^{-\kappa_D}$ （ $\kappa_D = \gamma\beta$ ），参数侧同理。该推导同时保证 $Q = 1$ 精确退化Chinchilla形式，对应题面退化要求。有效规模为

$$N_{\text{eff}} = N Q^{\kappa_N/\alpha}, \quad D_{\text{eff}} = D Q^{\kappa_D/\beta}.$$

配比标量来自问题一1M的clr系数并在 $\mathbf{p}_{\text{ref}}$ 处归一：

$$\varphi(\mathbf{p}) = \frac{1}{13} \sum_{v=1}^{13} \beta_v^{(1M)} \cdot \text{clr}(\mathbf{p}), \quad \tilde{\varphi}(\mathbf{p}) = \varphi(\mathbf{p}) - \varphi(\mathbf{p}_{\text{ref}}), \quad \mathbf{p}_{\text{ref}} = \text{A4 训练配比均值}.$$

$Q_B = 1$ 且 $\mathbf{p} = \mathbf{p}_{\text{ref}}$ 时两个乘子均为1，式退化为 L_0 ，满足题面退化要求。 $\mathbf{p}_{\text{ref}}$ 作为附件B隐含Pile配比的代理，属假设（见7.2）。

嵌套候选族与主式的确定。每种乘子形状（幂次 $Q^{-\kappa}$ 、指数 $e^{\kappa(1-Q)}$ 、线性 $1 + \kappa(1-Q)$ ）下比较：M0 ($\kappa_N = \kappa_D = 0$)、M1 ($\kappa_N = 0$)、M2 ($\kappa_D = 0$)、M3 ($\kappa_N = \kappa_D$)、M4（两项各自一个 κ ），再交叉有无地板，共26个候选。 κ 在 $[0, \kappa_{\max}]$ 上网格加密最小二乘（幂次/指数型1.2，线性型3.0）， k_0 在每个 κ 上闭式求解并截断为非负。

训练与留出边界。只用B6的360点估计参数与比较候选；B6的360点全部出现在B7且同点Loss相同，B7中不在B6的90点（全部为 $Q = 0.5$ 与 $Q = 0.7$ ，覆盖全部45个 (N, D) 格）作为留出集，按 Q, N, D 分组报告RMSE与残差；全B7450点的拟合含训练点，只作对照并写入接口 `fullB7_comparison`。主式按 **Spec** 固定为幂次M4加地板（两项 κ 都保留）；实际的交叉验证规则选择线性M4+F，仅写入 `cv_rule_choice` 作对照，不决定主式。

配比通道。A4/A5全部位于1M，训练数据无法识别配比效应随 N 的变化，故不估计尺度项，只设两个零新增参数假设：H_red（主）令配比乘可约部分且强度恒定， $s_{\text{red}} = c_{\text{train}}/\sigma_{\text{train}}$ ，其中 c_{train} 为冻结系数在1M训练集上的汇总校准斜率， $\sigma_{\text{train}} = (\bar{L}_{\text{train}} - E - k_0(1 - Q_{\text{ref}}))/\bar{L}_{\text{train}}$ ；H_tot（上界）令配比乘总损失。两个假设的参数只用**1M**训练行确定，A6-A11只以冻结系数计算各尺度校准斜率作事后比较，不重估任何参数。

边际、弹性、替代条件与闭式解。记 $T_N = AN^{-\alpha}Q^{-\kappa_N}$ 、 $T_D = BD^{-\beta}Q^{-\kappa_D}$ 、 $R = T_N + T_D$ ，令配比乘子暂为1：

$$\frac{\partial L}{\partial Q} = -\frac{\kappa_N T_N + \kappa_D T_D}{Q} - k_0, \quad \varepsilon_N = -\frac{\alpha T_N}{L}, \quad \varepsilon_D = -\frac{\beta T_D}{L}, \quad \varepsilon_Q = \frac{Q}{L} \frac{\partial L}{\partial Q}.$$

固定 D 把质量从 Q 提到 Q' 后，若只想靠增大 N 把损失拉回，需要

$$t = \left(\frac{Q}{Q'}\right)^{\kappa_N} + \frac{T_D}{T_N} \left[\left(\frac{Q}{Q'}\right)^{\kappa_D} - 1 \right] - \frac{k_0(Q' - Q)}{T_N} > 0, \quad N' = N t^{-1/\alpha},$$

$t \leq 0$ 时任何有限参数量都补不回这次提质。在 $6ND = C$ 且配比乘子为1时，最优参数量与地板无关：

$$N^*(C, Q) = \left(\frac{\alpha A Q^{-\kappa_N}}{\beta B Q^{-\kappa_D}} \right)^{1/(\alpha+\beta)} \left(\frac{C}{6} \right)^{\beta/(\alpha+\beta)}, \quad D^* = \frac{C}{6N^*}.$$

$\kappa_N > \kappa_D$ 时质量越低、 N^* 越大。沿最优前沿，质量从 Q 提到 Q' 等价于把算力乘以

$$M = \left\{ \frac{R^*(C, Q') - k_0(Q' - Q)}{R^*(C, Q)} \right\}^{-1/a}, \quad a = \frac{\alpha\beta}{\alpha + \beta}, \quad R^* = L^* - E - k_0(1 - Q);$$

花括号内不大于0时，再大的算力也追不上这次提质。 $k_0 = 0$ 时 M 与 C 无关； $k_0 > 0$ 时 M 随预算上升。配比乘子不为1时闭式一般不成立，需数值求解。

单位算力取舍与领域关系。单位算力收益定义为 $MU_x = -(\partial L / \partial x) \div (\partial C / \partial x)$ ，其中总成本取

$$C = (6 + \eta L_{ctx})ND + D[g(Q) - g(Q_0)]_+, \quad \eta = 2 \times 10^{-4}, \quad L_{ctx} = 2048,$$

并与问题三共用同一成本口径。配比边际为 $\partial L / \partial p_i = s_{red} R \partial \varphi / \partial p_i$ ， $\partial \varphi / \partial p_i$ 取问题一迁移矩阵的13域等权平均。领域之间的关系由迁移矩阵行向量余弦定义：余弦大于0.7记为功能替代，小于-0.3记为覆盖互补。线性clr模型没有交互项，因此超可加意义上的互补不可识别，“+加量”式交互不作声称。

5.3.6 模型求解

问题二使用Python 3.12.7、NumPy 1.26.4、pandas 2.2.2、SciPy 1.13.1，随机种子2026，脚本为src/code_q2/q2_01_fit.py、q2_02_theory.py、q2_03_economics.py。只读问题一接口目录，不读附件A原始表、不读P1缓存。

基线。 α, β 网格搜索、 E, A, B 线性最小二乘；用 $C/(6ND)$ 中位比核对算力记账。

质量参数。 κ 在 $[0, 1.2]$ （线性对照到3.0）上以初始步长0.02搜索，在最优点两侧加密两轮、步长每次除以5； k_0 在每个 κ 上闭式求解并截断为非负；训练数组取自B6，模型选择在同一B6上完成，留出用B7新增点。参数区间用B1行重抽样与B6的 (N, D) 格簇重抽样各300次， α, β 固定。

解析与数值互验。弹性、替代条件式与 N^* 、 M 的闭式在数值点上与直接求导/求解结果逐项对照；配比乘子不为1时不使用这些闭式。

5.3.7 结果分析

以下数值按当前P2接口v7与表T20–T33b核对；对应正式规范为Q2 Spec v7.1。下游是否已消费这一接口，仍按各问的实际代码与结果另行判定。

经典基线。B1共1,176行的拟合结果为 $E = 1.6901$ 、 $A = 406.39$ 、 $\alpha = 0.34$ 、 $B = 410.59$ 、 $\beta = 0.28$ ，训练RMSE为 1.51×10^{-4} ；对Hoffmann等（2022）常数的RMSE为 1.65×10^{-4} ， $C/(6ND)$ 中位比为1.0000（T20_baseline_fit.csv）。B1的损失数值与公开公式吻合到 10^{-4} 量级，因此它适合作为“真实训练设定、公式生成损失”的基线锚点；来源审计见5.3.8。

主式参数与留出表现。主式（幂次M4+地板）的参数为 $\kappa_N = 0.1416$ 、 $\kappa_D = 0.0112$ 、 $k_0 = 0.2280$ ；95%区间依次为 $[0.1264, 0.1568]$ 、 $[0.0000, 0.0408]$ 、 $[0.2013, 0.2554]$ ，且 $P(\kappa_N > \kappa_D) = P(k_0 > 0) = 1$ （T22_params_ci.csv，interface/P2_bootstrap.npz，300次重抽样）。区间由B1行重抽与B6 (N, D) 格簇重抽得到， α, β 固定，未覆盖形状比较和模型选择不确定性。 κ_D 的区间含0，收缩检验 $F = 0.63$ 、 $p = 0.43$ ，数据侧质量幂次没有被单独识别；主式仍保留该项，是因为指定的M4给数据项自己的指数。 $\kappa_N = \kappa_D$ 被拒绝（ $F = 57.19$ ， $p = 3.4 \times 10^{-13}$ ），地板被强烈支持（ $F = 307.11$ ， $p < 10^{-15}$ ）（T21b_nested_tests.csv）。

表 6 质量项候选比较 (B6 训练; 源自 T21_form_selection.csv, 正文表格; 留出为 B7 新增 90 点)

形状	模型	κ_N, κ_D, k_0	留一规模 CV	留出 RMSE	留出偏差 (预测 - 观测)
—	M0	0, 0, 0	0.2100	0.1616	-0.146
—	M0 + 地板	0, 0, 0.363	0.0781	0.0595	-0.001
幂次	M4 (去地板敏感性)	0.203, 0.153, 0	0.0813	0.0839	-0.070
幂次	M4 + 地板 (主)	0.142, 0.011, 0.228	0.05979	0.0531	-0.022
指数	M4 + 地板	0.370, 0.131, 0.144	0.05324	0.0421	-0.005
线性	M4 + 地板 (CV 对照)	0.430, 0.139, 0.142	0.05321	0.0416	-0.001

表中留出偏差按预测减观测计算, 接口 `holdout_bias` 为 -0.0219 ; 分组表 `T21g_holdout_by_group.csv` 的 `mean_resid` 按观测减预测计算, 整体符号相反。B7 新增 90 点 ($Q = 0.5$ 与 0.7 各 45 点、覆盖全部 45 个 (N, D) 格) 的留出 RMSE 为 0.0531, 按 Q 分组的 RMSE 为 0.0538 ($Q = 0.5$, 平均残差 $+0.0236$) 与 0.0525 ($Q = 0.7$, $+0.0202$); 按规模分组时 70M 的 RMSE 最大 (0.0865) (`T21f_holdout_points.csv`, `T21g_holdout_by_group.csv`, 图 8)。格内对 Q 做二次拟合的残差标准差中位数 (噪声代理) 为 0.0458, 留出误差高于噪声代理, 也高于线性对照的 0.0421。这是本问最主要的证据边界: 主式的幂次形状是有理论依据的指定形式 (有效样本量推导 [13]), 不是交叉验证选出的最佳预测模型; 交叉验证规则选出的线性 M4 + 地板留出 RMSE 为 0.0416, 比指定主式低约 22% (以主式 RMSE 为分母); 该误差差异是选择有效规模解释形式的代价, 理论依据不消除这一经验代价。图 8 的三个面板分别显示 $\Delta L(Q=0.1 \rightarrow 1)$ 随 N 的下降 (实测点与主式曲线)、B7 新增 90 点的观测—预测散点 (标注 RMSE 0.053) 与配比通道的观测斜率对照。




图 8 质量项候选比较与 B7 新增 90 点的留出表现

退化与其他诊断: B6 中 $Q = 1$ 的 45 个训练点相对 L_0 的平均残差为 $+0.0036$, 95% 区间 $[-0.0120, +0.0193]$, 与退化关系相容; 该切片属于训练数据内诊断, 不能视为独立验证, 且不检验 $\mathbf{p}_{\text{ref}}$ 的代理假设; 主式再加 $(1 - Q)^2$ 项的系数为 -0.0095 、 $p = 0.195$, 没有显著的额外曲率; ΔL (Q 从 0.1 到 1 的损失降幅) 范围为 $[0.107, 0.609]$, 与 $\ln N$ 的相关为 -0.767 、与 $\ln D$ 的相关为 -0.278 , 即质量收益主要随参数规模变小, 与 $\kappa_N > \kappa_D$ 的方向一致 (`T21c_deltaL_diagnostic.csv`, `T21d_shape_degeneration_tests.csv`)。全 B7 450 点的对照拟合为 $\kappa_N = 0.142$ 、 $\kappa_D = 0.006$ 、 $k_0 = 0.238$, 方向一致 (该组含训练点, 仅作对

照，interface/P2_scaling_law.json 的 fullB7_comparison)。B8 (1,704 行) 在最低质量档的平均损失为 0.545、 $Q = 1$ 时为 2.307，且 64.26% 的点低于 E ，与 B6/B7 方向相反，故不并入拟合 (T21e_B8_check.csv)。

边际效用、弹性与替代条件。取 $N = 10^9$ 、 $D = 3 \times 10^{11}$ 、 $Q = Q_0$ 、配比乘子为 1，损失 $L = 2.3945$ ，三个弹性为 $\varepsilon_N = -0.0533$ 、 $\varepsilon_D = -0.0295$ 、 $\varepsilon_Q = -0.0865$ ：质量弹性约为参数弹性的 1.62 倍，其中 72.97% 来自地板 (T31_marginal_utility_elasticity.csv)。四个配比份额的弹性绝对值之和为 0.0072，远小于质量弹性。规模加大后这一对比更强：在 $(10^{10}, 10^{12})$ 、 $(7 \times 10^{10}, 2 \times 10^{12})$ 处、 $Q = 0.9$ 时， $\varepsilon_Q/\varepsilon_N$ 为 4.13 与 7.60，地板占 $|\partial L/\partial Q|$ 的 89.04% 与 93.76% (T26_elasticities.csv)。在 $N = 10^9$ 、 $D = 3 \times 10^{11}$ 、 $Q = 0.6$ 处去掉地板后该比值降到 0.908 (T26_elasticities.csv)，说明“大模型上质量更敏感”在很大程度上依赖半合成数据中的地板项，外推时按假设使用。

表 7 质量提高 0.1 的等效参数倍数 (固定 $D = 3 \times 10^{11}$ ；源自 T24_equiv_substitution.csv，正文表格；括号内为去地板敏感性)

起点 Q	$N = 10^9$	$N = 10^{10}$	$N = 10^{11}$
0.5→0.6	1.299 (1.182)	1.648 (1.268)	2.996 (1.488)
0.7→0.8	1.282 (1.130)	1.641 (1.190)	3.066 (1.337)
0.9→1.0	1.274 (1.102)	1.644 (1.148)	3.144 (1.258)

表中倍数即替代条件式 $t > 0$ 时的 N'/N ，取值的分母为原参数量 N ；去地板一列的 $N = 10^{10}$ 值取自 T24_equiv_substitution.csv 的 law=nofloor 行。模型越大，同样的 0.1 提质越难用堆参数补回，因为地板在损失中的份额上升，而地板只能靠提质消掉；无地板时千亿参数处的倍数降到 1.26–1.49。沿 $6ND = C$ 的最优前沿，质量从 0.7 提到 0.8 相当于算力乘 1.191 ($C = 10^{19}$)、1.485 (10^{22})、2.134 (10^{24})，无地板时该倍数恒为 1.165、与预算无关 (T29_quality_compute_exchange.csv，图 9)。可替代的算力上限约 2.95×10^{30} FLOPs。 $Q = 0.5$ 时的 N^* 比 $Q = 1$ 大 15.7% ($Q = 0.7$ 为 7.8%、 $Q = 0.9$ 为 2.2%)，该比例与 C 无关； $C = 10^{24}$ 、 $Q = 0.5$ 时地板占可约损失的 32.94% (T25_compute_optimal.csv、T27_quality_floor.csv)。图 9 的三个面板分别给出等效参数倍数、等价算力倍数随预算的变化 (实线主式、虚线无地板) 与算力—质量前沿及渐近地板。高预算端的倍数与地板份额依赖半合成地板的外推，应作为假设下的推论。




图 9 等效参数倍数、等价算力倍数随预算的变化与算力—质量前沿

单位算力取舍与领域关系。

表 8 MU_Q/MU_N ($Q = Q_0$, $L_{ctx} = 2048$; 数据源: T33_cost_adjusted_N_vs_Q.csv; 括号内为去地板敏感性)

预算 C	指数型	幂函数型	对数型
10^{19}	0.868 (0.793)	0.477 (0.436)	1.057 (0.965)
10^{22}	42.48 (17.95)	23.34 (9.86)	51.71 (21.85)
10^{24}	627.30 (143.65)	344.59 (78.91)	763.61 (174.87)

大于 1 表示把一份 FLOP 用于提质比用于增加参数下降更多损失。 $Q = Q_0$ 时 $C = 10^{19}$ 的指数型与幂函数型小于 1、应优先扩参数，对数型略大于 1；T33b_quality_breakeven.csv 的 R_at_Q0 列显示 $C = 10^{20}$ 起三种成本函数的比值都大于 1（指数型 3.10、幂函数型 1.70、对数型 3.77），且比值随预算迅速增大。提质更划算的质量区间上界（T33b_quality_breakeven.csv 的 Q_favor_hi 列）在 $C = 10^{19}$ 时为指数型 0.64、幂函数型 0.53、对数型 0.99；即低预算下质量已较高时应转而扩参数。图 10 的三个面板分别给出 17×17 域对余弦热力图、 $\partial L / \partial p_i$ 边际与 MU_Q/MU_N 随预算的变化（横线为 1）。低预算结论对 $g(Q)$ 的形式敏感，高预算结论对成本函数不敏感。




图 10 域对余弦热力图、份额边际与 MU_Q/MU_N 随预算的变化

领域关系：按迁移矩阵行向量余弦，17 个域对中功能替代 4 对（最强 nih_exporter–enron_emails，余弦 0.969）、覆盖互补 10 对（最强 dm_mathematics–philpapers， -0.725 ）、其余 122 对为弱相关（T32b_domain_pair_relation.csv）。在 $N = 10^9$ 、 $D = 3 \times 10^{11}$ 、 $Q = Q_0$ 下，把份额拨向 dm_mathematics 使等权损失下降最快（ $\partial L / \partial p_i = -0.1475$ ），拨向 enron_emails 上升最快（ $+0.1381$ ）（T31b_p_marginal_by_domain.csv）。这是“增配后在各验证域上的梯度方向是否同号”，不是两个域同时加量的交互效应；线性 clr 模型无交互项，超可加意义的互补不可识别。

配比通道的证据位置。配比通道的参数为 $c_{train} = 1.0039$ 、 $Q_{ref} = 0.6640$ 、地板扣除 0.0766、 $\sigma_{train} = 0.6694$ ，故 $s_{red} = 1.4996207320397785$ ； $\tilde{\varphi}(\mathbf{p}^*) = -0.07104$ 、 $\tilde{\varphi}(\text{均匀}) = +0.03611$ ，推荐配比处的配比乘子为 $\exp(s_{red}\tilde{\varphi}(\mathbf{p}^*)) \approx 0.89894$ ，即配比效应使可约损失约为参照配比的 90%（T28_p_channel.csv、interface/P2_scaling_law.json 的 p_channel）。

表 9 两个配比通道假设与观测校准斜率的对照 (数据源: T28_p_channel.csv)

尺度	观测校准斜率 (仅评估)	H _{red} 预测	H _{tot} 预测	相 对 位 置 (0 = H _{red} , 1 = H _{tot})
1M 训练	1.004	1.004	1.004	—
1M 留出	0.995	0.998	1.004	—
60M	0.913	0.807	1.004	0.540
1B	0.612	0.309	1.004	0.436

表中 1M 训练行为参数来源 (role=train), 其余三档仅为评估 (role=eval), 未重估任何系数。在本表的 60M 与 1B 评估点, 观测斜率位于 H_{red} 与 H_{tot} 两个假设值之间; 这只构成当前评估点上的情景包络, 不是统计区间或普遍边界。下游可将两者作为预先设定的配比敏感性下、上情景, 不把 1.500 外推成随规模上升的经验函数。

5.3.8 模型检验

检验与拟合分开: 质量参数只用 B6 估计, 下面的留出、外源与解析对照都不再改 κ 与 k_0 。三组检验的设计与边界如下, 数值已在 5.3.7 给出。

留出与嵌套。B7 相对 B6 新增的 90 点 ($Q = 0.5, 0.7$, 覆盖全部 45 个 (N, D) 格, 属 Q 方向插值) 作留出; 留出 RMSE 高于同格的噪声代理与交叉验证更优的线性对照, 因此主式的幂次形状是有理论依据的指定 (5.3.5), 不是交叉验证选出的最佳预测模型。地板、 $\kappa_D = 0$ 、 $\kappa_N = \kappa_D$ 三个嵌套假设用 F 检验裁决; $Q = 1$ 切片相对 L_0 的平均残差用于核对退化条件。

跨来源对照。所有对照均在 $Q = 1$ 切片上检查经典基线趋势, 不检验质量项的泛化。B2 为半合成数据 ($n = 1,029$), 与基线预测的 Spearman 相关为 0.788, 但平均偏差为 +1.178; B3 是由 B1 插值得到的 4,000 条轨迹, Spearman 相关接近 1 只反映派生数据的一致性。B4 标注为真实记录, 共 57 点, 其中 13 点在 $(\log N, \log D)$ 上距 B1 小于 0.05 dex; 剔除近邻后保留 44 点, Spearman 相关从 0.983 变为 0.975, 平均偏差为 +0.176。B5 的 44 个文献点 Spearman 相关为 0.959, 但 tokenizer 与验证集口径不同, 故只比较趋势。B9 元数据与 B10 估算表按模型名及 N, D 对齐得到 128 对; B10 与公式的近乎完全相关是估算构造的结果, 不能当作观测验证。B2、B3、B10 均不能证明质量项可泛化到真实训练 (数据性质及指标见 T23_cross_source.csv、T23b_B4_neighbor_to_B1.csv、T23c_B9_B10_extrapolation.csv)。B8 与 B6/B7 的 Loss 方向相反 (64.26% 的点低于 E), 只作冲突诊断, 不并入拟合。

来源审计与解析互验。B11/B12 审计表明 B1 的 8 个 Pythia 名义规模、每个模型的 147 个训练步均被 B12 的检查点记录覆盖, $D/(\text{steps} \times \text{batch})$ 的中位比为 0.9986; B11 的模型族覆盖率为 3/12, B4 的 12 个模型族中仅 8.33% 出现在 B11 (T23e_B12_checkpoint_audit.csv、T23f_B11_family_audit.csv)。因此可以确认 B1 的训练设定有来源记录, 其损失值仍是按公开公式生成而非实测训练损失。替代条件式、 N^* 与算力等价倍数的解析值与数值解误差小于 10^{-8} (替代倍数小于 10^{-13}); 配比乘子不为 1 时不使用这些闭式。

5.3.9 评价与改进

本问的主式同时含有 $N, D, Q, \mathbf{p}$ ，在 $Q_B = 1$ 、 $\mathbf{p} = \mathbf{p}_{\text{ref}}$ 时回到经典式，并把「提质能否被规模替代」写成 $t > 0$ 这一可计算条件；B6 训练拟合、B7 的质量方向插值留出、跨源趋势对照及来源审计分别报告，半合成与估算数据没有被写成真实训练观测。

局限同样明确。质量参数只来自最大约 12B 的半合成网格； $C = 10^{24}$ 上「地板占可约损失约 33%」「提质远比扩参数划算」是把该地板外推出去的结果，应作为假设下的推论；外推到 $Q < 0.1$ 时三种乘子形状会分开。幂次是有有效样本量理论依据 [13]、为有效规模解释而指定的形式，线性与指数的留出误差更小，这已在 5.3.7 如实报告。 κ_D 未被单独识别。 $\mathbf{p}_{\text{ref}}$ 等于 Pile 配比、用 B1 的 E 与 B6 的 k_0 计算可约份额、以及 $Q_B = \bar{q}(\mathbf{p})$ ，都不能由本题数据单独证实；60M 与 1B 的配比斜率落在两个预设假设值之间，这只说明在已评估的点上形成情景包络，不能将恒定强度解释为已识别的下界或普遍规律。

可做的修正：若后续有真实的跨质量训练日志，用它替换 B6 重估 k_0 与 κ_N ，并允许 s 随 $\log N$ 变化；在得到真正的跨尺度配比试验之前，问题三应对 H_{red} 与 H_{tot} 各算一遍。下游引用本问接口时必须按幂次乘子 $Q^{-\kappa}$ 读取 κ_N, κ_D ，问题三已据此重跑（见 5.4.3）；问题四仍按 $Q = 1$ 切片使用，未读取 P3 最优配置。

5.4 问题三的模型建立与求解

5.4.1 模型建立

给定总预算 C （绝对 FLOPs）与外生上下文长度 L_{ctx} （token），在 N （参数个数）、 D （训练 token 数）和 $Q \in [Q_0, 1]$ 上最小化问题二的幂次主式。主方案固定问题一在 A4/A5 训练信赖域内选出的 17 域推荐配比 $\mathbf{p}^*$ ；这是题目允许的建模选择，不表示配比与规模精确可分离。记

$$\begin{aligned} m_* &= \exp\{s_{\text{red}}\tilde{\varphi}(\mathbf{p}^*)\} \approx 0.8989423, \\ T_N &= AN^{-\alpha}Q^{-\kappa_N}, \quad T_D = BD^{-\beta}Q^{-\kappa_D}, \\ L &= E + k_0(1 - Q) + m_*(T_N + T_D), \end{aligned}$$

乘子只作用于两项随规模变化的损失，不作用于 E 或质量地板。主质量映射按 P2 接口取 $Q_B = Q_A$ ，故当前 $Q_0 = 0.6623836418229694$ ；这是跨问题质量尺度的建模假设，不是直接观测等式。系数 $E, A, \alpha, B, \beta, \kappa_N, \kappa_D, k_0$ 全部读取冻结的 P2 接口，不在本问重拟合。约束为

$$6ND + D[g(Q) - g(Q_0)]_+ + \eta NDL_{\text{ctx}} \leq C, \quad Q_0 \leq Q \leq 1, \quad \eta = 2 \times 10^{-4},$$

作为映射敏感性对照，P2 的锚点映射 $Q_B = Q_A/Q_A(\mathbf{p}^*)$ 在推荐配比处给出 $Q_0 = 1$ ，此时没有可行的提质区间，记为 NO_QUALITY_RANGE。该映射下若域级质量超过 $[0, 1]$ 支持范围，按 P2 的 clip_policy=error 标记，不作静默截断。

必须比较题目附录 B 的三类单位 token 提质成本：指数型 $g = 10^7 e^{6Q}$ （凸）、幂函数型 $g = 5 \times 10^9 Q^4$ （凸）、对数渐近型 $g = 2 \times 10^9 \ln(1 + 10Q)$ （凹）。本问按单次训练的静态预算情景建模；题面未给训练起止日期、逐期预算、GPU 数、工期或碳排放等约束，不能把

它们写成硬要求。题面建议 $C = 10^{19}, 10^{22}, 10^{24}$ FLOPs, 硬要求是至少三个不同量级; 本项目自主采用 10^{19} 至 10^{25} 共七档网格, 并把三个建议档单列。 L_{ctx} 是情景输入, 不由优化器自由选择。连续 N, D 与 $Q \geq Q_0$ 是为解析求解设定的建模假设。

优化结论继承问题一、二的证据边界: $\mathbf{p}^*$ 来自 A4/A5 训练信赖域内的线性 clr+Huber 主模型, GBDT 仅作对照, 候选配比收益是预测值而非重新训练的实测收益。 幕次 M4+ 地板是问题二当前指定主式, 并非交叉验证中预测误差最低的形式; 其质量项由 B6 的 360 个半合成样本估计, B7 新增的 90 个半合成点用于 Q 方向插值留出。 幕次主式留出 RMSE 约为 0.053, 高于线性 M4+ 地板对照的约 0.042, 且 κ_D 的条件区间包含 0。 因此, 问题三的最优配置是给定该标度律、映射及参数后的模型内方案, 不能解释为真实训练收益或已验证的数据侧质量效应。 配比乘子通道在问题二中也标为探索性假设, 含 m_* 的结论须保留这一条件性。

降维与闭式对照。 三项成本都与 D 成正比, 而 $\partial L / \partial D = -m_* \beta T_D / D < 0$, 故在无额外 D 上限的本模型内预算用尽。 记 $K = 6 + \eta L_{ctx}$ 、 $\Delta g = [g(Q) - g(Q_0)]_+$, 由约束取等得

$$D = \frac{C}{KN + \Delta g},$$

问题降为 $(\log_{10} N, Q)$ 的二维有界优化, 仍须满足 $Q_0 \leq Q \leq 1$ 。 固定 Q 且令 $\Delta g = 0$ 的解析对照为 $N^* = [\alpha A Q^{-\kappa_N} / (\beta B Q^{-\kappa_D})]^{1/(\alpha+\beta)} (C/K)^{\beta/(\alpha+\beta)}$ 、 $D^* = C/(KN^*)$; 式中 m_* 与地板因对固定 Q 的规模求导而抵消, 其值仍影响不同 Q 之间的最优选择。 由此得

$$\frac{D^*}{N^*} \propto \left(\frac{C}{K}\right)^{(\alpha-\beta)/(\alpha+\beta)} Q^{2(\kappa_N-\kappa_D)/(\alpha+\beta)},$$

两个指数在当前参数下约为 0.09677 与 0.42065; 这只是无提质开销对照, 真实 $\Delta g > 0$ 情景的比值与预算斜率须由数值最优解计算。 上下文长度的解析临界值由注意力项与训练项之比 $\eta L_{ctx}/6$ 给出: $L_{ctx}^{\text{crit}} = 6/\eta = 30000$ token, 在固定 L_{ctx} 下该比值与 C, N, D 无关; C7 五档中 8192 在临界值以下、 32768 在其以上, 30000 本身不是 C7 的实测档位。

结构性转移的定义与判据。 本项目把”最优策略的质变”操作化为全局最优解的质量约束活跃状态变化: LOWER ($Q^* = Q_0$)、 INTERIOR、 UPPER ($Q^* = 1$), 并注明扫描预算区间、 离散化精度与边界分类容差; 若两个内点局部极小分支交换全局最优地位, 即使仍同属 INTERIOR 也单列”全局分支切换”。 这把”质变”落到可计算判据上并非孤立做法: Prescriptive Scaling Laws for Data Constrained Training[15] 在数据受限配置前沿上发现 turn-back 现象——预算越过临界后最优策略从”加重重复次数”质变为”加大模型、 减轮次”, 是预算驱动的最优策略质变在标度律文献中的直接先例 (其决策维度为模型容量与数据重复次数, 本文则为质量维度 Q)。 对固定 Q 的规模最优解, 令 $S = KN + \Delta g$, 剖面目标的质量导数与边际比为

$$F_Q = -k_0 - \frac{m_*}{Q} (\kappa_N T_N + \kappa_D T_D) + \frac{m_* \beta T_D g'(Q)}{S}, \quad \Phi(C; Q) = \frac{\left[k_0 + \frac{m_*}{Q} (\kappa_N T_N + \kappa_D T_D)\right] S}{m_* \beta T_D g'(Q)},$$

其中 N, D 均在该固定 Q 下优化, 不能代入其他质量点的全局规模解。 内层解光滑且未触及搜索边界时, $\Phi(C; Q_0) \leq 1$ 、 内点 $\Phi(C; Q) = 1$ 、 $\Phi(C; 1) \geq 1$ 分别是相应状态的局部一阶必要条件; $\Phi = 1$ 的根不是全局状态切换的充分条件, 须核对剖面曲线与

端点并分别输出局部根与全局临界点，二分只用于已括根且已检查单次切换的区间。 $Q_0 \geq 1 - 10^{-10}$ 时只有唯一质量状态，记 NO_QUALITY_RANGE，临界预算用 JSON null；搜索区间未括根返回 NOT_BRACKETED 与 null，不返回上界。公式正确性已做单点有限差分核对： $C = 10^{20}$ 、 $L_{ctx} = 2048$ 、指数型成本、 $Q = 0.8$ 处解析导数 -0.1164515205405 与差分 -0.1164515204932 的相对误差约 4.1×10^{-10} （对应 $\Phi = 1.63892372$ ），见 doc/Q3/新式子影响文档审查.md。

敏感性设计与输出要求。敏感性至少覆盖：三类 g 、C7 五档 L_{ctx} 、 $\eta = 10^{-4}, 2 \times 10^{-4}, 3 \times 10^{-4}$ （题设固定 2×10^{-4} ，另两值只是本项目扰动情景）、P2 参数重抽样、主/锚点两种质量映射、P1 域质量与配比不确定性，以及固定配比乘子 $m=1$ 、 H_{tot} 与 P2 无地板参数对照。其中 H_{tot} 在固定 $\mathbf{p}^*$ 时对完整基线 Loss 乘一个与 N, D, Q 无关的正常数，故其最优 N, D, Q 与 $m=1$ 对照相同、最优 Loss 按该常数缩放，须专门核验这一同配置关系。验收阈值：预算超限相对误差不大于 10^{-9} ，三项份额和误差小于 10^{-9} ， $N, D > 0$ 且 $Q \in [Q_0, 1]$ ，预算使用率与 1 之差小于 10^{-9} ，无提质开销时闭式 N^* 相对误差小于 10^{-5} ，关键 18 组求解 Loss 不劣于独立粗网格且差不超过 2×10^{-5} 。P3_optimal_config.csv 的份额分母统一为实际总消耗，同时另报预算使用率，不得混用分母； C, N, D 均为绝对量。

5.4.2 求解方法

按 5.4.1 消去 D 后，在 $(\log_{10} N, Q)$ 上求解。固定 Q 的内层对 $\log_{10} N$ 可用有界一维搜索；须核对搜索边界没有截住解。外层对 Q 加密搜索并保护 $Q_0, 1$ 两个端点，同时比较多个内点候选和独立粗网格，以检查不同局部极小分支。局部 $\Phi = 1$ 根与全局状态切换分别识别；仅当搜索区间已括根且已检查为单次切换时，才用二分定位临界预算。主网格为 3 种成本函数 $\times$ 7 档预算 $\times$ 5 档 C7 上下文长度 $\times$ 2 个同一质量映射下的起始质量对照，共 210 组；这是本项目设计，不是赛题规定的运行组数。对 $Q_0 = 1$ 和未括根的情形，分别记录 NO_QUALITY_RANGE、NOT_BRACKETED 与空数值，不以搜索上界代替结果。

本问已按幂次主式（ $Q^{-\kappa_N}, Q^{-\kappa_D}$ 与地板 $k_0(1 - Q)$ ，乘子 $m_* \approx 0.8989423$ ）重跑并生成运行 manifest (P3_run_manifest.json，北京时间 2026-09-26 11:37，含 P1/P2/C7 输入 SHA-256)。当前 q3_03_mixture_joint.py 已改为运行即退出，不作为主结论；其旧联立结果不作为本章证据。

5.4.3 结果与分析

结果证据范围。目标式已固定为问题二的幂次 M4+ 质量地板并保留配比乘子 $m_* \approx 0.8989423$ ， $Q_0 = 0.6623836418229694$ 。src/code_q3/ 已按该口径重跑（manifest 记录北京时间 2026-09-26 11:37）。主网格为 3 种成本函数 $\times$ 7 档预算 $\times$ 5 档 C7 上下文长度 $\times$ 2 个同映射下的起始质量对照，共 210 组；题面建议的三档预算 $10^{19}, 10^{22}, 10^{24}$ FLOPs 在结果中单列。 10^{22} 及以上已超出 B6 训练覆盖，属外推；质量参数来自半合成 B6、配比通道为探索性，证据边界与问题二一致。下文先给出可由主式推出的解析关系，再给出数值最优配置、成本份额与临界预算。

预算取等与降维。三项成本都与 D 成正比，且 $\partial L / \partial D = -m_* \beta T_D / D < 0$ ，故在无额外 D 上限的本模型内预算用尽， $D = C / (KN + \Delta g)$ ，其中 $K = 6 + \eta L_{ctx}$ 、 $\Delta g = [g(Q) - g(Q_0)]_+$ ；问题降为 $(\log_{10} N, Q)$ 的二维有界优化。

上下文长度的解析临界值。注意力项与训练项之比为 $\eta L_{ctx} / 6$ ，在固定 L_{ctx} 下与 C, N, D

无关；两者相等给出 $L_{ctx}^{crit} = 6/\eta = 30000$ token。C7 的五档可行值中有 8192（临界值以下）与 32768（临界值以上）；30000 本身不是 C7 的实测档位，因此“成本交叉”与“预算驱动的最优策略转移”是两件事，须分开陈述。

质量状态的分类与判据。质量约束的活跃状态分 LOWER ($Q^* = Q_0$)、INTERIOR、UPPER ($Q^* = 1$) 三类，离开下界与到达上界是两个不同的临界事件； $\Phi(C; Q_0) \leq 1$ 、内点 $\Phi(C; Q) = 1$ 、 $\Phi(C; 1) \geq 1$ 只是固定 Q 意义下的局部一阶必要条件，全局切换可能发生在两个内点分支相等处。因此求解须同时输出局部根与全局临界点。该 Φ 表达式的正确性已有单点有限差分依据： $C = 10^{20}$ 、 $L_{ctx} = 2048$ 、指数型成本、 $Q = 0.8$ 处解析导数 -0.1164515205405 与差分 -0.1164515204932 的相对误差约 4.1×10^{-10} （对应 $\Phi = 1.63892372$ ，核验边界见‘doc/Q3/问题三结果说明.md’）。这属于公式正确性证据，不是任何配置或临界预算的结果。

配比乘子的处理。主情景按 P2 的 p_channel 读取 $m_* = 0.8989423$ （由 s_red_main=1.4996207320397785 与 phi_tilde_pstar=-0.07104223742472571 给出），参考点是 $\mathbf{p}_{ref} = \mathbf{p}_{train_mean}$ 而非 $\mathbf{p}^*$ ；忽略配比效应的对照须单独标记 m=1。由于 P2 把跨规模配比通道标为 exploratory，含 m_* 的结论必须报告这一条件性来源并给出 m=1 对照。固定 $\mathbf{p}^*$ 时 H_{tot} 对完整基线 Loss 乘一个与 N, D, Q 无关的正常数，故其最优 N, D, Q 应与 m=1 完全一致、最优 Loss 按该常数缩放——这一同配置关系是可核验的，而不是可优化出来的差异。

数值最优配置 ($L_{ctx} = 2048$ ，主口径 $Q_B = Q_A$)。表 10 给出题面建议三档预算下三类单位 token 提质成本函数的最优 N, D, Q 与最优 Loss。低预算 $C = 10^{19}$ 时，指数型与幂函数型成本下最优质量停留在下界 $Q^* = Q_0$ （LOWER，不提质），而对数型成本函数的提质边际成本远低于前两者（凹、随 Q 递减）而直接提满 $Q^* = 1$ ；到 $C = 10^{22}$ 、 10^{24} ，三种成本函数下最优解均为 $Q^* = 1$ （UPPER），最优 N, D 随预算沿算力前沿增长、最优 Loss 随预算下降。

表 10 三档建议预算下的最优资源配置 ($L_{ctx} = 2048$ ，主口径；数据源 P3_optimal_config.csv，北京时间 2026-09-26 11:37)

成本 $g(Q)$	$\log_{10} C$	Q^*	N	D	最优 Loss	状态
指数型	19	0.6624	2.414×10^8	6.464×10^9	2.9780	LOWER（不提质）
指数型	22	1	5.584×10^9	2.545×10^{11}	2.1038	UPPER（提满）
指数型	24	1	4.072×10^{10}	3.780×10^{12}	1.8914	UPPER（提满）
幂函数型	19	0.6624	2.414×10^8	6.464×10^9	2.9780	LOWER（不提质）
幂函数型	22	1	5.663×10^9	2.479×10^{11}	2.1046	UPPER（提满）
幂函数型	24	1	4.082×10^{10}	3.764×10^{12}	1.8914	UPPER（提满）
对数型	19	1	3.167×10^8	3.620×10^9	2.9380	UPPER（提满）
对数型	22	1	5.140×10^9	2.969×10^{11}	2.0988	UPPER（提满）
对数型	24	1	4.023×10^{10}	3.867×10^{12}	1.8910	UPPER（提满）

成本份额。表 11 给出 $L_{ctx} = 2048$ 下三档预算的训练、注意力与提质三项成本的绝对份额（分母为实际总消耗，另报预算使用率并核验等于 1）。低预算 $C = 10^{19}$ 下训练成本占主导（指数型约 93.6%）；对数型成本在 $C = 10^{19}$ 已把约 26.5% 用于提质，反映其提质

边际成本远低于前两者。注意力份额随 L_{ctx} 增大显著上升 ($L_{ctx} = 32768$ 时已接近或超过训练份额)，这是 $L_{ctx}^{crit} = 30000$ 的直接体现。

表 11 三档预算下的成本份额 ($L_{ctx} = 2048$, 分母为实际总消耗; 数据源 P3_optimal_config.csv)

成本 $g(Q)$	$\log_{10} C$	训练份额	注意力份额	提质份额
指数型	19	93.61%	6.39%	0
指数型	22	85.27%	5.82%	8.91%
指数型	24	92.37%	6.31%	1.32%
幂函数型	19	93.61%	6.39%	0
幂函数型	22	84.24%	5.75%	10.01%
幂函数型	24	92.19%	6.29%	1.52%
对数型	19	68.77%	4.69%	26.54%
对数型	22	91.57%	6.25%	2.18%
对数型	24	93.34%	6.37%	0.28%

结构性转移。 $L_{ctx} = 2048$ 主口径下，全局最优解的质量约束状态随预算变化：指数型在 $\log_{10} C \approx 19.059$ 离开下界、 ≈ 20.355 到达 $Q = 1$ ；幂函数型为 19.529 与 20.106；对数型离开下界与到达上界同发生于 ≈ 18.579 （局部 $\Phi = 1$ 根约 18.904，与全局切换相差 0.325 dex）。P2 条件 bootstrap（300 次全部括根）给出离开下界的 5%–95% 区间：指数型 [19.038, 19.084]、幂函数型 [19.503, 19.560]、对数型 [18.539, 18.620]。因此“提质是否划算”存在明确的预算阈值，且该阈值随成本函数形状移动：对数型成本阈值最低，指数型居中，幂函数型最高。

求解核验。本轮预算残差 3.93×10^{-16} 、三项份额和误差 3.33×10^{-16} ，均小于 10^{-9} ；无提质开销时闭式 N^* 相对误差 1.54×10^{-7} （阈值 10^{-5} ）；关键组求解 Loss 与独立粗网格最大差 1.80×10^{-5} （阈值 2×10^{-5} ）；搜索边界未截住主解。锚点映射 $Q_B = Q_A/Q_A(\mathbf{p}^*)$ 下 $Q_0 = 1$ ，记为 NO_QUALITY_RANGE；pile_cc 单域映射质量越界记为 OUT_OF_SUPPORT 且不截断。

配比与 P2 参数的不确定性。问题一的逐次重抽样接口 (P1_pstar_bootstrap.csv, 200 次重选 $\mathbf{p}^*$) 已接入：把 $Q_0(\mathbf{p}^*) = \sum_i p_i Q_i$ 的重抽样不确定性（5% – 95% 为 [0.6613, 0.6636]）传播到离开下界的临界预算，三种成本函数下 $\log_{10} C$ 的配比重抽样区间为指数型 [19.053, 19.065]、幂函数型 [19.525, 19.534]、对数型 [18.579, 18.580] (T2_pstar_bootstrap_ccrit.csv)。该区间（约 0.001–0.012 dex）远小于 P2 参数联合 bootstrap 的区间 (0.046–0.081 dex)，故配比重抽样是次要不确定性来源；两类区间分属不同来源、未做联合抽样，仍未构成严格的全链条联合区间，但均已单独报告。

5.5 问题四的模型建立与求解

问题四需要把 Benchmark 表现、训练规模和时间变化放到同一口径下，分析规模扩张与非规模因素的模型内贡献，并在算力增速放缓情景下讨论开放权重模型的能力变化。现有材料包含两条实现流程；预测已按 $T_0 = 2026.75$ （现在）重新锚定并重跑，分解结果尚未按当前规范全部重跑。本节说明其可支持的范围与尚未通过的检验。

5.5.1 模型建立

数据口径与样本边界 主能力指标为 C1/C2 的 Average，由六项 Benchmark 维度等权汇总，量纲为 0–100 分。C2 在 C1 榜单上增加 Epoch 匹配信息，二者属于同一批榜单记录，不能互相作为独立验证。模型类型按榜单标签区分：base 包括 pretrained 与 continuously pretrained，chat 包括 chat 与 fine-tuned；merges、multimodal 与 other 不纳入这两类主回归。C2 的发布日期用于模型时间轴；C1 的提交日用于 C8 月度汇总。两类日期回答不同问题，不能互换。

本问关注开放权重模型，但“权重可获得”与许可证允许的用途是两个字段。许可证未知或缺失时保留未知状态，不能仅凭模型出现在 Hub 推断其权重可下载或许可范围。现有 C2×C4 面板尚未执行 Spec 要求的严格开放权重筛选和未知项审计，因此下文涉及该面板的结果应理解为候选样本分析，不能称为已验证的开放权重总体前沿。C2 与 C4 先按发布日期和组织匹配，再要求参数量差异小于 50%；未匹配记录及缺失原因应在重跑时单列，现有 P4 产物没有提供完整的匹配质量审计。若训练 token 缺失，则由 $D = C/(6N)$ 反解的值是估算量而非观测量。代入 $C = 6ND$ 时， N 与 D 使用绝对参数数和 token 数， C 为 FLOPs。

C3 混合了不同评测口径，只作为标记清楚的时间趋势敏感性材料，不并入主面板，也不用于证明主模型的外部有效性。C5/C6 的 Loss 来源与验证集可比性分层使用；高可比样本不能单独支撑映射曲线的高分段。

表 12 问题四两套实现流程的来源与验收状态

流程	数据、时间轴与产物	当前状态
既有主链	q4_01_c8_parse.py 至 q4_05_forecast.py；读取 C1/C2、C3、C4、C6、C8 及 P2。预测接口以 $T_0 = 2026.75$ 为起点，对应目标日期 2027.75 和 2028.75。数据截止 2025-03-13；时间审计已发现模型面板和算力估计样本中存在起点之后的数据（前视）。产物位于 src/outputs_q4/。	预测已按 $T_0 = 2026.75$ 重跑；分解结果仍属旧轮次，Q4 Spec 记录其生成早于 2026-09-25 的代码与公共接口修改，尚未在修改后从原始附件重跑。
补充独立实现	入口脚本为 src/code_q4/independent/run_q4_independent.py，配置为 config_q4.json。来源报告记录预测起点 2024-12-31、数据截止日 2025-03-13；报告产物并入文档，但本仓库没有相应的新运行目录。	尚未在本仓库运行核验；来源报告中的估计和预测不是本轮结果，也不构成独立数据验证。数值资源链标记为 DEFERRED_Q3。

两套实现流程及其状态 表 12 区分了程序实现与结果验收：两套代码都不能替代同一数据版本上的重跑、哈希记录和验收。既有主链的预测截止时间也没有形成覆盖 C1/C2/C4 的统一冻结清单，因此其回测与预测不能据此称为严格时间外检验。

C8 逐任务饱和度与去饱和分 为减少已接近任务上限的维度对汇总分变化的压缩，先按叶子任务随机基线 c_j 归一化得分

$$\hat{s}_j = \max \left\{ 0, \frac{s_j - c_j}{1 - c_j} \right\},$$

再按 C1 提交日构造任务级累计 Top-5 前沿 $F_{t,j}$ 。去饱和和剔除判为饱和的任务，以起点剩余空间作为家族内权重，并令六个任务家族等权：

$$S_{\text{desat},t} = 100 \sum_j w_j \hat{s}_{j,t}, \quad w_j \propto 1 - F_{\text{start},j}.$$

该分数依赖任务集合、随机基线和起点选择，因而是对 Average 的敏感性口径，不是同尺度的独立真值。




图 11 C8 叶子任务的饱和度分类

图 11 所依据的 P4_task_saturation.csv 含 39 个任务：饱和 10 个、快速增长 9 个、常规增长 17 个、低位停滞 3 个。这些标签来自预设的终点水平、剩余空间、关闭率和噪声判据，描述的是本任务集合内的分类，不表示相关 Benchmark 已被外部验证。

表 13 C1 与 C8 能力口径的历史窗口比较（2024-06 至 2025-03；源自 T5_desat_vs_average.csv）

口径	起点前沿	终点前沿	相对变化	月斜率
C1 Average	38.52	49.89	29.53%	1.285
C8 全任务重算	37.98	49.40	30.08%	1.326
C8 去饱和分	26.36	39.06	48.19%	1.536

表 13 中相对变化的分母为同一口径的起点前沿。去饱和分在该窗口内的相对变化高于 Average，说明结论会随任务饱和处理而变；不能据此说 Average 低估了某个可观测的“真实进步”。模型级重算与 C1 的一致性检查中，除 MATH 外五个任务族的 Pearson 相关不低于 0.989；MATH 的相关为 0.801、MAE 为 3.497 分（T5_c8_vs_c1_check.csv）。这只是同一评测体系内的复算一致性检查，MATH 差异原因尚未解释。

图10 去饱和和综合分 vs 榜单 Average




图 12 C8 去饱和分与 C1 Average 的历史窗口比较

图 12 将任务汇总口径和模型级得分并列展示。它能呈现任务选择与饱和处理对相对变化的影响，但因 C1 与 C8 记录存在同源和重叠，不能把相关性解释为独立验证或准确率。

Loss-Benchmark 桥接 C6 的 Loss 与 Benchmark 得分按可比性分层后，用有界 S 形函数描述二者关系：

$$S(L) = lo + \frac{hi - lo}{1 + \exp[k(L - L_0)]}, \quad 0 \leq lo \leq hi \leq 100, \quad k > 0.$$

High 层为同模型、同验证集记录，权重为 1；Medium 层的验证集不同但近似可比，权重为 0.5。主结果使用 C6，对 base/chat 和各评分维度分别拟合；C5 未并入该主拟合。既有 P4_bridge_params.json 中 base|Average 的参数为 $(lo, hi, k, L_0) = (8.626, 21.572, 46.119, 2.070)$ 。该组对应 44 行；C6 整体分层为 High 7 行和 Medium 68 行。对同一批 C6 样本作留一检查时，S 形、线性与常数模型的 RMSE 分别为 8.079、8.283 和 9.514 分 (P4_bridge_params.json)。误差差距有限，且留一检验没有跨来源独立样本，不能据此宣称 S 形映射已外部验证。High 层仅覆盖低分底噪区，主要约束下界；曲线上升段主要由 Medium 层决定。

图11 Loss→Benchmark 桥接映射 (High 权重 1, Medium 权重 0.5)




图 13 C6 分层 Loss-Benchmark 桥接的旧轮次拟合

图 13 展示按 base/chat 与评分维度拟合的桥接曲线。曲线只在 C6 的数据范围和分层假设下成立；拟合所得 hi 是该样本内的平台参数，不是 Benchmark 的分数上限。主分解模型

在 C2×C4 面板上重新估计得分映射，固定 C6 映射仅作对照；由于 C6 上界低于面板锚点，直接将其外推到面板高分段会越出训练支持域。面板重估减少了直接跨尺度外推，却没有消除 C6 到榜单的迁移误差；该误差尚未作为单独通道进入分解和预测区间。

规模与非规模因素的模型内分解 每个面板观测把 C2 能力分与 C4 匹配配置连接，再使用问题二的标度律计算规模状态 $\hat{L}_i$ 。既有主模型 M1b 将损失的非线性映射与时间项相加：

$$S_i = lo + \frac{amp}{1 + \exp[k(\hat{L}_i - L_0)]} + \tau(t_i - 2023) + \varepsilon_i.$$

其中 amp 为映射振幅， τ 表示控制已计算规模状态后的年度时间关联。对照 M1c 把时间项写入等效年降损 δ ：

$$S_i = lo + \frac{amp}{1 + \exp[k(\hat{L}_i - \delta(t_i - 2023) - L_0)]} + \varepsilon_i.$$

其他比较包括效率前沿线性模型 M2、分位数回归 M3 和以 $\log_{10} C$ 为解释变量的 OLS。对两个端点状态 $(\hat{L}_0, t_0)$ 与 $(\hat{L}_1, t_1)$ ，采用两因素 Shapley 分配，按两种变化顺序的平均分配模型预测变化 [11]：

$$\begin{aligned}\Delta S_{\text{scale}} &= \frac{1}{2}\{[f(\hat{L}_1, t_0) - f(\hat{L}_0, t_0)] + [f(\hat{L}_1, t_1) - f(\hat{L}_0, t_1)]\}, \\ \Delta S_{\text{time}} &= \frac{1}{2}\{[f(\hat{L}_0, t_1) - f(\hat{L}_0, t_0)] + [f(\hat{L}_1, t_1) - f(\hat{L}_1, t_0)]\}, \\ \Delta S_{\text{model}} &= \Delta S_{\text{scale}} + \Delta S_{\text{time}}.\end{aligned}$$

技术份额定义为 $\Delta S_{\text{time}}/\Delta S_{\text{model}}$ ，不是对观测增量的占比。模型的时间项可能吸收数据质量、后训练、架构和样本构成变化；它是条件关联，不是已识别的技术因果效应。chat 的后训练增益另按同组织 base/chat 配对估计，也只作描述性关联。

5.5.2 求解方法

既有主链按 q4_01_c8_parse.py、q4_02_saturation.py、q4_03_bridge.py、q4_04_decomp.py、q4_05_forecast.py 的顺序运行，末尾由 q4_99_check_report.py 检查接口和报告字段。C8 先按叶子任务解析，再与榜单模型匹配；C6 桥接以分层加权最小二乘估计，并用留一法比较函数形式。C2 与 C4 依发布日期、组织和参数量差异匹配；对未提供训练 token 的配置，按 $D = C/(6N)$ 反解时同时保留“估算”来源标记。

预测脚本以算力增长情景更新 C ，在 $Q = 1$ 、上下文长度 $L_{\text{ctx}} = 4096$ 的 P2 损失切片上计算规模损失变化，再锚定到既有前沿损失并经 M1b/M1c 映射为分数。该计算没有读取 P3 的最优配置接口，没有乘固定推荐配比的 $m(\mathbf{p}^*)$ ，也没有检验四变量联合资源关系；因此它只是 Q2 标度律在 $Q = 1$ 切片上的情景计算，不是当前 Q3 完整资源优化链的下游验证。项目核查还记录了 P2 的训练/留出边界尚未通过现行 Spec 验收，相关 P4 数值继承了这一上游限制。

需区分下列来源状态：第一，src/outputs_q4/ 中的预测接口 (P4_frontier_forecast.csv、T8_*、图 F14) 已按 $T_0 = 2026.75$ 重跑，但分解表图 (P4_decomposition.csv、图 F12/F13) 仍是代码及公共输入修订前生成的旧轮次结果；第二，independent/ 中的脚本和来源项目报告尚未在本仓库运行。预测数字表示既定参数、样本和映射条件下的模型输出，不表示已复现全链或通过验收。

5.5.3 结果与分析

旧轮次数据检查与分解结果 下列数值直接摘自仓库现存src/outputs_q4/ 表格和接口。它们与 Q4 Spec 审计所述的旧产物相对应，尚未在 2026-09-25 的代码与公共接口修订后重跑。因此这里均作为历史分析结果陈述，而不作为当前 Spec 下的验收结论。

表 14 base 历史窗口的模型内贡献分解 (2023.50→2025.00; $\Delta S_{\text{obs}} = 24.759$; 旧接口 P4_decomposition.csv)

方法	规模项	时间项	模型变化	时间项占模型变化	90% 区间
M1b	23.063	3.404	26.467	12.86%	6.07%–21.96%
M1c	20.115	6.037	26.153	23.09%	4.17%–45.49%
M2	7.358	6.186	13.544	45.67%	8.68%–59.88%
M3 ($q = 0.75$)	7.398	4.445	11.844	37.53%	–47.38%–58.24%
OLS	7.722	3.235	10.957	29.53%	10.94%–46.13%

表 14 中每种方法的时间份额分母均为各自的 ΔS_{model} 。以 M1b 为例，观测变化为 24.759 分、模型变化为 26.467 分，未解释差额为 -1.708 分；该差额没有分配给规模项或时间项。不同模型给出的时间份额也有明显差异，故不能把某一个份额表述为观测增长的唯一拆分。该分解是对既有面板和映射假设的模型内归因，不是因果效应估计。




图 14 旧轮次面板中的规模状态、能力分数与时间

图 14 展示旧面板下 M1b 曲线与规模状态、时间的联合关系；曲线来自面板内重估映射，不能视为 C6 固定桥接的直接外部验证。旧拟合表中 M1b、M1c 的 R^2 分别为 0.870 和 0.868，OLS 为 0.660 (T7_decomp_fit_quality.csv)。这些拟合指标只描述原面板内拟合，不能证明模型具有时间外预测能力。




图 15 汇总不同模型与时间窗口的分解。C3 敏感性表显示，仅用 C2×C4 base 样本时的算力等效速率为 0.781 dex/年；加入 C3 且权重设为 0.2 和 1.0 时分别为 0.499 和 0.205 dex/年 (T7_c3_sensitivity.csv)。C3 的 Average 与六维均值相关为 0.634，结果说明时间趋势对历史口径和权重较敏感，因此 C3 仅作敏感性对照，不应合并为主估计。

从 2026 起算的前沿情景预测与回测记录 预测以竞赛时间 $T_0 = 2026.75$ (2026-09) 为“现在”，给出未来 12/24 个月 (2027-09/2028-09) 的开放权重前沿条件情景。数据截止日为 2025-03-13，故 2026-09 的“现在”前沿状态本身是模型外推（自数据截止起约 1.5 年），12/24 个月预测实际含约 2.5/3.5 年的总外推，不确定性相应放大；锚点 base 得分为 37.302、chat 为 46.057（数据截止前沿，模型冻结于 2025-03）。

表 15 按算力增速给出的 base 条件分数情景（中位数及 5%–95% 分位；起点 $T_0 = 2026.75$ ，目标 2027-09/2028-09）

算力增速情景	base 12 个月	base 24 个月	24 个月时间项占模型变化
0.60 dex/年	47.42 [38.12, 66.76]	49.38 [37.73, 86.17]	63.07%
0.30 dex/年	46.34 [37.93, 63.43]	48.72 [37.93, 67.80]	70.42%
0.15 dex/年	45.32 [37.73, 58.21]	47.75 [37.92, 63.11]	77.88%

表 15 的分位数来自本轮按 $T_0 = 2026.75$ 重跑的 P4_frontier_forecast.csv，情景增速为输入假设。算力增速从 0.60 降至 0.15 dex/年时，24 个月 base 中位数从 49.38 降至 47.75（减少约 1.63 分），而模型定义的时间项份额由 63.07% 升至 77.88%，与历史窗口“算力放缓时非规模技术进步成为增量主体”的结论一致。chat 的基线 24 个月中位数在后训练线性延续情景为 69.79 [55.28, 94.43]，在后训练平台情景为 58.00 [46.57, 80.07]；差值是情景设定的结果，不能解释为后训练的因果效应。

本轮区间混合了 P2 参数抽样、分解模型簇抽样、后训练增益和面板残差，但没有单独传播 C6 桥接的跨数据域迁移误差，也没有覆盖数据筛选、模型匹配及完整 Q1–Q3 链条的不确定性，因此不是全链不确定区间；且低算力情景的 12/24 个月 base 5% 分位 (37.73/37.92) 仅略高于数据截止锚点 37.302，若“现在”前沿已因 1.5 年外推而抬升，则累

计前沿不下降的约束仍未严格满足。综上，本节数字是按 $T_0 = 2026.75$ 的条件情景预测，不是已验收的全链条前沿预测。




图 16 自数据截止锚点（2025-03）到 2027-09/2028-09 的算力情景分数模拟与回测记录

图 16 展示自数据截止锚点起的条件区间与回测误差（横轴起点为数据截止 2025.25，“现在” 2026.75 位于其与 2027.75 之间）。基于 T8_backtest.csv，在发布日轴上以 2024.5 前的 42 个 base 记录重估后预测 2025.25，M1b 在 0.60 dex/年情景下误差为 -0.805 分；使用该窗口实际算力增速时误差为 $+0.190$ 分。由于算力斜率的估计和面板筛选未形成起点前冻结记录，且审计发现原面板含起点之后的数据，这些数值只作为事后回看，不能称为独立时间外预测验证。

尚未关闭的验收项 截至 2026-09-26，问题四的预测已按 $T_0 = 2026.75$ （现在）重新锚定并重跑，但仍未通过全部验收。要形成现行 Spec 下可用的正文结果，至少需要：按可获得性与许可证分别执行并记录开放权重纳入规则；为每次分析保存一致的数据截止日、 T_0 、输入哈希和仅使用起点前信息的样本清单（前视冻结）；在修复后从原始附件重跑既有主链；独立运行补充链并将其视为代码实现对照而非独立数据验证；对 C6 到榜单映射的迁移误差单独校准和传播；按现行 P2/P3 接口重算，明确 $Q = 1$ 与固定 p^* 、 $m(p^*)$ 的差别及 DEFERRED_Q3 状态；最后验证预测对象究竟是当期新模型水平还是累计最高前沿，并据此检查区间单调性。此外，数据截止 2025-03 与预测起点 2026-09 之间存在约 1.5 年的数据缺口，该缺口的“现在”前沿状态只能靠模型外推。在这些检查完成前，本节中的预测仍属条件情景，不得表述为已验收的全链条前沿预测。

6 模型的检验与灵敏度分析

6.1 模型检验

表 16 汇总了全文的检验。「互相验证」只用于*同一问题、不同假设*的方法对，判据取排序或数值的一致性；上下游分工衔接的方法之间不存在验证关系，本文也不作此类声称。

表 16 全文检验清单

问题	检验对	类型	判据	结果
一	Huber 主分 vs 算术均值/PCA/TOPSIS	方法敏感性	样本级 Spearman	0.9936/0.8166/0.9588; 无质量真值
一	A1 vs A2/A3	冻结扩展检验	KS 的 p 值	0.313/0.220; 未检出明显分布差异
一	六来源候选跨集	冻结规则复检	候选比例与方向	5.00%/4.73%/4.99%; 主要方向有变化
一	clr+Huber vs 裸份额 OLS vs GBDT	1M 留出 (A6/A7)	逐域/等权目标 R^2	0.772/0.260、0.654/0.418、0.923/0.870
一	A1→A18 质量桥接	分层五折 + 六映射域对照	R^2 与 六域 MAE	0.4106 与 0.0365 ($n = 6$); 非独立真值
一	冻结 1M 模型 → 60M → 1B	跨尺度检验 (1B 为独立检验)	等权目标 Spearman	0.523/0.467/0.677; 绝对 Loss 不可直接迁移
一	尺度修正 (1M + 60M 标定, 幂律主口径)	1B 独立检验	逐域 MAE 均值	2.953 → 0.770; 平均预测 Loss 约 3.0 仍高于观测 2.23
一	A12-A15 估算表	一致性对照 (非验证)	排序与绝对误差	目标 Spearman 与 1M 实测相反, 只作反例
二	有地板 vs 无地板 (幂次 M4)	嵌套 F 检验	F 、 p	$F = 307.11$, $p < 10^{-15}$
二	$\kappa_N = \kappa_D$ 、 $\kappa_D = 0$	嵌套 F 检验	F 、 p	57.19 ($p = 3.4 \times 10^{-13}$) 拒绝; 0.63 ($p = 0.43$) 不能拒绝
二	B7 新增 90 点	留出 (半合成插值)	RMSE、偏差	RMSE 0.0531, 平均残差 +0.0219; 高于噪声代理 0.0458
二	解析式 vs 数值解	互相验证	相对误差	替代/闭式误差 $< 10^{-14}$ (替代倍数) / $< 10^{-8}$
二	$Q = 1$ 切片 vs L_0	退化条件核对	平均残差与区间	+0.0036, [-0.0120, +0.0193]
二	B4/B5/B2/B10	外部趋势对照 (仅 $Q = 1$)	Spearman、偏差	0.983/0.959/0.788/1.000; 水平不可比
二	B11/B12 来源审计	元数据核对	步数覆盖、 D 记账	步数覆盖 100%, $D/(\text{steps} \times \text{batch})$ 中位比 0.9986
三	数值解 vs 闭式 N^*	互相验证	相对误差	1.54×10^{-7} (阈值 10^{-5})
三	求解器 vs 粗网格穷举	互相验证	Loss 差与状态一致	最大差 1.80×10^{-5} (阈值 2×10^{-5})
三	剖面导数	有限差分核对	相对误差	4.1×10^{-10} (单点, $C = 10^{20}$)
四	C8 重算 vs C1 榜单	口径核验 (同批数据)	Pearson、MAE	0.9893 – 0.9995; MATH 例外 0.8009/3.4974
四	S 形 vs 线性 vs 常数桥接	留一 (同域)	RMSE	8.079 vs 8.283 vs 9.514
四	分解三口径 (M1b/M2/M3q75)	方法敏感性	技术占比极差	32.81 个百分点, 未过 ± 15 pp 门槛
四	预测回测 (发布日轴)	事后回测	2025.25 误差	M1b -0.805; 朴素线性 +2.651

以下按问题分别说明检验的角色、判据与边界，数值与检验对见表 16。

问题一。检验分三层且互不混用：A2/A3 是冻结评分的扩展检验（ p 值只说明未检出分布差异）；A6/A7 是配比模型的同尺度留出；A8–A11 是跨尺度检验，其中只有 A10/A11 (1B) 完全不参与估计，A8/A9 承担尺度修正的标定。需特别说明的是，由于依据 A6/A7 的表现选择 GBDT 作搜索交叉评估，该留出集不能再充当最终候选收益的独立验证；候选收益仍是 1M 代理模型内的预测差异。A12–A15 是估算/外推表（A12/A14 的配比逐行取自 A4 子集，A13/A15 由三尺度幂律外推生成），与修正模型的接近只是一致性对照，不是独立验证；估算表还隐含一个”大尺度排序反转”，而同一批配比从 1M 到 60M 的实测排序是保持的，该反转没有观测支持。

问题二。质量参数只用 B6（半合成）估计，留出只用 B7 相对 B6 新增的 90 点（ $Q = 0.5$ 、 0.7 ，覆盖全部 45 个 (N, D) 格，属 Q 方向插值）。B2 为半合成、B3 由 B1 插值派生、B10 本身即公式估算，因此这三项只能核对实现与趋势，不能证明质量项可泛化到真实训练；B4 的 57 点中有 13 点在对数尺度上距 B1 小于 0.05 dex，剔除后 44 点结果不变（Spearman 0.975、偏差 +0.176）。B8 与 B6/B7 的 Loss 方向相反（64.26% 的点低于 E ），只作反例。B11/B12 审计确认 B1 的 8 个名义规模、147 个步数均被 B12 覆盖且 8 个模型都在 B11 中，因此 B1 的训练设定是真实的，而损失数值是按公开公式生成的；B11 只含 3 个模型族，B4 的 12 族中仅覆盖 8.33%。

问题三。互验设计为：数值最优解与 $\Delta g = 0$ 的闭式 N^* 对照；求解器与独立粗网格穷举对照（Loss 差与状态判定）； Φ 的剖面导数与有限差分对照。按幂次主式重跑后，闭式 N^* 相对误差 1.54×10^{-7} （阈值 10^{-5} ），求解器与粗网格最大 Loss 差 1.80×10^{-5} （阈值 2×10^{-5} ），预算残差与份额和误差均小于 10^{-9} ，搜索边界未截住主解；锚点映射 $Q_0 = 1$ 记为 NO_QUALITY_RANGE、pile_cc 越界记为 OUT_OF_SUPPORT，均按规范验收。

问题四。C8 重算与 C1 的一致性是同批数据的口径核验（MATH 例外未解释）；桥接的留一是同一数据域内的留一，不是时间外留出；分解的三口径差异是方法敏感性而非验证；回测是事后回测，且重估样本未严格截在预测起点之前。因此问题四没有独立检验层结论，所有结论均标注为拟合层或条件外推层。

6.2 灵敏度与稳健性分析

问题一。六来源分歧阈值取同域 P90/P95/P97.5 时，候选比例约为 10.00%/5.00%/2.50%（A2 为 9.19%/4.73%/2.00%，A3 为 9.74%/4.99%/2.44%），数量级随阈值显著变化，说明这些数值只指导人工复核工作量，不能解释为真实冲突率随阈值变化。来源一致性加权实验分 Q_{v2} 与主分的秩相关为 0.9547/0.9207/0.9395、域级排序不变，但由于没有独立标签证明新权重更准确，主分不因此改变（T3_Q_v2_conflict_diff.csv，图 23）。分子与方法层面：单指标极端扰动下主分变动约小 30%；配比搜索在 13 域等权与 pile_cc 单域两个目标下给出不同候选，故评价目标必须在搜索前确定；质量交互项仅在 6/13 域显著且方向不一，故不构成质量效应结论。

问题二。去掉地板后，质量 +0.1 在 $N = 10^{11}$ 、 $D = 3 \times 10^{11}$ 处的等效参数倍数由约 3.0 降到 1.3–1.5，方向不变； κ_N 、 k_0 的 95% 区间为 [0.1264, 0.1568]、[0.2013, 0.2554]， κ_D 的区间含 0；主式的形状代价是留出 RMSE 高于线性对照（0.0531 对 0.0416）与噪声代理（0.0458）； $C = 10^{19}$ 时提质是否划算取决于成本函数， $C \geq 10^{20}$ 后三种 $g(Q)$ 都是提质更划

算 (T33b_quality_breakeven.csv 的 R_at_Q0 列)。高预算端的倍数与地板份额依赖半合成地板的外推, 属假设下的推论。

问题三。敏感性覆盖三类成本函数、C7 五档上下文长度、 η 的三档扰动 (题设固定 2×10^{-4} , 另两档为本项目扰动情景)、P2 参数重抽样、主/锚点两种质量映射、固定配比乘子 $m=1$ 与 H_{tot} 对照。与预算、成本函数和规模都无关的解析结论是注意力与训练成本之比恒为 $\eta L_{\text{ctx}}/6$, 其临界值 $L_{\text{ctx}}^{\text{crit}} = 30000$ token; 注意力份额随 L_{ctx} 增大而上升, $L_{\text{ctx}} = 32768$ 时已接近或超过训练份额。临界预算的 P2 bootstrap 区间 (离开下界, 5%-95%) 为指数型 [19.038, 19.084]、幂函数型 [19.503, 19.560]、对数型 [18.539, 18.620]; 配比重抽样 (P1 逐次重抽样, 200 次) 的区间为指数型 [19.053, 19.065]、幂函数型 [19.525, 19.534]、对数型 [18.579, 18.580], 远窄于 P2 参数区间, 属次要不确定性来源。

问题四。桥接的 Medium 层权重取 0.25-1.0 时 $S(1.85)$ 的变化不到 0.4 分, 但仅用 High 层时上平台降到 6.349, 说明上升段完全依赖 Medium 层。C3 历史点的权重取 0.2 与 1.0 时, 技术进步率为 0.499 与 0.205 dex/yr (不含 C3 时为 0.781), 因此时间估计对是否纳入混杂口径的历史点很敏感, C3 只作有标记的敏感性。分解换用 2024→2025 与 2024.5→2025.25 两个窗口时, M1b 的技术占比为 7.06% 与 8.18%, ”规模为主”的定性结论不变。预测对后训练增益是否延续最敏感 (约 6.8 分), 大于算力情景之间的差异 (约 2 分)。

7 模型的评价与推广

7.1 模型的优点

1. 唯一质量口径与证据分层。问题一的文档、领域、桥接标签与配比加权质量使用同一 CRITIC 加权 Huber 主分; A1 拟合、A2/A3 扩展、A6/A7 留出、A8/A9 标定、A10/A11 独立检验、A12-A15 估算表分开报告, A12-A15 明确标注为非观测。2. 训练与检验边界可追溯。问题二只用 B6 估计质量参数并选择模型, B7 相对 B6 新增的 90 点作留出; 配比通道的参数只由 1M 训练行确定, A6-A11 只用于评估。3. 形式与阈值可追溯。问题一的六来源阈值取 A1 同域 P95, 桥接以分层五折比较 Ridge 与 GBDT; 问题三的结构转移由质量约束的活跃状态定义, 并区分局部一阶根与全局切换; 问题二的主式是显式指定的并同时报告交叉验证更优的线性对照。4. 解析与数值互验。问题二的替代条件、 N^* 与算力等价倍数、问题三的降维闭式与 Φ 判据、问题四的 S 形桥接与 Shapley 分解都有闭式或可核验形式, 并与数值结果逐项对照。5. 职责分离。问题一先固定主分, 再报告六来源分歧与旧法对照; 阈值敏感性与实验加权分均不回写主评分, 避免把筛查预算当作真实冲突率。

7.2 模型的局限与改进方向

1. 无独立质量真值。问题一只报告方法一致性、扰动稳健性与下游敏感性, 不能给出质量准确率; 17 域中 11 域的质量依赖文本桥接 (五折 $R^2 = 0.4106$), 其区间不含模型选择与跨域偏差, ubuntu_irc (16 篇)、philpapers (63 篇) 须低置信使用。2. 质量参数的证据来自半合成数据。 κ_N, κ_D, k_0 只由 B6 (半合成, 最大规模约 12B) 估计, B7 留出也是 Q 方向插值; 主式是指定的幂次, 其留出 RMSE 高于线性对照与噪声代理; κ_D 未被单独识别。高预算端的”地板占可约损失约 33%”与”提质远比扩参数划算”是把该地板外推出去的结果。3. 跨尺度外推的幅度偏差。1B 独立检验显示尺度修正把绝对误差降低约 74%, 但平均预测仍高于观测, 且配比效应幅度在 1B 缩到约六成, 说明两档规模的单参数缩放外推

(对数线性或幂律)都不足以刻画曲率,而曲率参数在两档数据下欠定。4. 问题四的口径尚未由重跑固定。问题三已按幂次主式重跑并通过求解核验,配比与P2 参数两类不确定性已分别传播(但未联合抽样,严格的全链条联合区间仍未闭合);问题四预测已重锚定到 $T_0 = 2026.75$,但数据截止2025-03 存在约1.5 年缺口、主面板未执行严格的开放权重纳入规则、C6 桥接的迁移误差未进入预测区间、且存在前视,主链未在路径修复后从原始附件重跑。5. 问题四的方法分歧与占比口径。C6 的High 层只有7 点且全部位于底噪区,上升段依赖Medium 层;分解三口径的技术占比极差为32.81 个百分点,是本文最大的不确定性来源;所有占比的分母是模型解释增量而非观测增量,观测与模型增量不闭合。6. 预测不含离散突破。问题四的条件预测不包含新架构等非平滑变化;累计前沿区间在部分情景出现下界低于锚点,与累计定义冲突。

改进方向。

1. 为11 个inferred 域增补质量标签或模型评分信号,重新校准并检验桥接误差;对配比与P2 参数两类不确定性做联合抽样,给出严格闭合的全链条区间。2. 取得真实的跨质量、跨规模训练日志后替换B6 重估 k_0 与 κ_N ,并允许配比强度随 $\log N$ 变化;在得到真正的跨尺度配比试验前,问题三应对H_red 与H_tot 各算一遍。3. 对配比与P2 参数两类不确定性做联合抽样,闭合问题三临界预算的全链条区间;问题三的幂次主式求解已按现行Spec 重跑并通过求解核验。4. 问题四先执行明确的开放权重纳入规则(报告纳入前后样本量与结果敏感性),把建模、情景校准与回测样本全部截在各自预测起点之前,把C6 桥接的bootstrap 与残差作为独立不确定性通道进入区间,并统一占比的分母声明。5. 获得更多同验证集的Loss-Benchmark 对,以缩小问题四的结构口径与线性口径分歧。

7.3 模型的推广

“经典基线+质量修正+配比乘子”的标度律结构可推广到其他数据受限的资源配置问题(去重、合成数据、多模态对齐都能写成可约损失上的乘子与不随规模消失的地板);“约束取等后解析消元+活跃约束状态分类”的降维方法适用于含多种数据处理成本的预算优化;“分层S 形桥接+连续时间项+Shapley 分解”的框架适用于其他存在能力饱和的技术演进分析。推广时须保持同一纪律:明确数据的证据等级,把半合成、估算与外推数据标注为假设支撑,而不是观测验证。

8 结论

本文围绕“算力约束下如何配置资源以提升大语言模型能力”,建立了四个递进衔接的模型,结论及其证据范围如下。

问题一。以A1 冻结的CRITIC 加权Huber 中心作为唯一质量口径,把22 个字段展开为25 项指标,得到文档、领域与语料质量;六来源诊断在A1 标出约5% 的高分歧复核候选(多来源对立1.36%),在三集上的候选比例稳定(5.00%/4.73%/4.99%),但主要对立方向有变化,且没有人工质量真值,不把它当作真实冲突率或据此改分。17 域质量由映射与文本桥接补齐(五折 $R^2 = 0.4106$,六映射域MAE 0.0365)。配比模型给出 17×13 局部迁移效应;推荐候选 $\mathbf{p}^*$ 在1M 代理模型下相对均匀配比预测降损9.47% (bootstrap 中位数9.54%、95% 区间[7.82%, 11.16%]),这是代理模型预测,不是重新训练的实测收益。域质量与训练边际价值的秩相关为-0.211,说明单凭质量分不能代替配比实验。

问题二。建立了幂次广义标度律 $L = E + k_0(1 - Q) + [AN^{-\alpha}Q^{-\kappa_N} + BD^{-\beta}Q^{-\kappa_D}] \exp(s_{\text{red}}\tilde{\varphi}(\mathbf{p}))$ ，其中 $E = 1.6901$ 、 $A = 406.39$ 、 $\alpha = 0.34$ 、 $B = 410.59$ 、 $\beta = 0.28$ 由 B1 估计， $\kappa_N = 0.1416$ 、 $\kappa_D = 0.0112$ 、 $k_0 = 0.2280$ 、 $s_{\text{red}} = 1.4996$ 、 $Q_0 = 0.6623836418229694$ (质量参数来自半合成 B6，留出误差高于噪声代理)。在参照点上质量弹性约为参数弹性的 1.62 倍 (其中约 73% 来自地板)；固定 $D = 3 \times 10^{11}$ ，质量提高 0.1 在 $N = 10^9$ 处须把参数扩大为原来的 1.299 倍、在 $N = 10^{11}$ 处约 3.07 倍；沿算力前沿， Q 从 0.7 到 0.8 相当于算力乘 1.191/1.485/2.134 ($C = 10^{19}/10^{22}/10^{24}$)。 $C = 10^{19}$ 时指数型与幂函数型成本下扩参数更划算， $C \geq 10^{20}$ 后三者都是提质更划算。跨尺度上，配比效应的观测强度落在两个假设之间 (60M 为 0.913、1B 为 0.612)，故其作用只作探索性通道并以下界/上界报告。

问题三。把约束取等后解析消元，问题降为 $(\log_{10} N, Q)$ 的二维有界优化；以质量约束的活跃状态定义结构性转移，并以 $\Phi(C; Q) = 1$ 作为固定 Q 下的局部一阶必要条件 (其导数已做单点有限差分核验，相对误差约 4.1×10^{-10})。上下文长度存在与预算无关的解析临界值 $L_{\text{ctx}}^{\text{crit}} = 6/\eta = 30000$ token。数值上， $C = 10^{19}$ 时指数型与幂函数型成本下最优质量停留在下界 (不提质)、对数型成本直接提满； $C = 10^{22}, 10^{24}$ 三种成本函数下均提满 $Q^* = 1$ 。 $L_{\text{ctx}} = 2048$ 下离开下界的临界预算 ($\log_{10} C$) 约为 19.06 (指数型)、19.53 (幂函数型)、18.58 (对数型)，说明提质是否划算存在随成本函数形状移动的预算阈值；最优配置、临界预算与成本份额的具体数值见 5.4.3。

问题四。用”标度律 + S 形桥接 + 连续时间项”的结构模型分解历史前沿增长：在 2023.50 $\rightarrow$ 2025.00 窗口，base 前沿观测变化 24.759 分，模型解释的规模贡献 23.063、技术贡献 3.404，技术占比 12.86% (90% 区间 6.07%–21.96%)；换算为算力等效速率约 0.290 dex/yr。线性对照口径的技术占比为 29.5%–48.5%，三口径极差 32.81 个百分点，故结论表述为”规模扩张为主、非规模技术进步约 13%–23% (结构口径)，线性口径为其上界参考”，且占比分母为模型解释增量。能力口径上，去饱和综合分在 2024-06 ~ 2025-03 由 26.36 升至 39.06 (+48.19%)，比包含饱和任务的 Average (+29.53%) 反映更快的真实进展，但该副分依赖起点与任务选择。在算力增速由 0.60 降至 0.15 dex/yr 的情景下，以 $T_0 = 2026.75$ 为起点的 24 个月 base 中位数为 49.38，技术进步的增量占比由 63.07% 升至 77.88%，即算力放缓时非规模技术进步成为增量主体；该结果的数据截止为 2025-03，2026-09 起点本身为约 1.5 年的模型外推，且不含 C6 桥接迁移误差，属条件情景预测而非已验收区间。

四问共同指向一个判断：数据质量与领域配比是与算力并列的一等资源。在低预算段，预算的边际价值主要体现在模型规模上；当预算提高到质量收益足以补偿提质开销后，提质与配比优化的优先级上升；而算力增长放缓时，能力增长将越来越依赖非规模技术进步。上述判断中，涉及质量参数、配比通道与预测的定量部分都受半合成数据、探索性通道、数据缺口外推与未传播桥接误差的限制，其适用范围已在 7.2 逐条写明。

参考文献

- [1] Hoffmann J, Borgeaud S, Mensch A, et al. Training compute-optimal large language models[C]//Advances in Neural Information Processing Systems 35 (NeurIPS). 2022.
- [2] Bahri Y, Dyer E, Kaplan J, et al. Explaining neural scaling laws[J]. Proceedings of the National Academy of Sciences, 2024, 121(27): e2311878121.

- [3] Diakoulaki D, Mavrotas G, Papayannakis L. Determining objective weights in multiple criteria problems: The CRITIC method[J]. Computers & Operations Research, 1995, 22(7): 763–770.
- [4] Huber P J. Robust estimation of a location parameter[J]. The Annals of Mathematical Statistics, 1964, 35(1): 73–101.
- [5] Penedo G, et al. The FineWeb datasets: Decanting the web for the finest text data at scale[C]//NeurIPS Datasets and Benchmarks Track. 2024.
- [6] Aitchison J. The Statistical Analysis of Compositional Data[M]. London: Chapman & Hall, 1986.
- [7] Xia M, et al. RegMix: Data mixture as regression for language model pre-training[C]//International Conference on Machine Learning (ICML). 2024.
- [8] Biderman S, et al. Pythia: A suite for analyzing large language models across training and scaling[C]//International Conference on Machine Learning (ICML). 2023.
- [9] Muennighoff N, et al. Scaling data-constrained language models[C]//Advances in Neural Information Processing Systems 36 (NeurIPS). 2023.
- [10] Schaeffer R, Miranda B, Koyejo S. Are emergent abilities of large language models a mirage?[C]//Advances in Neural Information Processing Systems 36 (NeurIPS). 2023.
- [11] Shapley L S. A value for n -person games[M]//Contributions to the Theory of Games II. Princeton: Princeton University Press, 1953: 307–317.
- [12] Shafer G. A Mathematical Theory of Evidence[M]. Princeton: Princeton University Press, 1976.
- [13] Subramanyam A, Chen Y, Grossman R L. Scaling laws revisited: Modeling the role of data quality in language model pretraining[J]. arXiv preprint arXiv:2510.03313, 2025.
- [14] Xu Z, Wu S, Cho H, et al. Data-constrained language model pretraining: Improved regularization and scaling laws[J]. arXiv preprint arXiv:2606.06888, 2026.
- [15] Lovelace J, Belardi C, Kundurthy S, et al. Prescriptive scaling laws for data constrained training[J]. arXiv preprint arXiv:2605.01640, 2026.

附录 A 补充材料与程序

A.1 支撑材料清单与运行说明

正文各结论均按证据分层陈述：解析推导、拟合估计、尺度标定、留出检验、独立检验、评分后诊断、半合成数据、外推或估算，以及历史口径对照，其性质与边界已在正文相应处注明；半合成、估算与外推数据不作为观测验证。正文中*.csv、*.json、*.npz形式的文件名是相应结果的落盘名称：数据表在src/outputs_qN/tables/，跨间接口在src/outputs_qN/interface/，图在src/outputs_qN/figures/；每张表与每幅图的标题内注明其数据来源文件。

问题一：src/code_q1/q1_00_common.py（公共路径与工具）→ q1_01_extract.py → q1_02_quality.py → q1_03_conflict.py、q1_04_bridge.py → q1_05_mixture.py → q1_06_scale.py、q1_07_optimal.py → q1_08_audit.py；环境Python 3.12.13、NumPy 2.4.4、pandas 3.0.2，不依赖SciPy与scikit-learn。

问题二：src/code_q2/q2_01_fit.py、q2_02_theory.py、q2_03_economics.py；环境Python 3.12.7、NumPy 1.26.4、pandas 2.2.2、SciPy 1.13.1，随机种子2026；只读src/outputs_q1/interface/，不读附件A原始表。

问题三：src/code_q3/q3_00_model.py、q3_01_optimize.py、q3_02_transition.py、q3_03_mixture_joint.py；已按现行Spec的幂次目标式与配比乘子 m_* 重跑（manifest见P3_run_manifest.json，北京时间2026-09-26 11:37），q3_03运行即退出、不作主结论。

问题四：src/code_q4/q4_01_c8_parse.py → q4_02_saturation.py → q4_03_bridge.py → q4_04_decomp.py → q4_05_forecast.py → q4_99_check_report.py；q4_99_check_report.py的15项自检全部通过。

注：以上脚本路径与随机种子以各问Spec的「当前实现差异」与修订历史为准；本节只登记，不复述Spec。

A.2 核心程序

(1) CRITIC 权重与加权Huber主分 (code_q1/q1_02_quality.py 节选)

```
def fit_critic(self, Z):
    sd = Z.std(axis=0, ddof=1)                # contrast intensity
    R = np.corrcoef(Z.T)                     # indicator correlation
    C = sd * (1 - R).sum(axis=1)              # information content C_j
    self.critic_w = C / C.sum()
    return self.critic_w

def fit_delta(self, Z):                      # A1 weighted-MAD rule
    center = weighted_median(Z, self.critic_w)
    dev = np.abs(Z - center[:, None])
    mad = weighted_median(dev, self.critic_w)
    self.delta = float(np.clip(1.345 * 1.4826 * np.median(mad), .01, 1.0))
    return self.delta
```

```
def score(self, Z):
    # fixed weights and delta
    return weighted_huber_center(Z, self.critic_w, self.delta)
```

(2) 问题三向量化求解器 (code_q3/q3_00_model.py 节选, 按现行 Spec 幂次目标式)

注: 下列节选与现行 src/code_q3/q3_00_model.py 一致——幂次质量乘子 $Q^{-\kappa}$ 与固定配比乘子 $m_* = \exp\{s_{\text{red}}\tilde{\varphi}(\mathbf{p}^*)\} \approx 0.8989423$, 地板 $k_0(1-Q)$ 在括号外; q3_03 已改为运行即退出, 不作主结论。内层 $\log_{10} N$ 黄金分割与三级网格加密的结构不变, 此处只列出质量式与 Φ 判据的核心函数。

```
def hN(Q, p=PAR):
    # v5 power multiplier (drop linear 1+k
    (1-Q))
    return Q ** -p["kappa_N"]

def hD(Q, p=PAR):
    return Q ** -p["kappa_D"]

def loss(N, D, Q, p=PAR, m=M_STAR):
    """v5: floor k0(1-Q) outside bracket; mixture multiplier m only on scale
    terms"""
    return (p["E"] + p["k0"] * (1.0 - Q)
            + m * (p["A"] * hN(Q, p) * N ** -p["al"]
                    + p["B"] * hD(Q, p) * D ** -p["be"]))

def phi_ratio(C, g, Lctx, Qeval, Q0, p=PAR, eta=ETA, m=M_STAR):
    """v5 complete Phi at the fixed-Q optimal (N,D):
    Phi = [k0 + (m/Q)(kN TN + kD TD)] * S / [m * beta * TD * g'(Q)],
    S = (6+eta*L_ctx)N + dg,  TN = A N^-al Q^-kN,  TD = B D^-be Q^-kD"""
    kappa = 6 + eta * Lctx
    dg = max(g(Qeval) - g(Q0), 0.0)
    _, x = _profile(C, Qeval, dg, kappa, p, m=m) # inner golden section (
    unchanged)
    N = 10.0 ** x; D = C / (kappa * N + dg)
    TN = p["A"] * N ** -p["al"] * hN(Qeval, p) # TN = A N^-al Q^-kN
    TD = p["B"] * D ** -p["be"] * hD(Qeval, p) # TD = B D^-be Q^-kD
    S = kappa * N + dg
    num = (p["k0"] + m / Qeval * (p["kappa_N"] * TN + p["kappa_D"] * TD)) * S
    den = m * p["be"] * TD * g_prime(Qeval)
    return float(num / den) # C_crit solves Phi(C) = 1
```

(3) 结构分解模型与 Shapley 分解 (code_q4/q4_04_decomp.py 节选)

```
def f_add(p, L, t):
    # M1b: S-bridge + linear tech
    term
    return p["lo"] + p["amp"] * sig(L, p["k"], p["L0"]) + p["tau"] * t
```

```
def shapley(fun, L0, t0, L1, t1):
    """two-factor Shapley: scale (L_hat) vs technology (t)"""
    sc = 0.5 * ((fun(L1, t0) - fun(L0, t0)) + (fun(L1, t1) - fun(L0, t1)))
    te = 0.5 * ((fun(L0, t1) - fun(L0, t0)) + (fun(L1, t1) - fun(L1, t0)))
    return sc, te
```

A.3 诊断与敏感性图表

本节的图记录筛查阈值、来源一致性、历史口径对照与尺度修正的过程量，正文只引用其结论，不参与评分、筛选或参数估计。




图 17 A1 六来源内部跨度与一致性对照




图 18 六来源对立方向的加权份额




图 19 候选比例对筛查阈值的敏感性




图 20 六来源候选与历史四组候选的重合度




图 21 按前 5% 配平预算后的重合度与 Kappa




图 22 来源一致性加权实验分与主分的域级中位数对照




图 23 来源一致性加权实验分与主分的冲突文档差值分布

A.4 AI 使用披露

依据赛题“AI 使用规范”，现披露如下。

所用工具：Claude（Anthropic）、Kimi Code（Kimi）。

使用环节与贡献范围：(1) 资料整理与概念理解：梳理赛题附件的字段结构与《数据说明》中的条目；(2) 代码编写与调试：数据读取、向量化求解器、绘图脚本的编写与报错排查；(3) 结果核对：编写自动核对脚本，把报告中的数字与程序输出逐项比对；(4) 排版与文字：LaTeX 排版、图表整理与语句润色。上述 AI 产出的代码、数值与文字均经参赛队逐项复核。

参赛队的工作与责任：模型路线的选择（证据分层、质量项形式由交叉验证裁决、结构性转移按 KKT 活跃集定义、分解方法并列报告等）、公式推导与结论判断由参赛队确定，并对 AI 输出的全部代码与数值逐项运行、核验。文中理论、公式与结论均引用正式文献或由附件数据验证，未以 AI 输出作为学术依据。全部数值结果可由随文代码在附件数据上复现。