

算力约束下提升大语言模型能力的资源配置建模

——问题一、二：数据质量评价、领域配比与广义标度律

2026 年 9 月 23 日

摘 要

本文研究预训练语料的质量评价、领域配比及其与模型规模的联合作用规律。**问题一**：对 27.2 万篇文档的 22 个异质质量信号，建立“定向标量化—域内稳健归一—CRITIC 客观赋权—加权几何平均”的评分管线，得到样本级与域级连续质量分 Q ；以四组信号的域内分位排名极差定义指标冲突，用冲突率—阈值曲线自适应确定阈值 $\tau = 0.75$ ，测得冲突率 21.5% 并在两个全量扩展集上复现，采用 Huber 连续降权消解；对 512 组小模型配比实验做中心对数比 (clr) 变换后回归，检验集 R^2 由裸回归的 0.654 提升至 0.772，进而给出 17×13 领域迁移矩阵与最优配比 p^* （相对均匀配比预测降损 9.9%，95% CI [9.7%, 14.1%]）。域级质量分与训练边际价值的秩相关仅 -0.06 ，定量证实“内在质量不等于训练价值”。**问题二**：数据审计发现附件 B 的质量实验可被“基线标度律 + 加性质量惩罚”以噪声水平精确刻画；五种候选形式交叉验证表明加性形式 (cv-RMSE 0.051) 显著优于有效数据乘子族 (0.099–0.105)，据此建立广义标度律 $L = E + \tilde{A}(Q)N^{-\alpha} + BD^{-\beta} + (1-Q)k_0$ ， $\tilde{A}(Q) = A + k_1(1-Q)$ ，并给出弹性、质量—参数等效替代、质量地板与算力最优配置 $N^*(C, Q)$ 四组闭式解析结果，解析解与数值优化互验相对误差低于 10^{-6} 。主要结论：质量弹性约为规模弹性的 4 倍；质量提升 0.1 在 10^{10} 参数规模等效于参数扩大 1.64 倍；低质量造成规模不可弥补的损失下界 $(1-Q)k_0$ ；数据质量越高，算力最优配置越偏向“小模型、多数据”。

关键词：数据质量评价；指标冲突；成分数据回归；广义标度律；算力最优配置

1 问题重述

1.1 问题背景

大语言模型能力的提升依赖参数规模 N 、训练数据量 D 、数据质量 Q 与领域配比 p 的协同配置，而算力预算约束使四者之间存在权衡。工业实践 (FineWeb-Edu、DCLM、RegMix 等) 表明：数据侧工程能以远低于扩大规模的成本换取同等能力增益，但“质量”缺乏可进入数学模型的连续度量，配比决策也长期依赖人工经验。赛题提供三组附件：A（质量信号与配比实验）、B（标度律观测）、C（能力评测），要求以可核验的建模回答资源配置问题。

1.2 问题描述

问题一：基于附件 A 的 22 个质量指标，(a) 建立样本级与域级综合质量评分；(b) 定义并消解指标间冲突，在扩展集上复验；(c) 建立 17 域训练配比与 13 个验证域交叉熵损失的定量关系，用三种规模的留出实验验证，并讨论向 10B/70B 外推的稳健性。

问题二：融合附件 B 的多来源数据，将问题一输出的质量分 Q 与配比 p 引入经典标度律 $L = E + AN^{-\alpha} + BD^{-\beta}$ ，建立广义损失律；给出各因素的弹性与相互替代关系（如“质量提高 0.1 等效于增加多少参数”）。

问题三、四（后续报告）：算力预算约束下的资源配置优化与结构性转移识别；能力增长的规模/非规模因素分解与前沿预测。

2 问题分析

2.1 总体思路

四问构成递进链：问题一把数据侧压缩为两个可注入的量——连续质量分 Q 与配比—损失关系 $f(p)$ ；问题二将其嵌入标度律得到 $L(N, D, Q, p)$ ；问题三在成本约束下优化该损失；问题四将损失翻译为能力得分。因此问题一的每项产出都须落盘为明确接口（表 5），问题二的自变量口径须与问题一逐字一致。

数据处理遵循**证据分层**原则：直接观测（A1–A11）优先支撑主结论；半合成与插值数据（B2、B6–B8）用于形式选择并明示假设；外推生成数据（A12–A15、B10）只作稳健性讨论，不充当验证。建模顺序为：数据审计 → 质量评分与冲突消解 → 配比回归与跨尺度验证 → 标度律形式选择与拟合 → 解析理论与互验。

2.2 各问题的关键难点

问题一的难点：其一，22 个指标形态异质（8 个 logits 列表字段、3 个负对数比、15 个规则统计量），方向与量纲不一，且 github/arxiv 等域的指标基线存在结构性差异，直接聚合会把域间差异误判为质量差异；其二，冲突若用预设阈值定义会陷入“定义决定结论”的循环论证；其三，配比是成分数据（ $\sum_i p_i = 1$ ），直接回归产生闭合效应伪相关；其四，17 个配比域中仅 6 个有官方质量映射，其余 11 个域需自建关联。

问题二的难点：其一，附件 B 各表来源与噪声水平差异极大，须先审计再拟合，避免把不同源数据拼成同一因变量；其二，质量进入损失的函数形式（加性惩罚 vs 有效数据乘子）不能先验指定，须由数据选择；其三，附件 B 的 Q 与问题一的 Q 同范围不同尺度，须建立口径换算并作为显式假设。

3 模型假设

假设 1 (质量信号可信). 附件 A 的 22 个质量信号按其原始定义（*Meta-rater* 信号体系）如实计算，logits 字段经 *softmax* 后的概率/期望具有序数意义。适用条件：仅用于文档间相对比较，不解释为绝对语言学度量。

假设 2 (小代理可迁移). 配比对各验证域损失的排序效应在 $1M-1B$ 参数范围内近似保持。本假设不作先验接受，由三尺度留出集实证检验 (§5.5)，检验结果决定其适用边界。

假设 3 (质量口径锚定). 附件 B 的 Q 以 *Pythia* 所用 *Pile* 语料为 $Q = 1$ 锚点（附件内证据： $Q = 1$ 处 $B6/B7$ 与 $B1$ 基线之差 ≈ 0.004 ）。与问题一绝对质量分的换算为 $Q_B = Q_1/Q_{\text{ref}}$ ， $Q_{\text{ref}} = \bar{Q}(p_{\text{pile}}) = 0.5608$ 。敏感性分析对 Q_{ref} 取双口径。

假设 4 (评价权重固定). 汇总 13 个验证域损失的评价权重 w 取等权 (主口径) 并全文唯一; w 与被优化的配比 p 严格分离, 避免”改考卷”与”改备考策略”混淆。 $pile_cc$ 单域口径作为副口径报告。

假设 5 (成本代理有效). 问题二仅使用 $C \approx 6ND$ 作为训练算力代理 (用于最优配置推导); 质量成本与注意力成本留待问题三引入。

4 符号说明

表 1: 主要符号及含义

符号	含义	单位/范围
N, D	模型参数量、训练 token 数	个 (代入公式用实际值)
Q, Q_B	综合质量分 (问题一口径)、B 口径换算分	$[0, 1]$; $Q_B = Q/0.5608$
$z_i, Q(x_i)$	文档 i 的 25 维标准化指标、样本级质量分	$[0, 1]$
$\bar{Q}_d$	域 d 的域级质量分 (中位数主口径)	$[0, 1]$
$c(x), \tau$	文档冲突度、自适应冲突阈值	$[0, 1]$
$p \in \Delta^{16}$	17 域训练配比, $p_i \geq 0, \sum_i p_i = 1$	单纯形
$z = \text{clr}(p)$	配比的中心对数比坐标	$\mathbb{R}^{17}, \sum z_i = 0$
L_v, L_{tgt}	验证域 v 的交叉熵、按 w 加权的目标损失	nats
T_{iv}	迁移矩阵: $\partial \ln L_v / \partial p_i$ (均匀配比处)	—
ν_d	域 d 的训练边际价值	—
E, A, α, B, β	标度律基线参数	见表 3
k_0, k_1	质量惩罚的常数项与规模交互系数	同上
$\tilde{A}(Q)$	$A + k_1(1 - Q)$, 质量修正后的 N 项系数	—
$\varepsilon_N, \varepsilon_D, \varepsilon_Q$	损失对各因素的弹性	—
C	训练算力预算 ($C \approx 6ND$)	FLOPs

仅列全文反复使用的符号, 局部符号在首次出现处说明。

5 模型的建立与求解

5.1 数据预处理与审计

数据审计发现 (先于一切建模)。逐表核对附件实际文件得到四个影响建模路线的事实: (i) A10/A11 (1B 验证集) 配比表 64 行、损失表 63 行, 按 index 取交集使用; (ii) A16 的 17 域映射中仅 3 个 direct、3 个 near_direct, 11 个域无质量映射 (inferred); (iii) B1 (Pythia 训练日志 1,176 行) 可被三参数形式拟合至 $\text{RMSE} = 1.5 \times 10^{-4}$, 呈公式生成特征; (iv) B8 与 B6/B7 在相同 (N, D, Q) 点损失相关 -0.03 且方向相反, 两表不可比, B8 不参与联合拟合。

指标展开。22 个字段按输出形态展开为 25 个指标: 二元 logits (fluency_en、ad_en) 取 softmax 后正类概率; 6 档 logits (modernbert 四字段) 取期望档位 $\sum_k k \sigma_k / 5$; qurater 拆为写作/专业/事实/教育四个独立维度; fineweb_edu 直取; DSIR 三项为负对数比, 仅域内可比; 15 个规则统计量按定义方向处理。

域内稳健归一。每域每指标依次做: 适宜区间型指标 (词数、词长、一元熵等) 以距域内中位数偏离改单峰; 重尾指标先 $\log(1 + x)$; 1%/99% 缩尾; 域内 Min-Max 至 $[0, 1]$; 负向指标取补。全部

变换参数在 A1 上估计后冻结，原样应用于 A2/A3——否则管线差异会混入抽样偏差，破坏对照的归因（这也是“同一管线”为题目强制的原因）。A1–A3 缺失率均低于 0.03%，以域内中位数填补。

5.2 问题一 (a)：综合质量评分

主线：CRITIC 客观赋权 + 加权几何平均。 指标 j 的信息量与权重为

$$C_j = \sigma_j \sum_{k=1}^{25} (1 - r_{jk}), \quad w_j = C_j / \sum_k C_k, \quad Q(x) = \prod_{j=1}^{25} z_j(x)^{w_j}, \quad (1)$$

其中 σ_j 为对比强度、 r_{jk} 为指标相关。选 CRITIC 而非熵权，是因其额外惩罚冗余指标（如 `fluency` 与 `readability` 高相关时权重自动分摊）；选几何平均而非算术平均，是因乘法形式实现“短板支配”——广告概率经补转换趋零时总分被显著压低，与 FineWeb-Edu/DCLM 的一票否决式过滤实践的方向一致但保留连续性。

对照方法组。 等权几何平均、PCA（取累计方差 80.6% 的 10 个主成分、按方差贡献率合成，载荷矩阵输出至附表）、TOPSIS（以 CRITIC 权重加权的理想解贴近度）、K-means 三档聚类（仅给“优/普通/劣”相对档位）。样本级排序一致性：CRITIC 对等权 Spearman 0.991、对 TOPSIS 0.946、对 PCA 0.871——三套互不蕴含的赋权假设给出高度一致的排序，说明质量结构是数据内在的而非赋权人为制造；K-means 的档位边界与连续分的分位一致，但聚类无法输出问题三成本函数所需的连续 Q ，故仅作佐证。

域级聚合与抽样代表性。 域级分取中位数主口径并报 token 加权副口径与 bootstrap 95% CI ($B=2000$)。七域排序：arxiv 0.713 > stackexchange 0.590 > commoncrawl 0.557 > github 0.533 > book 0.511 > c4 0.499 > wikipedia 0.484 (图 1)。以同一冻结管线复算 A2 (arxiv 全量 17,523 篇) 与 A3 (github 全量 203,752 篇)：与 A1 对应子集的 KS 检验 $D = 0.021$ ($p = 0.60$) 与 $D = 0.012$ ($p = 0.12$)，Cohen’s $d \approx 0.005$ ——抽样集代表性良好，域级结论可由抽样外推。




图 1: A1 七域质量分布 (CRITIC 加权几何平均)。arxiv 显著最高；book 域仅 171 篇，其区间最宽。

5.3 问题一 (b)：指标冲突的定义、成因与消解

冲突定义（拒绝预设阈值）。 25 指标按信号来源分四组（规则型/DSIR/轻量分类器/模型评分器），组内 Kendall W 分别为 0.128/0.998/0.627/0.447——同源信号一致性高，冲突主要发生在

跨组，故在组级定义冲突：组分数取组内指标中位数，再转域内分位排名 $R_g(x) \in [0, 1]$ ，冲突度 $c(x) = \max_g R_g - \min_g R_g$ 。阈值 τ 由冲突率—阈值曲线的最大曲率点确定（图 2），得 $\tau = 0.75$ 。

测得冲突率 21.5%，直接否定《数据说明》页眉”冲突率约 0%”的说法——后者以预设小阈值定义冲突再宣布无冲突，属把结论藏进定义。冲突与域强相关 ($\chi^2 = 142.4$, $df = 6$, $p \approx 10^{-23}$)；主冲突类型为”DSIR 高 $\times$ 规则型低”，在 A1/A2/A3 中占比 19.6%/15.1%/18.1%，跨集复现；扩展集冲突率 21.1% (A2) 与 22.9% (A3)，与抽样集一致。对 30 篇高冲突文档的原文抽查 (A1 含 content) 证实两类机制：LaTeX/代码文本的专业价值高而表层流畅度指标低；模板化网页的规则统计量佳而模型评分器判为低教育价值。

消解：Huber 连续降权。对文档 x 的组 g ，按其排名偏离文档自身中位排名的程度 dev_g 施加权重 $u_g = \min(1, \tau_z/|\text{dev}_g|)$ ，与 CRITIC 权重逐指标相乘后重归一，重算式 (1) 得修正分 $\tilde{Q}$ 。效果：保序 ($\rho(Q, \tilde{Q}) = 0.997$)，冲突样本平均下调 0.0033 而非冲突样本几乎不动 (-0.0004)——降权而非删除，保留矛盾信息且不误伤专业语料；这是相对工业界硬过滤的改进点。严格口径的对照（冲突文档组分数取调和平均，下调 0.149）供敏感性使用。




图 2: 冲突率—阈值曲线与最大曲率点。结论在 $\tau \in [0.6, 0.85]$ 内定性不变。

5.4 跨体系桥接：17 个配比域的质量分

11 个 inferred 域无官方质量信号。利用规则统计量可精确复算的性质补全：自实现 11 个 **rps** 规则算子 $\Phi(\text{text})$ ，在 A1 上（每篇同时具备 Φ 与 $\tilde{Q}$ ， $n = 21,590$ ）以域分层五折交叉验证训练校准函数 $\hat{g}: \Phi \mapsto \tilde{Q}$ （梯度提升， $R_{cv}^2 = 0.31$ ，优于岭回归 0.25）；再对 A18 的 17 域原文（31,340 篇）计算 $\hat{Q} = \hat{g}(\Phi)$ 并域级聚合。6 个有映射域上校准分与官方分互验：Pearson 0.70、MAE 0.055。最终 $\hat{Q}_d$ 取”映射域用官方分、inferred 域用校准分”，全部带 bootstrap CI 与证据等级标注（图 3）：最高 arxiv 0.716，最低 dm_mathematics 0.355；ubuntu_irc (16 篇) 与 philpapers (63 篇) 标注低置信。




图 3: 17 配比域质量分 (颜色为映射类型; 误差条为 bootstrap 95% CI)。

5.5 问题一 (c): 配比—损失建模与最优配比

clr 变换消闭合效应 (改进点)。配比是成分数据: 某域份额上升必然伴随其余域合计下降, 直接回归会把机械的”此消彼长”误读为领域替代关系 (Aitchison, 1986)。对 $\mathbf{p}$ 做中心对数比变换 $z_i = \ln(p_i/g(\mathbf{p}))$ (g 为几何均值, 零分量乘性替换 10^{-4}), 对每个验证域在对数空间回归:

$$\ln L_v = b_v + \sum_{i=1}^{17} \beta_{v,i} z_i + \varepsilon_v, \quad v = 1, \dots, 13, \quad (2)$$

以 Huber 损失抗异常配方。1M 检验集 (256 组) 对照: **clr+Huber 的平均 $R^2 = 0.772$, 裸配比 OLS (RegMix 原式) 仅 0.654** (RMSE 0.320 vs 0.432) ——闭合效应处理的收益即本方案对文献的量化改进。梯度提升作非线性对照 ($R^2 = 0.897$), 表明存在域间交互; 故系数解释用线性、最优搜索用非线性, 两者在 10^5 个候选配比上的目标损失秩相关 0.77, 互为校验。

迁移矩阵。式 (2) 系数经链式法则折算到单纯形切空间, 得 $T_{iv} = \partial \ln L_v / \partial p_i$ (均匀配比处, 图 4)。全部 13 个自域效应为负 (增配本域降本域损失), dm_mathematics 自域效应最强 (-2.47); 跨域外溢揭示 stackexchange 与 github 的互补结构。四个无损失列的域 (nih_exporter 等) 保留为解释变量, 其效应经由相对配比间接体现。




图 4: 迁移矩阵 T_{iv} : 蓝色为增配降损。对角占优, 含非对角互补结构。

质量交互项检验。在式 (2) 加入 $\lambda_v \sum_i p_i (1 - \hat{Q}_{d(i)})$ 作嵌套检验: 10/13 个验证域 λ_v 显著 (bootstrap 95% CI 不含零) 且加项后检验集 RMSE 全部不升; 但**符号域间不一致** (中位数 -0.249 , arxiv 域 $+0.79$)。结论: 质量对配比—损失关系有独立解释力, 但作用方向依验证域条件化——这提示问题二不应把质量与配比合并为单一乘子, 二者应分开进入广义律。

最优配比。以训练配比均值为中心的多浓度 Dirichlet 采样 10^5 个候选, 取预测目标损失最优的前 100 个平均: 等权口径 $\mathbf{p}^*$ 前五位为 pile_cc 15.6%、stackexchange 10.0%、wikipedia 9.5%、pubmed_central 9.1%、arxiv 8.9%; 相对均匀配比预测降损 9.9% (固定 $\mathbf{p}^*$ 的 bootstrap 95% CI [9.7%, 14.1%])。pile_cc 单域口径下 pile_cc 占 33.2%, 复现 RegMix” 网页语料对下游最有利” 的反直觉结论。

跨尺度验证与外推 (假设 2 的检验)。1M 系数直接预测三尺度留出集的目标损失排名: Spearman 0.52 (1M 留出) / 0.47 (60M) / 0.68 (1B) ——排序中等保持; 但 60M/1B 的绝对预测完全失效 (R^2 为大负值), 系数漂移分解显示**截距显著下漂而斜率几乎不漂** ($\max_i |\rho_\beta| \approx 0.007$): 配比效应结构稳定, 基线水平随规模下移。对 A12–A15 (10B/70B, 幂律外推生成、非观测): 直接套 1M 系数 MAE ≈ 3.5 完全不可用, 以三尺度估计的漂移律 $b_v(N) = b_v^0 + \rho_v \ln(N/10^6)$ 修正后 MAE 收窄至 0.10 (35 倍改善)。外推稳健域排序: arxiv/pubmed_central 最稳 ($\rho > 0.85$), pile_cc/pubmed_abstracts 最不稳 ($\rho < 0.40$)。

质量 $\neq$ 训练价值。域级质量分 $\hat{Q}_d$ 与训练边际价值 $\nu_d = -(\bar{\beta}_d - \bar{\beta})$ 的秩相关 $\rho_{Q\nu} = -0.06$ (图 5): 内在质量几乎不预测训练价值, 配比必须由实验回归而非质量排名确定。该结论直接支撑问题二将 Q 与 $\mathbf{p}$ 设为两个独立自变量。




图 5: 质量—价值解耦: dm_mathematics 质量最低却训练边际价值最高。

5.6 问题二：广义标度律的形式选择与拟合

两步拟合。第一步在 B1 上网格搜索 (α, β) 并最小二乘定 (E, A, B) , 得 $L_0 = 1.6901 + 406.4N^{-0.340} + 410.6D^{-0.280}$ (RMSE = 1.5×10^{-4} ; 该表呈公式生成特征, 故此步为无噪声锚定)。第二步固定基线, 在 B6/B7 (450 点 $N \times D \times Q$ 网格) 上对质量项做五种候选形式的五折交叉验证:

表 2: 质量项形式选择 (cv-RMSE; 数据噪声水平 $\sigma \approx 0.05$)

候选形式	cv-RMSE	备注
加性 + 规模交互 $(1 - Q)(k_0 + k_1 N^{-\alpha})$	0.0512	主模型 (达噪声下限)
纯加性 $k(1 - Q)$	0.0731	缺规模交互
指数乘子 $D_{\text{eff}} = D e^{-\gamma(1-Q)}$	0.0985	有效数据乘子族
线性乘子 $D_{\text{eff}} = D(q_0 + (1 - q_0)Q)$	0.1030	(Muennighoff 风格)
幂律乘子 $D_{\text{eff}} = DQ^\gamma$	0.1050	全体落败

文献偏好的”质量折算有效数据量”乘子族 (Muennighoff 风格) 在本题数据上系统性落败——模型形式由交叉验证裁决而非先验借用。主模型为

$$L(N, D, Q) = E + \tilde{A}(Q) N^{-\alpha} + B D^{-\beta} + (1 - Q) k_0, \quad \tilde{A}(Q) = A + k_1(1 - Q) \quad (3)$$

表 3: 广义标度律参数 (残差 bootstrap $B = 500$)

E	A	α	B	β	k_0	k_1	噪声 σ
1.6901	406.4	0.340	410.6	0.280	0.192 [0.175, 0.211]	175.3 [156.6, 193.0]	0.051

$Q = 1$ 时式 (3) 严格退化为经典 Chinchilla 形式 (附件内锚定)。配比经问题一引入 (题目规定不

重复读取附件 A)： $\bar{Q}_B(\mathbf{p}) = \sum_i p_i \hat{Q}_{B,d(i)}$ 将配比映射为语料质量代入 Q ；配比的域结构效应由迁移矩阵 T 单独描述——依据 §5.5 的 λ 符号发现，质量与配比不合并为单一乘子。

跨源检验。真实文献点上主模型预测与观测的 Spearman: scaling_baseline(57 点) 0.983、published(44 点) 0.959，平均偏差 0.22/0.02 nats——趋势一致，绝对偏移源于 tokenizer 与验证集差异，符合”跨源只比趋势”的审计原则；B2 (Cerebras 半合成) 偏差 1.18 nats，仅作定性佐证。

5.7 问题二：解析理论

以下命题由式 (3) 直接推导，全部与数值优化互验（相对误差 $< 10^{-6}$ ）。

命题 1 (弹性). $\varepsilon_N = -\frac{\alpha \tilde{A}(Q) N^{-\alpha}}{L}$, $\varepsilon_D = -\frac{\beta B D^{-\beta}}{L}$, $\varepsilon_Q = -\frac{Q(k_0 + k_1 N^{-\alpha})}{L}$. 在 $(N, D, Q) = (10^{10}, 10^{12}, 0.9)$ 处三者为 $-0.028 / -0.024 / -0.115$ ：质量弹性约为规模弹性的 4 倍；且 k_0 项不随 N 衰减，规模越大质量的相对优势越明显。

命题 2 (质量—参数等效替代及其边界). 固定 D ，使 $L(N', D, Q) = L(N, D, Q + \delta)$ 的等效参数量

$$N' = N \left[1 - \frac{\delta(k_0 + k_1 N^{-\alpha})}{\tilde{A}(Q) N^{-\alpha}} \right]^{-1/\alpha}, \quad (4)$$

当且仅当括号内为正时有限。数值： $Q: 0.9 \rightarrow 1.0$ 在 $N = 10^9$ 等效参数 $\times 1.33$ ，在 $N = 10^{10}$ 等效 $\times 1.64$ ——同一份质量改进，模型越大越值钱；超过临界规模后任何有限扩参都无法替代该质量提升。

命题 3 (质量地板). $\lim_{N,D \rightarrow \infty} L = E + (1 - Q)k_0$ 。低质量造成规模不可救赎的损失下界： $Q = 0.5$ 的地板比 $Q = 1$ 高 0.096 nats。此为问题三”付费提质”的理论必要性。

命题 4 (算力最优配置随质量移动). 约束 $6ND = C$ 下，

$$N^*(C, Q) = \left[\frac{\alpha \tilde{A}(Q)}{\beta B} \right]^{\frac{1}{\alpha+\beta}} \left(\frac{C}{6} \right)^{\frac{\beta}{\alpha+\beta}}, \quad \frac{\beta}{\alpha+\beta} = 0.452, \quad \frac{\partial N^*}{\partial Q} < 0. \quad (5)$$

质量越高，最优配置越偏”小模型、多数据”： $C = 10^{22}$ 时最优 token/参数比从 $Q = 0.3$ 的 27 升至 $Q = 1$ 的 63。机制：低质数据抬高 $\tilde{A}(Q)$ ，变相提高参数的边际收益。该命题给出问题三”结构性转移”的机制来源。




图 6: 解析理论三联图：等损失线（左）、等效参数倍数（中）、 $N^*(C, Q)$ （右）。

6 模型检验

6.1 检验体系总览

表 4: 检验清单：方法关系、判据与结果

检验对	关系类型	判据	结果
CRITIC vs PCA/TOPSIS/等权	互相验证	样本级 Spearman	0.871/0.946/0.991, 排序稳健
clr 线性 vs 梯度提升	互相验证	10^5 采样点秩相关	0.77, p^* 非模型形式幻觉
clr vs 裸 OLS	改进证据	检验集 R^2 /RMSE	0.772 vs 0.654, 闭合效应实证
A1 vs A2/A3 全量	代表性检验	KS, Cohen's d	$p = 0.60/0.12$, $d \approx 0.005$
冲突结论跨集复现	稳健性	冲突率与主类型	21.5%/21.1%/22.9%, 类型一致
1M→60M→1B	假设 2 检验	排名 Spearman	0.52/0.47/0.68; 截距漂、斜率稳
10B/70B 外推表	稳健性讨论	修正前后 MAE	$3.5 \rightarrow 0.10$ (非观测, 只作讨论)
加性形式 vs 乘子族	形式选择	五折 cv-RMSE	0.051 vs 0.099–0.105
解析解 vs 数值优化	互相验证	相对误差	$< 10^{-6}$ (命题 2、4)
标度律 vs 真实文献点	外部合理性	趋势 Spearman	0.959–0.983, 仅比趋势
质量分 vs 训练价值	概念区分	$\rho_{Q\nu}$	−0.06: 分歧本身即结论

三点说明。其一，”互相验证”仅用于同一问题、不同假设的方法对（如 CRITIC 与 PCA），判据取排序一致性；分工衔接的上下游方法（如冲突分析与配比回归）之间不存在验证关系，不作此类声称。其二，不一致处同样是结论： $\rho_{Q\nu} = -0.06$ 是”内在质量 $\neq$ 训练价值”的定量证据而非检验失败；60M/1B 的绝对预测失效（ R^2 大负值）源于截距漂移，恰好论证了”跨尺度外推必须做尺度修正”并给出修正后 35 倍的误差收窄。其三，A12–A15 与 B8 的证据等级（外推生成/不同源）全程继承标注，未升格为实证。

6.2 灵敏度分析

冲突阈值： $\tau \in [0.6, 0.85]$ 内冲突率 12%–35% 连续变化，域排序与主冲突类型不变。**评价权重：**等权与 pile_cc 单域两口径下 p^* 的头部域一致（pile_cc 居首），仅集中度不同。**质量口径锚点（假设 3）：** Q_{ref} 取 Pile 配比加权（0.5608）与 token 加权全语料两口径， $\hat{Q}_B$ 相差 < 0.02 ，命题 1–4 的定性结论不变。**消解规则：**Huber 降权与调和平均两口径下域级质量排序 Spearman > 0.95 。**bootstrap 参数区间：** k_0, k_1 的 95% CI 宽度约 $\pm 10\%$ ，代入命题 2 的等效倍数区间为 $[1.52, 1.77]$ （ $N = 10^{10}$ ， $Q: 0.9 \rightarrow 1$ ），结论方向稳健。

7 模型的优缺点与改进方向

优点：(i) 全流程证据分层，半合成与外推数据未混入主结论；(ii) 冲突率、闭合效应、质量—价值解耦三处以量化证据修正了《数据说明》页眉与文献的现成说法；(iii) 广义标度律的形式由交叉验证

从五种候选中裁决，且四条解析命题全部闭式可验；(iv) 问题一至问题二的接口（ Q 口径、 $\mathbf{p}^*$ 、迁移矩阵、漂移律）落盘为文件，问题三、四可直接消费。

缺点与改进：(i) 17 域质量分中 11 个 inferred 域依赖校准函数（ $R_{cv}^2 = 0.31$ ），信息量有限，若增补这些域的模型评分器信号可显著收紧区间；(ii) 质量交互项 λ 符号域间不一致的机制尚未解释，需按验证域类型分层建模；(iii) B 附件为半合成数据， k_0, k_1 的绝对数值不宜直接外推到真实训练体系，应用时应以趋势与结构结论为主；(iv) 配比仅经 $\bar{Q}(\mathbf{p})$ 进入广义律，配比—规模交互未建模，可在问题三敏感性中补充。

8 结论

问题一建立了从 22 个异质信号到连续质量分的可复现管线，测得并消解了 21.5% 的指标冲突，以 clr 回归给出 17 域配比的迁移矩阵与最优配比（预测降损 9.9%），并发现内在质量与训练价值近乎正交。问题二以数据裁决的加性形式建立广义标度律 $L = E + \tilde{A}(Q)N^{-\alpha} + BD^{-\beta} + (1 - Q)k_0$ ，其四条解析推论——质量弹性四倍于规模弹性、等效替代随规模放大、质量地板的存在、最优配置随质量向”小模型多数据”移动——共同刻画了”数据质量是与算力并列的一等资源”这一核心判断，为问题三的约束优化提供了目标函数、初值与结构性转移机制。

表 5: 问题一、二产出与下游接口

产出	内容	下游用途
P1-Q_sample / Q_domain	27.2 万样本级 Q ；17 域 $\hat{Q}_d$ 及 CI	问题二 $\bar{Q}(\mathbf{p})$ ；问题三 Q_0
P1- $f(\mathbf{p})$ / T	配比回归系数； 17×13 迁移矩阵	问题三损失项；领域互补分析
P1- $\mathbf{p}^*$	双口径最优配比， $\bar{Q}(\mathbf{p}^*)$	问题三默认配比
P1-rank_decay	排名保持度随 N 的三点曲线	外推不确定性口径
P2-params / theory	式 (3) 全参数与 CI； $N^*(C, Q)$ 闭式	问题三目标函数与优化初值

参考文献

- [1] Hoffmann J, et al. Training Compute-Optimal Large Language Models. NeurIPS 2022.
- [2] Liu Q, et al. RegMix: Data Mixture as Regression for Language Model Pre-training. ICLR 2025.
- [3] SlimPajama-Meta-rater 数据集 (OpenDataLab): 多维质量信号体系.
- [4] Penedo G, et al. The FineWeb Datasets. NeurIPS 2024 (FineWeb-Edu 教育价值过滤) .
- [5] Muennighoff N, et al. Scaling Data-Constrained Language Models. NeurIPS 2023.
- [6] Aitchison J. The Statistical Analysis of Compositional Data. Chapman & Hall, 1986.
- [7] Diakoulaki D, Mavrotas G, Papayannakis L. Determining objective weights in multiple criteria problems: The CRITIC method. Computers & Operations Research, 1995.
- [8] Huber P J. Robust estimation of a location parameter. Ann. Math. Statist., 1964.
- [9] Biderman S, et al. Pythia: A Suite for Analyzing Large Language Models. ICML 2023.

附录：AI 使用披露

依据赛题规定，AI 工具仅用于资料整理、代码调试与文字排版辅助；本文的模型选择、公式推导、结果分析与论证由参赛队完成并逐项复核。全部数值结果可由随文代码（code_q1/、code_q2/）在附件数据上复现。